




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana de la
necesidad de soporte
vasopresor con noradrenalina
en UCI mediante aprendizaje
automático interpretable**

Documentación Técnica

Presentado por Daniel Marina de la Cal
en Universidad de Burgos

Tutores: Antonio Jesús Canepa Oneto – Sergio
Ossa Echeverri – Fernando Callejo Torre

Índice general

Índice general	1
Índice de figuras	3
Índice de tablas	5
Apéndice A Plan de Proyecto	7
A.1. Introducción	7
A.2. Metodología de ingeniería del software	8
A.3. Planificación temporal	9
A.4. Planificación económica	10
A.5. Viabilidad legal	13
Apéndice B Manual de especificación de diseño	17
B.1. Arquitectura	17
Apéndice C Especificación de Requisitos	21
C.1. Diagrama de casos de uso	21
C.2. Tablas de casos de uso	22
C.3. Prototipos	24
Apéndice D Documentación de usuario	31
D.1. Requisitos previos	31
D.2. Instalación y puesta en marcha	32
D.3. Manual de uso	34
D.4. Modo demostración	37
D.5. Manual integrado	37

D.6. Advertencias de uso	38
Apéndice E Manual del programador	39
E.1. Estructura de directorios	39
E.2. Compilación y ejecución	41
E.3. Pruebas del sistema	42
E.4. Instrucciones para la modificación o mejora del proyecto . .	44
Apéndice F Descripción de adquisición y tratamiento de datos	49
F.1. Descripción formal de los datos	49
F.2. Descripción clínica de los datos	51
Apéndice G Estudio experimental	63
G.1. Registro de experimentos	63
G.2. Parametrización	69
G.3. Resultados	73
Apéndice H Anexo de sostenibilización curricular	75
H.1. Reflexión personal sobre sostenibilidad	75
Apéndice I Registro de interacciones con sistemas de IA	79
I.1. Registro de interacciones	79
Bibliografía	85

Índice de figuras

A.1. Planificación inicial del proyecto (marzo – junio 2026).	9
A.2. Ejecución real del proyecto (marzo – junio 2026).	9
A.3. certificado de finalización del curso CITI Program.	15
A.4. informe de finalización del CITI Program con el detalle de módulos y puntuaciones, se censura información de carácter personal.	16
 B.1. arquitectura general del sistema: <i>pipeline</i> de modelado y entrenamiento, serialización de modelos y aplicación de visualización mediante <i>dashboard</i>	18
 C.1. diagrama de casos de uso del <i>dashboard</i>	22
C.2. pantalla de inicio del <i>dashboard</i> . Bajo el título se muestra el aviso permanente de prototipo de investigación y los controles de selección de ventana temporal, modo demostración y manual. La aplicación no realiza ninguna estimación hasta que el usuario selecciona una opción.	24
C.3. vista principal tras cargar un CSV de ejemplo en la ventana larga (12–48 h). A la izquierda se muestra el percentil de riesgo acompañado de su explicación textual y de los datos del caso; a la derecha, los factores individuales según los valores SHAP, donde las barras rojas empujan el riesgo al alza y las verdes lo reducen.	24
C.4. modo demostración. Permite explorar el funcionamiento del <i>dashboard</i> con casos ficticios, sin necesidad de cargar un CSV propio. Se muestra un caso de paciente con deterioro hemodinámico.	25

C.5.	manual de uso integrado, accesible desde la propia interfaz. Documenta las ventanas temporales disponibles, el modo de uso, el formato esperado del CSV de entrada y la interpretación del percentil de riesgo y de los valores SHAP.	25
F.1.	distribución comparada de los predictores del modelo final de la ventana media (6–24 h; XGBoost recalibrado) entre MIMIC-IV y eICU-CRD.	60
F.2.	distribución comparada de los predictores del modelo final de la ventana larga (12–48 h; XGBoost) entre MIMIC-IV y eICU-CRD.	60
F.3.	distribución comparada de los predictores del modelo CatBoost de la ventana media (6–24 h) entre MIMIC-IV y eICU-CRD.	61
F.4.	distribución comparada de los predictores del modelo CatBoost de la ventana larga (12–48 h) entre MIMIC-IV y eICU-CRD.	61
F.5.	distribución comparada de los predictores de la ventana corta (3–12 h; CatBoost) entre MIMIC-IV y eICU-CRD.	61

Índice de tablas

A.1. estimación de costes materiales del proyecto.	11
A.2. estimación del coste de personal del proyecto.	13
A.3. coste total estimado del proyecto.	13
C.1. CU-1 seleccionar la ventana temporal.	26
C.2. CU-2 cargar CSV con datos del caso evaluado.	27
C.3. CU-3 consultar el percentil de riesgo y la explicación SHAP.	28
C.4. CU-4 ejecutar el modo demostración.	29
C.5. CU-5 consultar el manual e información.	30
F.1. inventario de los ficheros CSV definitivos.	50
F.2. grupos de variables en los conjuntos MIMIC-IV (82 columnas totales).	51
F.3. distribución de la variable objetivo en los seis conjuntos definitivos.	57
F.4. características basales de las cohortes MIMIC-IV (desarrollo) y eICU-CRD (validación externa). Variables continuas: mediana [RIC]; categóricas: n (%). Contraste mediante prueba U de Mann– Whitney para continuas y χ^2 para categóricas.	59
G.1. configuración general de preprocesamiento y balanceo por familia de modelo.	70
G.2. análisis de desempate entre estadísticos para las variables en las que la elección no resultaba evidente por criterio clínico.	74
G.3. variables utilizadas por los modelos finalmente conservados para el prototipo de <i>dashboard</i>	74

Apéndice A

Plan de Proyecto

A.1. Introducción

El presente proyecto tiene como objetivo el desarrollo y validación de modelos de aprendizaje automático para la estimación temprana del riesgo de inicio de noradrenalina en pacientes adultos ingresados en la Unidad de Cuidados Intensivos (UCI), utilizando variables clínicas y analíticas disponibles durante las primeras horas de estancia. La motivación clínica reside en la necesidad de anticipar qué pacientes requerirán soporte vasopresor, lo que podría proporcionar una ventana terapéutica para una intervención más temprana y, en su caso, apoyar la priorización de pacientes y recursos (Evans et al., 2021; Firzli et al., 2023).

El alcance del trabajo comprende tres componentes principales: la construcción de cohortes y el desarrollo de modelos predictivos sobre la base de datos MIMIC-IV (Johnson et al., 2023), con evaluación interna mediante validación cruzada anidada; la validación externa sobre la base de datos multicéntrica eICU-CRD (Pollard et al., 2018), que permite evaluar la generalización de los modelos a entornos clínicos distintos del de desarrollo; y el desarrollo de un prototipo de *dashboard* clínico interpretable implementado en Streamlit, orientado a demostrar la viabilidad de integrar los modelos en una interfaz funcional de apoyo a la interpretación del riesgo.

El proyecto no incluye validación prospectiva ni despliegue clínico en entorno asistencial real, por lo que se enmarca como investigación aplicada y prueba de concepto. Las consideraciones metodológicas, temporales, económicas y legales relevantes se desarrollan en los apartados siguientes.

El repositorio público del proyecto se encuentra disponible en: <https://github.com/DaniMr21/Estimacion-temprana-de-la-necesidad-de-soporte-vasopresor-con-noradrenalina-en-UCI>.

A.2. Metodología de ingeniería del software

La metodología seguida durante el desarrollo se describe en detalle en la sección de Metodología de la memoria. En síntesis, se empleó un enfoque experimental e iterativo con un ciclo incremental por versiones, código organizado en módulos funcionales y control de versiones con Git y GitHub. Este enfoque se corresponde con un modelo de desarrollo iterativo e incremental: cada versión del flujo de trabajo se construyó sobre la anterior y se refinó en función de los resultados obtenidos, sin un diseño cerrado definido a priori.

Esta naturaleza iterativa queda reflejada en la propia estructura del repositorio, cuyas sucesivas carpetas de pruebas documentan la evolución del trabajo: desde los primeros ensayos por ventana sobre MIMIC-IV, pasando por los refinamientos de la cohorte general, la eliminación de registros incompletos, la restricción de ventanas temporales y el análisis del subgrupo de sepsis, hasta las versiones finales del modelo y la validación externa sobre eICU-CRD.

Las fases principales llevadas a cabo fueron:

1. Revisión bibliográfica y definición del problema.
2. Acceso a datos: formación CITI y registro en PhysioNet ([CITI Program, 2026](#); [PhysioNet, 2026](#)).
3. Construcción de cohortes mediante consultas SQL sobre MIMIC-IV y eICU-CRD, previamente importadas en una instancia local de PostgreSQL autorizada para el desarrollo del proyecto.
4. Preprocesamiento y selección de variables.
5. Entrenamiento, optimización y evaluación interna mediante validación cruzada anidada.
6. Calibración de probabilidades e interpretabilidad mediante valores SHAP.
7. Validación externa sobre eICU-CRD.

8. Desarrollo del prototipo de *dashboard* y encuesta exploratoria de usabilidad.
9. Redacción de la memoria, anexos y documentación del repositorio.

Desde el punto de vista de producto, el ciclo de vida queda limitado a una prueba de concepto. Quedan fuera del alcance de este TFG la validación con datos locales del Hospital Universitario de Burgos, la validación prospectiva y la integración del *dashboard* en sistemas de información sanitarios.

Si se deseara continuar con el presente trabajo para dejar lista y validada una herramienta clínica, podría plantearse una metodología Scrum (Sutherland and Sutherland, 2014), ya que permitiría incorporar el *feedback* continuo de los clínicos en iteraciones cortas y facilitaría la coordinación entre perfiles técnicos y sanitarios durante el desarrollo.

A.3. Planificación temporal

La planificación inicial propuesta se representa en la Figura A.1 y la finalmente seguida en la Figura A.2.



Figura A.1: Planificación inicial del proyecto (marzo – junio 2026).



Figura A.2: Ejecución real del proyecto (marzo – junio 2026).

Leyenda de colores:

- **Amarillo:** tarea no realizada, sustituida por la obtención y uso de eICU-CRD como cohorte de validación externa.
- **Rojo:** retraso en el inicio de la tarea respecto a la planificación inicial.

- **Barras rojas:** tiempo adicional necesario para completar la tarea.
- **Verde:** tarea finalizada antes de lo previsto.
- **Barras verdes:** tarea iniciada con anterioridad a lo planificado.

Las desviaciones respecto a la planificación inicial se debieron principalmente a dos causas. Los retrasos se produjeron al encontrar dificultades no anticipadas o al haber subestimado la complejidad de determinadas tareas. Los adelantos respondieron al motivo contrario: tareas cuya dificultad o duración resultó inferior a la estimada inicialmente.

El seguimiento del proyecto se organizó en GitHub mediante *milestones* e *issues*, agrupando las tareas en siete fases: (1) obtención de datos y formación CITI/PhysioNet, (2) trámites universitarios y revisión de viabilidad legal, (3) investigación inicial y estado del arte, (4) definición de la cohorte y extracción de MIMIC-IV, (5) validación externa sobre eICU-CRD, (6) desarrollo del *dashboard* y (7) redacción de la memoria y los anexos.

Las fases vinculadas a la obtención de datos, construcción de cohortes, experimentación principal y validación externa se completaron dentro del alcance finalmente definido. El desarrollo del *dashboard* y la redacción de la memoria constituyeron la etapa final del trabajo, concentrada en las últimas semanas de mayo y primera de junio. La experimentación interna—entrenamiento, calibración e iteración sucesiva de los modelos— se gestionó por versiones en el repositorio en lugar de como un *milestone* independiente, tal como refleja la sucesión de carpetas de pruebas descrita en el apartado anterior.

A.4. Planificación económica

A continuación se estima el coste que supondría ejecutar este proyecto en un contexto profesional. Se valora, por un lado, el coste material imputable, incluyendo hardware, software y datos, y por otro, el coste de personal, calculando la dedicación al precio de mercado fijado por convenio. El software empleado es de código abierto o de libre acceso y las bases de datos utilizadas no tienen coste económico directo para fines de investigación, por lo que el coste material se reduce a la amortización del equipo.

Costes materiales

Para el desarrollo se utilizó un equipo HP Pavilion Plus con procesador Intel Core Ultra 7, 32 GB de RAM, SSD de 1 TB y tarjeta gráfica Nvidia RTX 4050 con 6 GB de VRAM, adquirido en febrero de 2026 por 1.500 €.

Suponiendo una vida útil de cinco años y una jornada anual máxima de 1.792 horas, la vida útil total estimada del equipo es:

$$1.792 \times 5 = 8.960 \text{ h}$$

El coste horario de amortización es, por tanto:

$$\frac{1.500}{8.960} \approx 0,167 \text{ €/h}$$

Dado que el proyecto requirió 360 horas de trabajo, el coste de hardware imputable asciende a:

$$\frac{1.500}{8.960} \times 360 = 60,27 \text{ €}$$

Tabla A.1: estimación de costes materiales del proyecto.

Categoría	Concepto	Coste
Hardware	Amortización proporcional del portátil	60,27 €
Software	Python, R y SQL en VS Code y PostgreSQL	0,00 €
Datos	MIMIC-IV y eICU-CRD (PhysioNet)	0,00 €
Total costes materiales		60,27 €

Costes de personal

Para estimar el coste de personal se toma como referencia el XX Convenio colectivo nacional de empresas de ingeniería, oficinas de estudios técnicos, inspección, supervisión y control técnico y de calidad ([Ministerio de Trabajo y Economía Social, 2023](#)). Según la clasificación profesional recogida en dicho convenio (Art. 17), un graduado universitario se encuadra en el Nivel Salarial 2.

El convenio publica las tablas salariales de 2021 y 2022 en su Anexo II y, para los años siguientes, establece (Art. 33.2) que los importes se

actualicen aplicando a la tabla del año anterior un porcentaje en función de la variación interanual del Índice de Precios de Consumo (IPC) a 31 de diciembre. Partiendo del importe de la tabla salarial del Nivel 2 en 2022 (18.634,84 €) y aplicando los incrementos correspondientes —+3,50 % en 2023 (IPC interanual de diciembre de 2022 del 5,7 %) y +2,30 % en 2024 (IPC interanual de diciembre de 2023 del 3,1 %), la tabla salarial del Nivel 2 para 2024 resulta:

$$18.634,84 \times 1,035 \times 1,023 \approx 19.730,66 \text{ €}$$

A esta cifra se añade el plus de convenio fijado para 2024 en el Art. 38 (2.493,50 €), de modo que la retribución total anual del Nivel 2 asciende a:

$$19.730,66 + 2.493,50 = 22.224,16 \text{ €}$$

Considerando la jornada anual máxima de 1.792 horas establecida en el convenio (Art. 22.1), el coste salarial horario equivalente es:

$$\frac{22.224,16}{1.792} \approx 12,40 \text{ €/h}$$

Para las 360 horas de dedicación, el salario bruto proporcional asciende a:

$$\frac{22.224,16}{1.792} \times 360 = 4.464,68 \text{ €}$$

A este importe se añaden las cotizaciones empresariales a la Seguridad Social. A efectos de estimación, se aplica un porcentaje conjunto del 32,30 % sobre el salario bruto, formado por las aportaciones empresariales por contingencias comunes, desempleo, FOGASA, formación profesional, Mecanismo de Equidad Intergeneracional y una estimación de contingencias profesionales. Estas últimas dependen de la tarifa de primas aplicable, por lo que el porcentaje empleado debe interpretarse como una aproximación razonable para la estimación económica del proyecto.

$$4.464,68 \times 0,3230 = 1.442,09 \text{ €}$$

Por tanto, el coste de personal estimado es:

$$4.464,68 + 1.442,09 = 5.906,77 \text{ €}$$

Tabla A.2: estimación del coste de personal del proyecto.

Concepto	Cálculo	Importe
Salario bruto proporcional	$12,4019 \text{ €/h} \times 360 \text{ h}$	4.464,68 €
Cotizaciones empresariales estimadas	$32,30 \% \times 4.464,68 \text{ €}$	1.442,09 €
Coste de personal		5.906,77 €

Costes indirectos y coste total

No se imputan costes indirectos (electricidad, conexión a internet o espacio de trabajo) de forma separada, al haberse desarrollado el proyecto con recursos personales y sin instalaciones dedicadas; su efecto se considera marginal frente a los costes de personal y se omite de forma deliberada.

Sumando los costes materiales y de personal, el coste total estimado de ejecución del proyecto es:

$$60,27 + 5.906,77 = 5.967,03 \text{ €}$$

Tabla A.3: coste total estimado del proyecto.

Concepto	Importe
Costes materiales	60,27 €
Coste de personal	5.906,77 €
Coste total estimado	5.967,03 €

Este importe no representa un precio de venta o de facturación, sino una estimación del coste interno de ejecución, considerando la amortización del equipo, el salario bruto proporcional y las cotizaciones empresariales estimadas a la Seguridad Social.

A.5. Viabilidad legal

Dado que este trabajo constituye un análisis retrospectivo sobre bases de datos públicas y desidentificadas por sus custodios originales ([Johnson et al.](#),

2023; Pollard et al., 2018; PhysioNet, 2026), el análisis desarrollado en este TFG no requirió una aprobación adicional por parte de un Comité de Ética de Investigación local, sin embargo, el acceso a MIMIC-IV y eICU-CRD a través de PhysioNet exige acreditar formación en ética de la investigación con datos de sujetos humanos y suscribir el correspondiente acuerdo de uso de datos. Por ello, se aporta la certificación del CITI Program completada por el autor como documento acreditativo de dicha formación.

La formación corresponde al curso *Human Research — Data or Specimens Only Research (Stage 1, Basic Course)*, completado el 14 de marzo de 2026 con una puntuación de 95 sobre un mínimo exigido de 90 (Record ID 75910225), e incluyó módulos sobre el Informe Belmont, regulación y revisión por IRB, investigación basada en registros (*Records-Based Research*), protecciones de privacidad HIPAA y conflictos de interés, entre otros. El certificado se muestra en la Figura A.3 y el informe detallado de módulos en la Figura A.4.

No obstante, para continuar con una validación externa con datos del Hospital Universitario de Burgos o para validar el *dashboard* como herramienta clínica, sí se precisa la aprobación del Comité de Ética de Investigación correspondiente. Por este motivo, en este anexo se incluye la acreditación disponible para el alcance finalmente desarrollado, y se explicita que cualquier extensión del trabajo a datos locales o a validación prospectiva requeriría autorización ética específica.



Figura A.3: certificado de finalización del curso CITI Program.

COLLABORATIVE INSTITUTIONAL TRAINING INITIATIVE (CITI PROGRAM)
COMPLETION REPORT - PART 1 OF 2
COURSEWORK REQUIREMENTS*

* Scores on this [Requirements Report](#) (Part 1) reflect quiz completions at the time all requirements for the course were met. The Transcript Report (Part 2) lists more recent quiz scores, including those on optional (supplemental) course elements.

• **Name:** Daniel Marina (ID: 15457287)
 • **Institution Affiliation:** [REDACTED]
 • **Institution Email:** [REDACTED]
 • **Institution Unit:** [REDACTED]
 • **Phone:** [REDACTED]

• **Curriculum Group:** Human Research
 • **Course Learner Group:** Data or Specimens Only Research
 • **Stage:** Stage 1 - Basic Course

• **Record ID:** 75910225
 • **Completion Date:** 14-Mar-2026
 • **Expiration Date:** 14-Mar-2029
 • **Minimum Passing:** 90
 • **Reported Score*:** 95

REQUIRED AND ELECTIVE MODULES ONLY	DATE COMPLETED	SCORE
Belmont Report and Its Principles (ID: 1127)	14-Mar-2026	3/3 (100%)
History and Ethics of Human Subjects Research (ID: 498)	14-Mar-2026	5/5 (100%)
Basic Institutional Review Board (IRB) Regulations and Review Process (ID: 2)	14-Mar-2026	5/5 (100%)
Records-Based Research (ID: 5)	14-Mar-2026	4/4 (100%)
Genetic Research in Human Populations (ID: 6)	14-Mar-2026	4/5 (80%)
Populations in Research Requiring Additional Considerations and/or Protections (ID: 16680)	14-Mar-2026	5/5 (100%)
Research and HIPAA Privacy Protections (ID: 14)	14-Mar-2026	5/5 (100%)
Conflicts of Interest in Human Subjects Research (ID: 17464)	14-Mar-2026	4/5 (80%)
Massachusetts Institute of Technology (ID: 1290)	14-Mar-2026	No Quiz

For this Report to be valid, the learner identified above must have had a valid affiliation with the CITI Program subscribing institution identified above or have been a paid Independent Learner.

This document was generated on 14-Mar-2026. Verify at www.citiprogram.org/verify/2k3262cccb-eeef-429e-a6d2-782694c9db5e-75910225

Collaborative Institutional Training Initiative (CITI Program)
 101 NE 3rd Avenue
 Suite 320
 Fort Lauderdale, FL 33301 US

Email: support@citiprogram.org
 Phone: 888-529-5929
 Web: <https://www.citiprogram.org>

Figura A.4: informe de finalización del CITI Program con el detalle de módulos y puntuaciones, se censura información de carácter personal.

Apéndice *B*

Manual de especificación de diseño

B.1. Arquitectura

El sistema desarrollado se organiza en dos subsistemas principales y desacoplados: un *pipeline* de modelado y entrenamiento, encargado de transformar los datos clínicos en modelos predictivos entrenados, calibrados e interpretables; y una aplicación de visualización o *dashboard*, encargada de cargar dichos modelos y aplicarlos sobre los datos introducidos para un paciente concreto. La Figura [B.1](#) resume la arquitectura general del sistema mediante un diagrama de bloques.

El *pipeline* de modelado constituye la parte experimental del proyecto. Su flujo comienza con las fuentes de datos, principalmente MIMIC-IV para el entrenamiento y eICU-CRD para la validación externa. A partir de estas bases se realiza la extracción de cohortes mediante consultas SQL, seguida del preprocesamiento de los datos, la selección de variables, el entrenamiento de los modelos, la optimización mediante validación cruzada anidada y la calibración probabilística. Finalmente, los modelos seleccionados se serializan en formato `.pkl` mediante `joblib`, separando así la fase de entrenamiento de la fase posterior de inferencia.

La aplicación de visualización, implementada en Streamlit, funciona como un módulo independiente que consume los modelos ya entrenados. El usuario carga un fichero CSV con mediciones clínicas del paciente, estructurado como registros temporales. A partir de estos datos, la aplicación calcula los estadísticos agregados (mínimo, máximo o media, según la variable)

correspondientes al conjunto de predictores de la ventana seleccionada, carga el modelo correspondiente, obtiene la probabilidad estimada de inicio de noradrenalina y contextualiza el resultado mediante un percentil de riesgo respecto a la cohorte de referencia.

Además de la probabilidad estimada, el *dashboard* incorpora una explicación individual mediante valores SHAP, mostrando qué variables contribuyen a aumentar o reducir la predicción para el paciente evaluado. De este modo, la arquitectura no se limita a producir una salida numérica, sino que integra también una capa de interpretabilidad orientada a facilitar la revisión del resultado.

La separación entre entrenamiento e inferencia permite que los modelos finales puedan reutilizarse sin repetir el proceso completo de entrenamiento. Esta decisión simplifica el uso del prototipo, reduce el coste computacional durante la ejecución del *dashboard* y mantiene una frontera clara entre el desarrollo experimental de los modelos y su uso posterior como herramienta de visualización.




Figura B.1: arquitectura general del sistema: *pipeline* de modelado y entrenamiento, serialización de modelos y aplicación de visualización mediante *dashboard*.

El diseño adoptado es deliberadamente modular. Las etapas de extracción, preprocesamiento, entrenamiento, calibración, interpretabilidad y visualización pueden modificarse de forma independiente, siempre que se mantenga la compatibilidad entre las variables requeridas por los modelos serializados y las variables calculadas por el *dashboard*. Esta modularidad facilita la trazabilidad del flujo experimental y permitiría, en trabajos futuros, sustituir modelos, actualizar cohortes o integrar nuevas fuentes de datos sin rediseñar por completo la aplicación.

Apéndice C

Especificación de Requisitos

C.1. Diagrama de casos de uso

El único subsistema interactivo del trabajo es el *dashboard*; el pipeline de modelado se ejecuta de forma desatendida y no requiere interacción directa por parte del usuario final. Por este motivo, los casos de uso modelan exclusivamente la aplicación de visualización. El actor único considerado es el facultativo de Medicina Intensiva como usuario evaluador del prototipo. La Figura C.1 resume las funcionalidades principales.




Figura C.1: diagrama de casos de uso del *dashboard*.

C.2. Tablas de casos de uso

A modo de contexto, los casos de uso se apoyan en los siguientes requisitos funcionales (RF) y no funcionales (RNF):

Requisitos funcionales:

- **RF-1:** permitir seleccionar la ventana temporal de predicción disponible en el prototipo: media (6–24 h) o larga (12–48 h).
- **RF-2:** permitir cargar un fichero CSV con las mediciones clínicas del caso evaluado.
- **RF-3:** calcular los estadísticos agregados requeridos por el modelo a partir de las mediciones temporales del CSV.
- **RF-4:** cargar el modelo correspondiente a la ventana seleccionada y calcular la estimación de riesgo.

- **RF-5:** mostrar el riesgo estimado como percentil respecto a la distribución de referencia de MIMIC-IV.
- **RF-6:** mostrar la explicación individual de la predicción mediante valores SHAP.
- **RF-7:** disponer de un modo demostración con casos ficticios.
- **RF-8:** ofrecer un manual de uso y un aviso visible sobre el alcance del prototipo.

Requisitos no funcionales:

- **RNF-1 (interpretabilidad):** las salidas deben presentarse de forma comprensible para personal clínico, combinando percentil de riesgo y explicación local mediante SHAP.
- **RNF-2 (no prescriptivo):** la interfaz no debe emitir recomendaciones terapéuticas automáticas, proponer dosis ni sustituir la valoración médica.
- **RNF-3 (usabilidad):** la interfaz debe ser sencilla y permitir una navegación básica mediante botones de ventana temporal, modo demostración y manual.
- **RNF-4 (privacidad y uso local):** el prototipo no persiste los datos cargados ni los envía explícitamente a servicios externos dentro del flujo implementado. En cualquier uso con datos reales, la ejecución debería realizarse en un entorno controlado y con datos adecuadamente autorizados o desidentificados.
- **RNF-5 (portabilidad):** la aplicación debe poder ejecutarse en un equipo con un entorno Python compatible y las dependencias del proyecto instaladas, sin requerir hardware especializado.
- **RNF-6 (estado del producto):** la aplicación es un prototipo académico de prueba de concepto, sin validación clínica prospectiva ni autorización regulatoria; no está destinada a uso asistencial real.
- **RNF-7 (tolerancia básica a errores):** la aplicación debe mostrar avisos cuando falten columnas esperadas en el CSV o se produzcan errores durante el procesamiento, sin interpretar estos controles como una validación clínica exhaustiva de la calidad del dato.

C.3. Prototipos




Figura C.2: pantalla de inicio del *dashboard*. Bajo el título se muestra el aviso permanente de prototipo de investigación y los controles de selección de ventana temporal, modo demostración y manual. La aplicación no realiza ninguna estimación hasta que el usuario selecciona una opción.




Figura C.3: vista principal tras cargar un CSV de ejemplo en la ventana larga (12–48 h). A la izquierda se muestra el percentil de riesgo acompañado de su explicación textual y de los datos del caso; a la derecha, los factores individuales según los valores SHAP, donde las barras rojas empujan el riesgo al alza y las verdes lo reducen.

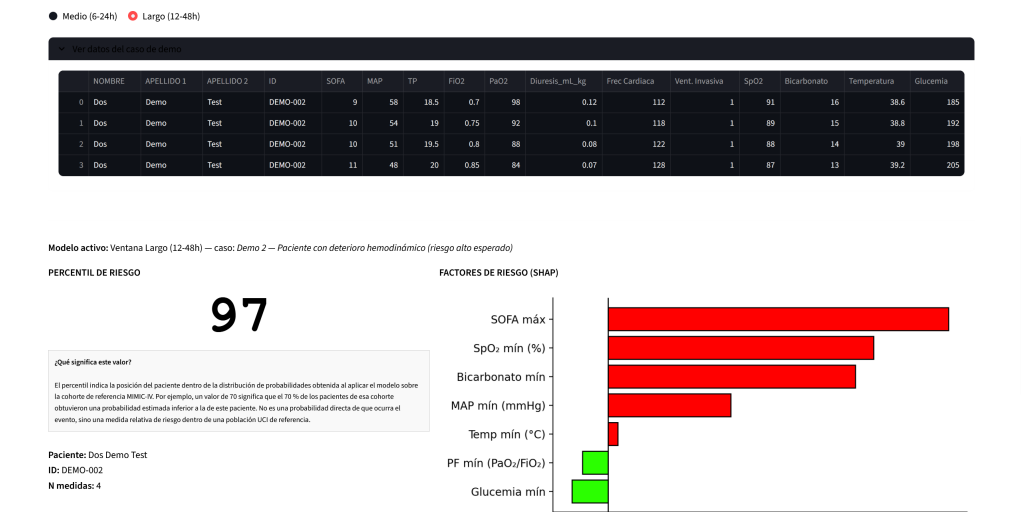


Figura C.4: modo demostración. Permite explorar el funcionamiento del *dashboard* con casos ficticios, sin necesidad de cargar un CSV propio. Se muestra un caso de paciente con deterioro hemodinámico.




Figura C.5: manual de uso integrado, accesible desde la propia interfaz. Documenta las ventanas temporales disponibles, el modo de uso, el formato esperado del CSV de entrada y la interpretación del percentil de riesgo y de los valores SHAP.

CU-1	Seleccionar la ventana temporal
Versión del caso de uso	1.0
Autor	Daniel Marina de la Cal
Requisitos asociados	RF-1
Descripción	El facultativo selecciona la ventana temporal de predicción disponible en el prototipo: media (6–24 h) o larga (12–48 h). La selección determina el modelo que se aplicará.
Precondición	La aplicación está en ejecución.
Acciones	1. El facultativo pulsa el botón de la ventana deseada. 2. El sistema registra la ventana seleccionada para la consulta posterior.
Postcondición	Queda seleccionada la ventana temporal y el modelo asociado.
Excepciones	—
Importancia	Alta

Tabla C.1: CU-1 seleccionar la ventana temporal.

CU-2	Cargar CSV con datos del caso evaluado
Versión del caso de uso	1.0
Autor	Daniel Marina de la Cal
Requisitos asociados	RF-2, RF-3, RNF-7
Descripción	El facultativo carga un fichero CSV con mediciones clínicas temporales. El sistema intenta procesar el fichero y calcular los estadísticos agregados requeridos por el modelo.
Precondición	Haber seleccionado una ventana temporal (CU-1) y disponer de un CSV con el formato esperado.
Acciones	1. El facultativo selecciona la opción de carga de datos. 2. Elige el fichero CSV del caso evaluado. 3. El sistema lee el fichero. 4. El sistema calcula los estadísticos agregados necesarios para la ventana seleccionada. 5. El sistema habilita la consulta del riesgo y la explicación.
Postcondición	Los datos quedan cargados y transformados en las variables requeridas por el modelo.
Excepciones	Si faltan columnas esperadas o se produce un error durante el procesamiento, el sistema muestra un aviso y no presenta resultados. Estos controles son básicos y no equivalen a una validación clínica exhaustiva del CSV.
Importancia	Alta

Tabla C.2: CU-2 cargar CSV con datos del caso evaluado.

CU-3	Consultar el percentil de riesgo y la explicación SHAP
Versión del caso de uso	1.0
Autor	Daniel Marina de la Cal
Requisitos asociados	RF-4, RF-5, RF-6, RNF-1, RNF-2
Descripción	El facultativo consulta el riesgo estimado de inicio de noradrenalina, expresado como percentil respecto a la población de referencia, junto con la explicación individual de las variables que contribuyen a la predicción.
Precondición	Datos del caso cargados y procesados (CU-2).
Acciones	1. El sistema aplica el modelo de la ventana seleccionada. 2. Calcula la probabilidad estimada de inicio de noradrenalina. 3. Traduce la probabilidad a un percentil respecto a la distribución de referencia de MIMIC-IV. 4. Muestra el percentil de riesgo. 5. Calcula los valores SHAP individuales y muestra las variables que empujan o reducen el riesgo.
Postcondición	Se muestran el percentil de riesgo y la explicación individualizada de la predicción.
Excepciones	Si el modelo o el fichero de referencia de percentiles no está disponible, el sistema muestra un error y no calcula el resultado.
Importancia	Alta

Tabla C.3: CU-3 consultar el percentil de riesgo y la explicación SHAP.

CU-4	Ejecutar el modo demostración
Versión del caso de uso	1.0
Autor	Daniel Marina de la Cal
Requisitos asociados	RF-7, RF-4, RF-5, RF-6
Descripción	El facultativo explora el funcionamiento del <i>dashboard</i> con casos ficticios, sin necesidad de cargar un CSV propio.
Precondición	La aplicación está en ejecución.
Acciones	1. El facultativo pulsa el botón de modo demostración. 2. Selecciona uno de los casos ficticios disponibles. 3. Selecciona la ventana temporal de demostración. 4. El sistema muestra los datos del caso, el percentil de riesgo y la explicación SHAP correspondientes.
Postcondición	Se muestra el resultado del caso de demostración seleccionado.
Excepciones	Si no se puede cargar el modelo o la referencia de percentiles, el sistema muestra un error.
Importancia	Baja

Tabla C.4: CU-4 ejecutar el modo demostración.

CU-5	Consultar el manual e información
Versión del caso de uso	1.0
Autor	Daniel Marina de la Cal
Requisitos asociados	RF-8, RNF-2, RNF-6
Descripción	El facultativo consulta el manual de uso integrado, que documenta las ventanas disponibles, el formato esperado del CSV, la interpretación de los resultados y el aviso de prototipo.
Precondición	La aplicación está en ejecución.
Acciones	1. El facultativo pulsa el botón de manual / información. 2. El sistema muestra las instrucciones de uso. 3. El sistema muestra el aviso de alcance del prototipo.
Postcondición	Se muestra la documentación de uso en pantalla.
Excepciones	—
Importancia	Baja-media

Tabla C.5: CU-5 consultar el manual e información.

Apéndice *D*

Documentación de usuario

D.1. Requisitos previos

Este manual está dirigido al uso del prototipo de *dashboard* por parte de personal clínico o técnico del hospital. La aplicación permite introducir datos clínicos de un paciente o caso de ejemplo y visualizar una estimación relativa del riesgo de inicio de noradrenalina, junto con una explicación individual mediante valores SHAP.

El usuario final previsto es un facultativo o profesional sanitario que consulta la interfaz ya en ejecución. La instalación inicial, en cambio, debería ser realizada por personal técnico o por una persona con conocimientos básicos de Python, ya que requiere preparar un entorno local y ejecutar una aplicación Streamlit.

La ejecución del *dashboard* no requiere descargar ni acceder directamente a las bases de datos MIMIC-IV o eICU-CRD. Los modelos ya han sido entrenados previamente y se distribuyen como ficheros serializados en formato `.pkl`. Por tanto, el uso descrito en este manual corresponde exclusivamente a la fase de inferencia y visualización, no al reentrenamiento completo del sistema.

Requisitos de hardware

Para ejecutar el prototipo se recomienda disponer de:

- un ordenador personal o equipo hospitalario con sistema operativo Windows, Linux o macOS;

- al menos 4 GB de memoria RAM;
- aproximadamente 1 GB de espacio libre para el entorno de Python, dependencias y archivos del *dashboard*;
- no se requiere tarjeta gráfica dedicada, ya que la inferencia se ejecuta en CPU.

Requisitos de software

El equipo debe disponer de:

- Python 3.12 o una versión compatible;
- un navegador web actualizado;
- acceso local a la carpeta **Dashboard** del repositorio;
- las bibliotecas necesarias para ejecutar la aplicación: **streamlit**, **pandas**, **numpy**, **scikit-learn**, **xgboost**, **shap**, **matplotlib** y **joblib**.

La carpeta **Dashboard** debe contener los siguientes archivos:

- `pruebas_dashboard.py`;
- `modelo_Medio_6_24_XGB_calibrado.pkl`;
- `modelo_Largo_12_48_XGB.pkl`;
- `referencia_percentiles_medio.npy`;
- `referencia_percentiles_largo.npy`.

Si alguno de estos archivos falta o se mueve a otra ubicación, la aplicación puede no cargar correctamente los modelos o las referencias utilizadas para calcular los percentiles de riesgo.

D.2. Instalación y puesta en marcha

La instalación debe realizarse una única vez en el equipo donde vaya a ejecutarse la aplicación. En un contexto hospitalario real, este paso correspondería al personal técnico. El facultativo no tendría que ejecutar comandos, sino acceder a la interfaz ya abierta en el navegador.

Instalación en un equipo local

Los pasos recomendados son los siguientes:

1. Descargar o clonar el repositorio del proyecto desde GitHub.

```
git clone <URL del repositorio público del proyecto>
```

2. Entrar en la carpeta del repositorio.

```
cd Estimacion-temprana-*
```

3. Crear un entorno virtual de Python (opcional).

```
python -m venv .venv
```

4. Activar el entorno virtual. En Windows:

```
.venv\Scripts\activate
```

En Linux o macOS:

```
source .venv/bin/activate
```

5. Instalar las dependencias principales de la aplicación.

```
pip install streamlit pandas numpy  
pip install scikit-learn xgboost shap  
pip install matplotlib joblib
```

6. Entrar en la carpeta del *dashboard*.

```
cd Dashboard
```

7. Ejecutar la aplicación.

```
python -m streamlit run pruebas_dashboard.py
```

8. Abrir en el navegador la dirección indicada por Streamlit. Habitualmente será:

`http://localhost:8501`

Una vez abierta la aplicación, el usuario clínico puede utilizarla desde el navegador sin interactuar con la terminal.

Comprobación inicial

Antes de entregar la aplicación al usuario final, se recomienda que el personal técnico compruebe que:

- la pantalla principal se abre correctamente;
- aparecen los botones de selección de ventana temporal;
- el botón *Modo Demo* funciona;
- el botón *Manual / Info* muestra las instrucciones integradas;
- los modelos de ventana media y larga cargan sin error;
- los ficheros `.pkl` y `.npy` permanecen en la carpeta `Dashboard`.

D.3. Manual de uso

Al iniciar el *dashboard*, el usuario visualiza una pantalla de portada con el título del proyecto, los botones principales y un aviso de alcance del prototipo. Esta pantalla se muestra en la Figura C.2 del Apéndice C.

La aplicación ofrece tres acciones principales:

- seleccionar una ventana temporal de predicción;
- cargar un CSV con mediciones clínicas;
- utilizar el modo demostración con casos ficticios.

Paso 1: seleccionar la ventana temporal

El usuario debe elegir una de las dos ventanas disponibles:

- **Ventana media (6–24 h):** estima el riesgo relativo de inicio de noradrenalina en el intervalo comprendido entre las 6 y las 24 horas.
- **Ventana larga (12–48 h):** estima el riesgo relativo de inicio de noradrenalina en el intervalo comprendido entre las 12 y las 48 horas.

La selección de la ventana determina qué modelo se carga internamente. El prototipo final del *dashboard* no incluye la ventana corta.

Paso 2: preparar el CSV

El fichero de entrada debe estar en formato CSV y contener una fila por medición temporal. El objetivo es que el usuario introduzca datos clínicos ordinarios, no las variables agregadas finales utilizadas por el modelo. La aplicación calcula después los mínimos, máximos, medias o sumas necesarios según la ventana seleccionada.

Las columnas esperadas son:

NOMBRE, APELLIDO 1, APELLIDO 2, ID, SOFA, MAP, TP, FiO2, PaO2, Diuresis_mL_kg, Frec Cardiaca, Vent. Invasiva, SpO2, Bicarbonato, Temperatura, Glucemia

El significado práctico de las columnas principales es:

- **SOFA:** puntuación SOFA registrada en la medición.
- **MAP:** presión arterial media.
- **TP:** tiempo de protrombina.
- **FiO2:** fracción inspirada de oxígeno, introducida en escala decimal.
- **PaO2:** presión arterial de oxígeno.
- **Diuresis_mL_kg:** diuresis normalizada por peso.
- **Frec Cardiaca:** frecuencia cardiaca.

- **Vent. Invasiva:** indicador binario de ventilación mecánica invasiva.
- **SpO2:** saturación periférica de oxígeno.
- **Bicarbonato:** bicarbonato sérico.
- **Temperatura:** temperatura corporal.
- **Glucemia:** glucemia.

Las columnas **NOMBRE**, **APELLIDO 1**, **APELLIDO 2** e **ID** se muestran únicamente como identificación visual del caso dentro de la interfaz. En un contexto real, deberían emplearse datos debidamente autorizados o identificadores seudonimizados, de acuerdo con las normas del centro.

Paso 3: cargar el CSV

Una vez seleccionada la ventana temporal, el usuario debe pulsar el botón de carga de archivo y seleccionar el CSV correspondiente al caso evaluado.

Si el archivo se carga correctamente, la aplicación calcula automáticamente las variables agregadas necesarias para el modelo. Si faltan columnas esperadas o se produce un error durante el procesamiento, la interfaz muestra un aviso. Estos controles son básicos y no constituyen una validación clínica exhaustiva de la calidad del dato.

Paso 4: consultar el resultado

Tras procesar el CSV, la pantalla principal muestra dos bloques, como se observa en la Figura [C.3](#) del Apéndice C:

- a la izquierda, el percentil de riesgo y un resumen del caso evaluado;
- a la derecha, los factores individuales asociados a la predicción mediante valores SHAP.

El resultado no debe interpretarse como una orden clínica ni como una recomendación terapéutica. La aplicación no indica si debe iniciarse noradrenalina, no propone dosis y no sustituye la valoración del facultativo responsable.

Interpretación del percentil de riesgo

El percentil indica la posición del caso evaluado dentro de la distribución de probabilidades estimadas en la cohorte de referencia MIMIC-IV.

Por ejemplo, un percentil de 90 significa que el 90 % de los pacientes de la cohorte de referencia obtuvieron una probabilidad estimada inferior a la del caso evaluado. No significa que el paciente tenga un 90 % de probabilidad directa de iniciar noradrenalina. Es una medida relativa de riesgo respecto a una población de referencia.

Interpretación de los valores SHAP

El gráfico SHAP muestra cómo contribuye cada variable a la predicción individual de ese caso concreto.

- Las barras rojas empujan la estimación hacia mayor riesgo.
- Las barras verdes reducen la estimación de riesgo.
- La longitud de cada barra representa la magnitud de la contribución.

Esta explicación es local: describe el resultado del caso cargado, no la importancia global de las variables en todo el modelo.

D.4. Modo demostración

El botón *Modo Demo* permite explorar el funcionamiento de la aplicación con casos ficticios, sin cargar un CSV propio. Esta opción está pensada para formación, demostración y comprobación inicial del sistema.

El modo demostración permite seleccionar entre casos simulados y elegir la ventana temporal. A continuación, el *dashboard* muestra la tabla de datos del caso, el percentil de riesgo y la explicación SHAP correspondiente. Un ejemplo de esta pantalla se recoge en la Figura C.4 del Apéndice C.

Este modo no utiliza datos reales y no debe interpretarse como una evaluación clínica.

D.5. Manual integrado

La aplicación incluye un botón *Manual / Info*, accesible desde la pantalla principal. Este apartado integrado resume:

- el objetivo del *dashboard*;
- las ventanas temporales disponibles;
- el formato esperado del CSV;
- la interpretación del percentil de riesgo;
- la interpretación de los valores SHAP;
- el modo demostración;
- las advertencias de uso.

La pantalla del manual integrado se muestra en la Figura C.5 del Apéndice C.

D.6. Advertencias de uso

El *dashboard* desarrollado es un prototipo académico y experimental. No está validado prospectivamente, no dispone de autorización regulatoria y no debe emplearse para tomar decisiones clínicas reales.

La aplicación no recomienda iniciar noradrenalina, no propone dosis, no genera alarmas clínicas y no sustituye la valoración médica. Su finalidad es demostrar la viabilidad técnica de integrar un modelo predictivo interpretable en una interfaz de visualización.

Cualquier uso futuro con datos reales de pacientes requeriría validación clínica, autorización ética y revisión por parte del centro sanitario correspondiente.

Apéndice *E*

Manual del programador

E.1. Estructura de directorios

El repositorio se organiza separando la documentación académica, el prototipo de *dashboard*, el flujo experimental de modelado, la validación externa y las pruebas históricas. La estructura general entregada es la siguiente:

```
.
+-- Archivo/
|   +-- Pruebas preliminares/
+-- Dashboard/
+-- Memoria/
|   +-- img/
|   +-- qmd/
+-- Pipeline/
|   +-- Experimentos/
|   +-- FINAL/
+-- Validacion_externa/
|   +-- eICU/
```

La carpeta **Archivo/** contiene pruebas preliminares y versiones antiguas del desarrollo. Se conserva por trazabilidad histórica, pero no constituye la referencia principal para reproducir los resultados finales.

La carpeta **Dashboard/** contiene el prototipo de aplicación desarrollado en Streamlit. Incluye el script principal **pruebas_dashboard.py**, los modelos

finales serializados en formato `.pkl` y los ficheros `.npy` utilizados como referencia para calcular los percentiles de riesgo. Esta carpeta es la unidad mínima necesaria para ejecutar el prototipo de inferencia una vez instaladas las dependencias.

La carpeta **Memoria/** contiene la documentación académica del TFG. En **Memoria/qmd/** se almacenan los ficheros fuente en Quarto/Markdown, mientras que **Memoria/img/** contiene las imágenes, diagramas y capturas empleadas en la memoria y los anexos.

La carpeta **Pipeline/Experimentos/** recoge versiones intermedias del desarrollo experimental. Estas carpetas documentan la evolución metodológica del proyecto, incluyendo construcción de cohortes, selección de variables, reducción de predictores, análisis de significancia, comprobación de dirección del efecto y refinamiento progresivo de los modelos.

La carpeta **Pipeline/FINAL/** contiene la versión final del flujo experimental utilizada para generar los resultados incluidos en la memoria. En ella se almacenan los scripts principales, modelos entrenados, tablas de métricas, figuras de validación interna, figuras de calibración, análisis SHAP y comparaciones finales entre modelos o calibradores. Debe considerarse la carpeta de referencia para consultar los resultados consolidados del modelado.

La carpeta **Validacion_externa/elCU/** contiene el material asociado a la validación externa sobre eICU-CRD: consultas SQL, scripts de adaptación, tablas, figuras y resultados derivados de aplicar los modelos entrenados en MIMIC-IV sobre una cohorte externa independiente.

En términos funcionales, la relación entre carpetas puede resumirse como:

- **Pipeline/Experimentos/**: trazabilidad metodológica y versiones intermedias.
- **Pipeline/FINAL/**: entrenamiento final, calibración, modelos, métricas y SHAP.
- **Validacion_externa/elCU/**: validación externa sobre eICU-CRD.
- **Dashboard/**: inferencia y visualización mediante Streamlit.
- **Memoria/**: documentación académica.
- **Archivo/**: pruebas históricas no necesarias para el flujo final.

E.2. Compilación y ejecución

Este proyecto no se compila en el sentido clásico de una aplicación cerrada. El código se ejecuta mediante scripts de Python y la interfaz de usuario se lanza como una aplicación Streamlit. Deben distinguirse dos niveles de ejecución: el uso del *dashboard*, descrito anteriormente, y la reproducción del flujo experimental.

Reproducción del flujo experimental

La reproducción completa del flujo experimental requiere disponer de acceso autorizado a las bases de datos originales MIMIC-IV y eICU-CRD.

En el desarrollo de este TFG, las tablas originales de MIMIC-IV y eICU-CRD se importaron en un servidor local de PostgreSQL, desde el que se ejecutaron las consultas SQL de extracción de cohortes. Este servidor local se empleó únicamente como entorno de trabajo para el procesamiento autorizado de los datos y no forma parte del repositorio público. Por tanto, para reproducir completamente el flujo experimental es necesario disponer de acceso autorizado a PhysioNet, descargar las bases de datos bajo sus condiciones de uso e importarlas previamente en una instancia local de PostgreSQL con una estructura equivalente.

A nivel general, la reproducción sigue esta secuencia:

1. Importar MIMIC-IV y eICU-CRD en una instancia local de PostgreSQL autorizada y ejecutar sobre ella las consultas SQL de extracción de cohortes.
2. Generar los CSV definitivos por ventana temporal.
3. Aplicar el preprocesamiento y la selección de variables.
4. Ejecutar los scripts finales de entrenamiento y validación interna en Pipeline/FINAL/.
5. Evaluar calibración y generar figuras de validación.
6. Calcular explicaciones SHAP.
7. Aplicar los modelos entrenados sobre eICU-CRD en Validacion_externa/eICU/.
8. Serializar los modelos finales y referencias de percentiles para su uso en Dashboard/.

La carpeta `Pipeline/FINAL/` contiene los scripts y salidas finales del modelado. Las carpetas de `Pipeline/Experimentos/` permiten reconstruir las decisiones metodológicas previas, pero no sustituyen a `Pipeline/FINAL/` como salida consolidada.

Compilación de la documentación

La memoria y los anexos se encuentran en la carpeta `Memoria/`. La compilación se realiza mediante Quarto, utilizando los ficheros `.qmd` y las imágenes almacenadas en `Memoria/img/`. Desde la carpeta correspondiente puede ejecutarse:

```
quarto render anexos.qmd
```

o, para la memoria principal:

```
quarto render memoria.qmd
```

La compilación requiere tener instalado Quarto, una distribución LaTeX compatible y las dependencias de R/Python utilizadas por los bloques ejecutables, en caso de que el documento los incluya.

E.3. Pruebas del sistema

Al tratarse de un trabajo de investigación de carácter experimental, no se desarrolló una batería completa de pruebas unitarias, pruebas de integración o integración continua propia de un software de producción. La validación del sistema se abordó desde dos perspectivas: validación metodológica de los modelos y comprobación funcional básica del prototipo de *dashboard*.

Desde el punto de vista metodológico, se aplicaron las siguientes estrategias:

- **Validación interna** mediante validación cruzada anidada (5×3) con agrupamiento por paciente, para evitar fugas de información entre particiones.
- **Validación externa** sobre la cohorte independiente y multicéntrica eICU-CRD.

- **Análisis por subgrupos** según presencia de sepsis, para evaluar la estabilidad del rendimiento en MIMIC-IV.
- **Comparación frente a SOFA** como referencia clínica de gravedad.
- **Evaluación de calibración** mediante ECE, Brier Score y Brier Skill Score.
- **Auditoría de interpretabilidad** mediante valores SHAP, comprobando la coherencia clínica de las variables con mayor contribución.
- **Evaluación exploratoria de usabilidad** del *dashboard* mediante una encuesta a ocho facultativos del servicio de Medicina Intensiva del HUBU.

Además, para el prototipo de *dashboard* se realizaron comprobaciones funcionales básicas:

- apertura correcta de la aplicación en Streamlit;
- carga de los modelos serializados en formato `.pkl`;
- carga de los ficheros de referencia de percentiles en formato `.npy`;
- selección de las ventanas media y larga;
- ejecución del modo demostración;
- carga de CSV con el formato esperado;
- cálculo de las variables agregadas requeridas por cada modelo;
- visualización del percentil de riesgo;
- generación de la explicación individual mediante SHAP;
- visualización del manual integrado;
- aparición de avisos cuando faltan columnas o se produce un error durante el procesamiento.

Estas comprobaciones no sustituyen a una validación clínica prospectiva ni a una certificación del software como producto sanitario. Su objetivo fue verificar la coherencia técnica del prototipo dentro del alcance académico del TFG.

Los resultados cuantitativos de la validación interna, la validación externa, la calibración, la comparación frente a SOFA y la encuesta de usabilidad se recogen en los capítulos de Resultados y Discusión de la memoria.

E.4. Instrucciones para la modificación o mejora del proyecto

Para facilitar futuras ampliaciones, se ofrecen las siguientes recomendaciones:

Validación externa pendiente con datos del HUBU

Una ampliación prioritaria del proyecto sería realizar una validación externa local con datos del Hospital Universitario de Burgos. A diferencia del reentrenamiento, esta validación debería aplicar los modelos ya entrenados sobre MIMIC-IV a una cohorte independiente del HUBU, sin reajustar los parámetros del modelo, con el objetivo de evaluar su transportabilidad al entorno clínico local.

Para llevar a cabo esta validación sería necesario:

- obtener la autorización ética y administrativa correspondiente para el uso secundario de los datos clínicos locales;
- definir una cohorte de pacientes de UCI equivalente a la empleada en MIMIC-IV;
- adaptar las consultas de extracción al sistema de información hospitalario disponible;
- reconstruir las mismas ventanas temporales de observación y predicción;
- calcular la variable objetivo de inicio de noradrenalina con la misma definición temporal;
- armonizar las unidades, nombres de variables y criterios de completitud con los empleados en el entrenamiento;
- aplicar los modelos entrenados sin reentrenamiento sobre la cohorte HUBU;

- comparar el rendimiento frente a SOFA y frente a los resultados obtenidos en MIMIC-IV y eICU-CRD;
- evaluar discriminación, calibración, rendimiento probabilístico e interpretabilidad mediante SHAP;
- analizar posibles desplazamientos de distribución entre MIMIC-IV, eICU-CRD y HUBU.

Esta validación local permitiría comprobar si el comportamiento observado en bases de datos internacionales se mantiene en el contexto asistencial del hospital. En caso de observarse una pérdida relevante de rendimiento o problemas de calibración, podría plantearse posteriormente una recalibración local o un reentrenamiento parcial, siempre manteniendo una separación clara entre validación externa y ajuste del modelo.

Reentrenamiento con una nueva cohorte

Reentrenar los modelos con una cohorte nueva requiere reproducir el flujo completo de extracción, preprocesamiento, selección de variables, entrenamiento, calibración e interpretación. Esta opción sería posterior a una validación externa local y solo estaría justificada si el rendimiento de los modelos originales no resultase adecuado en la nueva cohorte.

- adaptar las consultas SQL al esquema de la nueva fuente de datos;
- reconstruir las ventanas temporales de observación y predicción;
- recalcular la variable objetivo de inicio de noradrenalina;
- aplicar los mismos criterios de exclusión y control de fugas temporales;
- repetir la selección de variables;
- reentrenar los modelos;
- recalibrar las probabilidades si fuera necesario;
- generar nuevos ficheros de referencia de percentiles;
- serializar los modelos finales con `joblib`;
- actualizar el *dashboard* para que cargue los nuevos modelos.

Los nuevos modelos podrían sustituir a los actuales en la carpeta **Dashboard/**, siempre que se mantuviera la compatibilidad entre las variables esperadas por el modelo y las variables calculadas por la aplicación.

Añadir una nueva ventana temporal

Añadir una nueva ventana temporal implica replicar la lógica de etiquetado y agregación para el nuevo horizonte. No basta con entrenar un nuevo modelo: también habría que actualizar el *dashboard* para que reconozca la nueva ventana y cargue los ficheros correspondientes.

Los cambios mínimos serían:

- Definir la nueva ventana de observación y el nuevo horizonte de predicción;
- Generar la cohorte correspondiente;
- Entrenar y validar el modelo específico de esa ventana;
- Guardar el modelo serializado en formato **.pkl**;
- Guardar la referencia de percentiles en formato **.npy**;
- Añadir un nuevo botón o selector de ventana en el *dashboard*;
- Registrar las variables esperadas por el nuevo modelo;
- Implementar la lógica de agregación asociada a la nueva ventana;
- Actualizar el manual de usuario y las capturas de interfaz.

Mejoras recomendadas del *dashboard*

Como mejoras de mantenibilidad y robustez del prototipo se recomienda:

- Añadir una función explícita de validación del CSV de entrada, comprobando columnas obligatorias, tipos numéricos, escala de FiO2 y rangos fisiológicamente plausibles;
- Separar la lógica de carga de modelos, procesamiento del CSV, cálculo de percentiles y visualización SHAP en módulos independientes;

- Externalizar la configuración de los modelos (rutas, nombres de ficheros y variables esperadas por ventana) a un fichero de configuración, en lugar de definirla directamente en el script;
- Añadir pruebas funcionales simples para comprobar que el modo demostración, la carga de CSV y la generación de SHAP no fallan tras modificar el código;

Evolución metodológica futura

Como líneas de evolución del proyecto podrían explorarse modelos temporales, como LSTM o Transformers, o enfoques de análisis de supervivencia. Estas alternativas requerirían rediseñar la representación de los datos y seleccionar los registros que lo permitan, ya que el flujo actual se basa en estadísticos agregados por ventana temporal.

También podría plantearse la integración del *dashboard* en sistemas de información hospitalaria. Esta evolución requeriría validación clínica prospectiva, autorización ética, revisión de seguridad, control de accesos, auditoría de datos y adaptación a la infraestructura tecnológica del centro sanitario.

Apéndice F

Descripción de adquisición y tratamiento de datos

F.1. Descripción formal de los datos

Los datos utilizados en este trabajo proceden de dos bases de datos clínicas de cuidados críticos: MIMIC-IV (Medical Information Mart for Intensive Care) ([Johnson et al., 2023](#)), empleada para el entrenamiento y la evaluación interna de los modelos, y eICU-CRD (eICU Collaborative Research Database) ([Pollard et al., 2018](#)), empleada para la validación externa. Ambas están alojadas en PhysioNet ([PhysioNet, 2026](#)) y su acceso requirió completar el curso de formación CITI Program ([CITI Program, 2026](#)), registrar el proyecto y firmar el acuerdo de uso de datos correspondiente.

Sobre las variables clínicas continuas se aplicó una winsorización al percentil 2–98, siguiendo la estrategia de tratamiento de valores extremos del flujo de procesamiento de [Gupta et al. \(2022\)](#). Esta técnica acota los valores situados por debajo del percentil 2 y por encima del percentil 98 a dichos umbrales, en lugar de eliminarlos, lo que limita el efecto de los valores atípicos y de los errores de registro sobre el entrenamiento sin reducir el tamaño de la cohorte ni descartar estancias completas. Quedaron excluidas de este recorte las variables binarias (`tiene_sepsis` y `ventilacion_invasiva_*h`), sobre las que la winsorización no tiene sentido, así como los identificadores y la variable objetivo.

Estructura de ficheros generados

El proceso de extracción y preprocesado produjo seis conjuntos de datos definitivos, uno por cada combinación de base de datos y ventana temporal. La tabla F.1 los enumera junto con sus dimensiones. Conviene precisar que estos ficheros CSV no se incluyen en el repositorio público del proyecto, ya que contienen datos derivados de MIMIC-IV y eICU-CRD y su redistribución está prohibida por el acuerdo de uso de datos de PhysioNet suscrito para acceder a ellas. El repositorio contiene únicamente el código de extracción, procesamiento y modelado, de modo que cualquier persona con acceso acreditado a las bases originales pueda regenerar los conjuntos.

Tabla F.1: inventario de los ficheros CSV definitivos.

Fichero	Base	Ventana obs.	Horizonte pred.	Observaciones	Variables
definitivo_v4p.csv	MIMIC-IV	0–3 h	3–12 h	1 667	82
definitivo_v4.csv	MIMIC-IV	0–6 h	6–24 h	3 282	82
definitivo_v4l.csv	MIMIC-IV	0–12 h	12–48 h	4 088	82
eICU_3_12_definitivo.csv	eICU-CRD	0–3 h	3–12 h	789	12
eICU_6_24_definitivo.csv	eICU-CRD	0–6 h	6–24 h	1 396	16
eICU_12_48_definitivo.csv	eICU-CRD	0–12 h	12–48 h	2 030	17

Las diferencias de tamaño entre ventanas de la misma base responden a los criterios de inclusión: la ventana larga exige una duración de estancia superior a 48 h, las ventanas corta y media requieren únicamente más de 24 h, pero las variables calculadas sobre apenas 3 h de observación implican mayor presencia de datos ausentes en analíticas con baja frecuencia de extracción, lo que reduce la cohorte elegible. El menor número de variables en los CSV de eICU refleja que la validación externa se realizó únicamente con las variables seleccionadas por los modelos evaluados externamente, no con el conjunto completo de 82 predictores candidatos de MIMIC-IV.

Variables incluidas en los conjuntos MIMIC-IV

Cada uno de los tres ficheros MIMIC contiene exactamente 82 columnas, distribuidas en los grupos descritos en la tabla F.2.

La diferencia entre las 82 columnas totales y las 76 variables sobre las que se realizó el análisis de correlación y selección se debe a seis columnas no predictoras: los tres identificadores (`subject_id`, `hadm_id`, `stay_id`), las dos columnas de la variable objetivo (`etiqueta_norad_*` y `horas_hasta_norad`) y la diuresis en volumen bruto (`diuresis_volumen_6h`), excluida por ser redundante con la diuresis normalizada por peso (`diuresis_ml_kg_6h`), que sí se conservó como predictor.

Tabla F.2: grupos de variables en los conjuntos MIMIC-IV (82 columnas totales).

Grupo	N.º columnas	Ejemplos representativos
Identificadores	3	subject_id, hadm_id, stay_id
Demográficas y administrativas	4	anchor_age, gender, peso_kg, contador_estancia_uci
Clínico-proceso	4	tiene_sepsis, ventilacion_invasiva_*h, diuresis_volumen, diuresis_ml_kg
Constantes vitales (x3 estadísticos)	15	FC, FR, temperatura, SpO ₂ , PAM
Gasometría y respiratorio (x3)	15	PaO ₂ , PaCO ₂ , pH, FiO ₂ , PaO ₂ /FiO ₂
Analítica de laboratorio (x3)	33	lactato, creatinina, plaquetas, bilirrubina, TP, GPT, GOT, leucocitos, hemoglobina, bicarbonato, glucemia
Neurológica y de gravedad (x3)	6	GCS, SOFA
Variable objetivo	2	etiqueta_norad_*, horas_hasta_norad
Total	82	

Las 23 variables clínicas cuantitativas continuas se representan con tres estadísticos calculados sobre la ventana de observación: valor mínimo (`_min`), media (`_media`) y valor máximo (`_max`). Esta triple representación captura tanto el valor central como la variabilidad y los extremos del parámetro durante el periodo de observación, lo que resulta especialmente relevante para variables con alta fluctuación intraindividual como la frecuencia cardíaca, la glucemia o el lactato.

F.2. Descripción clínica de los datos

Se describe a continuación el significado fisiopatológico e interpretación clínica de las variables clínicas incluidas en los conjuntos de datos. Para cada parámetro continuo se calcularon tres estadísticos sobre la ventana de observación (mínimo `_min`, media `_media` y máximo `_max`); se indica entre paréntesis el estadístico de mayor relevancia clínica en cada caso.

Gravedad y proceso clínico

- **Puntuación SOFA (`sofa_max`):** El *Sequential Organ Failure Assessment* es una escala que cuantifica el grado de disfunción de seis sistemas orgánicos (respiratorio, coagulación, hepático, cardiovascular, neurológico y renal), asignando de 0 a 4 puntos a cada uno. El valor máximo dentro de la ventana resume la peor situación de disfunción orgánica del periodo de observación. Un SOFA elevado traduce fallo multiorgánico y se asocia estrechamente a inestabilidad hemodinámica

y a la necesidad de soporte vasopresor; en este trabajo actúa además como referencia clínica frente a la que se comparan los modelos ([Singer et al., 2016](#); [Vincent and De Backer, 2013](#)).

- **Presencia de sepsis (`tiene_sepsis`):** Indicador de sepsis definido según los criterios Sepsis-3 (disfunción orgánica potencialmente mortal causada por una respuesta desregulada del huésped a la infección). El síndrome séptico desencadena vasodilatación patológica y shock distributivo, mecanismo fisiopatológico directamente ligado a la necesidad de soporte vasopresor con noradrenalina como fármaco de primera línea ([Singer et al., 2016](#); [Evans et al., 2021](#)).
- **Ventilación mecánica invasiva (`ventilacion_invasiva_*h`):** Indicador binario que señala si el paciente recibió ventilación mecánica invasiva durante la ventana de observación. No representa una variable fisiológica directa, sino un proxy de gravedad y de intensidad del soporte clínico, ya que identifica pacientes con insuficiencia respiratoria relevante y mayor complejidad asistencial.

Constantes vitales

- **Presión arterial media — PAM (`map_min`):** Representa la fuerza motriz de perfusión orgánica. En situaciones de shock distributivo o hipovolémico, un descenso sostenido de la PAM por debajo de 65 mmHg sobrepasa la capacidad de autorregulación vascular de órganos críticos (cerebro, riñones y corazón), provocando isquemia tisular. Su monitorización e intervención inmediata con noradrenalina es crucial para asegurar la supervivencia celular ([Evans et al., 2021](#); [Vincent and De Backer, 2013](#); [Grupo de Trabajo Sepsis HUBU, 2025](#)).
- **Frecuencia cardíaca media (`hr_media`):** Número de latidos por minuto. La taquicardia es uno de los primeros mecanismos compensatorios ante la hipovolemia, la hipotensión o la respuesta inflamatoria sistémica, ya que el organismo intenta mantener el gasto cardíaco aumentando la frecuencia cuando el volumen sistólico se ve comprometido. Una frecuencia elevada y sostenida acompaña por tanto a los estados de inestabilidad hemodinámica que pueden requerir soporte vasopresor ([Vincent and De Backer, 2013](#); [Mesquida et al., 2011](#)).
- **Frecuencia respiratoria máxima (`rr_max`):** Número de respiraciones por minuto. La taquipnea es un signo precoz e inespecífico de deterioro: aparece como respuesta a la hipoxemia, a la acidosis

metabólica (mecanismo de compensación respiratoria) o al distrés, y forma parte de los criterios clásicos de respuesta inflamatoria sistémica. Su elevación señala aumento del trabajo respiratorio y gravedad clínica (Singer et al., 2016).

- **Temperatura mínima (temp_min):** Temperatura corporal. Tanto la fiebre como, de forma especialmente relevante, la hipotermia son marcadores de gravedad en el paciente crítico. La hipotermia en el contexto séptico refleja una respuesta desregulada del huésped y disfunción de la termorregulación propia del shock avanzado, y se asocia a peor pronóstico; por ello el valor mínimo de la ventana resulta particularmente informativo (Singer et al., 2016; Vincent and De Backer, 2013).
- **Saturación periférica de oxígeno — SpO₂ (spo2_min):** Estima de forma no invasiva, mediante pulsioximetría, el porcentaje de hemoglobina saturada de oxígeno. Su descenso indica hipoxemia y deterioro del intercambio gaseoso. Conviene un matiz que se discute en la memoria: una SpO₂ aparentemente elevada puede coexistir con mayor gravedad si el paciente recibe oxigenoterapia intensiva o ventilación mecánica, ya que en ese caso la cifra observada depende de la FiO₂ y del soporte aplicado, no solo del estado pulmonar subyacente (Evans et al., 2021; Vincent and De Backer, 2013).

Gasometría y función respiratoria

- **Relación PaO₂/FiO₂ — índice de Kirby (pf_min):** Evalúa la integridad del intercambio gaseoso en la membrana alveolocapilar. En pacientes sépticos, la cascada inflamatoria daña la microcirculación pulmonar, provocando edema alveolar y distrés respiratorio (SDRA). La caída de este índice por debajo de 300 mmHg refleja un fallo respiratorio agudo que asocia un sobreesfuerzo cardíaco que desestabiliza la hemodinámica (Singer et al., 2016; Grupo de Trabajo Sepsis HUBU, 2025).
- **Presión arterial de oxígeno — PaO₂ (pao2_min):** Mide la presión parcial de oxígeno disuelto en sangre arterial y refleja directamente la eficacia de la oxigenación. Su descenso (hipoxemia) es expresión de fallo en el intercambio gaseoso pulmonar y, mantenido, agrava la hipoxia tisular. Constituye además el numerador del índice de Kirby, por lo que su interpretación va ligada a la FiO₂ administrada (Vincent and De Backer, 2013).

- **Fracción inspirada de oxígeno — FiO_2 (`fio2_max`):** Proporción de oxígeno en el aire inspirado, desde 0,21 (aire ambiente) hasta 1,0. Refleja la intensidad del soporte de oxigenoterapia: una FiO_2 alta indica que se precisa un aporte elevado para mantener una oxigenación aceptable, lo que en sí mismo señala gravedad respiratoria. Es el denominador del índice de Kirby, de modo que una misma PaO_2 con FiO_2 creciente implica peor función pulmonar ([Singer et al., 2016](#)).
- **Presión arterial de CO_2 — PaCO_2 (`paco2_max`):** Mide la presión parcial de dióxido de carbono en sangre arterial y depende fundamentalmente de la ventilación alveolar. Sus alteraciones reflejan trastornos de la ventilación y participan en el equilibrio ácido-base: su elevación produce acidosis respiratoria y su descenso, alcalosis. En el paciente crítico, su valor contribuye a caracterizar el estado respiratorio y metabólico global ([Vincent and De Backer, 2013](#)).
- **pH arterial mínimo (`ph_min`):** Mide el grado de acidez de la sangre. La acidemia (pH bajo), habitualmente de origen metabólico por acúmulo de lactato en situaciones de hipoperfusión, tiene consecuencias hemodinámicas directas: deprime la contractilidad miocárdica y reduce la respuesta vascular a las catecolaminas endógenas y administradas. Un pH mínimo bajo es, por tanto, un marcador de gravedad y de potencial refractariedad al tratamiento ([Vincent and De Backer, 2013](#); [Grupo de Trabajo Sepsis HUBU, 2025](#)).
- **Bicarbonato sérico mínimo (`bicarbonato_min`):** Principal sistema tampón del equilibrio ácido-base. Su descenso refleja acidosis metabólica, que en el paciente crítico se debe con frecuencia al consumo de bicarbonato para tamponar el ácido láctico generado por la hipoperfusión y la hipoxia tisular. Un bicarbonato bajo señala así la magnitud del trastorno metabólico subyacente y se asocia a estados que requieren soporte hemodinámico ([Vincent and De Backer, 2013](#); [Grupo de Trabajo Sepsis HUBU, 2025](#)).

Analítica de laboratorio

- **Lactato máximo (`lactato_max`):** El lactato es el subproducto metabólico derivado de la glucólisis anaerobia. Cuando existe hipoperfusión sistémica e hipoxia celular, la célula desvía su metabolismo fuera de la cadena respiratoria mitocondrial. Un lactato elevado ($> 2,0 \text{ mmol/L}$) es el indicador analítico más sensible de deuda de oxígeno tisular y

disfunción microcirculatoria ([Singer et al., 2016](#); [Evans et al., 2021](#); [Grupo de Trabajo Sepsis HUBU, 2025](#)).

- **Creatinina máxima (creatinina_max):** La creatinina es el metabolito muscular depurado por filtración renal. En estados de inestabilidad hemodinámica, el riñón sufre precozmente por la vasoconstricción compensatoria que prioriza el flujo hacia cerebro y corazón. Su incremento es la manifestación analítica del fracaso renal agudo inducido por hipoperfusión ([Singer et al., 2016](#); [Grupo de Trabajo Sepsis HUBU, 2025](#)).
- **Recuento de plaquetas mínimo (plaquetas_min):** La trombocitopenia en el paciente crítico refleja un estado procoagulante destructivo. La disfunción endotelial masiva activa de forma anómala la cascada de coagulación, consumiendo plaquetas en la microvasculatura (coagulación intravascular diseminada, CID), lo que perpetúa la hipoxia microvascular y el fallo orgánico múltiple ([Singer et al., 2016](#); [Grupo de Trabajo Sepsis HUBU, 2025](#)).
- **Bilirrubina máxima (bilirrubina_max):** Producto de la degradación de la hemoglobina, depurado por el hígado. Su elevación traduce disfunción hepática y colestasis, frecuente en el contexto de hipoperfusión y sepsis. Es uno de los seis componentes de la escala SOFA, donde cuantifica el grado de fallo hepático, y por tanto un marcador reconocido de disfunción orgánica ([Singer et al., 2016](#)).
- **Tiempo de protrombina máximo (tp_max):** Mide el tiempo de coagulación por la vía extrínseca y refleja la síntesis hepática de factores de coagulación. Su prolongación indica alteración de la coagulación, asociada tanto a disfunción hepática como a la coagulopatía de consumo característica del paciente crítico y la sepsis grave ([Singer et al., 2016](#); [Vincent and De Backer, 2013](#)).
- **Transaminasa GPT/ALT máxima (gpt_max):** Enzima de localización predominantemente hepática; su elevación es un marcador relativamente específico de daño hepatocelular. En el paciente crítico puede reflejar hipoperfusión hepática (hígado de shock o hepatitis isquémica) secundaria al bajo gasto y a la redistribución del flujo sanguíneo ([Vincent and De Backer, 2013](#)).
- **Transaminasa GOT/AST máxima (got_max):** Enzima presente en hígado, músculo y otros tejidos. Su elevación indica daño hepatocelular y, de forma más inespecífica, sufrimiento tisular por hipoperfusión e

hipoxia. Junto con la GPT contribuye a valorar la afectación hepática en el contexto de inestabilidad hemodinámica ([Vincent and De Backer, 2013](#)).

- **Leucocitos máximo (`leucocitos_max`):** Recuento de glóbulos blancos. Tanto la leucocitosis como la leucopenia forman parte de los criterios clásicos de respuesta inflamatoria sistémica y traducen la activación (o el agotamiento) de la respuesta inmunitaria frente a la infección. Su alteración acompaña al cuadro séptico que puede evolucionar a shock distributivo ([Singer et al., 2016](#)).
- **Hemoglobina mínima (`hemoglobina_min`):** Proteína transportadora de oxígeno en los hematíes; determina la capacidad de transporte de oxígeno de la sangre. La anemia reduce el aporte de oxígeno a los tejidos y agrava la deuda tisular en estados de bajo gasto, aunque en el paciente crítico el umbral transfusional es restrictivo, ya que mantener cifras más altas no mejora los resultados ([Vincent and De Backer, 2013](#); [Hébert et al., 1999](#)).
- **Glucemia mínima (`glucemia_min`):** Concentración de glucosa en sangre. La disregulación glucémica es muy frecuente en el paciente crítico: la respuesta de estrés provoca hiperglucemia, mientras que la hipoglucemia, espontánea o inducida por el tratamiento insulínico, se asocia de forma independiente a un aumento de la mortalidad. Por ello tanto los valores extremos altos como bajos son informativos del estado metabólico y de la gravedad ([NICE-SUGAR Study Investigators, 2009](#)).

Estado neurológico

- **Escala de coma de Glasgow — GCS (`gcs_min`):** Cuantifica el nivel de consciencia mediante la valoración de la respuesta ocular, verbal y motora, con una puntuación de 3 a 15. Su descenso refleja deterioro neurológico, que en el paciente crítico acompaña a la hipoperfusión cerebral, a la encefalopatía séptica y a la gravedad sistémica. Es el componente neurológico de la escala SOFA ([Singer et al., 2016](#)).

Función renal y balance hídrico

- **Diuresis (`diuresis_volumen_6h` y `diuresis_ml_kg_6h`):** Cuantifican el volumen de orina producido durante la ventana de observación,

en términos absolutos y normalizado por peso corporal (mL/kg). La oliguria es uno de los signos más precoces de hipoperfusión renal y bajo gasto cardíaco: ante la caída de la perfusión, el riñón reduce la diuresis como respuesta a la vasoconstricción compensatoria y a la activación neurohormonal. Una diuresis baja anticipa por tanto el deterioro hemodinámico y la eventual necesidad de noradrenalina. La variable `diuresis_ml_kg_6h` se obtiene dividiendo el volumen acumulado en la ventana por `peso_kg` (Vincent and De Backer, 2013; Mesquida et al., 2011).

Variables incluidas en los conjuntos eICU-CRD

Los conjuntos eICU contienen exclusivamente las variables retenidas por los modelos evaluados externamente tras la selección de características en MIMIC-IV: entre 12 y 17 columnas según la ventana temporal (tabla F.1). En todos los casos se incluyen los identificadores (`subject_id`, `stay_id`), las variables demográficas básicas (`anchor_age`, `gender`, `peso_kg`, `contador_estancia_uci`), la variable objetivo, y el subconjunto de predictores seleccionados, que son en todos los casos un subconjunto de los disponibles en MIMIC-IV.

Variable objetivo

La variable objetivo binaria (`etiqueta_norad_*`) toma el valor 1 cuando el paciente recibió su primera dosis de noradrenalina dentro del horizonte de predicción definido para esa ventana, y 0 en caso contrario. La tabla F.3 muestra la distribución en los seis conjuntos.

Tabla F.3: distribución de la variable objetivo en los seis conjuntos definitivos.

Conjunto	Total	Positivos	Negativos	% positivos
MIMIC-IV 3 h	1667	172	1495	10,3 %
MIMIC-IV 6 h	3282	338	2944	10,3 %
MIMIC-IV 12 h	4088	456	3632	11,2 %
eICU-CRD 3 h	789	114	675	14,4 %
eICU-CRD 6 h	1396	166	1230	11,9 %
eICU-CRD 12 h	2030	199	1831	9,8 %

La proporción de positivos oscila entre el 9,8 % y el 14,4 %, lo que indica un desbalanceo moderado consistente con la prevalencia real del evento

en UCI (Firzli et al., 2023). El conjunto eICU de 3 h presenta la mayor proporción de positivos (14,4 %). La columna `horas_hasta_norad` registra el tiempo transcurrido entre el inicio de la ventana de observación y la primera administración de noradrenalina; esta columna es `NA` para todos los pacientes con etiqueta 0, ya que el evento no tuvo lugar.

Valores perdidos y estrategia de no-imputación

Con el fin de preservar la fidelidad fisiológica de los datos reales, no se aplicaron técnicas de imputación de valores faltantes. En su lugar se adoptó un enfoque de caso completo, conservando únicamente las estancias con todas sus variables clínicas y demográficas pobladas. La columna `horas_hasta_norad` constituye una excepción por definición: toma el valor `NA` en todos los casos negativos, ya que en ellos el evento no llegó a producirse. Este mismo criterio se aplicó a los conjuntos de validación de eICU-CRD.

Análisis exploratorio y comparación de las cohortes

Con el fin de caracterizar la cohorte de desarrollo (MIMIC-IV) y compararla con la cohorte de validación externa (eICU-CRD), se realizó un análisis exploratorio de datos. La tabla F.4 resume las características basales de ambas poblaciones en las tres ventanas temporales, y las figuras F.1–F.5 comparan la distribución de los predictores entre bases de datos.

La comparación revela que ambas cohortes son demográficamente similares en edad y sexo, con diferencias estadísticamente significativas pero de escasa magnitud clínica. La diferencia más relevante se observa en la gravedad: la cohorte de eICU-CRD presenta de forma sistemática un SOFA máximo superior al de MIMIC-IV en las tres ventanas (mediana 7 frente a 4–5; $p < 0,001$), así como una mayor proporción de primeras estancias en UCI. Esta mayor gravedad basal de la cohorte externa es coherente con su mayor prevalencia del evento en las ventanas corta y media, y constituye un ejemplo de desplazamiento de distribución (*dataset shift*) entre centros que conviene tener presente al interpretar la transferencia de los modelos. El tiempo hasta el inicio de noradrenalina, en cambio, fue comparable entre cohortes dentro de cada ventana, lo que sugiere una dinámica temporal del evento similar en ambas bases.

Conviene precisar que las cohortes se definen a nivel de estancia en UCI (`stay_id`). En la cohorte de desarrollo, el número de estancias es muy próximo al de pacientes únicos en las tres ventanas: 1 667 estancias de 1 645 pacientes en la corta (1,01 estancias por paciente), 3 282 de 3 198 en la media

Tabla F.4: características basales de las cohortes MIMIC-IV (desarrollo) y eICU-CRD (validación externa). Variables continuas: mediana [RIC]; categóricas: n (%). Contraste mediante prueba U de Mann–Whitney para continuas y χ^2 para categóricas.

Variable	MIMIC-IV (desarrollo)	eICU-CRD (validación)	<i>p</i>
<i>Ventana corta (3–12 h)</i>			
N	1 667	789	—
Edad (años)	60,0 [48,0–70,0]	63,0 [50,0–74,0]	0,002
Sexo masculino	995 (59,7 %)	449 (56,9 %)	0,206
Peso (kg)	80,2 [67,3–97,0]	82,9 [69,2–99,7]	0,019
SOFA máx.	4,0 [2,0–6,0]	7,0 [5,0–9,0]	< 0,001
Primera estancia en UCI	1 334 (80,0 %)	682 (86,4 %)	< 0,001
Noradrenalina (positivos)	172 (10,3 %)	114 (14,4 %)	0,004
Horas hasta noradrenalina*	6,0 [4,4–8,4]	5,9 [4,2–8,1]	0,473
<i>Ventana media (6–24 h)</i>			
N	3 282	1 396	—
Edad (años)	62,0 [50,0–73,0]	61,0 [49,0–72,0]	0,248
Sexo masculino	1 971 (60,1 %)	794 (56,9 %)	0,047
Peso (kg)	80,3 [67,3–96,0]	82,2 [68,5–100,0]	0,003
SOFA máx.	4,0 [2,0–6,0]	7,0 [5,0–9,0]	< 0,001
Primera estancia en UCI	2 575 (78,5 %)	1 193 (85,5 %)	< 0,001
Noradrenalina (positivos)	338 (10,3 %)	166 (11,9 %)	0,120
Horas hasta noradrenalina*	10,9 [8,0–16,2]	11,2 [8,0–15,5]	0,659
<i>Ventana larga (12–48 h)</i>			
N	4 088	2 030	—
Edad (años)	62,0 [50,0–73,0]	62,0 [51,0–73,0]	0,989
Sexo masculino	2 444 (59,8 %)	1 136 (56,0 %)	0,005
Peso (kg)	80,5 [67,3–97,2]	83,3 [68,1–100,0]	< 0,001
SOFA máx.	5,0 [3,0–7,0]	7,0 [6,0–9,0]	< 0,001
Primera estancia en UCI	3 305 (80,8 %)	1 721 (84,8 %)	< 0,001
Noradrenalina (positivos)	456 (11,2 %)	199 (9,8 %)	0,117
Horas hasta noradrenalina*	22,3 [16,2–31,3]	19,2 [14,6–27,7]	0,003

*Calculada únicamente sobre los casos positivos.

(1,03) y 4088 de 3918 en la larga (1,04). Esta escasa presencia de pacientes con múltiples ingresos indica un bajo riesgo de dependencia entre estancias. Aun así, la validación cruzada se estratificó con agrupamiento por paciente para garantizar que ninguna persona apareciera simultáneamente en los conjuntos de entrenamiento y prueba.

El análisis de la distribución de los predictores confirma esta lectura: las variables fisiológicas presentan rangos y medianas ampliamente solapados entre MIMIC-IV y eICU-CRD, lo que respalda la viabilidad de aplicar sobre la cohorte externa un modelo entrenado en MIMIC-IV. La diferencia más marcada vuelve a recaer en el SOFA máximo, desplazado hacia valores superiores en eICU-CRD, en consonancia con la mayor gravedad de esa cohorte. Las figuras F.1 y F.2 muestran esta comparación para los predictores de los modelos evaluados externamente (XGBoost en las ventanas media y larga), mientras que las figuras F.3, F.4 y F.5 recogen la comparación para los conjuntos de variables de los modelos comparativos (CatBoost en las ventanas media y larga, y la ventana corta).




Figura F.1: distribución comparada de los predictores del modelo final de la ventana media (6–24 h; XGBoost recalibrado) entre MIMIC-IV y eICU-CRD.




Figura F.2: distribución comparada de los predictores del modelo final de la ventana larga (12–48 h; XGBoost) entre MIMIC-IV y eICU-CRD.




Figura F.3: distribución comparada de los predictores del modelo CatBoost de la ventana media (6–24 h) entre MIMIC-IV y eICU-CRD.




Figura F.4: distribución comparada de los predictores del modelo CatBoost de la ventana larga (12–48 h) entre MIMIC-IV y eICU-CRD.




Figura F.5: distribución comparada de los predictores de la ventana corta (3–12 h; CatBoost) entre MIMIC-IV y eICU-CRD.

Estudio experimental

G.1. Registro de experimentos

Visión general del flujo experimental

El desarrollo de este trabajo no siguió una trayectoria lineal, sino un proceso iterativo de prueba, error y refinamiento progresivo. Antes de consolidar el flujo definitivo, se llevó a cabo una fase exploratoria preliminar cuyo objetivo no era obtener los modelos finales, sino familiarizarse con las bases de datos, ensayar enfoques de preprocesamiento y descartar estrategias que no resultaban adecuadas. Estas pruebas iniciales, conservadas en el repositorio con fines de trazabilidad, resultaron decisivas para orientar las decisiones metodológicas posteriores.

En una primera etapa se construyeron cohortes generales de UCI y se entrenaron modelos de referencia con las seis familias de algoritmos consideradas. Sobre estas cohortes se ensayó la imputación de valores ausentes mediante el algoritmo de los k vecinos más cercanos (KNN), con distintos valores de k (3 y 5). Sin embargo, este enfoque se descartó por dos motivos. En primer lugar, varias variables clínicas presentaban un porcentaje de valores ausentes muy elevado, de modo que su imputación habría supuesto reconstruir artificialmente una fracción muy considerable de los datos, comprometiendo la fidelidad fisiológica de la cohorte. En segundo lugar, imputar de forma rigurosa sobre datos agregados por ventana añadía una complejidad metodológica notable, difícil de justificar y de controlar frente a sus posibles beneficios. Por ello se adoptó, de forma mantenida en todo el trabajo posterior, un enfoque de caso completo que conserva únicamente las estancias con todas sus variables pobladas.

Una segunda observación relevante de esta fase preliminar fue la necesidad de imponer un criterio temporal mínimo de inclusión. Las estancias debían superar una duración mínima —24 horas en las ventanas corta y media, y 48 horas en la ventana larga— con el fin de evitar la entrada de ingresos muy breves, como postoperatorios programados o derivaciones rápidas, que introducían falsos negativos y ruido en el etiquetado. Este criterio, junto con la incorporación progresiva de variables como la diuresis, sentó las bases de la definición de cohortes y ventanas temporales empleada en el flujo definitivo.

A partir de estas conclusiones se consolidó un flujo experimental estructurado de forma modular, en el que cada etapa se implementó de manera independiente para favorecer la reproducibilidad y la trazabilidad: extracción de cohortes mediante consultas SQL sobre MIMIC-IV y eICU-CRD, preprocesamiento y tratamiento de valores extremos, análisis exploratorio, definición de ventanas temporales, selección de variables en varias fases, entrenamiento de modelos, calibración de probabilidades, análisis de interpretabilidad, validación externa y, finalmente, integración de los modelos seleccionados en el prototipo de *dashboard*. Las secciones siguientes detallan el registro de experimentos realizados, la justificación de las configuraciones empleadas y los resultados obtenidos en cada fase.

Evolución del trabajo experimental por fases

Una vez definida la cohorte de trabajo sobre MIMIC-IV, el proceso de selección de variables y de ajuste de los modelos se organizó en tres fases sucesivas, cada una de las cuales refinó las conclusiones de la anterior. Estas fases se conservan en el repositorio como versiones diferenciadas (**Pruebas_v4**, **Pruebas_v4_2** y **Pruebas_v4_3**) y documentan tanto los análisis que se incorporaron al flujo final como aquellos que se exploraron y posteriormente se descartaron.

Fase 1: caracterización inicial y reducción de redundancia

La primera fase tuvo como objetivo caracterizar el conjunto de predictores candidatos y reducir su redundancia. Se establecieron los modelos de referencia (*baseline*) sobre los seis algoritmos y se aplicó el tratamiento de valores extremos mediante winsorización al percentil 2–98 sobre las variables clínicas continuas. A continuación se realizó un análisis de correlación de Spearman entre las variables candidatas, filtrando previamente a una única estancia por paciente para evitar dependencias entre observaciones.

De forma exploratoria, también se calcularon factores de inflación de la varianza (VIF) para valorar posibles problemas de multicolinealidad multivariante entre predictores. No obstante, este análisis no se incorporó como criterio formal de eliminación, ya que añadía complejidad interpretativa y resultaba menos alineado con el objetivo final de seleccionar variables clínicamente defendibles y poco redundantes. Por ello, la reducción definitiva se apoyó en la correlación de Spearman, el agrupamiento jerárquico y el criterio clínico dentro de esta fase.

En esta fase se abordó también un problema específico de representación: cada variable clínica continua disponía de tres estadísticos por ventana (mínimo, media y máximo), muy correlacionados entre sí. La elección del estadístico a conservar se guio en primer lugar por criterio clínico, atendiendo a qué resumen resultaba fisiológicamente más informativo para cada parámetro (por ejemplo, el valor mínimo para la presión arterial media o el máximo para el lactato). Únicamente cuando esta elección no resultaba evidente, como por ejemplo, al dudar entre el mínimo y el máximo de una misma variable, se recurrió a un análisis de desempate, evaluando para cada estadístico su capacidad discriminativa univariante (AUC-ROC) y el tamaño del efecto entre pacientes positivos y negativos mediante la d de Cohen, además de comprobar que el sentido observado en las medianas de ambos grupos fuera clínicamente coherente. Este procedimiento permitió retener, para cada variable, un único estadístico representativo en lugar de arrastrar los tres.

Fase 2: significancia, importancia y eliminación de variables

La segunda fase profundizó en la selección combinando varios criterios estadísticos. Se evaluó la significancia univariante de cada variable frente a la variable objetivo y, posteriormente, su comportamiento en un contexto multivariante mediante regresión logística ajustada, aplicando en ambos casos la corrección de Benjamini–Hochberg para el control de comparaciones múltiples cuando procedía. El contraste entre ambos análisis permitió distinguir variables clínicamente relevantes cuya señal quedaba absorbida por otros predictores, variables redundantes y variables cuyo comportamiento ajustado resultaba difícil de justificar desde el punto de vista fisiopatológico.

El análisis multivariante no se utilizó como criterio único de selección, sino como una auditoría de coherencia. En particular, se examinó la *odds ratio* (OR) ajustada de cada predictor para comprobar si la dirección de asociación era compatible con la interpretación clínica esperada. Por tanto, una OR superior a 1 indica una asociación positiva con la necesidad de

noradrenalina, mientras que una OR inferior a 1 indica una asociación inversa, siempre interpretada según el sentido clínico de la variable. Así, una OR inferior a 1 puede ser coherente en variables donde valores más bajos implican peor situación clínica, como la presión arterial media o el bicarbonato.

Un ejemplo de variable clínicamente relevante pero con señal ajustada débil fue el lactato (`lactato_max`). Pese a ser uno de los marcadores de hipoperfusión tisular mejor establecidos, su asociación con la variable objetivo se diluía en algunos análisis multivariantes, probablemente por solapamiento con otros indicadores de gravedad, perfusión y disfunción orgánica.

Un segundo caso, de naturaleza distinta, resultó lo bastante llamativo como para motivar un experimento específico: el de la transaminasa `gpt_max`. En el modelo de regresión logística multivariante, esta variable resultaba estadísticamente significativa pero con un OR inferior a uno, es decir, una asociación ajustada aparentemente protectora según la cual un valor más alto de la enzima se asociaba a un menor riesgo de requerir noradrenalina. Esta dirección carecía de sentido fisiológico dentro del objetivo del trabajo. Su origen más probable estaba en la composición de la muestra, la redundancia con otras variables o un efecto de supresión estadística. El modelo, por tanto, no estaba aprendiendo un mecanismo causal clínicamente defendible, sino un patrón ajustado que no convenía incorporar sin revisión.

Para cuantificar su contribución real se diseñó un experimento que comparó, mediante validación cruzada, un modelo de *Random Forest* entrenado con la variable frente al mismo modelo sin ella. La eliminación de `gpt_max` apenas modificó la discriminación (AUC-ROC de 0,707 con la variable frente a 0,701 sin ella), lo que confirmó que su aportación predictiva era marginal y prescindible y respaldó su exclusión. En conjunto, estos hallazgos pusieron de manifiesto que el comportamiento estadístico de una variable, ya sea por su capacidad discriminativa aislada o por su asociación en un modelo ajustado, no basta por sí solo como criterio de selección, y motivaron la verificación de la coherencia clínica de cada predictor descrita en la fase siguiente.

Fase 3: consolidación y verificación de la dirección de asociación

La tercera fase consolidó la selección de variables y la sometió a una verificación final. Se construyó un criterio de significancia propio que combinaba los resultados de las fases anteriores, definiendo para cada familia de modelo el subconjunto de variables cuya importancia por permutación excluía el cero. Sobre ese subconjunto se reentrenaron los modelos de referencia, en

dos versiones sucesivas, hasta fijar la configuración definitiva de predictores por ventana.

Como comprobación final, se revisó la dirección de asociación de las variables retenidas mediante regresión logística multivariante ajustada. Esta revisión se basó en la OR ajustada de cada predictor y en las medianas observadas en pacientes positivos y negativos. El objetivo no era inferir causalidad, sino comprobar que el patrón estadístico observado fuera compatible con la fisiopatología esperada. Así, se consideró coherente que variables como `sofa_max`, `lactato_max` o `fio2_max` tendieran a asociarse con mayor riesgo cuando aumentaban, mientras que variables como `map_min`, `pf_min`, `bicarbonato_min` o `spo2_min` podían mostrar una asociación inversa, al representar situaciones en las que valores más bajos indican mayor deterioro clínico.

Esta verificación evitó incorporar a los modelos finales variables cuya relación ajustada con el evento, aun siendo estadísticamente significativa, resultara contraria a la lógica clínica o difícil de defender. Por tanto, la OR se utilizó como herramienta de auditoría de la dirección de asociación, complementaria a la importancia por permutación, al análisis univariante y a la revisión clínica de los diagramas SHAP.

Experimentos de recalibración probabilística

Los experimentos de recalibración se aplicaron de forma selectiva sobre modelos candidatos o de interés comparativo: CatBoost y XGBoost en la ventana corta (3–12 h), XGBoost y CatBoost en la ventana media (6–24 h), y XGBoost en la ventana larga (12–48 h). No se aplicó una recalibración sistemática a todos los algoritmos evaluados inicialmente ni a todos los modelos preseleccionados, sino solo a aquellos sobre los que se consideró necesario comprobar si una transformación probabilística mejoraba la calibración sin deteriorar el rendimiento global.

En estos experimentos se compararon las probabilidades originales de cada modelo frente a versiones recalibradas mediante escalado de Platt y regresión isotónica, utilizando predicciones *out-of-fold* y manteniendo la separación entre entrenamiento y prueba en cada partición. En el experimento final de XGBoost en la ventana media se incorporó además una variante de Platt regularizado. La comparación se basó en curvas de calibración, ECE, Brier score y BSS, evitando seleccionar un calibrador únicamente por una mejora aislada del ECE.

Los resultados mostraron que la recalibración no aportaba una mejora consistente en todos los modelos evaluados. En varios casos, las versiones recalibradas reducían de forma marginal el ECE, comprimían excesivamente las probabilidades o no mantenían un equilibrio adecuado con el BSS. Por ello, la recalibración no se incorporó como paso automático del flujo experimental.

Finalmente, solo se conservó una versión recalibrada para XGBoost en la ventana media (6–24 h), mediante escalado de Platt regularizado. Este modelo se guardó de forma independiente y fue el utilizado posteriormente como modelo recalibrado en la validación externa y en el prototipo de *dashboard* para la ventana media.

Identificación del evento en cada base de datos

La variable objetivo de este trabajo es el inicio de soporte vasopresor con noradrenalina. Dado que MIMIC-IV y eICU-CRD presentan estructuras y nomenclaturas distintas, la identificación del evento requirió una definición específica para cada base, buscando en ambos casos el primer instante de administración de noradrenalina en cada estancia.

En **MIMIC-IV**, las administraciones de fármacos en la UCI se registran en la tabla `inputevents`, donde cada medicamento se identifica mediante un código numérico (`itemid`). La noradrenalina corresponde al código 221906. El evento se definió como el primer registro de administración de este fármaco en cada estancia (`stay_id`), exigiendo además que la cantidad administrada fuera positiva (`amount > 0`) para descartar registros nulos o anotaciones sin perfusión efectiva. El instante de inicio se obtuvo como el mínimo de los tiempos de comienzo (`starttime`) de dichos registros.

En **eICU-CRD**, las perfusiones se registran en la tabla `infusionDrug`, en la que el fármaco se identifica por su nombre (`drugname`) en lugar de por un código normalizado. Para localizar la noradrenalina se seleccionaron los registros cuyo nombre contenía el término `norepinephrine` o su nombre comercial `levophed`. Adicionalmente, se excluyeron los registros cuyo nombre contenía el término `volume`, con el fin de evitar falsos positivos asociados a anotaciones de volumen o de soluciones de reposición que no se corresponden con una perfusión vasopresora activa. El instante de inicio se obtuvo como el mínimo de los desplazamientos temporales de perfusión (`infusionoffset`) por estancia (`patientunitstayid`).

Esta doble definición, adaptada a las particularidades de cada fuente, permitió construir una variable objetivo homogénea en su significado clínico,

el primer inicio de noradrenalina dentro del horizonte de predicción, y, por ende, comparable entre la cohorte de desarrollo y la de validación externa.

G.2. Parametrización

Justificación de la configuración de las técnicas utilizadas

La parametrización del flujo experimental se diseñó con un objetivo doble: por un lado, permitir una comparación homogénea entre familias de modelos; por otro, evitar configuraciones excesivamente complejas que pudieran favorecer el sobreajuste en cohortes de tamaño limitado y con desbalanceo de clases. Por este motivo, las decisiones de configuración se mantuvieron constantes entre ventanas siempre que fue posible, adaptándose únicamente a las necesidades específicas de cada algoritmo.

Modelos evaluados

Se evaluaron seis algoritmos para datos tabulares: regresión logística, Naive Bayes gaussiano, Random Forest, XGBoost, LightGBM y CatBoost. Esta selección permitió comparar modelos lineales y probabilísticos simples con métodos de ensamblado basados en árboles, incluyendo tanto *bagging* como *gradient boosting*.

La regresión logística se empleó como referencia lineal interpretable. Naive Bayes se incluyó como clasificador probabilístico basal. Random Forest permitió evaluar un método de ensamblado menos sensible a relaciones lineales estrictas. XGBoost, LightGBM y CatBoost se incorporaron por su buen rendimiento habitual en problemas tabulares, su capacidad para capturar relaciones no lineales y su compatibilidad con herramientas de interpretabilidad post-hoc.

Escalado de variables

El escalado se aplicó únicamente a los modelos sensibles a la escala de entrada. En concreto, regresión logística y Naive Bayes se integraron en un *pipeline* con **RobustScaler**. Este escalador se eligió por su menor sensibilidad a valores extremos, al basarse en estadísticos robustos de posición y dispersión. Los modelos basados en árboles no requirieron escalado, ya que sus particiones dependen del orden relativo de los valores y no de su escala absoluta.

El escalado se ajustó exclusivamente sobre el conjunto de entrenamiento de cada partición de validación cruzada y se aplicó después al conjunto de prueba correspondiente. De este modo se evitó que la información del conjunto de prueba influyera en la transformación de las variables.

Ponderación de clases

Dado que el inicio de noradrenalina era un evento minoritario, se aplicaron estrategias de ponderación de clases en los modelos que lo permitían de forma directa. En regresión logística y LightGBM se utilizó `class_weight='balanced'`, de forma que el peso de cada clase se ajustara inversamente a su frecuencia en el conjunto de entrenamiento. En Random Forest se empleó `class_weight='balanced_subsample'`, calculando la ponderación en cada submuestra utilizada para construir los árboles.

En XGBoost se ajustó el parámetro `scale_pos_weight` a partir de la relación entre negativos y positivos del conjunto de entrenamiento de cada partición. En Naive Bayes y CatBoost no se aplicó un parámetro específico de balanceo en el flujo principal.

Tabla G.1: configuración general de preprocesamiento y balanceo por familia de modelo.

Modelo	Escalado	Balanceo de clases	Comentario
Regresión logística	RobustScaler	<code>class_weight='balanced'</code>	Modelo lineal de referencia
Naive Bayes	RobustScaler	No aplicado	Clasificador probabilístico basal
Random Forest	No	<code>class_weight='balanced_subsample'</code>	Ensamblado por <i>bagging</i>
XGBoost	No	<code>scale_pos_weight</code>	Ajustado según la relación entre clases
LightGBM	No	<code>class_weight='balanced'</code>	<i>Gradient boosting</i> eficiente
CatBoost	No	No aplicado	<i>Gradient boosting</i> robusto para datos tabulares

Búsqueda de hiperparámetros

La optimización de hiperparámetros se realizó dentro del bucle interno de la validación cruzada anidada, mediante `GridSearchCV`, utilizando AUC-ROC como métrica de optimización. El objetivo de esta búsqueda fue ajustar la complejidad de cada modelo sin utilizar información del conjunto de prueba externo.

Los espacios de búsqueda se definieron de forma específica para cada familia de modelos. En regresión logística se exploró la intensidad de regularización. En Random Forest se ajustaron parámetros relacionados con el número de árboles, la profundidad máxima, el tamaño mínimo de hoja y la selección de variables por división. En los modelos de *gradient boosting* se evaluaron combinaciones de número de estimadores, profundidad, tasa

de aprendizaje, regularización y muestreo. En Naive Bayes se exploró el parámetro `var_smoothing`.

La configuración final de cada modelo se obtuvo a partir de los hiperparámetros seleccionados en los folds externos. Cuando existían discrepancias entre folds, se tomó como configuración final el valor más frecuente. Posteriormente, el modelo definitivo se reentrenó sobre el conjunto completo de desarrollo de MIMIC-IV antes de su aplicación a la validación externa o su serialización para el *dashboard*.

Validación cruzada anidada

La evaluación interna se realizó mediante validación cruzada anidada 5×3 . El bucle externo constó de cinco particiones y se utilizó para estimar el rendimiento de generalización del modelo. El bucle interno constó de tres particiones y se utilizó exclusivamente para la selección de hiperparámetros.

Las particiones se construyeron mediante `StratifiedGroupKFold`, manteniendo la proporción de clases y agrupando las estancias por paciente. Esta decisión evitó que estancias pertenecientes a un mismo paciente pudieran aparecer simultáneamente en entrenamiento y prueba, reduciendo así el riesgo de fuga de información.

Predicciones out-of-fold

Además de las métricas medias por fold externo, se generaron predicciones *out-of-fold* para construir curvas ROC, curvas precisión-recall y curvas de calibración. En este esquema, cada estancia recibe una probabilidad predicha por un modelo que no la ha utilizado durante su entrenamiento.

Estas predicciones permitieron obtener una representación gráfica homogénea del comportamiento de cada modelo en la cohorte de desarrollo, facilitando la comparación visual entre algoritmos, ventanas temporales y estrategias de calibración.

Métricas de evaluación

La evaluación combinó métricas de discriminación, rendimiento probabilístico y calibración. La discriminación se evaluó mediante AUC-ROC y AUC-PR. La AUC-ROC mide la capacidad del modelo para ordenar correctamente pacientes positivos y negativos, mientras que la AUC-PR resulta especialmente informativa en problemas desbalanceados, al centrarse en la relación entre precisión y sensibilidad para la clase positiva.

El Brier score cuantifica el error cuadrático medio entre las probabilidades predichas y la etiqueta observada:

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2$$

donde $\hat{p}_i$ es la probabilidad predicha para la estancia i e y_i su etiqueta observada.

El Brier Skill Score (BSS) compara el Brier score del modelo frente al de un modelo nulo que asigna una probabilidad constante igual a la prevalencia del evento:

$$\text{BSS} = 1 - \frac{\text{Brier}_{\text{modelo}}}{\text{Brier}_{\text{nulo}}}$$

Un BSS positivo indica que el modelo mejora la predicción probabilística respecto a esta referencia trivial. Un BSS igual o inferior a cero indica que el modelo no mejora, o incluso empeora, la predicción probabilística frente a asignar siempre la prevalencia basal.

La *LogLoss* se utilizó como métrica complementaria de rendimiento probabilístico, penalizando especialmente los errores cometidos con alta confianza. La calibración se evaluó mediante el Expected Calibration Error (ECE), agrupando las predicciones en diez intervalos y comparando en cada uno de ellos la probabilidad media predicha con la frecuencia observada del evento.

Recalibración de probabilidades

La recalibración probabilística se evaluó como una transformación posterior de las probabilidades generadas por los modelos candidatos, utilizando predicciones *out-of-fold* y manteniendo el mismo esquema de particionado agrupado por paciente. En cada partición, el modelo base se entrenó sobre el conjunto de entrenamiento y los calibradores se ajustaron únicamente con información procedente de dicho conjunto, aplicándose después sobre el conjunto de prueba correspondiente.

Se compararon las probabilidades originales frente a versiones recalibradas mediante escalado de Platt y regresión isotónica. En el experimento final de calibración se incorporó además una variante de Platt regularizado mediante validación cruzada interna, implementada con `LogisticRegressionCV`.

La comparación no se basó únicamente en el ECE, sino también en el Brier score, el BSS, las curvas de calibración y la distribución de probabilidades antes y después de la transformación.

Interpretabilidad mediante SHAP

La interpretabilidad post-hoc se abordó mediante valores SHAP, adaptando el método de cálculo a la familia de cada modelo. En los modelos basados en árboles se empleó `TreeExplainer`; en la regresión logística, `LinearExplainer`; y en Naive Bayes, `KernelExplainer`.

Los valores SHAP se utilizaron como herramienta de auditoría posterior, no como criterio principal de selección de variables. Su objetivo fue comprobar si los modelos basaban sus predicciones en patrones clínicamente razonables y si la dirección de las contribuciones era compatible con la fisiopatología esperada.

En los modelos recalibrados, la interpretación SHAP se calculó sobre el modelo base, mientras que el calibrador se utilizó únicamente para transformar la probabilidad final. Esta separación permitió conservar una explicación asociada al patrón predictivo aprendido por el modelo, evitando atribuir al calibrador una estructura de contribuciones clínicas que no le corresponde.

Organización modular del código

El código se organizó de forma modular para facilitar la trazabilidad del flujo experimental. Las etapas principales se separaron en bloques funcionales: extracción SQL, preprocesamiento, análisis exploratorio, definición de ventanas temporales, selección de variables, entrenamiento, calibración, interpretabilidad, validación externa y desarrollo del *dashboard*.

Esta organización permitió conservar versiones sucesivas del trabajo experimental, documentar decisiones descartadas y mantener una separación clara entre el desarrollo de modelos, la validación externa y la aplicación final de visualización.

G.3. Resultados

Tabla G.2: análisis de desempate entre estadísticos para las variables en las que la elección no resultaba evidente por criterio clínico.

Variable	Estadístico	AUC-ROC	d de Cohen	Dirección (pos vs neg)
Frecuencia cardíaca	hr_media	0,562	+0,228	↑
	hr_min	0,545	+0,160	↑
	hr_max	0,557	+0,209	↑
Temperatura	temp_media	0,514	−0,091	↓
	temp_min	0,526	−0,149	↓
	temp_max	0,503	+0,005	=
Puntuación SOFA	sofa_media	0,586	+0,302	↑
	sofa_min	0,538	+0,108	↑
	sofa_max	0,606	+0,401	↑
Glucemia	glucemia_media	0,518	−0,021	=
	glucemia_min	0,522	−0,030	↓
	glucemia_max	0,515	−0,021	↑

Tabla G.3: variables utilizadas por los modelos finalmente conservados para el prototipo de *dashboard*.

Ventana	Modelo	Variables
Media (6–24 h)	XGBoost recalibrado	pf_min, map_min, diuresis_ml_kg_6h, hr_media, sofa_max, ventilacion_invasiva_6h
Larga (12–48 h)	XGBoost	temp_min, pf_min, spo2_min, bicarbonato_min, map_min, glucemia_min, sofa_max

Anexo de sostenibilización curricular

H.1. Reflexión personal sobre sostenibilidad

La sostenibilidad curricular no puede entenderse únicamente como una cuestión ambiental o de reducción de consumo energético. Siguiendo las directrices de sostenibilidad de la CRUE, también implica reflexionar sobre el impacto social, económico, ético y profesional de las decisiones técnicas tomadas durante el desarrollo de un proyecto. En el caso de este TFG, esta reflexión resulta especialmente relevante porque el trabajo se sitúa en la intersección entre ingeniería, datos clínicos y cuidados intensivos, un contexto en el que cualquier herramienta tecnológica debe diseñarse con prudencia y responsabilidad.

Durante el desarrollo del proyecto he comprendido que un modelo predictivo en salud no puede valorarse solo por sus métricas de rendimiento. Aunque el objetivo técnico era estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes de UCI, el objetivo de fondo era explorar si una herramienta de aprendizaje automático podía aportar información útil, interpretable y clínicamente revisable. Esta distinción es importante: el sistema no pretende sustituir al médico ni automatizar una decisión terapéutica, sino mostrar una estimación de riesgo acompañada de explicaciones mediante SHAP para facilitar una lectura crítica del resultado. Desde el punto de vista de la sostenibilidad social, esta decisión contribuye a evitar una visión de la inteligencia artificial como una caja negra y refuerza el papel del profesional sanitario como responsable final de la interpretación clínica.

El proyecto también me ha permitido desarrollar una competencia clara de contextualización crítica. Trabajar con MIMIC-IV y eICU-CRD ha mostrado que los datos clínicos no son neutros: proceden de hospitales concretos, con formas de registro, poblaciones y protocolos propios. Por ello, se incluyó una validación externa sobre eICU-CRD y se evitó presentar el modelo como una herramienta universal. Esta limitación no es un defecto menor, sino una parte esencial del aprendizaje: cualquier aplicación futura en un hospital concreto, como el Hospital Universitario de Burgos, requeriría validación local, autorización ética y evaluación prospectiva antes de plantear un uso asistencial real.

Desde el punto de vista económico, el trabajo se relaciona con la gestión eficiente de recursos sanitarios críticos. La noradrenalina se utiliza en pacientes con inestabilidad hemodinámica, y anticipar el deterioro podría ayudar, en un futuro validado, a planificar mejor la vigilancia, la disponibilidad de personal, las camas de UCI y los recursos terapéuticos. Sin embargo, he intentado no plantear esta posible utilidad como un ahorro demostrado, sino como una línea potencial que todavía necesitaría validación. Esta cautela forma parte de la sostenibilidad profesional: no sobreprometer resultados es tan importante como desarrollar modelos técnicamente correctos.

En cuanto al impacto ambiental, el proyecto no se basó en redes neuronales profundas ni en entrenamientos masivos, sino en modelos tabulares relativamente eficientes, como XGBoost, CatBoost, Random Forest, regresión logística, Naive Bayes y LightGBM. Aun así, la validación cruzada anidada, la búsqueda de hiperparámetros y el análisis SHAP implicaron un coste computacional no despreciable. Esta experiencia me ha hecho más consciente de que la reproducibilidad y el rigor metodológico deben equilibrarse con un uso razonable de recursos. En este sentido, organizar los experimentos, conservar los resultados intermedios y evitar ejecuciones innecesarias también forma parte de una práctica sostenible de la ingeniería.

Otra competencia transversal desarrollada ha sido la participación en procesos comunitarios. Aunque el sistema no se validó clínicamente, sí se presentó como prototipo a facultativos de Medicina Intensiva del HUBU mediante una encuesta exploratoria. Sus respuestas permitieron valorar la comprensión de la interfaz, la utilidad potencial percibida y la claridad de las explicaciones. Esta interacción me ayudó a entender que el diseño de herramientas sanitarias no puede hacerse únicamente desde el código o desde las métricas: necesita incorporar la perspectiva de quienes conocen el entorno real de uso.

Finalmente, este TFG ha reforzado mi responsabilidad ética como futuro ingeniero de la salud. Se han respetado las restricciones de uso de MIMIC-IV y eICU-CRD, sin redistribuir datos clínicos originales, y se ha mantenido el código en un repositorio público para favorecer la trazabilidad y la revisión. También se ha insistido de forma explícita en que el dashboard es un prototipo académico, no una herramienta clínica validada. Para mí, esta es una de las principales lecciones de sostenibilidad del proyecto: desarrollar tecnología sanitaria útil no consiste solo en conseguir buenos resultados, sino en reconocer sus límites, documentarlos con honestidad y diseñar siempre pensando en la seguridad del paciente, la transparencia y el uso responsable de los recursos.

Apéndice I

Registro de interacciones con sistemas de IA

I.1. Registro de interacciones

NOTA: la herramienta usada siempre ha sido el modelo Sonnet 4.6 de Claude by Anthropic salvo que se indique lo contrario, a continuación se muestran las interacciones más significativas:

N.º	Fecha	Prompt / consulta	Uso posterior
1	Marzo (1.ª q.)	¿Por qué la noradrenalina se llama norepinefrina en EE.UU. y otros países?	Consulta conceptual
2	Marzo (2.ª q.)	Revisa esta expresión CASE WHEN en SQL para transformar temperaturas de MIMIC-IV de Fahrenheit a Celsius cuando aparecen mezcladas.	Revisión de código SQL
3	Marzo (2.ª q.)	Revisa una consulta SQL de eICU que combina vitalPeriodic y vitalAperiodic para obtener la PAM mínima en una ventana 0–X horas.	Revisión de extracción SQL
4	Marzo (2.ª q.)	Comprueba si la lógica de diuresis deja NULL en pacientes sin registros de orina y solo calcula mL/kg cuando hay volumen y peso válidos.	Control de calidad de datos

continúa en la página siguiente

Registro de interacciones con sistemas de IA

N.º	Fecha	Prompt / consulta	Uso posterior
5	Marzo (2. ^a q.)	Revisa que el SOFA se calcule usando únicamente filas cuyo endtime cae dentro de la ventana de observación, sin imputarlo a cero si no hay registro.	Prevención de sesgo en variables
6	Marzo (2. ^a q.)	Qué columnas auxiliares conviene revisar para comprobar que bilirrubina, plaquetas, creatinina, PaO ₂ , FiO ₂ y GCS están realmente medidos antes del filtrado.	Auditoría de completitud
7	Abril (1. ^a q.)	Revisa una función de control previo que comprueba valores perdidos, infinitos y tipos de datos antes de entrenar los modelos.	Preprocesamiento
8	Abril (1. ^a q.)	Ayúdame a estructurar una comparación entre el dataset completo y el dataset limpio: pacientes, positivos, prevalencia y variables eliminadas.	Auditoría de datos
9	Abril (2. ^a q.)	Revisa una propuesta de organización de la configuración de ventanas Corto_3_12, Medio_6_24 y Largo_12_48 para no duplicar rutas y variables en varios scripts.	Organización del código
10	Abril (2. ^a q.)	Comprueba cómo verificar que ningún subject_id aparezca simultáneamente en train y test dentro de cada fold externo.	Prevención de fuga de pacientes
11	Abril (2. ^a q.)	Revisa una función común para calcular AUC-ROC, AUC-PR, Brier, BSS, ECE, sensibilidad, especificidad y F1 de forma homogénea.	Métricas homogéneas
12	Abril (2. ^a q.)	Comprueba que el umbral óptimo se elige en train y se evalúa en test sin recalcularlo con datos de test.	Umbral sin fuga de información
13	Abril (2. ^a q.)	Revisa el planteamiento de un sistema de checkpoint para leer el CSV de resultados y omitir combinaciones ventana-modelo ya evaluadas.	Reanudación de experimentos
14	Abril (2. ^a q.)	Revisa la comparación entre Platt sin regularización, Platt regularizado e isotónico para detectar posibles errores metodológicos o de fuga.	Revisión de calibración

continúa en la página siguiente

Registro de interacciones con sistemas de IA

N.º	Fecha	Prompt / consulta	Uso posterior
15	Abril (2.ª q.)	Comprueba si el criterio de escoger el menor ECE solo entre calibradores con BSS positivo es coherente y cómo documentarlo.	Selección de calibrador
16	Abril (2.ª q.)	Revisa la fórmula del Brier Skill Score comparando el Brier del modelo frente a una predicción nula basada en la prevalencia.	Métrica de calibración
17	Abril (2.ª q.)	Revisa si el calibrador isotónico puede sobreajustar con pocos positivos y cómo compararlo con Platt usando ECE, BSS y curvas de calibración.	Control metodológico
18	Abril (2.ª q.)	Comprueba cómo calcular pendiente e intercepto de calibración mediante regresión logística sobre el logit de las probabilidades predichas.	Evaluación de calibración
19	Abril (2.ª q.)	Revisa el uso de TreeExplainer para modelos de árboles, manteniendo las variables originales sin escalar.	Revisión de SHAP
20	Abril (2.ª q.)	Revisa cómo aplicar LinearExplainer a la regresión logística cuando los datos han pasado por el escalador del pipeline.	Revisión de SHAP
21	Abril (2.ª q.)	Revisa el planteamiento de KernelExplainer para Naive Bayes con un fondo estratificado que incluya positivos y negativos.	Revisión de SHAP
22	Abril (2.ª q.)	Ayúdame a comprobar una función calcular_shap que decide entre TreeExplainer, LinearExplainer y KernelExplainer según el algoritmo.	Depuración de SHAP
23	Abril (2.ª q.)	Revisa un script que recorre ventanas y modelos para cargar cada modelo guardado y guardar los gráficos SHAP globales correspondientes.	Automatización de análisis
24	Abril (2.ª q.)	Revisa una forma de resumir importancias SHAP ya calculadas en una tabla o visualización comparativa por variable, algoritmo y ventana.	Comparativa de explicabilidad
25	Mayo (1.ª q.)	Cómo estructurar un wrapper de modelo calibrado compatible con predict_proba sin romper la integración con sklearn.	Revisión de diseño software

continúa en la página siguiente

Registro de interacciones con sistemas de IA

N.º	Fecha	Prompt / consulta	Uso posterior
26	Mayo (1. ^a q.)	Revisa cómo evitar duplicar la clase del wrapper calibrado entre entrenamiento y dashboard.	Refactorización
27	Mayo (1. ^a q.)	Qué metadatos conviene guardar junto al modelo final: variables, calibrador, métricas, ventana y configuración.	Trazabilidad del modelo
28	Mayo (1. ^a q.)	Comprueba si es correcto explicar con SHAP el modelo base y usar el calibrador solo para transformar la probabilidad final.	Claridad metodológica
29	Mayo (1. ^a q.)	Revisa el esquema para aplicar en eICU un modelo entrenado en MIMIC-IV sin reentrenamiento y detectar incompatibilidades de variables.	Validación externa
30	Mayo (1. ^a q.)	Ayúdame a revisar el cálculo de AUC, AUC-PR, Brier, ECE y calibración-in-the-large en la validación externa.	Métricas externas
31	Mayo (1. ^a q.)	Cómo presentar una comparación entre rendimiento interno en MIMIC-IV y rendimiento externo en eICU-CRD usando diferencias absolutas de métricas.	Comparación interna-externa
32	Mayo (1. ^a q.)	Revisa una función que detecta si el modelo cargado es un Pipeline y extrae por separado el escalador y el estimador final antes de calcular SHAP.	Depuración de pipeline
33	Mayo (1. ^a q.)	Revisa qué comprobaciones de forma conviene incluir para verificar que los datos, los valores SHAP y los nombres de variables tienen dimensiones compatibles antes de graficar.	Depuración SHAP
34	Mayo (1. ^a q.)	Antes de validar en eICU, comprueba que las variables disponibles coinciden exactamente con las variables del modelo entrenado en MIMIC-IV.	Preparación de validación externa
35	Mayo (1. ^a q.)	Imprime por fold el número de pacientes únicos, estancias, positivos, negativos y prevalencia para auditar la validación cruzada.	Auditoría de particiones
36	Mayo (2. ^a q.)	Revisa el cálculo de pf_min en el dashboard a partir de PaO2 y FiO2, evitando divisiones inválidas, infinitos o escalas ambiguas de FiO2.	Ingeniería de variables

continúa en la página siguiente

N.º	Fecha	Prompt / consulta	Uso posterior
37	Mayo (2.ª q.)	Comprueba cómo usar los percentiles de riesgo guardados del entrenamiento para posicionar a pacientes nuevos en Streamlit.	Percentiles en dashboard
38	Mayo (2.ª q.)	Revisa el diseño de una visualización local con percentil de riesgo, datos básicos del paciente y gráfico horizontal de contribuciones SHAP.	Visualización del dashboard
39	Mayo (2.ª q.)	Traduce nombres técnicos de variables a etiquetas clínicas y unidades; por ejemplo, pf_min como peor PaO2/FiO2.	Lectura clínica
40	Mayo (2.ª q.)	Revisa textos explicativos para aclarar que el percentil es riesgo relativo frente a la cohorte de referencia y no una probabilidad clínica directa.	Explicabilidad
41	Mayo (2.ª q.)	Revisa cómo podría plantearse una validación previa del CSV del paciente, incluyendo columnas obligatorias, tipos numéricos, escala de FiO2 y valores plausibles antes de aplicar el modelo.	Mejora futura del dashboard
42	Mayo (2.ª q.)	Revisa la coherencia de tres CSV ficticios de demostración para comprobar que representan perfiles esperados de bajo, medio y alto riesgo relativo.	Pruebas del dashboard
43	Mayo (2.ª q.)	Revisa cómo cambiar rutas absolutas de Windows a rutas relativas basadas en BASE_DIR para mejorar la portabilidad del repositorio.	Portabilidad
44	Mayo (2.ª q.)	Revisa la transformación de resultados ya calculados en una tabla de hiperparámetros finales para XGBoost, LightGBM, Random Forest, CatBoost, regresión logística y Naive Bayes.	Documentación de entrenamiento
45	Mayo (2.ª q.)	Revisa la transformación de resultados estadísticos ya obtenidos en una tabla resumen de variables significativas por regresor.	Resultados
46	Mayo (2.ª q.)	Revisa una nota de documentación en el código para aclarar que los valores SHAP pertenecen al modelo base y que la calibración solo transforma la probabilidad final.	Claridad metodológica

continúa en la página siguiente

Registro de interacciones con sistemas de IA

N.º	Fecha	Prompt / consulta	Uso posterior
47	Mayo (2. ^a q.)	Revisa un texto bajo el gráfico SHAP que aclare que las barras indican contribución al modelo, no causalidad clínica.	Advertencia metodológica
48	Mayo (2. ^a q.)	(Nano Banana 2) Genérame una imagen según la temática de este proyecto [link repositorio] para meter en el readme, que sea tipo dibujo o logo, no una imagen realista	Imagen decorativa

Bibliografía

- CITI Program (2026). Collaborative institutional training initiative. Accedido en marzo de 2026.
- Evans, L., Rhodes, A., Alhazzani, W., et al. (2021). Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021. *Intensive Care Medicine*, 47:1181–1247.
- Firzli, T. R., Miah, F. Z., Horton, C., Akhtar, H., Riddle, M., and Siddiqui, F. (2023). Influence of time from admission to norepinephrine administration and volume of fluids received on outcomes of patients meeting sepsis-3 criteria: a retrospective study using the mimic-iv database. *Trauma Surgery & Acute Care Open*, 8(1):e001024.
- Grupo de Trabajo Sepsis HUBU (2025). Protocolo Código Sepsis HUBU. Manejo integral del paciente séptico. III edición. Technical report, Complejo Asistencial Universitario de Burgos.
- Gupta, M., Gallamoza, B., Cutrona, N., Dhakal, P., Poulain, R., and Behesh-ti, R. (2022). An extensive data processing pipeline for MIMIC-IV. In *Proceedings of the 2nd Machine Learning for Health Symposium*, volume 193 of *Proceedings of Machine Learning Research*, pages 311–325. PMLR.
- Hébert, P. C., Wells, G., Blajchman, M. A., Marshall, J., Martin, C., Pagliarello, G., Tweeddale, M., Schweitzer, I., and Yetisir, E. (1999). A multicenter, randomized, controlled clinical trial of transfusion requirements in critical care. *New England Journal of Medicine*, 340(6):409–417.
- Johnson, A. E. W., Bulgarelli, L., Shen, L., et al. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.

- Mesquida, J., Borrat, X., Lorente, J. A., Masip, J., and Baigorri, F. (2011). Objetivos de la reanimación hemodinámica. *Medicina Intensiva*, 35(8):499–508.
- Ministerio de Trabajo y Economía Social (2023). Resolución de 27 de febrero de 2023, de la dirección general de trabajo, por la que se registra y publica el XX convenio colectivo nacional de empresas de ingeniería; oficinas de estudios técnicos; inspección, supervisión y control técnico y de calidad. Boletín Oficial del Estado (BOE) núm. 59, de 10 de marzo de 2023, ref. BOE-A-2023-6346. Accedido en junio de 2026.
- NICE-SUGAR Study Investigators (2009). Intensive versus conventional glucose control in critically ill patients. *New England Journal of Medicine*, 360(13):1283–1297.
- PhysioNet (2026). Physionet: The research resource for complex physiologic signals. Accedido en marzo de 2026.
- Pollard, T. J., Johnson, A. E. W., Raffa, J. D., Celi, L. A., Mark, R. G., and Badawi, O. (2018). The eICU collaborative research database, a freely available multi-center database for critical care research. *Scientific Data*, 5:180178.
- Singer, M., Deutschman, C. S., Seymour, C. W., Shankar-Hari, M., Annane, D., Bauer, M., Bellomo, R., Bernard, G. R., Chiche, J.-D., Coopersmith, C. M., Hotchkiss, R. S., Levy, M. M., Marshall, J. C., Martin, G. S., Opal, S. M., Rubenfeld, G. D., van der Poll, T., Vincent, J.-L., and Angus, D. C. (2016). The third international consensus definitions for sepsis and septic shock (Sepsis-3). *JAMA*, 315(8):801–810.
- Sutherland, J. and Sutherland, J. J. (2014). *Scrum: The Art of Doing Twice the Work in Half the Time*. Crown Business, New York.
- Vincent, J.-L. and De Backer, D. (2013). Circulatory shock. *New England Journal of Medicine*, 369(18):1726–1734.