




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana del
riesgo de inicio de
noradrenalina en UCI
mediante aprendizaje
automático y dashboard
interpretable**


Presentado por Daniel Marina de la Cal
en Universidad de Burgos

Tutores: Antonio Jesús Canepa Oneto – Sergio
Ossa Echeverri – Fernando Callejo Torre



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior
Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana del
riesgo de inicio de
noradrenalina en UCI
mediante aprendizaje
automático y dashboard
interpretable**

Presentado por Daniel Marina de la Cal
en Universidad de Burgos

19 de mayo de 2026

Tutores: Antonio Jesús Canepa Oneto – Sergio Ossa
Echeverri – Fernando Callejo Torre



UNIVERSIDAD
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Antonio Jesús Canepa Oneto, profesor/a del departamento de Ingeniería Informática del área de Lenguajes Informáticos. D. Sergio Ossa Echeverri, médico intensivista del Hospital Universitario de Burgos. D. Fernando Callejo Torre, médico intensivista del Hospital Universitario de Burgos.

Expone/n:

Que el/la alumno/a D. Daniel Marina de la Cal, con DNI 71565266F, ha realizado el Trabajo final de Grado en Ingeniería de la Salud titulado *Estimación temprana del riesgo de inicio de noradrenalina en UCI mediante aprendizaje automático y dashboard interpretable*.

Y que dicho trabajo ha sido realizado por el/la alumno/a bajo la dirección del/los que suscribe/n.

En Burgos, a 19 de mayo de 2026

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Antonio Jesús
Canepa Oneto

D. Sergio Ossa
Echeverri

D. Fernando Callejo
Torre

Resumen

Este TFG propone el desarrollo de modelos de aprendizaje automático orientados a estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes críticos ingresados en UCI, a partir de variables clínicas disponibles durante las primeras horas de estancia, como constantes vitales, parámetros analíticos y datos básicos del paciente. El objetivo no es solo predecir si el paciente requerirá soporte vasopresor en una ventana temporal definida, sino también ofrecer una herramienta interpretable, en forma de dashboard, que permita visualizar el riesgo estimado y los factores que más contribuyen a dicha predicción en cada caso.

Descriptores

Aprendizaje automático, Predicción, Dashboard, Sepsis, UCI, Noradrenalina, vasopresor.

Abstract

This Bachelor's Thesis proposes the development of machine learning models aimed at the early estimation of the risk of initiating noradrenaline in critically ill patients admitted to the ICU, based on clinical variables available during the first hours of admission, such as vital signs, laboratory parameters, and basic patient data. The objective is not only to predict whether the patient will require vasopressor support within a defined time window, but also to provide an interpretable tool in the form of a dashboard. This tool will allow the visualization of the estimated risk and the factors that contribute most to this prediction in each individual case.

Keywords

Machine Learning, Sepsis, Prediction, Dashboard, ICU, norepinephrine, vasopressor.

Índice general

Índice general	iii
Índice de figuras	iv
Índice de tablas	v
Introducción	1
Objetivos	5
Conceptos teóricos	9
Metodología	15
4.1. Descripción de los datos	15
4.2. Técnicas y herramientas	15
4.3. Metodología de Ingeniería del Software	16
Resultados	17
5.1. Resumen de resultados	17
Discusión	19
Conclusiones	21
7.1. Aspectos relevantes	21
Líneas de trabajo futuras	23
Bibliografía	25

Índice de figuras

5.1. Distribución de la longitud de sépalo por especie en el conjunto iris	18
--	----

Índice de tablas

4.1. Estadísticos descriptivos del conjunto de datos iris	16
---	----

Introducción

Contexto clínico y relevancia del problema

El paciente crítico ingresado en la Unidad de Cuidados Intensivos (UCI) presenta con frecuencia situaciones de fallo orgánico o riesgo inminente de deterioro clínico, lo que exige una monitorización continua y una respuesta terapéutica rápida. Dentro de este contexto, la inestabilidad hemodinámica constituye uno de los problemas más relevantes, ya que puede comprometer la perfusión tisular y favorecer la progresión hacia disfunción multiorgánica.

Entre las intervenciones empleadas para el soporte hemodinámico se encuentra la administración de vasopresores. Estos fármacos permiten mantener una presión de perfusión adecuada cuando los mecanismos compensadores del organismo y la reposición de volumen no son suficientes. La noradrenalina es el vasopresor de primera elección en la mayoría de los escenarios de shock distributivo e inestabilidad hemodinámica en UCI, especialmente en el shock séptico [Evans et al. \(2021\)](#).

La sepsis y el shock séptico representan una de las principales causas de necesidad de soporte vasopresor en pacientes críticos. A escala global, se estimaron 48,9 millones de casos de sepsis y 11 millones de muertes atribuibles en 2017 [Fleischmann-Struzek et al. \(2020\)](#). En adultos hospitalizados, la incidencia de sepsis tratada en UCI alcanza aproximadamente 58 casos por cada 100.000 personas-año [Fleischmann-Struzek et al. \(2020\)](#). En España, la mortalidad de los pacientes sépticos ingresados en UCI se sitúa alrededor del 30, % y puede alcanzar el 50, % en los casos de shock séptico [Grupo de Trabajo Sepsis HUBU \(2025\)](#). No obstante, la necesidad de noradrenalina no se limita a la sepsis, ya que otras formas de shock circulatorio pueden requerir también soporte vasopresor [Vincent and De Backer \(2013\)](#). Por ello, la predicción del inicio de noradrenalina constituye un problema clínico

relevante en la cohorte general de pacientes críticos, más allá de un único diagnóstico.

Justificación del problema

La decisión de iniciar noradrenalina en un paciente crítico no depende de una única variable aislada. En la práctica clínica habitual, esta decisión se basa en la interpretación conjunta de múltiples señales, como la evolución de la presión arterial, la frecuencia cardíaca, el lactato, la respuesta a la fluidoterapia, la diuresis, el grado de disfunción orgánica, la situación respiratoria y el contexto clínico global del paciente [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta complejidad puede dificultar la identificación temprana de los pacientes que evolucionarán hacia la necesidad de soporte vasopresor.

Además, el momento óptimo de inicio de la noradrenalina continúa siendo un aspecto clínico relevante. Un inicio excesivamente tardío puede prolongar la hipoperfusión y favorecer una mayor acumulación de fluidos, mientras que una indicación innecesaria podría exponer al paciente a tratamientos invasivos no justificados. En este contexto, disponer de herramientas capaces de estimar de forma temprana el riesgo de requerir noradrenalina podría ayudar a complementar la valoración clínica y favorecer una vigilancia más dirigida de los pacientes con mayor probabilidad de deterioro hemodinámico.

Planteamiento del trabajo

En los últimos años, el aprendizaje automático (*machine learning*, ML) ha adquirido un papel creciente en el análisis de datos clínicos complejos. Su capacidad para integrar simultáneamente variables fisiológicas, analíticas y demográficas resulta especialmente atractiva en el entorno de UCI, donde la toma de decisiones se apoya en información heterogénea y cambiante. Las bases de datos clínicas de gran escala, como MIMIC-IV y eICU, han facilitado el desarrollo y la evaluación de este tipo de modelos en pacientes críticos [Johnson et al. \(2023\)](#); [Pollard et al. \(2018\)](#).

El presente Trabajo de Fin de Grado propone el desarrollo y la validación de modelos de aprendizaje automático para estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes adultos ingresados en UCI. Para ello, se emplean variables clínicas y analíticas disponibles durante las primeras horas de estancia, con el objetivo de anticipar la necesidad de soporte vasopresor antes de que se produzca el evento.

A diferencia de enfoques centrados exclusivamente en pacientes sépticos, este trabajo se plantea sobre una cohorte general de pacientes adultos de UCI de MIMIC-IV, sin restricción diagnóstica inicial. Esta decisión permite

abordar el problema desde una perspectiva más amplia y ajustada al uso real de la noradrenalina en cuidados intensivos. La presencia de sepsis se considera posteriormente como variable de análisis para estudiar el comportamiento diferencial de los modelos en subgrupos clínicamente relevantes.

El trabajo incorpora tres elementos de interés práctico. En primer lugar, se diseñan distintas ventanas temporales de predicción para evaluar el rendimiento del modelo en diferentes escenarios de anticipación clínica. En segundo lugar, se aplica interpretabilidad mediante valores SHAP, con el fin de identificar qué variables contribuyen con mayor peso a la predicción tanto a nivel global como individual. En tercer lugar, se desarrolla un prototipo de *dashboard* clínico en Streamlit, orientado a visualizar el riesgo estimado y los factores explicativos principales de cada paciente. Finalmente, la capacidad de generalización del modelo se evalúa mediante validación externa sobre la base de datos eICU [Pollard et al. \(2018\)](#).

Estructura de la memoria

El presente documento se organiza en ocho capítulos. Tras este capítulo introductorio, el **Capítulo 2** recoge los objetivos del trabajo. El **Capítulo 3** desarrolla el marco teórico y el estado del arte, incluyendo los fundamentos clínicos del shock, el uso de vasopresores, las bases del aprendizaje automático aplicado a UCI y la revisión de trabajos previos relacionados. El **Capítulo 4** describe la metodología empleada, incluyendo la construcción de cohortes, la definición del evento objetivo, el preprocesamiento de datos, el entrenamiento de modelos y la validación externa. Los **Capítulos 5 y 6** presentan y discuten los resultados obtenidos. El **Capítulo 7** recoge las conclusiones principales y el **Capítulo 8** propone posibles líneas de trabajo futuro.

Objetivos

Objetivo principal

El objetivo principal de este Trabajo de Fin de Grado es desarrollar y validar modelos de aprendizaje automático para la estimación temprana del riesgo de inicio de noradrenalina en pacientes adultos ingresados en la Unidad de Cuidados Intensivos (UCI), utilizando variables clínicas y analíticas disponibles durante las primeras horas de estancia. Esto se materializará en un *dashboard* interpretable diseñado para su uso a pie de cama, que permitirá visualizar el riesgo estimado y los factores clínicos con mayor contribución a dicha predicción en cada paciente de forma individualizada.

Objetivos específicos

1. Desarrollar modelos predictivos de aprendizaje automático entrenados sobre la base de datos MIMIC-IV que estimen la probabilidad de inicio de noradrenalina en UCI en distintas ventanas temporales tras el ingreso.
2. Evaluar y comparar el rendimiento de distintos algoritmos de clasificación supervisada, incluyendo regresión logística, XGBoost, entre otros, mediante métricas de discriminación y calibración.
3. Desarrollar un prototipo de *dashboard* clínico interpretable que muestre, para cada paciente, la probabilidad estimada de requerir noradrenalina, los factores con mayor peso en la predicción y una clasificación orientativa del nivel de riesgo basada en percentiles.
4. Realizar una validación externa de los modelos predictivos con datos de pacientes reales provenientes de otro repositorio distinto del de entrenamiento.

5. Medir la usabilidad del *dashboard* mediante una encuesta de satisfacción dirigida al personal clínico de la UCI del Hospital Universitario de Burgos.

Objetivos técnicos

1. Definir y construir a partir de MIMIC-IV la cohorte general de pacientes adultos de UCI, registrando la presencia de sepsis como variable para el análisis de rendimiento diferencial por subgrupos.
2. Extraer y preprocesar las variables predictoras relevantes disponibles en las primeras horas del ingreso en UCI, incluyendo constantes vitales, parámetros analíticos y otros indicadores de disfunción orgánica y perfusión tisular.
3. Identificar el evento objetivo, definido como el inicio de noradrenalina, a partir de la tabla `inputevents` de MIMIC-IV, distinguiendo entre diferentes ventanas temporales de predicción.
4. Implementar técnicas de manejo del desequilibrio de clases, imputación de datos faltantes y evaluación de calibración, adaptadas a las características habituales de los datos clínicos reales de UCI.
5. Aplicar técnicas de interpretabilidad basadas en valores SHAP (*SHapley Additive exPlanations*) para cuantificar la contribución individual de cada variable a la predicción, tanto a nivel global de la cohorte como a nivel de paciente individual [Lundberg and Lee \(2017\)](#).
6. Desarrollar la interfaz del prototipo del *dashboard* utilizando Python (Streamlit), incorporando visualización del riesgo estimado, explicación por variables y clasificación orientativa del nivel de alerta.
7. Documentar todo el proceso de desarrollo en el repositorio GitHub del proyecto, con el objetivo de favorecer la reproducibilidad del código y del entorno de trabajo.

Objetivos personales

1. Aplicar de forma integrada los conocimientos adquiridos en el Grado de Ingeniería de la Salud a un problema clínico real y de alta relevancia asistencial.

2. Adquirir experiencia práctica en el manejo de bases de datos clínicas de gran escala como MIMIC-IV, así como en los flujos de trabajo habituales en ciencia de datos aplicada a la salud.
3. Profundizar en el campo del aprendizaje automático interpretable y su aplicación en entornos de cuidados intensivos, donde la explicabilidad de las predicciones es un requisito clínico especialmente relevante.
4. Comprender las implicaciones éticas, legales y de privacidad del uso de datos clínicos en investigación, así como los procedimientos de validación en entornos hospitalarios reales.
5. Desarrollar capacidad crítica para comparar el trabajo propio con la literatura existente, identificando las aportaciones diferenciales del presente TFG respecto a los trabajos previos en el área.

Conceptos teóricos

Inestabilidad hemodinámica en UCI y deterioro hemodinámico

Fisiopatológicamente, el shock séptico representa el estadio más crítico de la disfunción hemodinámica, caracterizado por una profunda alteración de la macro y microcirculación secundaria a una respuesta desregulada del huésped frente a la infección [Singer et al. \(2016\)](#). Los criterios operativos establecidos por el consenso Sepsis-3 no son meros umbrales estadísticos, sino reflejos de hitos fisiológicos críticos. Una PAM inferior a 65 mmHg compromete la presión de perfusión crítica de órganos vitales (como el cerebro y el riñón), pudiendo superar los límites inferiores funcionales. Por su parte, la elevación del lactato actúa como un marcador de hipoxia tisular, indicando el viraje del metabolismo celular hacia la vía anaerobia debido a la hipoperfusión.

La evaluación de este estado de shock en la práctica asistencial requiere la integración continua de flujos heterogéneos de información. El protocolo institucional del Código Sepsis del Hospital Universitario de Burgos (HUBU) sistematiza esta valoración mediante el uso secuencial de escalas de cribado y gravedad como qSOFA y SOFA, complementadas con la monitorización estrecha de indicadores analíticos y funcionales de fallo orgánico, tales como el ritmo diurético, la función renal (creatinina), el perfil hepático (bilirrubina), la coagulación (recuento plaquetario) y el intercambio gaseoso (relación $\text{PaO}_2/\text{FiO}_2$) [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta aproximación permite al clínico componer un mapa del estado hemodinámico y de la reserva funcional del paciente crítico.

Sin embargo, la traducción de estas variables analíticas y constantes vitales en una decisión terapéutica concreta, como el inicio de soporte vasopresor con noradrenalina, revela las limitaciones inherentes de los sistemas

de puntuación tradicionales. El deterioro hemodinámico real es un proceso dinámico y caracterizado por interacciones no lineales entre las variables fisiológicas, donde la respuesta a tratamientos previos (como la fluidoterapia) altera continuamente la probabilidad del evento objetivo [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Por consiguiente, la identificación predictiva del riesgo de requerir vasopresores excede la capacidad de las reglas de decisión clínicas fijas, justificando la exploración de otras metodologías capaces de modelar esta complejidad temporal de forma continua.

Uso de vasopresores y papel de la noradrenalina

Tanto las guías de la *Surviving Sepsis Campaign* como el protocolo local del HUBU establecen la noradrenalina como vasopresor de primera elección en el shock séptico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#), y esta recomendación se extiende de facto a la mayoría de los escenarios de shock distributivo en UCI. Cuando se requieren dosis elevadas de noradrenalina para alcanzar una presión arterial media segura, puede asociarse vasopresina como segundo vasopresor. Asimismo, en presencia de disfunción miocárdica asociada o de hipoperfusión persistente a pesar de una adecuada presión arterial, puede considerarse el uso de dobutamina como soporte inotrópico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Este esquema terapéutico refleja que el tratamiento hemodinámico del paciente crítico no es estático, sino progresivo y dependiente de la evolución clínica.

Bases de datos clínicas y aprendizaje automático en UCI

El desarrollo de modelos predictivos en cuidados intensivos ha estado estrechamente ligado a la disponibilidad de bases de datos clínicas de gran escala. Entre ellas, MIMIC-IV (*Medical Information Mart for Intensive Care*, versión IV) ocupa un lugar destacado por tratarse de una base de datos pública, desidentificada y diseñada específicamente para investigación clínica [Johnson et al. \(2023\)](#). MIMIC-IV integra información hospitalaria de un único centro terciario de Boston, incluyendo episodios de UCI, resultados analíticos, administración de fármacos, procedimientos y medidas fisiológicas, todo ello con una estructura que permite estudiar eventos dinámicos como el inicio de vasopresores o la evolución hemodinámica del paciente [Johnson et al. \(2023\)](#).

Para la evaluación de la generalización de los modelos fuera del entorno de desarrollo, la base de datos eICU-CRD (*eICU Collaborative Research Database*) constituye un recurso complementario de gran relevancia [Pollard et al. \(2018\)](#). A diferencia de MIMIC-IV, eICU-CRD agrega datos de centenares de hospitales de Estados Unidos, lo que permite evaluar si un modelo

entrenado en un único centro mantiene su rendimiento en una población más heterogénea y con prácticas clínicas potencialmente distintas [Pollard et al. \(2018\)](#). Esta característica la convierte en un entorno especialmente adecuado para la validación externa de modelos desarrollados sobre MIMIC-IV.

La estimación del riesgo de inicio de noradrenalina exige definir ventanas de observación y de predicción clínicamente plausibles, utilizando únicamente la información disponible antes del evento. Ambas bases de datos comparten una estructura temporal que hace posible este tipo de diseño retrospectivo.

Dentro de este marco, el aprendizaje automático ha adquirido un papel creciente en la predicción de eventos clínicos en pacientes críticos. En datos clínicos tabulares se emplean con frecuencia algoritmos como la regresión logística, Random Forest, XGBoost, LightGBM o CatBoost, que permiten modelar relaciones no lineales e interacciones complejas entre variables. Su atractivo radica en la capacidad para combinar simultáneamente información procedente de múltiples dominios clínicos, algo difícil de reproducir con reglas clínicas simples o con modelos univariantes. Sin embargo, este aumento de capacidad predictiva suele ir acompañado de una menor interpretabilidad, lo que supone una limitación importante cuando el objetivo final es apoyar decisiones clínicas reales.

Interpretabilidad y explicabilidad de modelos

En aplicaciones clínicas, la interpretabilidad del modelo no constituye un elemento accesorio, sino un requisito relevante para facilitar la confianza del profesional sanitario y permitir una evaluación crítica de la predicción generada. En este contexto, adquieren relevancia técnicas de explicación como SHAP (*SHapley Additive exPlanations*), que permiten descomponer la predicción de un modelo en la contribución individual de cada variable [Lundberg and Lee \(2017\)](#).

Este enfoque ofrece una doble utilidad. Por un lado, permite identificar qué variables son más influyentes a nivel global dentro de la cohorte, lo que facilita interpretar el comportamiento general del modelo. Por otro, hace posible explicar predicciones concretas a nivel individual, mostrando qué factores empujan el riesgo estimado en una u otra dirección para un paciente determinado [Lundberg and Lee \(2017\)](#). En un entorno de apoyo a la decisión clínica, esta capacidad puede resultar especialmente valiosa, ya que aproxima la salida del modelo a un razonamiento más comprensible para el profesional.

Estado del arte y trabajos relacionados

Entre los estudios más próximos al objetivo de este TFG destaca el trabajo de Duval et al., que desarrollaron un modelo interpretable basado en historia clínica electrónica para predecir el inicio de perfusión continua de vasopresores en pacientes sépticos ingresados en UCI a partir de datos de MIMIC-IV [Duval et al. \(2025\)](#). El modelo utilizó variables medidas en la ventana de -6 a -2 horas respecto al inicio del tratamiento y el mejor clasificador fue un *Random Forest* con un AUROC de 0,75. Entre los predictores más relevantes se encontraban el descenso de la presión arterial media entre -2 y -4 horas, un lactato $> 2,5$ mmol/L y valores de hematocrito fuera del rango 30-37 % [Duval et al. \(2025\)](#). Los autores señalan, además, que las alertas del modelo podrían generarse entre 2 y 4 horas antes del inicio del vasopresor, lo que apoya la viabilidad técnica de anticipar este tipo de decisión terapéutica [Duval et al. \(2025\)](#). No obstante, el propio estudio subraya que se trata de una validación interna y que aún se requiere validación externa y evaluación prospectiva antes de plantear una implementación clínica real.

Junto a este trabajo, existen otros estudios relacionados que contribuyen a contextualizar el problema, aunque orientados a objetivos clínicos sutilmente distintos. Scheibner et al. desarrollaron y validaron externamente modelos de aprendizaje automático para predecir la respuesta a la vasopresina como segundo vasopresor en pacientes con shock séptico tratados con noradrenalina, mostrando un rendimiento modesto y poniendo de manifiesto la complejidad de anticipar la respuesta farmacológica individual [Scheibner et al. \(2022\)](#). En una línea diferente, Persson et al. realizaron un ensayo clínico aleatorizado y prospectivo para validar un algoritmo de predicción temprana de sepsis en pacientes críticos, demostrando que este tipo de sistemas puede evaluarse más allá del entorno retrospectivo y en condiciones más próximas a la práctica clínica real [Persson et al. \(2024\)](#). Aunque su objetivo no fue la monitorización de vasopresores, este estudio refuerza la relevancia de avanzar hacia diseños de validación más cercanos al uso asistencial.

Otros trabajos han abordado tareas más complejas, como la predicción continua de dosis o la optimización de decisiones terapéuticas mediante modelos temporales y aprendizaje por refuerzo. Jiang et al. propusieron ChronoSynthNet, un modelo con componentes *Transformer* y LSTM para estimar en tiempo real la dosis de noradrenalina y detectar precozmente hipotensión en pacientes con shock séptico [Jiang et al. \(2025\)](#). Este tipo de enfoques aprovecha mejor la naturaleza temporal de los datos, pero también incrementa de forma notable la complejidad metodológica. En paralelo, los enfoques de aprendizaje por refuerzo han intentado derivar políticas terapéuticas para orientar decisiones hemodinámicas en sepsis. Por ejemplo, Zhang et al. describieron un modelo orientado a optimizar estrategias de

tratamiento mediante recomendaciones sobre vasopresores y fluidoterapia, incorporando mecanismos para reducir ajustes bruscos de dosis [Zhang et al. \(2024\)](#), mientras que el estudio OVISS exploró el momento óptimo de inicio de vasopresina en pacientes con shock séptico tratados con noradrenalina [Kalimoultou et al. \(2025\)](#). Aunque estos trabajos son metodológicamente ambiciosos, responden a preguntas clínicas distintas y más complejas que la estimación temprana del primer inicio de noradrenalina.

Limitaciones de la literatura y posicionamiento del TFG

A pesar del avance metodológico observado, la literatura disponible presenta varias limitaciones recurrentes. En primer lugar, muchos estudios continúan evaluando su rendimiento principalmente mediante métricas de discriminación retrospectiva, especialmente el AUROC, sin trasladar de forma suficiente esos resultados a escenarios de uso clínico real [Shanmugam et al. \(2025\)](#). En segundo lugar, la validación externa sigue siendo limitada en una parte importante de los trabajos publicados, lo que dificulta valorar la robustez de los modelos fuera del centro o cohorte de desarrollo [Rockenschaub et al. \(2025\)](#). Además, una proporción relevante de los estudios permanece en fases de validación retrospectiva o de prueba de concepto, lo que limita la estimación de su utilidad operativa real y refuerza la necesidad de modelos interpretables y clínicamente integrables [Shanmugam et al. \(2025\)](#); [Rockenschaub et al. \(2025\)](#).

A partir de esta revisión, el nicho del presente TFG queda claramente definido. El interés del trabajo no reside únicamente en desarrollar un modelo predictivo adicional, sino en abordar un problema clínico concreto y accionable: la estimación temprana del riesgo de inicio de noradrenalina en pacientes críticos a partir de variables disponibles durante las primeras horas de estancia, sobre una cohorte general de adultos en UCI sin restricción diagnóstica. La propuesta añade, además, tres elementos de interés práctico: el uso de modelos con selección de variables por ventana, la traducción del resultado a una interfaz funcional tipo *dashboard* y la validación externa sobre una cohorte multicéntrica independiente. De este modo, el trabajo se orienta no solo a la obtención de un buen rendimiento predictivo, sino también a su posible utilidad como herramienta de apoyo a la decisión clínica.

Metodología

4.1. Descripción de los datos

Se describirán los datos utilizados en el proyecto.

4.2. Técnicas y herramientas

A continuación se muestra un **ejemplo de tabla generada con R** usando `knitr::kable()`:

```
library(knitr)
library(dplyr)

iris |>
  group_by(Species) |>
  summarise(
    N          = n(),
    Media_SL   = round(mean(Sepal.Length), 2),
    SD_SL      = round(sd(Sepal.Length), 2),
    Media_PL   = round(mean(Petal.Length), 2),
    SD_PL      = round(sd(Petal.Length), 2)
  ) |>
  kable(
    col.names = c("Especie", "N", "Media Sep.L",
                  "SD Sep.L", "Media Pet.L", "SD Pet.L"),
    booktabs  = TRUE,
    format    = "latex"
  )
```

Tabla 4.1: Estadísticos descriptivos del conjunto de datos iris

Especie	N	Media Sep.L	SD Sep.L	Media Pet.L	SD Pet.L
setosa	50	5.01	0.35	1.46	0.17
versicolor	50	5.94	0.52	4.26	0.47
virginica	50	6.59	0.64	5.55	0.55

Y podremos referenciar esta tabla en el texto como la tabla [4.1](#) que aparece en la página [16](#).

4.3. Metodología de Ingeniería del Software

Si el TFG incluye desarrollo software, indicar la metodología seguida. Se pueden incluir diagramas de casos de uso, diagramas de clases, diagramas de secuencia, etc. para describir el diseño del software desarrollado.

Resultados

5.1. Resumen de resultados

Breve resumen de los resultados. En caso de ser un trabajo muy experimental, los resultados completos pueden aparecer en su anexo correspondiente.

Debería haber una correspondencia entre los objetivos y los resultados explicados en esta sección

A continuación se muestra un **ejemplo de figura generada con R**:

```
library(ggplot2)

ggplot(iris, aes(x = Species, y = Sepal.Length, fill = Species)) +
  geom_boxplot(alpha = 0.7, show.legend = FALSE) +
  labs(
    x = "Especie",
    y = "Longitud del sépalo (cm)"
  ) +
  theme_minimal(base_size = 11) +
  theme(panel.grid.minor = element_blank())
```

Debería existir correspondencia entre los objetivos definidos y los resultados mostrados (Koza, 1992).




Figura 5.1: Distribución de la longitud de sépal por especie en el conjunto iris

Discusión

Se realizará un análisis crítico de los resultados, interpretando su significado y, cuando sea pertinente, comparándolos con los resultados de trabajos previos, obtenidos con la revisión del estado del arte; de forma que se destaquen las mejoras y aportes sobre el mismo.

Conclusiones

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas.

7.1. Aspectos relevantes

Este apartado pretende recoger los aspectos más interesantes del **desarrollo del proyecto**, comentados por los autores del mismo y que den respuesta a los objetivos planteados.

Debe incluir los detalles más relevantes en cada fase del desarrollo, justificando los caminos tomados, especialmente aquellos que no sean triviales.

Puede ser el lugar más adecuado para documentar los aspectos más interesantes del proyecto y también los resultados negativos obtenidos por soluciones previas a la solución entregada.

Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

Líneas de trabajo futuras

Este capítulo debería ser informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

- Duval, L., Villié, A., Zheng, F., Terraz, G., Blein, S., Duperchy, E., Everett, M., Frieling, J., Llitjos, J.-F., and Bodinier, M. (2025). Early prediction of vasopressor initiation in ICU sepsis patients using an interpretable EHR-based ML model. *BMC Medical Informatics and Decision Making*, 25(1):442.
- Evans, L., Rhodes, A., Alhazzani, W., et al. (2021). Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021. *Intensive Care Medicine*, 47:1181–1247.
- Fleischmann-Struzek, C., Mellhammar, L., Rose, N., et al. (2020). Incidence and mortality of hospital- and ICU-treated sepsis: results from an updated and expanded systematic review and meta-analysis. *Intensive Care Medicine*, 46:1552–1562.
- Grupo de Trabajo Sepsis HUBU (2025). Protocolo Código Sepsis HUBU. Manejo integral del paciente séptico. III edición. Technical report, Complejo Asistencial Universitario de Burgos.
- Jiang, Z., Zhang, S., Yuan, Y., Wang, J., and Hu, Z. (2025). Chronosynthnet: a dual-task deep learning model development and validation study for predicting real-time norepinephrine dosage and the early detection of hypotension in patients with septic shock. *Cardiovascular Diagnosis and Therapy*, 15(4):833–846.
- Johnson, A. E. W., Bulgarelli, L., Shen, L., et al. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.
- Kalimouttou, A., Kennedy, J. N., Feng, J., Singh, H., Saria, S., Angus, D. C., Seymour, C. W., and Pirracchio, R. (2025). Optimal vasopressin

- initiation in septic shock: The OVISS reinforcement learning study. *JAMA*, 333(19):1688–1698.
- Koza, J. R. (1992). *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30.
- Persson, I., Macura, A., Becedas, D., and Sjövall, F. (2024). Early prediction of sepsis in intensive care patients using the machine learning algorithm NAVOY® sepsis, a prospective randomized clinical validation study. *Journal of Critical Care*, 80:154400.
- Pollard, T. J., Johnson, A. E. W., Raffa, J. D., Celi, L. A., Mark, R. G., and Badawi, O. (2018). The eICU collaborative research database, a freely available multi-center database for critical care research. *Scientific Data*, 5:180178.
- Rockenschaub, P., Akay, E. M., Carlisle, B. G., et al. (2025). External validation of AI-based scoring systems in the ICU: a systematic review and meta-analysis. *BMC Medical Informatics and Decision Making*, 25:5.
- Scheibner, A., Betthausen, K. D., Bewley, A. F., Juang, P., Lizza, B., Micek, S., and Lyons, P. G. (2022). Machine learning to predict vasopressin responsiveness in patients with septic shock. *Pharmacotherapy*, 42(6):460–471.
- Shanmugam, H., Airen, L., and Rawat, S. (2025). Machine learning and deep learning models for early sepsis prediction: A scoping review. *Indian Journal of Critical Care Medicine*, 29(6):516–524.
- Singer, M., Deutschman, C. S., Seymour, C. W., Shankar-Hari, M., Annane, D., Bauer, M., Bellomo, R., Bernard, G. R., Chiche, J.-D., Coopersmith, C. M., Hotchkiss, R. S., Levy, M. M., Marshall, J. C., Martin, G. S., Opal, S. M., Rubenfeld, G. D., van der Poll, T., Vincent, J.-L., and Angus, D. C. (2016). The third international consensus definitions for sepsis and septic shock (Sepsis-3). *JAMA*, 315(8):801–810.
- Vincent, J.-L. and De Backer, D. (2013). Circulatory shock. *New England Journal of Medicine*, 369(18):1726–1734.

Zhang, T., Qu, Y., Wang, D., Zhong, M., Cheng, Y., and Zhang, M. (2024).
Optimizing sepsis treatment strategies via a reinforcement learning model.
Biomedical Engineering Letters, 14(2):279–289.