




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana del
riesgo de inicio de
noradrenalina en UCI
mediante aprendizaje
automático y dashboard
interpretable**


Presentado por Daniel Marina de la Cal
en Universidad de Burgos

Tutores: Antonio Jesús Canepa Oneto – Sergio
Ossa Echeverri – Fernando Callejo Torre



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior
Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana del
riesgo de inicio de
noradrenalina en UCI
mediante aprendizaje
automático y dashboard
interpretable**

Presentado por Daniel Marina de la Cal
en Universidad de Burgos

22 de mayo de 2026

Tutores: Antonio Jesús Canepa Oneto – Sergio Ossa
Echeverri – Fernando Callejo Torre



UNIVERSIDAD
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Antonio Jesús Canepa Oneto, profesor/a del departamento de Ingeniería Informática del área de Lenguajes Informáticos. D. Sergio Ossa Echeverri, médico intensivista del Hospital Universitario de Burgos. D. Fernando Callejo Torre, médico intensivista del Hospital Universitario de Burgos.

Expone/n:

Que el/la alumno/a D. Daniel Marina de la Cal, con DNI 71565266F, ha realizado el Trabajo final de Grado en Ingeniería de la Salud titulado *Estimación temprana del riesgo de inicio de noradrenalina en UCI mediante aprendizaje automático y dashboard interpretable*.

Y que dicho trabajo ha sido realizado por el/la alumno/a bajo la dirección del/los que suscribe/n.

En Burgos, a 22 de mayo de 2026

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Antonio Jesús
Canepa Oneto

D. Sergio Ossa
Echeverri

D. Fernando Callejo
Torre

Resumen

Este TFG propone el desarrollo de modelos de aprendizaje automático orientados a estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes críticos ingresados en UCI, a partir de variables clínicas disponibles durante las primeras horas de estancia, como constantes vitales, parámetros analíticos y datos básicos del paciente. El objetivo no es solo predecir si el paciente requerirá soporte vasopresor en una ventana temporal definida, sino también ofrecer una herramienta interpretable, en forma de dashboard, que permita visualizar el riesgo estimado y los factores que más contribuyen a dicha predicción en cada caso.

Descriptores

Aprendizaje automático, Predicción, Dashboard, Sepsis, UCI, Noradrenalina, vasopresor.

Abstract

This Bachelor's Thesis proposes the development of machine learning models aimed at the early estimation of the risk of initiating noradrenaline in critically ill patients admitted to the ICU, based on clinical variables available during the first hours of admission, such as vital signs, laboratory parameters, and basic patient data. The objective is not only to predict whether the patient will require vasopressor support within a defined time window, but also to provide an interpretable tool in the form of a dashboard. This tool will allow the visualization of the estimated risk and the factors that contribute most to this prediction in each individual case.

Keywords

Machine Learning, Sepsis, Prediction, Dashboard, ICU, norepinephrine, vasopressor.

Índice general

Índice general	iii
Índice de figuras	iv
Índice de tablas	v
Introducción	1
Objetivos	5
Conceptos teóricos	9
Metodología	15
4.1. Datos y variables por ventana	15
4.2. Baseline final y métricas	25
4.3. Dashboard clínico y limitaciones de uso	31
4.4. Metodología de Ingeniería del Software	33
Resultados	35
5.1. Resumen de resultados	35
Discusión	37
Conclusiones	39
7.1. Aspectos relevantes	39
Líneas de trabajo futuras	41

Índice de figuras

4.1.	Análisis de correlación y estructura de agrupamiento de las 76 variables predictoras (MIMIC-IV, ventana Medio). Izquierda: matriz de correlación de Spearman. Derecha: dendrograma jerárquico con corte en $ \rho = 0,7$	22
4.2.	Dendrogramas de agrupamiento jerárquico sobre el conjunto final de variables predictoras en cada ventana temporal. Distancia $= 1 - \rho $; línea roja: $ \rho = 0,7$; línea naranja: $ \rho = 0,5$	23
4.3.	Importancia por permutación de cada variable para los seis algoritmos evaluados, en cada ventana temporal. Las barras representan la caída media de AUC-ROC al permutar la variable; los intervalos de confianza al 95 % se calcularon sobre los 5 folds externos. Las variables cuyo IC95 % excluye el cero se consideraron estadísticamente significativas para ese regresor.	24
4.4.		29
4.5.	Ejemplos de diagramas SHAP tipo <i>beeswarm</i> de los modelos por ventana temporal.	30
5.1.	Distribución de la longitud de sépalo por especie en el conjunto iris	36

Índice de tablas

4.1. Pseudocódigo de los algoritmos del repositorio MIT-LCP para el cálculo horario del SOFA y la detección del <i>onset</i> de Sepsis-3 en MIMIC-IV Johnson et al. (2023)MIT Laboratory for Computational Physiology (2024).	18
4.2. Efecto del filtro de completitud sobre el tamaño y la prevalencia de cada cohorte de entrenamiento (MIMIC-IV).	19
4.3. Efecto del filtro de completitud sobre el tamaño y la prevalencia de cada cohorte de validación externa (eICU-CRD).	20

Introducción

Contexto clínico y relevancia del problema

El paciente crítico ingresado en la Unidad de Cuidados Intensivos (UCI) presenta con frecuencia situaciones de fallo orgánico o riesgo inminente de deterioro clínico, lo que exige una monitorización continua y una respuesta terapéutica rápida. Dentro de este contexto, la inestabilidad hemodinámica constituye uno de los problemas más relevantes, ya que puede comprometer la perfusión tisular y favorecer la progresión hacia disfunción multiorgánica.

Entre las intervenciones empleadas para el soporte hemodinámico se encuentra la administración de vasopresores. Estos fármacos permiten mantener una presión de perfusión adecuada cuando los mecanismos compensadores del organismo y la reposición de volumen no son suficientes. La noradrenalina es el vasopresor de primera elección en la mayoría de los escenarios de shock distributivo e inestabilidad hemodinámica en UCI, especialmente en el shock séptico [Evans et al. \(2021\)](#).

La sepsis y el shock séptico representan una de las principales causas de necesidad de soporte vasopresor en pacientes críticos. A escala global, se estimaron 48,9 millones de casos de sepsis y 11 millones de muertes atribuibles en 2017 [Fleischmann-Struzek et al. \(2020\)](#). En adultos hospitalizados, la incidencia de sepsis tratada en UCI alcanza aproximadamente 58 casos por cada 100.000 personas-año [Fleischmann-Struzek et al. \(2020\)](#). En España, la mortalidad de los pacientes sépticos ingresados en UCI se sitúa alrededor del 30, % y puede alcanzar el 50, % en los casos de shock séptico [Grupo de Trabajo Sepsis HUBU \(2025\)](#). No obstante, la necesidad de noradrenalina no se limita a la sepsis, ya que otras formas de shock circulatorio pueden requerir también soporte vasopresor [Vincent and De Backer \(2013\)](#). Por ello, la predicción del inicio de noradrenalina constituye un problema clínico

relevante en la cohorte general de pacientes críticos, más allá de un único diagnóstico.

Justificación del problema

La decisión de iniciar noradrenalina en un paciente crítico no depende de una única variable aislada. En la práctica clínica habitual, esta decisión se basa en la interpretación conjunta de múltiples señales, como la evolución de la presión arterial, la frecuencia cardíaca, el lactato, la respuesta a la fluidoterapia, la diuresis, el grado de disfunción orgánica, la situación respiratoria y el contexto clínico global del paciente [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta complejidad puede dificultar la identificación temprana de los pacientes que evolucionarán hacia la necesidad de soporte vasopresor.

Además, el momento óptimo de inicio de la noradrenalina continúa siendo un aspecto clínico relevante. Un inicio excesivamente tardío puede prolongar la hipoperfusión y favorecer una mayor acumulación de fluidos, mientras que una indicación innecesaria podría exponer al paciente a tratamientos invasivos no justificados. En este contexto, disponer de herramientas capaces de estimar de forma temprana el riesgo de requerir noradrenalina podría ayudar a complementar la valoración clínica y favorecer una vigilancia más dirigida de los pacientes con mayor probabilidad de deterioro hemodinámico.

Planteamiento del trabajo

En los últimos años, el aprendizaje automático (*machine learning*, ML) ha adquirido un papel creciente en el análisis de datos clínicos complejos. Su capacidad para integrar simultáneamente variables fisiológicas, analíticas y demográficas resulta especialmente atractiva en el entorno de UCI, donde la toma de decisiones se apoya en información heterogénea y cambiante. Las bases de datos clínicas de gran escala, como MIMIC-IV y eICU, han facilitado el desarrollo y la evaluación de este tipo de modelos en pacientes críticos [Johnson et al. \(2023\)](#); [Pollard et al. \(2018\)](#).

El presente Trabajo de Fin de Grado propone el desarrollo y la validación de modelos de aprendizaje automático para estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes adultos ingresados en UCI. Para ello, se emplean variables clínicas y analíticas disponibles durante las primeras horas de estancia, con el objetivo de anticipar la necesidad de soporte vasopresor antes de que se produzca el evento.

A diferencia de enfoques centrados exclusivamente en pacientes sépticos, este trabajo se plantea sobre una cohorte general de pacientes adultos de UCI de MIMIC-IV, sin restricción diagnóstica inicial. Esta decisión permite

abordar el problema desde una perspectiva más amplia y ajustada al uso real de la noradrenalina en cuidados intensivos. La presencia de sepsis se considera posteriormente como variable de análisis para estudiar el comportamiento diferencial de los modelos en subgrupos clínicamente relevantes.

El trabajo incorpora tres elementos de interés práctico. En primer lugar, se diseñan distintas ventanas temporales de predicción para evaluar el rendimiento del modelo en diferentes escenarios de anticipación clínica. En segundo lugar, se aplica interpretabilidad mediante valores SHAP, con el fin de identificar qué variables contribuyen con mayor peso a la predicción tanto a nivel global como individual. En tercer lugar, se desarrolla un prototipo de *dashboard* clínico en Streamlit, orientado a visualizar el riesgo estimado y los factores explicativos principales de cada paciente. Finalmente, la capacidad de generalización del modelo se evalúa mediante validación externa sobre la base de datos eICU [Pollard et al. \(2018\)](#).

Estructura de la memoria

El presente documento se organiza en ocho capítulos. Tras este capítulo introductorio, el **Capítulo 2** recoge los objetivos del trabajo. El **Capítulo 3** desarrolla el marco teórico y el estado del arte, incluyendo los fundamentos clínicos del shock, el uso de vasopresores, las bases del aprendizaje automático aplicado a UCI y la revisión de trabajos previos relacionados. El **Capítulo 4** describe la metodología empleada, incluyendo la construcción de cohortes, la definición del evento objetivo, el preprocesamiento de datos, el entrenamiento de modelos y la validación externa. Los **Capítulos 5 y 6** presentan y discuten los resultados obtenidos. El **Capítulo 7** recoge las conclusiones principales y el **Capítulo 8** propone posibles líneas de trabajo futuro.

Objetivos

Objetivo principal

El objetivo principal de este Trabajo de Fin de Grado es desarrollar y validar modelos de aprendizaje automático para la estimación temprana del riesgo de inicio de noradrenalina en pacientes adultos ingresados en la Unidad de Cuidados Intensivos (UCI), utilizando variables clínicas y analíticas disponibles durante las primeras horas de estancia. Esto se materializará en un *dashboard* interpretable diseñado para su uso a pie de cama, que permitirá visualizar el riesgo estimado y los factores clínicos con mayor contribución a dicha predicción en cada paciente de forma individualizada.

Objetivos específicos

1. Desarrollar modelos predictivos de aprendizaje automático entrenados sobre la base de datos MIMIC-IV que estimen la probabilidad de inicio de noradrenalina en UCI en distintas ventanas temporales tras el ingreso.
2. Evaluar y comparar el rendimiento de distintos algoritmos de clasificación supervisada, incluyendo regresión logística, XGBoost, entre otros, mediante métricas de discriminación y calibración.
3. Desarrollar un prototipo de *dashboard* clínico interpretable que muestre, para cada paciente, la probabilidad estimada de requerir noradrenalina, los factores con mayor peso en la predicción y una clasificación orientativa del nivel de riesgo basada en percentiles.
4. Realizar una validación externa de los modelos predictivos con datos de pacientes reales provenientes de otro repositorio distinto del de entrenamiento.

5. Medir la usabilidad del *dashboard* mediante una encuesta de satisfacción dirigida al personal clínico de la UCI del Hospital Universitario de Burgos.

Objetivos técnicos

1. Definir y construir a partir de MIMIC-IV la cohorte general de pacientes adultos de UCI, registrando la presencia de sepsis como variable para el análisis de rendimiento diferencial por subgrupos.
2. Extraer y preprocesar las variables predictoras relevantes disponibles en las primeras horas del ingreso en UCI, incluyendo constantes vitales, parámetros analíticos y otros indicadores de disfunción orgánica y perfusión tisular.
3. Identificar el evento objetivo, definido como el inicio de noradrenalina, a partir de la tabla `inputevents` de MIMIC-IV, distinguiendo entre diferentes ventanas temporales de predicción.
4. Implementar técnicas de manejo del desequilibrio de clases, imputación de datos faltantes y evaluación de calibración, adaptadas a las características habituales de los datos clínicos reales de UCI.
5. Aplicar técnicas de interpretabilidad basadas en valores SHAP (*SHapley Additive exPlanations*) para cuantificar la contribución individual de cada variable a la predicción, tanto a nivel global de la cohorte como a nivel de paciente individual [Lundberg and Lee \(2017\)](#).
6. Desarrollar la interfaz del prototipo del *dashboard* utilizando Python (Streamlit), incorporando visualización del riesgo estimado, explicación por variables y clasificación orientativa del nivel de alerta.
7. Documentar todo el proceso de desarrollo en el repositorio GitHub del proyecto, con el objetivo de favorecer la reproducibilidad del código y del entorno de trabajo.

Objetivos personales

1. Aplicar de forma integrada los conocimientos adquiridos en el Grado de Ingeniería de la Salud a un problema clínico real y de alta relevancia asistencial.

2. Adquirir experiencia práctica en el manejo de bases de datos clínicas de gran escala como MIMIC-IV, así como en los flujos de trabajo habituales en ciencia de datos aplicada a la salud.
3. Profundizar en el campo del aprendizaje automático interpretable y su aplicación en entornos de cuidados intensivos, donde la explicabilidad de las predicciones es un requisito clínico especialmente relevante.
4. Comprender las implicaciones éticas, legales y de privacidad del uso de datos clínicos en investigación, así como los procedimientos de validación en entornos hospitalarios reales.
5. Desarrollar capacidad crítica para comparar el trabajo propio con la literatura existente, identificando las aportaciones diferenciales del presente TFG respecto a los trabajos previos en el área.

Conceptos teóricos

Inestabilidad hemodinámica en UCI y deterioro hemodinámico

Fisiopatológicamente, el shock séptico representa el estadio más crítico de la disfunción hemodinámica, caracterizado por una profunda alteración de la macro y microcirculación secundaria a una respuesta desregulada del huésped frente a la infección [Singer et al. \(2016\)](#). Los criterios operativos establecidos por el consenso Sepsis-3 no son meros umbrales estadísticos, sino reflejos de hitos fisiológicos críticos. Una PAM inferior a 65 mmHg compromete la presión de perfusión crítica de órganos vitales (como el cerebro y el riñón), pudiendo superar los límites inferiores funcionales. Por su parte, la elevación del lactato actúa como un marcador de hipoxia tisular, indicando el viraje del metabolismo celular hacia la vía anaerobia debido a la hipoperfusión.

La evaluación de este estado de shock en la práctica asistencial requiere la integración continua de flujos heterogéneos de información. El protocolo institucional del Código Sepsis del Hospital Universitario de Burgos (HUBU) sistematiza esta valoración mediante el uso secuencial de escalas de cribado y gravedad como qSOFA y SOFA, complementadas con la monitorización estrecha de indicadores analíticos y funcionales de fallo orgánico, tales como el ritmo diurético, la función renal (creatinina), el perfil hepático (bilirrubina), la coagulación (recuento plaquetario) y el intercambio gaseoso (relación $\text{PaO}_2/\text{FiO}_2$) [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta aproximación permite al clínico componer un mapa del estado hemodinámico y de la reserva funcional del paciente crítico.

Sin embargo, la traducción de estas variables analíticas y constantes vitales en una decisión terapéutica concreta, como el inicio de soporte vasopresor con noradrenalina, revela las limitaciones inherentes de los sistemas

de puntuación tradicionales. El deterioro hemodinámico real es un proceso dinámico y caracterizado por interacciones no lineales entre las variables fisiológicas, donde la respuesta a tratamientos previos (como la fluidoterapia) altera continuamente la probabilidad del evento objetivo [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Por consiguiente, la identificación predictiva del riesgo de requerir vasopresores excede la capacidad de las reglas de decisión clínicas fijas, justificando la exploración de otras metodologías capaces de modelar esta complejidad temporal de forma continua.

Uso de vasopresores y papel de la noradrenalina

Tanto las guías de la *Surviving Sepsis Campaign* como el protocolo local del HUBU establecen la noradrenalina como vasopresor de primera elección en el shock séptico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#), y esta recomendación se extiende de facto a la mayoría de los escenarios de shock distributivo en UCI. Cuando se requieren dosis elevadas de noradrenalina para alcanzar una presión arterial media segura, puede asociarse vasopresina como segundo vasopresor. Asimismo, en presencia de disfunción miocárdica asociada o de hipoperfusión persistente a pesar de una adecuada presión arterial, puede considerarse el uso de dobutamina como soporte inotrópico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Este esquema terapéutico refleja que el tratamiento hemodinámico del paciente crítico no es estático, sino progresivo y dependiente de la evolución clínica.

Bases de datos clínicas y aprendizaje automático en UCI

El desarrollo de modelos predictivos en cuidados intensivos ha estado estrechamente ligado a la disponibilidad de bases de datos clínicas de gran escala. Entre ellas, MIMIC-IV (*Medical Information Mart for Intensive Care*, versión IV) ocupa un lugar destacado por tratarse de una base de datos pública, desidentificada y diseñada específicamente para investigación clínica [Johnson et al. \(2023\)](#). MIMIC-IV integra información hospitalaria de un único centro terciario de Boston, incluyendo episodios de UCI, resultados analíticos, administración de fármacos, procedimientos y medidas fisiológicas, todo ello con una estructura que permite estudiar eventos dinámicos como el inicio de vasopresores o la evolución hemodinámica del paciente [Johnson et al. \(2023\)](#).

Para la evaluación de la generalización de los modelos fuera del entorno de desarrollo, la base de datos eICU-CRD (*eICU Collaborative Research Database*) constituye un recurso complementario de gran relevancia [Pollard et al. \(2018\)](#). A diferencia de MIMIC-IV, eICU-CRD agrega datos de centenares de hospitales de Estados Unidos, lo que permite evaluar si un modelo

entrenado en un único centro mantiene su rendimiento en una población más heterogénea y con prácticas clínicas potencialmente distintas [Pollard et al. \(2018\)](#). Esta característica la convierte en un entorno especialmente adecuado para la validación externa de modelos desarrollados sobre MIMIC-IV.

La estimación del riesgo de inicio de noradrenalina exige definir ventanas de observación y de predicción clínicamente plausibles, utilizando únicamente la información disponible antes del evento. Ambas bases de datos comparten una estructura temporal que hace posible este tipo de diseño retrospectivo.

Dentro de este marco, el aprendizaje automático ha adquirido un papel creciente en la predicción de eventos clínicos en pacientes críticos. En datos clínicos tabulares se emplean con frecuencia algoritmos como la regresión logística, Random Forest, XGBoost, LightGBM o CatBoost, que permiten modelar relaciones no lineales e interacciones complejas entre variables. Su atractivo radica en la capacidad para combinar simultáneamente información procedente de múltiples dominios clínicos, algo difícil de reproducir con reglas clínicas simples o con modelos univariantes. Sin embargo, este aumento de capacidad predictiva suele ir acompañado de una menor interpretabilidad, lo que supone una limitación importante cuando el objetivo final es apoyar decisiones clínicas reales.

Interpretabilidad y explicabilidad de modelos

En aplicaciones clínicas, la interpretabilidad del modelo no constituye un elemento accesorio, sino un requisito relevante para facilitar la confianza del profesional sanitario y permitir una evaluación crítica de la predicción generada. En este contexto, adquieren relevancia técnicas de explicación como SHAP (*SHapley Additive exPlanations*), que permiten descomponer la predicción de un modelo en la contribución individual de cada variable [Lundberg and Lee \(2017\)](#).

Este enfoque ofrece una doble utilidad. Por un lado, permite identificar qué variables son más influyentes a nivel global dentro de la cohorte, lo que facilita interpretar el comportamiento general del modelo. Por otro, hace posible explicar predicciones concretas a nivel individual, mostrando qué factores empujan el riesgo estimado en una u otra dirección para un paciente determinado [Lundberg and Lee \(2017\)](#). En un entorno de apoyo a la decisión clínica, esta capacidad puede resultar especialmente valiosa, ya que aproxima la salida del modelo a un razonamiento más comprensible para el profesional.

Estado del arte y trabajos relacionados

Entre los estudios más próximos al objetivo de este TFG destaca el trabajo de Duval et al., que desarrollaron un modelo interpretable basado en historia clínica electrónica para predecir el inicio de perfusión continua de vasopresores en pacientes sépticos ingresados en UCI a partir de datos de MIMIC-IV [Duval et al. \(2025\)](#). El modelo utilizó variables medidas en la ventana de -6 a -2 horas respecto al inicio del tratamiento y el mejor clasificador fue un *Random Forest* con un AUROC de 0,75. Entre los predictores más relevantes se encontraban el descenso de la presión arterial media entre -2 y -4 horas, un lactato $> 2,5$ mmol/L y valores de hematocrito fuera del rango 30-37 % [Duval et al. \(2025\)](#). Los autores señalan, además, que las alertas del modelo podrían generarse entre 2 y 4 horas antes del inicio del vasopresor, lo que apoya la viabilidad técnica de anticipar este tipo de decisión terapéutica [Duval et al. \(2025\)](#). No obstante, el propio estudio subraya que se trata de una validación interna y que aún se requiere validación externa y evaluación prospectiva antes de plantear una implementación clínica real.

Junto a este trabajo, existen otros estudios relacionados que contribuyen a contextualizar el problema, aunque orientados a objetivos clínicos sutilmente distintos. Scheibner et al. desarrollaron y validaron externamente modelos de aprendizaje automático para predecir la respuesta a la vasopresina como segundo vasopresor en pacientes con shock séptico tratados con noradrenalina, mostrando un rendimiento modesto y poniendo de manifiesto la complejidad de anticipar la respuesta farmacológica individual [Scheibner et al. \(2022\)](#). En una línea diferente, Persson et al. realizaron un ensayo clínico aleatorizado y prospectivo para validar un algoritmo de predicción temprana de sepsis en pacientes críticos, demostrando que este tipo de sistemas puede evaluarse más allá del entorno retrospectivo y en condiciones más próximas a la práctica clínica real [Persson et al. \(2024\)](#). Aunque su objetivo no fue la monitorización de vasopresores, este estudio refuerza la relevancia de avanzar hacia diseños de validación más cercanos al uso asistencial.

Otros trabajos han abordado tareas más complejas, como la predicción continua de dosis o la optimización de decisiones terapéuticas mediante modelos temporales y aprendizaje por refuerzo. Jiang et al. propusieron ChronoSynthNet, un modelo con componentes *Transformer* y LSTM para estimar en tiempo real la dosis de noradrenalina y detectar precozmente hipotensión en pacientes con shock séptico [Jiang et al. \(2025\)](#). Este tipo de enfoques aprovecha mejor la naturaleza temporal de los datos, pero también incrementa de forma notable la complejidad metodológica. En paralelo, los enfoques de aprendizaje por refuerzo han intentado derivar políticas terapéuticas para orientar decisiones hemodinámicas en sepsis. Por ejemplo, Zhang et al. describieron un modelo orientado a optimizar estrategias de

tratamiento mediante recomendaciones sobre vasopresores y fluidoterapia, incorporando mecanismos para reducir ajustes bruscos de dosis [Zhang et al. \(2024\)](#), mientras que el estudio OVISS exploró el momento óptimo de inicio de vasopresina en pacientes con shock séptico tratados con noradrenalina [Kalimoultou et al. \(2025\)](#). Aunque estos trabajos son metodológicamente ambiciosos, responden a preguntas clínicas distintas y más complejas que la estimación temprana del primer inicio de noradrenalina.

Limitaciones de la literatura y posicionamiento del TFG

A pesar del avance metodológico observado, la literatura disponible presenta varias limitaciones recurrentes. En primer lugar, muchos estudios continúan evaluando su rendimiento principalmente mediante métricas de discriminación retrospectiva, especialmente el AUROC, sin trasladar de forma suficiente esos resultados a escenarios de uso clínico real [Shanmugam et al. \(2025\)](#). En segundo lugar, la validación externa sigue siendo limitada en una parte importante de los trabajos publicados, lo que dificulta valorar la robustez de los modelos fuera del centro o cohorte de desarrollo [Rockenschaub et al. \(2025\)](#). Además, una proporción relevante de los estudios permanece en fases de validación retrospectiva o de prueba de concepto, lo que limita la estimación de su utilidad operativa real y refuerza la necesidad de modelos interpretables y clínicamente integrables [Shanmugam et al. \(2025\)](#); [Rockenschaub et al. \(2025\)](#).

A partir de esta revisión, el nicho del presente TFG queda claramente definido. El interés del trabajo no reside únicamente en desarrollar un modelo predictivo adicional, sino en abordar un problema clínico concreto y accionable: la estimación temprana del riesgo de inicio de noradrenalina en pacientes críticos a partir de variables disponibles durante las primeras horas de estancia, sobre una cohorte general de adultos en UCI sin restricción diagnóstica. La propuesta añade, además, tres elementos de interés práctico: el uso de modelos con selección de variables por ventana, la traducción del resultado a una interfaz funcional tipo *dashboard* y la validación externa sobre una cohorte multicéntrica independiente. De este modo, el trabajo se orienta no solo a la obtención de un buen rendimiento predictivo, sino también a su posible utilidad como herramienta de apoyo a la decisión clínica.

Metodología

El trabajo se estructuró en tres fases principales: construcción de las cohortes, desarrollo y evaluación interna de los modelos sobre MIMIC-IV, y validación externa sobre eICU-CRD. El objetivo metodológico central fue definir tres ventanas temporales clínicamente diferenciadas: corta (observación 0–3 h, predicción 3–12 h), media (observación 0–6 h, predicción 6–24 h) y larga (observación 0–12 h, predicción 12–48 h), con el fin de cubrir distintos escenarios asistenciales, desde la detección precoz de deterioro hemodinámico inminente hasta la identificación de pacientes con riesgo de evolución desfavorable en un plazo más amplio. En todos los casos, los predictores se extrajeron exclusivamente de periodos anteriores al inicio de la noradrenalina, evitando cualquier fuga de información desde el evento hacia el modelo.

4.1. Datos y variables por ventana

La cohorte de entrenamiento y evaluación interna se construyó a partir de MIMIC-IV. El acceso a esta base de datos requirió completar el curso de formación en investigación con datos humanos del CITI Program ([CITI Program, 2026](#)), registrar el proyecto en PhysioNet ([PhysioNet, 2026](#)), esperar su aprobación y firmar el correspondiente acuerdo de uso de datos. Dicho acuerdo obliga, entre otros aspectos, a no intentar reidentificar pacientes, no redistribuir los datos y publicar el código necesario para la reproducibilidad del proyecto en un repositorio público.

Inicialmente se valoró utilizar como cohorte de validación externa datos desidentificados de la UCI del Hospital Universitario de Burgos (HUBU), con el objetivo de evaluar la extrapolabilidad a un contexto sanitario europeo.

Esta opción fue descartada por la dificultad técnica de extraer de forma homogénea todas las variables requeridas y por la marcada heterogeneidad entre los sistemas asistenciales de ambas cohortes, que afectaba no solo al origen geográfico de los pacientes sino principalmente a criterios de ingreso en UCI, intensidad de monitorización, disponibilidad de variables y pautas de tratamiento.

A pesar de ello, se elaboró el documento requerido para el Comité de Ética en Investigación del HUBU. Una vez confirmada la viabilidad de extracción de las variables necesarias, se prevé solicitar su aprobación para realizar una validación externa sobre estos datos del HUBU. Esta validación tendría una doble finalidad: evaluar la extrapolabilidad antes mencionada y explorar su posible publicación científica una vez identificados todos los aspectos a considerar.

Finalmente se seleccionó eICU-CRD ([Pollard et al., 2018](#)) como cohorte de validación externa. Aunque también procede de población norteamericana, su carácter multicéntrico permite evaluar el rendimiento de los modelos en un entorno interhospitalario heterogéneo, con variabilidad real entre centros y prácticas asistenciales, abordando una de las principales limitaciones que presentaban la mayor parte de estudios publicados y mencionados en el estado del arte. Al mismo tiempo, mantiene una mayor comparabilidad estructural con MIMIC-IV que la disponible inicialmente con los datos del HUBU. Los requisitos de acceso y utilización fueron equivalentes a los de MIMIC-IV, al tratarse también de una base de datos alojada en PhysioNet.

La selección inicial de variables para la cohorte de desarrollo se basó en criterios clínicos y disponibilidad en MIMIC-IV, priorizando constantes vitales, parámetros analíticos, variables respiratorias y marcadores de función orgánica con relación fisiopatológica plausible con el deterioro hemodinámico. La selección se apoyó además en el Protocolo Código Sepsis del HUBU, lo que garantizó que el conjunto inicial de predictores no se definiera únicamente por disponibilidad técnica sino también por relevancia clínica. Algunas variables inicialmente consideradas, como la procalcitonina o la proteína C reactiva, se descartaron por no estar disponibles de forma suficientemente completa o estructurada en MIMIC-IV.

Se identificaron todas las estancias en UCI y se exigió una duración mínima que garantizara que el horizonte de predicción quedara completamente contenido dentro del seguimiento disponible: más de 24 horas para las ventanas Corto y Medio, y más de 48 horas para la ventana Largo. Este criterio evita casos negativos falsos en pacientes cuya estancia fue demasiado breve para observar el evento.

El evento objetivo fue el primer inicio de perfusión de noradrenalina durante la estancia en UCI, localizado en MIMIC-IV a partir del `itemid` 221906 de la tabla `inputevents`. Se excluyeron las estancias en las que la noradrenalina se había iniciado antes del comienzo de la ventana de observación, garantizando que todos los predictores procedieran de un periodo libre de tratamiento vasopresor.

Para cada ventana temporal se asignó una etiqueta binaria. Una estancia recibió etiqueta positiva (1) cuando el primer inicio de perfusión de noradrenalina ocurrió estrictamente dentro del intervalo de predicción definido para esa ventana. Por el contrario, recibió etiqueta negativa (0) cuando no ocurrió dentro de dicho horizonte. La etiqueta negativa incluye dos situaciones: pacientes que nunca requirieron soporte vasopresor durante toda su estancia en UCI y pacientes que iniciaron noradrenalina fuera del horizonte predictivo evaluado, por ejemplo de forma tardía una vez cerrada la ventana de predicción.

La presencia de sepsis se identificó mediante la tabla derivada `mimicv_derived.sepsis3`. La puntuación SOFA se obtuvo a partir de `mimicv_derived.sofa`. Ambas tablas proceden del repositorio oficial de scripts derivados de MIMIC-IV mantenido por MIT-LCP ([MIT Laboratory for Computational Physiology, 2024](#)), que implementa los criterios Sepsis-3.

La puntuación SOFA se incorporó como variable predictora. La variable de sepsis se utilizó principalmente como variable de análisis diferencial por subgrupos, dada su importancia clínica y su relación directa con el inicio de soporte vasopresor.

La cohorte de validación externa se construyó mediante consultas SQL sobre las tablas de eICU-CRD, alojadas en el mismo entorno local que MIMIC-IV. Se aplicaron las mismas restricciones de estancia mínima obligatoria utilizadas en la cohorte de desarrollo.

En eICU-CRD, el evento objetivo se identificó a partir de la tabla `infusionDrug`. Se buscaron perfusiones cuyo nombre de fármaco contuviera los términos *norepinephrine* o *levophed* (nombre comercial). Se excluyeron las entradas que contenían el término *volume*, con el fin de evitar falsos positivos relacionados con soluciones de reposición o registros no correspondientes a perfusión vasopresora. Para cada estancia se registró el primer inicio de noradrenalina en horas desde el ingreso en UCI. Se aplicaron los mismos criterios de exclusión de noradrenalina precoz y de asignación de etiqueta binaria utilizados en la cohorte de entrenamiento.

Cálculo del SOFA (ventana 24 h)	Detección de Sepsis-3
Para cada hora h de la estancia: Respiratorio: $P/F < 100 \rightarrow 4$, $< 200 \rightarrow 3$, $< 300 \rightarrow 2$, $< 400 \rightarrow 1$ Coagulación: $plt < 20 \rightarrow 4$, $< 50 \rightarrow 3$, $< 100 \rightarrow 2$, $< 150 \rightarrow 1$ Hepático: $bili \geq 12 \rightarrow 4$, $\geq 6 \rightarrow 3$, $\geq 2 \rightarrow 2$, $\geq 1.2 \rightarrow 1$ Cardiovascular: $norepi > 0.1 \rightarrow 4$, $\leq 0.1 \rightarrow 3$, dopamina $> 0 \rightarrow 2$, MAP $< 70 \rightarrow 1$ Neurológico: $GCS < 6 \rightarrow 4$, $6-9 \rightarrow 3$, $10-12 \rightarrow 2$, $13-14 \rightarrow 1$ Renal: $creat \geq 5 \rightarrow 4$, $\geq 3.5 \rightarrow 3$, $\geq 2 \rightarrow 2$, $\geq 1.2 \rightarrow 1$ Componente _{24h} $\leftarrow$ MAX(componente, 23 h) SOFA _{24h} $\leftarrow \sum 6$ componentes _{24h}	Para cada antibiótico administrado: Si cultivo en $\pm 72/24$ h del antibiótico: sospesa $\leftarrow$ verdadero $t_s \leftarrow \min(t_{\text{cultivo}}, t_{\text{antibiótico}})$ Para cada evento de sospecha: Si $\exists$ SOFA ≥ 2 en $[t_s - 48h, t_s + 24h]$: sepsis3 $\leftarrow$ verdadero $t_{\text{onset}} \leftarrow$ primer endtime con SOFA ≥ 2 Devolver registro más temprano con sospecha $\wedge$ SOFA ≥ 2

Tabla 4.1: Pseudocódigo de los algoritmos del repositorio MIT-LCP para el cálculo horario del SOFA y la detección del *onset* de Sepsis-3 en MIMIC-IV [Johnson et al. \(2023\)](#) MIT Laboratory for Computational Physiology (2024).

A diferencia de MIMIC-IV, eICU-CRD no dispone de tablas derivadas precalculadas para SOFA ni para sepsis. Por ello, el índice SOFA se calculó específicamente en SQL a partir de sus seis componentes fundamentales y de manera similar a como se calcula en el repositorio del MIT-LCP. En eICU-CRD no fue posible obtener un indicador de sepsis equivalente al disponible en MIMIC-IV. Aunque eICU-CRD dispone de información microbiológica estructurada en la tabla `microLab`, esta se encuentra poco poblada debido a la disponibilidad limitada de interfaces de microbiología en los distintos centros participantes, según la documentación oficial.

Se valoró aproximar la sepsis mediante los diagnósticos registrados en la tabla `diagnosis`, incluyendo códigos ICD y descripciones clínicas compatibles. Sin embargo, esta opción se descartó por no considerarse metodológicamente equivalente. Estos diagnósticos reflejan problemas documentados durante la estancia en UCI, pero no permiten reconstruir de forma fiable la sospecha de infección según Sepsis-3 ni garantizar una correspondencia

homogénea con el criterio empleado en MIMIC-IV. Por tanto, el análisis diferencial por subgrupos de sepsis se realizó únicamente sobre la cohorte de MIMIC-IV.

El tratamiento de datos faltantes se abordó con un criterio estricto. Se descartó la imputación estadística en las variables predictoras de MIMIC-IV y eICU-CRD, así como en los componentes del SOFA calculado para eICU-CRD. Esta decisión evitó introducir valores sintéticos basados en supuestos sobre el mecanismo de ausencia de datos. Por tanto, se conservaron únicamente las estancias con registros completos en las variables analizadas.

Este filtrado modificó la composición de las cohortes finales, como se recoge en las Tabla 4.2 y Tabla 4.3. En MIMIC-IV, la prevalencia del evento aumentó del 4–6 % en las cohortes brutas al 10–11 % tras el filtro; en eICU-CRD, el incremento fue del 3–4 % al 10–14 %. Este cambio es compatible con un sesgo de monitorización esperable en UCI: los pacientes con analíticas completas, gases arteriales, constantes frecuentes y control de diuresis suelen corresponder a perfiles de mayor gravedad percibida.

Tabla 4.2: Efecto del filtro de completitud sobre el tamaño y la prevalencia de cada cohorte de entrenamiento (MIMIC-IV).

	Estancias Ventana brutas	Prevalencia bruta	Estancias tras filtro	Prevalencia tras filtro
Corto (3–12 h)	67.858	5,29 %	1.667	10,32 %
Medio (6–24 h)	65.825	4,31 %	3.282	10,30 %
Largo (12–48 h)	38.051	5,63 %	4.088	11,15 %

Tabla 4.3: Efecto del filtro de completitud sobre el tamaño y la prevalencia de cada cohorte de validación externa (eICU-CRD).

	Estancias Ventana brutas	Prevalencia bruta	Estancias tras filtro	Prevalencia tras filtro
Corto (3–12 h)	125.124	3,65 %	789	14,45 %
Medio (6–24 h)	122.922	3,46 %	1.396	11,89 %
Largo (12–48 h)	68.778	3,91 %	2.030	9,80 %

Aunque este filtrado reduce el tamaño muestral y selecciona una población de mayor gravedad, también aproxima la cohorte hacia la población diana real del modelo: pacientes con alta intensidad de monitorización y sospecha de deterioro hemodinámico. Las estancias excluidas podrían corresponder a ingresos postquirúrgicos breves o cuadros de baja complejidad, escenarios donde la necesidad de soporte vasopresor es poco frecuente y donde una herramienta predictiva de este tipo tendría menor valor asistencial.

Antes del modelado se realizó un análisis exploratorio de la cohorte de MIMIC-IV mediante un *notebook* de Jupyter. Para cada variable continua se revisaron estadísticos descriptivos, percentiles extremos y distribuciones estratificadas por etiqueta, identificando asimetrías, colas pesadas y valores extremos frecuentes en variables clínicas de pacientes críticos.

Para el tratamiento de valores extremos se siguió una estrategia coherente con el preprocesamiento propuesto por Gupta et al. (Gupta et al., 2022) para MIMIC-IV, donde los outliers de variables clínicas pueden tratarse mediante umbrales percentilares definidos por el usuario, eliminando o reemplazando los valores situados fuera del intervalo. En este trabajo se optó por la segunda alternativa, equivalente a una winsorización, sustituyendo los valores por debajo del percentil 2 y por encima del percentil 98 por los límites correspondientes.

La eliminación directa de filas se descartó porque en UCI un valor extremo no es necesariamente un error de registro, sino que puede reflejar la situación real de un paciente crítico. Prescindir de esas estancias habría introducido un sesgo de selección adicional sobre una cohorte ya filtrada por

completitud. La imputación de valores extremos también se descartó, por el mismo motivo que en el tratamiento de datos faltantes: introducir valores sintéticos exige asumir supuestos sobre la distribución real que no pueden verificarse con los datos disponibles.

La winsorización se aplicó de forma uniforme a todas las variables clínicas continuas, utilizando los percentiles 2 y 98 calculados en MIMIC-IV. El procedimiento se realizó sobre los estadísticos agregados por estancia y ventana —media, mínimo y máximo—, no sobre las mediciones individuales en bruto, ya que la unidad de análisis del modelo era la estancia. Así, el objetivo fue limitar valores extremos capaces de distorsionar los resúmenes usados como predictores, sin eliminar picos puntuales que podrían reflejar transitorios clínicos reales.

Como ejemplo, valores de MAP inferiores a 20 mmHg o superiores a 200 mmHg en el resumen de una ventana de observación son difícilmente atribuibles a una situación fisiológica mantenida y resultan más compatibles con artefactos de monitorización, errores de transcripción o problemas de calibración.

Quedaron excluidas de la winsorización las variables con rango acotado por definición —Glasgow (3–15) y SOFA (0–24)— y las variables binarias, para las que el procedimiento carece de sentido. Los percentiles 2 y 98 se calcularon exclusivamente sobre MIMIC-IV y se almacenaron en un fichero de referencia aplicado posteriormente a eICU-CRD, de modo que el tratamiento de valores extremos en la cohorte externa utilizó parámetros aprendidos únicamente en la cohorte de entrenamiento.

Con el objetivo de identificar redundancias en el espacio de predictores, se calculó la matriz de correlación de Spearman sobre las 76 variables del conjunto inicial, utilizando únicamente la primera estancia por paciente para evitar que las réplicas de un mismo sujeto inflaran artificialmente las asociaciones. Se eligió Spearman frente a Pearson por su mayor robustez ante distribuciones asimétricas, relaciones no lineales monótonas y valores extremos residuales.

La matriz de correlación mostró bloques de alta redundancia entre los tres estadísticos de resumen de una misma variable fisiológica —media, mínimo y máximo—, con correlaciones superiores a 0,7 de forma sistemática. Este patrón era esperable, ya que los tres estadísticos proceden de la misma señal clínica dentro de la misma ventana de observación. También se observaron asociaciones moderadas-altas entre variables fisiopatológicamente relacionadas, como PAFI y sus componentes, o entre marcadores de función hepática como GPT, GOT y bilirrubina. Para complementar la matriz, se




Figura 4.1: Análisis de correlación y estructura de agrupamiento de las 76 variables predictoras (MIMIC-IV, ventana Medio). Izquierda: matriz de correlación de Spearman. Derecha: dendrograma jerárquico con corte en $|\rho| = 0,7$.

construyó un dendrograma jerárquico mediante enlace promedio sobre la distancia $1 - |\rho|$. Este análisis confirmó la formación de grupos compactos dentro de cada variable fisiológica y la presencia de agrupaciones entre magnitudes clínicamente relacionadas.

A partir de estos resultados se aplicó una reducción inicial del espacio de predictores. En primer lugar, se seleccionó un único estadístico de resumen por variable fisiológica, priorizando el criterio clínico. Se conservó el mínimo cuando el peor estado del paciente se asociaba a valores bajos, como MAP, P/F, SpO₂, GCS, pH, bicarbonato, plaquetas o hemoglobina; y el máximo cuando el peor estado se asociaba a valores elevados, como creatinina, lactato, frecuencia respiratoria, tiempo de protrombina, SOFA o FiO₂.

En las variables donde existían varios estadísticos clínicamente plausibles, la elección se apoyó en un desempate estadístico basado en el AUC univariante, la d de Cohen y la dirección de la diferencia entre pacientes positivos y negativos. El AUC permitió valorar la capacidad discriminativa aislada, mientras que la d de Cohen cuantificó la magnitud del efecto entre grupos. Cuando las diferencias entre estadísticos fueron pequeñas o la

interpretación clínica no era inequívoca, se priorizó el resumen con mayor coherencia fisiopatológica y menor redundancia con el resto de predictores.

Tras seleccionar un único estadístico por variable, se eliminaron predictores redundantes por solapamiento de información. La PaO_2 se descartó por estar ya incorporada en el cociente P/F, la GOT por su elevada correlación con GPT, y `tiene_sepsis` por reservarse para el análisis diferencial por subgrupos y no estar disponible de forma equivalente en eICU-CRD. En la ventana larga se eliminó adicionalmente `fio2_max` por su alta correlación con P/F.

El conjunto final, tras eliminar `fio2_max` en las tres ventanas, quedó reducido a 25 variables. La correlación máxima residual fue $|\rho| = 0,514$ (bilirrubina media – plaquetas mínimas) en la ventana corta, $|\rho| = 0,473$ (ventilación invasiva – GCS mínimo) en la media y $|\rho| = 0,516$ (ventilación invasiva – GCS mínimo) en la larga, muy por debajo del umbral de $|\rho| = 0,7$. Esto indica ausencia de multicolinealidad relevante en el espacio de predictores final.




Figura 4.2: Dendrogramas de agrupamiento jerárquico sobre el conjunto final de variables predictoras en cada ventana temporal. Distancia = $1 - |\rho|$; línea roja: $|\rho| = 0,7$; línea naranja: $|\rho| = 0,5$.

Con el fin de identificar qué variables contribuían de forma significativa al rendimiento de cada clasificador evaluado —regresión logística, Naive Bayes, Random Forest, LightGBM, XGBoost y CatBoost—, se utilizó una validación cruzada anidada con estructura 5×3 . El bucle externo dividió las estancias en cinco particiones mediante `StratifiedGroupKFold`, manteniendo la proporción de positivos y negativos y garantizando que todas las estancias de un mismo paciente quedaran en el mismo fold, para evitar fuga de información entre observaciones del mismo sujeto. El bucle interno repitió el mismo esquema con tres particiones para la búsqueda de hiperparámetros mediante `GridSearchCV`. En cada fold externo, el modelo

con los mejores hiperparámetros seleccionados internamente se reentrenó sobre el conjunto de entrenamiento completo del fold y se evaluó sobre el conjunto de test, que no había participado ni en el entrenamiento ni en la selección de hiperparámetros. En la regresión logística y en Naive Bayes se integró **RobustScaler** dentro del **pipeline**, de forma que la normalización se ajustara exclusivamente sobre los datos de entrenamiento de cada fold.

Sobre el conjunto de test de cada fold externo se calculó la importancia por permutación (*permutation importance*). Para ello, cada variable se permutó aleatoriamente 50 veces y se registró la caída resultante en el AUC-ROC. Una variable se consideró significativa para un modelo dado cuando el intervalo de confianza al 95 % de dicha caída —calculado mediante los percentiles 2,5 y 97,5 de las caídas observadas en las repeticiones y folds— excluía el cero, indicando una contribución positiva distinguible de la variación aleatoria. Este proceso se ejecutó de forma independiente para cada algoritmo y ventana temporal. Paralelamente, se realizó un análisis univariante sobre la primera estancia de cada paciente para evitar dependencias entre observaciones del mismo sujeto. Para las variables continuas se aplicó el test de Mann-Whitney U y para las variables binarias el test chi-cuadrado. Los p-valores se corrigieron mediante Benjamini-Hochberg ($FDR\ q < 0,05$) para controlar la tasa de falsos descubrimientos por comparaciones múltiples.




Figura 4.3: Importancia por permutación de cada variable para los seis algoritmos evaluados, en cada ventana temporal. Las barras representan la caída media de AUC-ROC al permutar la variable; los intervalos de confianza al 95 % se calcularon sobre los 5 folds externos. Las variables cuyo IC95 % excluye el cero se consideraron estadísticamente significativas para ese regresor.

Que una variable sea significativa en la *permutation importance* no garantiza que su asociación sea fisiopatológicamente coherente: podría reflejar

un artefacto de la muestra, una correlación espuria o una dirección contraria a la esperada clínicamente. Por ello, se calculó sobre la primera estancia por paciente el *odds ratio* ajustado mediante regresión logística multivariante, incluyendo todas las variables del conjunto reducido y estandarizándolas previamente para hacer comparables los coeficientes. La dirección del OR ajustado se contrastó con la dirección observada en los datos brutos. Cuando los pacientes positivos presentaban valores más altos de una variable pero el OR ajustado era menor que 1, o viceversa, se interpretó como una incoherencia de dirección compatible con supresión estadística, confusión residual o colinealidad no completamente eliminada.

Las variables que mostraron incoherencias claras entre la dirección observada en los datos brutos y el OR ajustado fueron revisadas individualmente. Cuando la inversión de dirección no resultaba clínicamente justificable y era compatible con supresión estadística, confusión residual o artefactos de la muestra, la variable se excluyó del conjunto final de la ventana correspondiente. En la ventana media se eliminaron por este criterio `creatinina_max`, `ph_min` y `gpt_max`. En la ventana corta se eliminaron `creatinina_max` y `gpt_max`. En la ventana larga se eliminaron `ph_min`, `lactato_max` y `gpt_max`, esta última por mostrar un comportamiento incoherente de forma repetida en las tres ventanas.

4.2. Baseline final y métricas

La elección de algoritmos buscó cubrir distintos niveles de complejidad y familias de aprendizaje supervisado sobre datos tabulares: modelos lineales, probabilísticos, ensamblados por *bagging* y métodos de *gradient boosting*. Además, se priorizaron algoritmos con implementaciones maduras, uso extendido en problemas clínicos/tabulares e interpretabilidad posterior mediante SHAP, evitando modelos difícilmente auditables.

Se evaluaron seis algoritmos de clasificación supervisada: regresión logística, Naive Bayes gaussiano, Random Forest, XGBoost, LightGBM y CatBoost. La regresión logística se incluyó como modelo lineal de referencia, mientras que Naive Bayes actuó como modelo probabilístico basal. Random Forest representó los métodos de ensamblado por *bagging*, capaces de capturar relaciones no lineales mediante múltiples árboles de decisión. XGBoost, LightGBM y CatBoost se incluyeron como implementaciones modernas de *gradient boosting*, ampliamente utilizadas en problemas tabulares por su capacidad para modelar interacciones y relaciones no lineales.

La prevalencia del evento positivo tras el filtro de completitud se situó aproximadamente entre el 10 % y el 11 % según la ventana, por lo que se consideró un problema con desbalance moderado de clases. Para mitigarlo, en regresión logística, Random Forest y LightGBM se emplearon esquemas de ponderación mediante `class_weight='balanced'`, incluyendo también `balanced_subsample` en el caso de Random Forest. En XGBoost se exploraron distintos valores de `scale_pos_weight`, parámetro equivalente para ajustar el peso relativo de la clase positiva. En CatBoost y Naive Bayes no se incorporó un parámetro específico de balanceo en el diseño experimental.

El escalado se aplicó únicamente a los modelos sensibles a la magnitud de las variables, concretamente la regresión logística y Naive Bayes gaussiano. En ambos casos se utilizó `RobustScaler`, que centra las variables mediante la mediana y las escala según el rango intercuartílico, reduciendo la influencia de valores extremos residuales tras la winsorización. Los modelos basados en árboles —Random Forest, XGBoost, LightGBM y CatBoost— no requirieron escalado, ya que sus particiones dependen del orden relativo de los valores y son invariantes a transformaciones monótonas. Adicionalmente, el escalado se integró dentro del *pipeline* de scikit-learn, de modo que sus parámetros (medianas y rangos intercuartílicos) se ajustaron exclusivamente sobre los datos de entrenamiento de cada fold, evitando así fuga de información desde el conjunto de test.

Para cada algoritmo se definió un *grid* específico de hiperparámetros, orientado a controlar la complejidad del modelo, la regularización, el balanceo de clases y el riesgo de sobreajuste. La búsqueda se realizó mediante `GridSearchCV` dentro del bucle interno de la validación cruzada anidada. En conjunto, los *grids* exploraron el parámetro de regularización C en regresión logística; el número de árboles, profundidad, tamaño mínimo de hoja y selección de variables en Random Forest; número de estimadores, profundidad, tasa de aprendizaje, regularización y muestreo en XGBoost, LightGBM y CatBoost; y el parámetro `var_smoothing` en Naive Bayes.

El rendimiento de cada modelo se estimó mediante la validación cruzada anidada 5×3 ya descrita, optimizando el AUC-ROC en la búsqueda interna de hiperparámetros.

La evaluación combinó métricas de discriminación, rendimiento probabilístico y calibración. Como métricas discriminativas se emplearon AUC-ROC y AUC-PR. El AUC-ROC mide la capacidad del modelo para ordenar correctamente a los pacientes según su riesgo, mientras que el AUC-PR resulta especialmente informativo en problemas con desbalance de clases, al evaluar el rendimiento sobre la clase positiva.

Para evaluar el rendimiento probabilístico se calcularon el Brier score, el Brier Skill Score (BSS) y la LogLoss. El Brier score mide el error cuadrático medio entre probabilidades predichas y etiquetas reales, mientras que el BSS compara dicho error frente a un modelo nulo que predice siempre la prevalencia del evento:

$$\text{BSS} = 1 - \frac{\text{Brier}_{\text{modelo}}}{\text{Brier}_{\text{nulo}}}$$

Un BSS positivo indica que el modelo mejora la predicción trivial basada únicamente en la prevalencia. La LogLoss complementa esta evaluación penalizando especialmente las predicciones erróneas realizadas con alta confianza.

Finalmente, la calibración se evaluó mediante el Expected Calibration Error (ECE), calculado agrupando las predicciones en 10 intervalos y comparando la probabilidad media predicha con la frecuencia observada del evento. Esta métrica fue especialmente relevante porque el objetivo del sistema es mostrar probabilidades interpretables, no solo ordenar pacientes por riesgo.

La validación cruzada anidada proporciona una estimación del rendimiento generalizable, pero no genera un único modelo final, ya que en cada fold externo se entrena un modelo distinto con hiperparámetros potencialmente diferentes. Por ello, tras completar la validación, se seleccionó para cada hiperparámetro el valor más frecuente entre los cinco folds externos y se reentrenó el `pipeline` completo sobre el 100 % de la cohorte de MIMIC-IV. Los modelos finales se serializaron en formato `.pkl` mediante `joblib`, lo que permitió reutilizarlos posteriormente en la validación externa sobre eICU-CRD y en el prototipo de *dashboard*.

Aunque la validación cruzada anidada proporciona la estimación principal del rendimiento, sus resultados se resumen por folds y no permiten obtener directamente curvas globales de ROC, precisión-recall o calibración. Por ello, se generaron predicciones *out-of-fold* (OOF) mediante `cross_val_predict`, utilizando el mismo esquema externo `StratifiedGroupKFold` con cinco particiones, semilla fija y agrupamiento por `subject_id`. De este modo, cada estancia recibió una probabilidad estimada por un modelo que no había visto a ese paciente durante el entrenamiento. Las probabilidades OOF concatenadas se utilizaron exclusivamente para construir curvas globales de ROC, precisión-recall y calibración, permitiendo una comparación visual homogénea entre modelos. Para cada combinación de modelo y ventana temporal se generó una figura compuesta por tres paneles: curva ROC con


AUC, curva precisión-recall con AUC-PR y curva de calibración. En la curva precisión-recall se incluyó la línea horizontal correspondiente a la prevalencia del evento como referencia basal. La curva de calibración se construyó con diez bins de igual número de muestras mediante estrategia *quantile*, evitando bins vacíos en regiones de baja densidad de probabilidad predicha.

La discriminación medida por AUC-ROC no garantiza que las probabilidades estén bien calibradas, distinción especialmente relevante para el *dashboard*, donde la probabilidad mostrada debía ser interpretable y no solo una puntuación relativa. Por ello, tras la evaluación inicial se revisaron las curvas de calibración OOF junto con el Expected Calibration Error (ECE) y el Brier Skill Score (BSS). Se consideraron candidatos a recalibración los modelos con buen rendimiento discriminativo pero peor calibración, identificándose CatBoost en las ventanas corta y media, y XGBoost en las tres ventanas.

Para los modelos candidatos se evaluaron tres estrategias de calibración sobre probabilidades OOF: Platt sin regularización, Platt regularizado y regresión isotónica. El método de Platt ajusta una regresión logística sobre las probabilidades brutas, mientras que la isotónica aprende una transformación monótona no paramétrica, más flexible pero más sensible al tamaño muestral. Cada calibrador se entrenó dentro de los cinco folds externos, usando únicamente las probabilidades brutas del conjunto de entrenamiento de cada fold, y se aplicó después sobre el conjunto de test correspondiente. Así, la evaluación de la calibración mantuvo el mismo principio de no fuga de información que el resto del proceso.

El calibrador final se seleccionó priorizando el menor ECE entre los métodos que mantenían un BSS positivo. Esta restricción evitó aceptar calibradores que redujeran el ECE a costa de comprimir las probabilidades hacia la prevalencia y perder capacidad informativa. Cuando ningún calibrador cumplía este criterio, se conservó el modelo sin calibrar. Una vez seleccionado el método, el calibrador se ajustó sobre las probabilidades OOF completas y se serializó junto con el modelo base en una clase `ModeloCalibrado`, compatible con los métodos `predict_proba` y `predict` de `sklearn` para su integración en el *dashboard*.

La interpretabilidad post-hoc se abordó mediante valores SHAP (*SHapley Additive exPlanations*), que descomponen la predicción individual de cada paciente en contribuciones atribuibles a cada variable. A diferencia de la importancia por permutación, que evalúa la relevancia de los predictores a nivel agregado, SHAP permite analizar el efecto de cada variable sobre




(a) Comparación de curvas de calibración y distribución de probabilidades antes y después de la recalibración mediante Platt regularizado para XGBoost en la ventana media.

Figura 4.4


una predicción concreta, así como su importancia global y la dirección de su asociación con el riesgo estimado.

El cálculo de SHAP se adaptó al tipo de modelo. En los algoritmos basados en árboles —Random Forest, XGBoost, LightGBM y CatBoost— se utilizó **TreeExplainer**; en la regresión logística, **LinearExplainer**; y en Naive Bayes, **KernelExplainer**. La visualización se realizó mediante diagramas *beeswarm* (*summary plots*), que representan para cada variable la magnitud del impacto sobre la predicción, la dirección del efecto y el valor original de la variable. Esto permitió verificar si los modelos asociaban mayor riesgo a patrones clínicamente esperables —hipotensión, peor oxigenación, deterioro neurológico o marcadores de disfunción orgánica— y comprobar que, tras el tratamiento de valores extremos, las predicciones no dependían de artefactos aislados de registro. Por tanto, SHAP no se empleó como técnica de selección automática de variables, sino como una capa de auditoría e interpretabilidad para reducir el carácter de “caja negra” de los modelos finales.


Tras seleccionar y calibrar el modelo final de cada ventana, se evaluó su rendimiento por subgrupos clínicos según presencia o ausencia de sepsis. El objetivo fue comprobar si el comportamiento del modelo era homogéneo entre ambos grupos, dado que el inicio de noradrenalina es especialmente frecuente en el contexto del shock séptico. Este análisis se realizó exclusivamente en MIMIC-IV, ya que en eICU-CRD no fue posible construir un indicador de



(a) Ventana corta: CatBoost, 3–12 h



(b) Ventana media: XGBoost, 6–24 h



(c) Ventana larga: XGBoost, 12–48 h

Figura 4.5: Ejemplos de diagramas SHAP tipo *beeswarm* de los modelos por ventana temporal.

sepsis equivalente al empleado en la cohorte de desarrollo, como se justificó previamente.

Para mantener una evaluación sin fuga de información, se utilizaron probabilidades OOF calibradas. En cada fold externo, el modelo base y el calibrador se ajustaron únicamente sobre el conjunto de entrenamiento y se aplicaron después sobre el conjunto de test correspondiente. Las probabilidades resultantes se estratificaron según la variable `tiene_sepsis` en tres grupos: cohorte global, pacientes con sepsis según Sepsis-3 y pacientes sin sepsis identificada. En cada subgrupo se calcularon las mismas métricas que en la evaluación global: AUC-ROC, AUC-PR, BSS y ECE.

Como referencia clínica, se comparó el rendimiento del modelo con la puntuación SOFA utilizada como predictor aislado. Dado que SOFA es una escala ordinal y no una probabilidad calibrada, la comparación se limitó a métricas basadas en ranking, AUC-ROC y AUC-PR. La comparación se realizó sobre los mismos pacientes y etiquetas empleados para evaluar el modelo, de forma que las diferencias observadas reflejaran la capacidad predictiva adicional del modelo frente a una escala clínica ampliamente utilizada en UCI.

4.3. Dashboard clínico y limitaciones de uso

Como parte final del trabajo se desarrolló un prototipo de *dashboard* clínico en Python utilizando Streamlit. El objetivo de esta aplicación no fue sustituir la valoración médica, sino demostrar la viabilidad técnica de integrar los modelos entrenados en una interfaz sencilla, interpretable y orientada a la consulta individual de pacientes. El diseño del *dashboard* siguió deliberadamente un enfoque minimalista. La aplicación permite seleccionar una ventana temporal, cargar un archivo CSV con las variables clínicas del paciente durante el periodo de observación correspondiente y obtener una estimación individualizada del riesgo de inicio de noradrenalina. En la versión final del prototipo se integraron únicamente los modelos de las ventanas media y larga: la ventana media estima el riesgo de inicio entre las 6 y las 24 horas, mientras que la ventana larga estima el riesgo entre las 12 y las 48 horas tras el ingreso. La ventana corta se excluyó del *dashboard* final por su limitada capacidad discriminativa en la validación externa (ver en resultados).

El CSV de entrada contiene una fila por medición del paciente e incluye las variables clínicas necesarias para cada modelo. A partir de estos datos, la aplicación calcula automáticamente los estadísticos agregados requeridos,

como `map_min`, el cociente $\text{PaO}_2/\text{FiO}_2$, la diuresis acumulada normalizada por peso, la frecuencia cardiaca media, el SOFA máximo o los valores mínimos de SpO_2 , bicarbonato, temperatura y glucemia, según la ventana seleccionada. De este modo, el usuario introduce mediciones clínicas ordinarias, no directamente las variables finales del modelo, que son generadas internamente por la aplicación.

Una vez generado el vector de entrada, la aplicación carga el modelo correspondiente desde un archivo `.pkl` mediante `joblib` o `pickle`. La probabilidad estimada se transforma en un percentil de riesgo usando como referencia la distribución de probabilidades obtenida en la cohorte de entrenamiento de MIMIC-IV. Esta transformación facilita la interpretación del resultado: en lugar de mostrar solo una probabilidad aislada, el sistema indica la posición relativa del paciente respecto a una población UCI de referencia. Así, un percentil 90 indica que el paciente presenta un riesgo estimado superior al 90 % de los pacientes de referencia.

Junto al percentil de riesgo, el *dashboard* muestra una explicación individual mediante valores SHAP, indicando qué variables aumentan o reducen la predicción en ese paciente concreto. Esto permite comprobar si la estimación se apoya en factores clínicamente plausibles, como hipotensión, peor oxigenación, mayor SOFA o alteraciones metabólicas, reduciendo el carácter de “caja negra” del modelo.

Una decisión central del diseño fue evitar que el *dashboard* emitiera recomendaciones clínicas directas. La aplicación no indica si debe iniciarse noradrenalina, no propone dosis, no genera alarmas terapéuticas ni clasifica al paciente en categorías de actuación. Esta restricción fue deliberada: ofrecer recomendaciones automáticas a partir de un modelo retrospectivo no validado prospectivamente supondría un riesgo metodológico, ético y asistencial. El inicio de soporte vasopresor depende de factores no siempre recogidos en los datos estructurados, como la exploración clínica, la respuesta a fluidoterapia, el contexto quirúrgico, la evolución reciente y el criterio del equipo responsable. Por este motivo, el prototipo se planteó únicamente como herramienta de apoyo visual a la interpretación del riesgo. Los modelos integrados no deben entenderse como sistemas de decisión clínica, sino como aproximaciones complementarias a distintos horizontes temporales: la ventana media estima riesgo en un plazo más próximo y la ventana larga explora una posible evolución desfavorable más tardía. Ambas salidas deben interpretarse como información adicional, no como indicación terapéutica.

La interfaz incluye un aviso explícito indicando que se trata de un prototipo académico de investigación, sin validación clínica prospectiva ni

autorización regulatoria, y que no debe utilizarse en práctica clínica real. Su uso asistencial requeriría validación prospectiva, revisión clínica y ética, análisis de impacto en el flujo de trabajo e integración segura con los sistemas de información hospitalarios. En conjunto, el *dashboard* demuestra que los modelos pueden desplegarse en una interfaz comprensible, reproducible e interpretable, cuya función dentro de este TFG es exclusivamente demostrativa: ilustrar cómo podrían presentarse las predicciones y sus explicaciones en un entorno clínico real.

4.4. Metodología de Ingeniería del Software

El desarrollo software del proyecto siguió una metodología experimental e iterativa, propia de un trabajo de ciencia de datos. A diferencia de una aplicación tradicional con requisitos cerrados desde el inicio, el flujo de trabajo se refinó progresivamente en función de los resultados obtenidos en la construcción de cohortes, el análisis exploratorio, la selección de variables, el entrenamiento, la calibración y la validación externa.

No se aplicó un marco formal como Scrum, dado que el proyecto fue desarrollado por un único autor y estuvo guiado principalmente por objetivos metodológicos. En su lugar, se siguió un ciclo incremental basado en versiones sucesivas de los conjuntos de datos, modelos y scripts de análisis. El código se organizó en módulos funcionales: extracción de cohortes mediante SQL, preprocesamiento, análisis exploratorio, definición de ventanas temporales, selección de variables, entrenamiento, calibración, interpretabilidad mediante SHAP, validación externa y desarrollo del prototipo de *dashboard*. Esta organización permitió mantener la trazabilidad entre los resultados presentados en la memoria y los scripts utilizados para generarlos.

El control de versiones se realizó mediante Git y GitHub. El repositorio incluye el código necesario para reproducir el flujo de trabajo, respetando las restricciones de uso de MIMIC-IV y eICU-CRD, que impiden redistribuir directamente los datos clínicos. Por ello, los archivos intermedios derivados de las bases de datos no se incluyen en el repositorio, aunque sí se documenta el procedimiento necesario para regenerarlos a partir de las credenciales y permisos correspondientes.

El prototipo de *dashboard* se desarrolló con Streamlit. La aplicación carga modelos entrenados y serializados, transforma un CSV de entrada en las variables requeridas, calcula el percentil de riesgo del paciente respecto a la cohorte de referencia y muestra una explicación individual mediante SHAP.

Resultados

5.1. Resumen de resultados

Breve resumen de los resultados. En caso de ser un trabajo muy experimental, los resultados completos pueden aparecer en su anexo correspondiente.

Debería haber una correspondencia entre los objetivos y los resultados explicados en esta sección

A continuación se muestra un **ejemplo de figura generada con R**:

```
library(ggplot2)

ggplot(iris, aes(x = Species, y = Sepal.Length, fill = Species)) +
  geom_boxplot(alpha = 0.7, show.legend = FALSE) +
  labs(
    x = "Especie",
    y = "Longitud del sépalo (cm)"
  ) +
  theme_minimal(base_size = 11) +
  theme(panel.grid.minor = element_blank())
```

Debería existir correspondencia entre los objetivos definidos y los resultados mostrados (Koza, 1992).




Figura 5.1: Distribución de la longitud de sépal por especie en el conjunto iris

Discusión

Se realizará un análisis crítico de los resultados, interpretando su significado y, cuando sea pertinente, comparándolos con los resultados de trabajos previos, obtenidos con la revisión del estado del arte; de forma que se destaquen las mejoras y aportes sobre el mismo.

Conclusiones

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas.

7.1. Aspectos relevantes

Este apartado pretende recoger los aspectos más interesantes del **desarrollo del proyecto**, comentados por los autores del mismo y que den respuesta a los objetivos planteados.

Debe incluir los detalles más relevantes en cada fase del desarrollo, justificando los caminos tomados, especialmente aquellos que no sean triviales.

Puede ser el lugar más adecuado para documentar los aspectos más interesantes del proyecto y también los resultados negativos obtenidos por soluciones previas a la solución entregada.

Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

Líneas de trabajo futuras

La línea de trabajo más prioritaria e inmediata consiste en retomar y consolidar la validación externa planificada sobre los datos reales del Hospital Universitario de Burgos (HUBU). Aunque la heterogeneidad en las estructuras de registro y las barreras técnicas de extracción obligaron a sustituir esta cohorte por la base de datos multicéntrica eICU-CRD, la transferencia del modelo a una población de referencia europea sigue siendo un hito indispensable para garantizar la generalizabilidad del algoritmo sobre esta población. Una vez garantizada la viabilidad de extracción desde los sistemas de información clínica de la UCI del HUBU, se procederá a la tramitación ante el Comité de Ética de Investigación del centro, y se diseñará un proceso de mapeo y traducción iterativa de variables clínicas locales hacia el esquema estructurado de la pipeline actual, garantizando la homogeneidad de los predictores clave.

Una segunda línea de trabajo sería la transición hacia modelos basados en series temporales. El enfoque actual utiliza métricas estáticas resumidas (mínimos, máximos o medias) dentro de una ventana fija, descartando la riqueza dinámica y la tendencia temporal de las constantes vitales. Se plantea reestructurar la arquitectura predictiva sustituyendo los árboles estáticos por modelos capaces de procesar secuencias temporales. Esto incluye la implementación de redes neuronales recurrentes (LSTM) o Transformers temporales adaptados a registros clínicos tabulares, o el uso de librerías como `tsfresh` o `sktime` para la extracción automatizada de características dinámicas.

Un tercer ejemplo es la implementación de modelos de análisis de supervivencia. La formulación binaria estricta ligada a ventanas temporales fijas limita la toma de decisiones clínicas. La integración de técnicas de Análisis

de Supervivencia aplicado al Machine Learning permitirá modelar de forma continua el tiempo hasta el evento gestionando correctamente la censura de datos (altas hospitalarias o fallecimientos prematuros antes de que ocurra el evento).

Por último, podría valorarse de cara a un futuro y si estos modelos predictivos cumplen con los requisitos para convertirse en herramientas clínicas validadas, la integración de estos en el software de una UCI que ya se use para monitorizar pacientes, por ejemplo, mediante conexión directa del backend con las bases de datos de monitorización en tiempo real de la unidad, ejecutando el algoritmo en segundo plano de forma automática ante cada nueva analítica o constante registrada. En su defecto, también cabría explorar la posibilidad de que el Dashboard se convierta en uno multipaciente que permita la vigilancia simultánea y centralizada de todas las camas del servicio.

Bibliografía

- CITI Program (2026). Collaborative institutional training initiative. Accedido en marzo de 2026.
- Duval, L., Villié, A., Zheng, F., Terraz, G., Blein, S., Duperchy, E., Everett, M., Frieling, J., Llitjos, J.-F., and Bodinier, M. (2025). Early prediction of vasopressor initiation in ICU sepsis patients using an interpretable EHR-based ML model. *BMC Medical Informatics and Decision Making*, 25(1):442.
- Evans, L., Rhodes, A., Alhazzani, W., et al. (2021). Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021. *Intensive Care Medicine*, 47:1181–1247.
- Fleischmann-Struzek, C., Mellhammar, L., Rose, N., et al. (2020). Incidence and mortality of hospital- and ICU-treated sepsis: results from an updated and expanded systematic review and meta-analysis. *Intensive Care Medicine*, 46:1552–1562.
- Grupo de Trabajo Sepsis HUBU (2025). Protocolo Código Sepsis HUBU. Manejo integral del paciente séptico. III edición. Technical report, Complejo Asistencial Universitario de Burgos.
- Gupta, M., Gallamoza, B., Cutrona, N., Dhakal, P., Poulain, R., and Behesh-ti, R. (2022). An extensive data processing pipeline for MIMIC-IV. In *Proceedings of the 2nd Machine Learning for Health Symposium*, volume 193 of *Proceedings of Machine Learning Research*, pages 311–325. PMLR.
- Jiang, Z., Zhang, S., Yuan, Y., Wang, J., and Hu, Z. (2025). Chronosynthnet: a dual-task deep learning model development and validation study for

- predicting real-time norepinephrine dosage and the early detection of hypotension in patients with septic shock. *Cardiovascular Diagnosis and Therapy*, 15(4):833–846.
- Johnson, A. E. W., Bulgarelli, L., Shen, L., et al. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.
- Kalimouttou, A., Kennedy, J. N., Feng, J., Singh, H., Saria, S., Angus, D. C., Seymour, C. W., and Pirracchio, R. (2025). Optimal vasopressin initiation in septic shock: The OVISS reinforcement learning study. *JAMA*, 333(19):1688–1698.
- Koza, J. R. (1992). *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30.
- MIT Laboratory for Computational Physiology (2024). MIMIC code repository. <https://github.com/MIT-LCP/mimic-code>. Accedido: abril de 2026.
- Persson, I., Macura, A., Becedas, D., and Sjövall, F. (2024). Early prediction of sepsis in intensive care patients using the machine learning algorithm NAVOY® sepsis, a prospective randomized clinical validation study. *Journal of Critical Care*, 80:154400.
- PhysioNet (2026). Physionet: The research resource for complex physiologic signals. Accedido en marzo de 2026.
- Pollard, T. J., Johnson, A. E. W., Raffa, J. D., Celi, L. A., Mark, R. G., and Badawi, O. (2018). The eICU collaborative research database, a freely available multi-center database for critical care research. *Scientific Data*, 5:180178.
- Rockenschaub, P., Akay, E. M., Carlisle, B. G., et al. (2025). External validation of AI-based scoring systems in the ICU: a systematic review and meta-analysis. *BMC Medical Informatics and Decision Making*, 25:5.
- Scheibner, A., Betthausen, K. D., Bewley, A. F., Juang, P., Lizza, B., Micek, S., and Lyons, P. G. (2022). Machine learning to predict vasopressin responsiveness in patients with septic shock. *Pharmacotherapy*, 42(6):460–471.

- Shanmugam, H., Airen, L., and Rawat, S. (2025). Machine learning and deep learning models for early sepsis prediction: A scoping review. *Indian Journal of Critical Care Medicine*, 29(6):516–524.
- Singer, M., Deutschman, C. S., Seymour, C. W., Shankar-Hari, M., Annane, D., Bauer, M., Bellomo, R., Bernard, G. R., Chiche, J.-D., Coopersmith, C. M., Hotchkiss, R. S., Levy, M. M., Marshall, J. C., Martin, G. S., Opal, S. M., Rubenfeld, G. D., van der Poll, T., Vincent, J.-L., and Angus, D. C. (2016). The third international consensus definitions for sepsis and septic shock (Sepsis-3). *JAMA*, 315(8):801–810.
- Vincent, J.-L. and De Backer, D. (2013). Circulatory shock. *New England Journal of Medicine*, 369(18):1726–1734.
- Zhang, T., Qu, Y., Wang, D., Zhong, M., Cheng, Y., and Zhang, M. (2024). Optimizing sepsis treatment strategies via a reinforcement learning model. *Biomedical Engineering Letters*, 14(2):279–289.