




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana del
riesgo de inicio de
noradrenalina en UCI
mediante aprendizaje
automático y dashboard
interpretable**

Presentado por Daniel Marina de la Cal
en Universidad de Burgos


Tutores: Antonio Jesús Canepa Oneto – Sergio
Ossa Echeverri – Fernando Callejo Torre



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana del
riesgo de inicio de
noradrenalina en UCI
mediante aprendizaje
automático y dashboard
interpretable**

Presentado por Daniel Marina de la Cal
en Universidad de Burgos

22 de mayo de 2026

Tutores: Antonio Jesús Canepa Oneto – Sergio Ossa
Echeverri – Fernando Callejo Torre



UNIVERSIDAD
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Antonio Jesús Canepa Oneto, profesor/a del departamento de Ingeniería Informática del área de Lenguajes Informáticos. D. Sergio Ossa Echeverri, médico intensivista del Hospital Universitario de Burgos. D. Fernando Callejo Torre, médico intensivista del Hospital Universitario de Burgos.

Expone/n:

Que el/la alumno/a D. Daniel Marina de la Cal, con DNI 71565266F, ha realizado el Trabajo final de Grado en Ingeniería de la Salud titulado *Estimación temprana del riesgo de inicio de noradrenalina en UCI mediante aprendizaje automático y dashboard interpretable*.

Y que dicho trabajo ha sido realizado por el/la alumno/a bajo la dirección del/los que suscribe/n.

En Burgos, a 22 de mayo de 2026

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Antonio Jesús
Canepa Oneto

D. Sergio Ossa
Echeverri

D. Fernando Callejo
Torre

Resumen

Este TFG propone el desarrollo de modelos de aprendizaje automático orientados a estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes críticos ingresados en UCI, a partir de variables clínicas disponibles durante las primeras horas de estancia, como constantes vitales, parámetros analíticos y datos básicos del paciente. El objetivo no es solo predecir si el paciente requerirá soporte vasopresor en una ventana temporal definida, sino también ofrecer una herramienta interpretable, en forma de dashboard, que permita visualizar el riesgo estimado y los factores que más contribuyen a dicha predicción en cada caso.

Descriptores

Aprendizaje automático, Predicción, Dashboard, Sepsis, UCI, Noradrenalina, vasopresor.

Abstract

This Bachelor's Thesis proposes the development of machine learning models aimed at the early estimation of the risk of initiating noradrenaline in critically ill patients admitted to the ICU, based on clinical variables available during the first hours of admission, such as vital signs, laboratory parameters, and basic patient data. The objective is not only to predict whether the patient will require vasopressor support within a defined time window, but also to provide an interpretable tool in the form of a dashboard. This tool will allow the visualization of the estimated risk and the factors that contribute most to this prediction in each individual case.

Keywords

Machine Learning, Sepsis, Prediction, Dashboard, ICU, norepinephrine, vasopressor.

Índice general

Índice general	iii
Índice de figuras	iv
Índice de tablas	v
Introducción	1
Objetivos	5
Conceptos teóricos	9
Metodología	15
4.1. Datos y variables por ventana	15
4.2. Baseline final y métricas	26
4.3. Dashboard clínico y limitaciones de uso	34
4.4. Metodología de Ingeniería del Software	36
Resultados	39
5.1. Resumen de resultados	39
Discusión	41
Conclusiones	43
7.1. Aspectos relevantes	43
Líneas de trabajo futuras	45

Índice de figuras

4.1.	Análisis de correlación y estructura de agrupamiento de las 76 variables predictoras (MIMIC-IV, ventana Medio). Izquierda: matriz de correlación de Spearman. Derecha: dendrograma jerárquico con corte en $ \rho = 0,7$	22
4.2.	Dendrogramas de agrupamiento jerárquico sobre el conjunto final de variables predictoras en cada ventana temporal. Distancia $= 1 - \rho $; línea roja: $ \rho = 0,7$; línea naranja: $ \rho = 0,5$. Ningún par de variables supera el umbral de $ \rho = 0,52$	24
4.3.	Importancia por permutación de cada variable para los seis algoritmos evaluados, en cada ventana temporal. Las barras representan la caída media de AUC-ROC al permutar la variable; los intervalos de confianza al 95 % se calcularon sobre los 5 folds externos. Las variables cuyo IC95 % excluye el cero se consideraron estadísticamente significativas para ese regresor.	25
5.1.	Distribución de la longitud de sépalo por especie en el conjunto iris	40

Índice de tablas

4.1. Pseudocódigo de los algoritmos del repositorio MIT-LCP para el cálculo horario del SOFA y la detección del <i>onset</i> de Sepsis-3 en MIMIC-IV Johnson et al. (2023)MIT Laboratory for Computational Physiology (2024).	18
4.2. Efecto del filtro de completitud sobre el tamaño y la prevalencia de cada cohorte de entrenamiento (MIMIC-IV).	20
4.3. Efecto del filtro de completitud sobre el tamaño y la prevalencia de cada cohorte de validación externa (eICU-CRD).	20

Introducción

Contexto clínico y relevancia del problema

El paciente crítico ingresado en la Unidad de Cuidados Intensivos (UCI) presenta con frecuencia situaciones de fallo orgánico o riesgo inminente de deterioro clínico, lo que exige una monitorización continua y una respuesta terapéutica rápida. Dentro de este contexto, la inestabilidad hemodinámica constituye uno de los problemas más relevantes, ya que puede comprometer la perfusión tisular y favorecer la progresión hacia disfunción multiorgánica.

Entre las intervenciones empleadas para el soporte hemodinámico se encuentra la administración de vasopresores. Estos fármacos permiten mantener una presión de perfusión adecuada cuando los mecanismos compensadores del organismo y la reposición de volumen no son suficientes. La noradrenalina es el vasopresor de primera elección en la mayoría de los escenarios de shock distributivo e inestabilidad hemodinámica en UCI, especialmente en el shock séptico [Evans et al. \(2021\)](#).

La sepsis y el shock séptico representan una de las principales causas de necesidad de soporte vasopresor en pacientes críticos. A escala global, se estimaron 48,9 millones de casos de sepsis y 11 millones de muertes atribuibles en 2017 [Fleischmann-Struzek et al. \(2020\)](#). En adultos hospitalizados, la incidencia de sepsis tratada en UCI alcanza aproximadamente 58 casos por cada 100.000 personas-año [Fleischmann-Struzek et al. \(2020\)](#). En España, la mortalidad de los pacientes sépticos ingresados en UCI se sitúa alrededor del 30, % y puede alcanzar el 50, % en los casos de shock séptico [Grupo de Trabajo Sepsis HUBU \(2025\)](#). No obstante, la necesidad de noradrenalina no se limita a la sepsis, ya que otras formas de shock circulatorio pueden requerir también soporte vasopresor [Vincent and De Backer \(2013\)](#). Por ello, la predicción del inicio de noradrenalina constituye un problema clínico

relevante en la cohorte general de pacientes críticos, más allá de un único diagnóstico.

Justificación del problema

La decisión de iniciar noradrenalina en un paciente crítico no depende de una única variable aislada. En la práctica clínica habitual, esta decisión se basa en la interpretación conjunta de múltiples señales, como la evolución de la presión arterial, la frecuencia cardíaca, el lactato, la respuesta a la fluidoterapia, la diuresis, el grado de disfunción orgánica, la situación respiratoria y el contexto clínico global del paciente [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta complejidad puede dificultar la identificación temprana de los pacientes que evolucionarán hacia la necesidad de soporte vasopresor.

Además, el momento óptimo de inicio de la noradrenalina continúa siendo un aspecto clínico relevante. Un inicio excesivamente tardío puede prolongar la hipoperfusión y favorecer una mayor acumulación de fluidos, mientras que una indicación innecesaria podría exponer al paciente a tratamientos invasivos no justificados. En este contexto, disponer de herramientas capaces de estimar de forma temprana el riesgo de requerir noradrenalina podría ayudar a complementar la valoración clínica y favorecer una vigilancia más dirigida de los pacientes con mayor probabilidad de deterioro hemodinámico.

Planteamiento del trabajo

En los últimos años, el aprendizaje automático (*machine learning*, ML) ha adquirido un papel creciente en el análisis de datos clínicos complejos. Su capacidad para integrar simultáneamente variables fisiológicas, analíticas y demográficas resulta especialmente atractiva en el entorno de UCI, donde la toma de decisiones se apoya en información heterogénea y cambiante. Las bases de datos clínicas de gran escala, como MIMIC-IV y eICU, han facilitado el desarrollo y la evaluación de este tipo de modelos en pacientes críticos [Johnson et al. \(2023\)](#); [Pollard et al. \(2018\)](#).

El presente Trabajo de Fin de Grado propone el desarrollo y la validación de modelos de aprendizaje automático para estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes adultos ingresados en UCI. Para ello, se emplean variables clínicas y analíticas disponibles durante las primeras horas de estancia, con el objetivo de anticipar la necesidad de soporte vasopresor antes de que se produzca el evento.

A diferencia de enfoques centrados exclusivamente en pacientes sépticos, este trabajo se plantea sobre una cohorte general de pacientes adultos de UCI de MIMIC-IV, sin restricción diagnóstica inicial. Esta decisión permite

abordar el problema desde una perspectiva más amplia y ajustada al uso real de la noradrenalina en cuidados intensivos. La presencia de sepsis se considera posteriormente como variable de análisis para estudiar el comportamiento diferencial de los modelos en subgrupos clínicamente relevantes.

El trabajo incorpora tres elementos de interés práctico. En primer lugar, se diseñan distintas ventanas temporales de predicción para evaluar el rendimiento del modelo en diferentes escenarios de anticipación clínica. En segundo lugar, se aplica interpretabilidad mediante valores SHAP, con el fin de identificar qué variables contribuyen con mayor peso a la predicción tanto a nivel global como individual. En tercer lugar, se desarrolla un prototipo de *dashboard* clínico en Streamlit, orientado a visualizar el riesgo estimado y los factores explicativos principales de cada paciente. Finalmente, la capacidad de generalización del modelo se evalúa mediante validación externa sobre la base de datos eICU [Pollard et al. \(2018\)](#).

Estructura de la memoria

El presente documento se organiza en ocho capítulos. Tras este capítulo introductorio, el **Capítulo 2** recoge los objetivos del trabajo. El **Capítulo 3** desarrolla el marco teórico y el estado del arte, incluyendo los fundamentos clínicos del shock, el uso de vasopresores, las bases del aprendizaje automático aplicado a UCI y la revisión de trabajos previos relacionados. El **Capítulo 4** describe la metodología empleada, incluyendo la construcción de cohortes, la definición del evento objetivo, el preprocesamiento de datos, el entrenamiento de modelos y la validación externa. Los **Capítulos 5 y 6** presentan y discuten los resultados obtenidos. El **Capítulo 7** recoge las conclusiones principales y el **Capítulo 8** propone posibles líneas de trabajo futuro.

Objetivos

Objetivo principal

El objetivo principal de este Trabajo de Fin de Grado es desarrollar y validar modelos de aprendizaje automático para la estimación temprana del riesgo de inicio de noradrenalina en pacientes adultos ingresados en la Unidad de Cuidados Intensivos (UCI), utilizando variables clínicas y analíticas disponibles durante las primeras horas de estancia. Esto se materializará en un *dashboard* interpretable diseñado para su uso a pie de cama, que permitirá visualizar el riesgo estimado y los factores clínicos con mayor contribución a dicha predicción en cada paciente de forma individualizada.

Objetivos específicos

1. Desarrollar modelos predictivos de aprendizaje automático entrenados sobre la base de datos MIMIC-IV que estimen la probabilidad de inicio de noradrenalina en UCI en distintas ventanas temporales tras el ingreso.
2. Evaluar y comparar el rendimiento de distintos algoritmos de clasificación supervisada, incluyendo regresión logística, XGBoost, entre otros, mediante métricas de discriminación y calibración.
3. Desarrollar un prototipo de *dashboard* clínico interpretable que muestre, para cada paciente, la probabilidad estimada de requerir noradrenalina, los factores con mayor peso en la predicción y una clasificación orientativa del nivel de riesgo basada en percentiles.
4. Realizar una validación externa de los modelos predictivos con datos de pacientes reales provenientes de otro repositorio distinto del de entrenamiento.

5. Medir la usabilidad del *dashboard* mediante una encuesta de satisfacción dirigida al personal clínico de la UCI del Hospital Universitario de Burgos.

Objetivos técnicos

1. Definir y construir a partir de MIMIC-IV la cohorte general de pacientes adultos de UCI, registrando la presencia de sepsis como variable para el análisis de rendimiento diferencial por subgrupos.
2. Extraer y preprocesar las variables predictoras relevantes disponibles en las primeras horas del ingreso en UCI, incluyendo constantes vitales, parámetros analíticos y otros indicadores de disfunción orgánica y perfusión tisular.
3. Identificar el evento objetivo, definido como el inicio de noradrenalina, a partir de la tabla `inputevents` de MIMIC-IV, distinguiendo entre diferentes ventanas temporales de predicción.
4. Implementar técnicas de manejo del desequilibrio de clases, imputación de datos faltantes y evaluación de calibración, adaptadas a las características habituales de los datos clínicos reales de UCI.
5. Aplicar técnicas de interpretabilidad basadas en valores SHAP (*SHapley Additive exPlanations*) para cuantificar la contribución individual de cada variable a la predicción, tanto a nivel global de la cohorte como a nivel de paciente individual [Lundberg and Lee \(2017\)](#).
6. Desarrollar la interfaz del prototipo del *dashboard* utilizando Python (Streamlit), incorporando visualización del riesgo estimado, explicación por variables y clasificación orientativa del nivel de alerta.
7. Documentar todo el proceso de desarrollo en el repositorio GitHub del proyecto, con el objetivo de favorecer la reproducibilidad del código y del entorno de trabajo.

Objetivos personales

1. Aplicar de forma integrada los conocimientos adquiridos en el Grado de Ingeniería de la Salud a un problema clínico real y de alta relevancia asistencial.

2. Adquirir experiencia práctica en el manejo de bases de datos clínicas de gran escala como MIMIC-IV, así como en los flujos de trabajo habituales en ciencia de datos aplicada a la salud.
3. Profundizar en el campo del aprendizaje automático interpretable y su aplicación en entornos de cuidados intensivos, donde la explicabilidad de las predicciones es un requisito clínico especialmente relevante.
4. Comprender las implicaciones éticas, legales y de privacidad del uso de datos clínicos en investigación, así como los procedimientos de validación en entornos hospitalarios reales.
5. Desarrollar capacidad crítica para comparar el trabajo propio con la literatura existente, identificando las aportaciones diferenciales del presente TFG respecto a los trabajos previos en el área.

Conceptos teóricos

Inestabilidad hemodinámica en UCI y deterioro hemodinámico

Fisiopatológicamente, el shock séptico representa el estadio más crítico de la disfunción hemodinámica, caracterizado por una profunda alteración de la macro y microcirculación secundaria a una respuesta desregulada del huésped frente a la infección [Singer et al. \(2016\)](#). Los criterios operativos establecidos por el consenso Sepsis-3 no son meros umbrales estadísticos, sino reflejos de hitos fisiológicos críticos. Una PAM inferior a 65 mmHg compromete la presión de perfusión crítica de órganos vitales (como el cerebro y el riñón), pudiendo superar los límites inferiores funcionales. Por su parte, la elevación del lactato actúa como un marcador de hipoxia tisular, indicando el viraje del metabolismo celular hacia la vía anaerobia debido a la hipoperfusión.

La evaluación de este estado de shock en la práctica asistencial requiere la integración continua de flujos heterogéneos de información. El protocolo institucional del Código Sepsis del Hospital Universitario de Burgos (HUBU) sistematiza esta valoración mediante el uso secuencial de escalas de cribado y gravedad como qSOFA y SOFA, complementadas con la monitorización estrecha de indicadores analíticos y funcionales de fallo orgánico, tales como el ritmo diurético, la función renal (creatinina), el perfil hepático (bilirrubina), la coagulación (recuento plaquetario) y el intercambio gaseoso (relación $\text{PaO}_2/\text{FiO}_2$) [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta aproximación permite al clínico componer un mapa del estado hemodinámico y de la reserva funcional del paciente crítico.

Sin embargo, la traducción de estas variables analíticas y constantes vitales en una decisión terapéutica concreta, como el inicio de soporte vasopresor con noradrenalina, revela las limitaciones inherentes de los sistemas

de puntuación tradicionales. El deterioro hemodinámico real es un proceso dinámico y caracterizado por interacciones no lineales entre las variables fisiológicas, donde la respuesta a tratamientos previos (como la fluidoterapia) altera continuamente la probabilidad del evento objetivo [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Por consiguiente, la identificación predictiva del riesgo de requerir vasopresores excede la capacidad de las reglas de decisión clínicas fijas, justificando la exploración de otras metodologías capaces de modelar esta complejidad temporal de forma continua.

Uso de vasopresores y papel de la noradrenalina

Tanto las guías de la *Surviving Sepsis Campaign* como el protocolo local del HUBU establecen la noradrenalina como vasopresor de primera elección en el shock séptico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#), y esta recomendación se extiende de facto a la mayoría de los escenarios de shock distributivo en UCI. Cuando se requieren dosis elevadas de noradrenalina para alcanzar una presión arterial media segura, puede asociarse vasopresina como segundo vasopresor. Asimismo, en presencia de disfunción miocárdica asociada o de hipoperfusión persistente a pesar de una adecuada presión arterial, puede considerarse el uso de dobutamina como soporte inotrópico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Este esquema terapéutico refleja que el tratamiento hemodinámico del paciente crítico no es estático, sino progresivo y dependiente de la evolución clínica.

Bases de datos clínicas y aprendizaje automático en UCI

El desarrollo de modelos predictivos en cuidados intensivos ha estado estrechamente ligado a la disponibilidad de bases de datos clínicas de gran escala. Entre ellas, MIMIC-IV (*Medical Information Mart for Intensive Care*, versión IV) ocupa un lugar destacado por tratarse de una base de datos pública, desidentificada y diseñada específicamente para investigación clínica [Johnson et al. \(2023\)](#). MIMIC-IV integra información hospitalaria de un único centro terciario de Boston, incluyendo episodios de UCI, resultados analíticos, administración de fármacos, procedimientos y medidas fisiológicas, todo ello con una estructura que permite estudiar eventos dinámicos como el inicio de vasopresores o la evolución hemodinámica del paciente [Johnson et al. \(2023\)](#).

Para la evaluación de la generalización de los modelos fuera del entorno de desarrollo, la base de datos eICU-CRD (*eICU Collaborative Research Database*) constituye un recurso complementario de gran relevancia [Pollard et al. \(2018\)](#). A diferencia de MIMIC-IV, eICU-CRD agrega datos de centenares de hospitales de Estados Unidos, lo que permite evaluar si un modelo

entrenado en un único centro mantiene su rendimiento en una población más heterogénea y con prácticas clínicas potencialmente distintas [Pollard et al. \(2018\)](#). Esta característica la convierte en un entorno especialmente adecuado para la validación externa de modelos desarrollados sobre MIMIC-IV.

La estimación del riesgo de inicio de noradrenalina exige definir ventanas de observación y de predicción clínicamente plausibles, utilizando únicamente la información disponible antes del evento. Ambas bases de datos comparten una estructura temporal que hace posible este tipo de diseño retrospectivo.

Dentro de este marco, el aprendizaje automático ha adquirido un papel creciente en la predicción de eventos clínicos en pacientes críticos. En datos clínicos tabulares se emplean con frecuencia algoritmos como la regresión logística, Random Forest, XGBoost, LightGBM o CatBoost, que permiten modelar relaciones no lineales e interacciones complejas entre variables. Su atractivo radica en la capacidad para combinar simultáneamente información procedente de múltiples dominios clínicos, algo difícil de reproducir con reglas clínicas simples o con modelos univariantes. Sin embargo, este aumento de capacidad predictiva suele ir acompañado de una menor interpretabilidad, lo que supone una limitación importante cuando el objetivo final es apoyar decisiones clínicas reales.

Interpretabilidad y explicabilidad de modelos

En aplicaciones clínicas, la interpretabilidad del modelo no constituye un elemento accesorio, sino un requisito relevante para facilitar la confianza del profesional sanitario y permitir una evaluación crítica de la predicción generada. En este contexto, adquieren relevancia técnicas de explicación como SHAP (*SHapley Additive exPlanations*), que permiten descomponer la predicción de un modelo en la contribución individual de cada variable [Lundberg and Lee \(2017\)](#).

Este enfoque ofrece una doble utilidad. Por un lado, permite identificar qué variables son más influyentes a nivel global dentro de la cohorte, lo que facilita interpretar el comportamiento general del modelo. Por otro, hace posible explicar predicciones concretas a nivel individual, mostrando qué factores empujan el riesgo estimado en una u otra dirección para un paciente determinado [Lundberg and Lee \(2017\)](#). En un entorno de apoyo a la decisión clínica, esta capacidad puede resultar especialmente valiosa, ya que aproxima la salida del modelo a un razonamiento más comprensible para el profesional.

Estado del arte y trabajos relacionados

Entre los estudios más próximos al objetivo de este TFG destaca el trabajo de Duval et al., que desarrollaron un modelo interpretable basado en historia clínica electrónica para predecir el inicio de perfusión continua de vasopresores en pacientes sépticos ingresados en UCI a partir de datos de MIMIC-IV [Duval et al. \(2025\)](#). El modelo utilizó variables medidas en la ventana de -6 a -2 horas respecto al inicio del tratamiento y el mejor clasificador fue un *Random Forest* con un AUROC de 0,75. Entre los predictores más relevantes se encontraban el descenso de la presión arterial media entre -2 y -4 horas, un lactato $> 2,5$ mmol/L y valores de hematocrito fuera del rango 30-37 % [Duval et al. \(2025\)](#). Los autores señalan, además, que las alertas del modelo podrían generarse entre 2 y 4 horas antes del inicio del vasopresor, lo que apoya la viabilidad técnica de anticipar este tipo de decisión terapéutica [Duval et al. \(2025\)](#). No obstante, el propio estudio subraya que se trata de una validación interna y que aún se requiere validación externa y evaluación prospectiva antes de plantear una implementación clínica real.

Junto a este trabajo, existen otros estudios relacionados que contribuyen a contextualizar el problema, aunque orientados a objetivos clínicos sutilmente distintos. Scheibner et al. desarrollaron y validaron externamente modelos de aprendizaje automático para predecir la respuesta a la vasopresina como segundo vasopresor en pacientes con shock séptico tratados con noradrenalina, mostrando un rendimiento modesto y poniendo de manifiesto la complejidad de anticipar la respuesta farmacológica individual [Scheibner et al. \(2022\)](#). En una línea diferente, Persson et al. realizaron un ensayo clínico aleatorizado y prospectivo para validar un algoritmo de predicción temprana de sepsis en pacientes críticos, demostrando que este tipo de sistemas puede evaluarse más allá del entorno retrospectivo y en condiciones más próximas a la práctica clínica real [Persson et al. \(2024\)](#). Aunque su objetivo no fue la monitorización de vasopresores, este estudio refuerza la relevancia de avanzar hacia diseños de validación más cercanos al uso asistencial.

Otros trabajos han abordado tareas más complejas, como la predicción continua de dosis o la optimización de decisiones terapéuticas mediante modelos temporales y aprendizaje por refuerzo. Jiang et al. propusieron ChronoSynthNet, un modelo con componentes *Transformer* y LSTM para estimar en tiempo real la dosis de noradrenalina y detectar precozmente hipotensión en pacientes con shock séptico [Jiang et al. \(2025\)](#). Este tipo de enfoques aprovecha mejor la naturaleza temporal de los datos, pero también incrementa de forma notable la complejidad metodológica. En paralelo, los enfoques de aprendizaje por refuerzo han intentado derivar políticas terapéuticas para orientar decisiones hemodinámicas en sepsis. Por ejemplo, Zhang et al. describieron un modelo orientado a optimizar estrategias de

tratamiento mediante recomendaciones sobre vasopresores y fluidoterapia, incorporando mecanismos para reducir ajustes bruscos de dosis [Zhang et al. \(2024\)](#), mientras que el estudio OVISS exploró el momento óptimo de inicio de vasopresina en pacientes con shock séptico tratados con noradrenalina [Kalimoultou et al. \(2025\)](#). Aunque estos trabajos son metodológicamente ambiciosos, responden a preguntas clínicas distintas y más complejas que la estimación temprana del primer inicio de noradrenalina.

Limitaciones de la literatura y posicionamiento del TFG

A pesar del avance metodológico observado, la literatura disponible presenta varias limitaciones recurrentes. En primer lugar, muchos estudios continúan evaluando su rendimiento principalmente mediante métricas de discriminación retrospectiva, especialmente el AUROC, sin trasladar de forma suficiente esos resultados a escenarios de uso clínico real [Shanmugam et al. \(2025\)](#). En segundo lugar, la validación externa sigue siendo limitada en una parte importante de los trabajos publicados, lo que dificulta valorar la robustez de los modelos fuera del centro o cohorte de desarrollo [Rockenschaub et al. \(2025\)](#). Además, una proporción relevante de los estudios permanece en fases de validación retrospectiva o de prueba de concepto, lo que limita la estimación de su utilidad operativa real y refuerza la necesidad de modelos interpretables y clínicamente integrables [Shanmugam et al. \(2025\)](#); [Rockenschaub et al. \(2025\)](#).

A partir de esta revisión, el nicho del presente TFG queda claramente definido. El interés del trabajo no reside únicamente en desarrollar un modelo predictivo adicional, sino en abordar un problema clínico concreto y accionable: la estimación temprana del riesgo de inicio de noradrenalina en pacientes críticos a partir de variables disponibles durante las primeras horas de estancia, sobre una cohorte general de adultos en UCI sin restricción diagnóstica. La propuesta añade, además, tres elementos de interés práctico: el uso de modelos con selección de variables por ventana, la traducción del resultado a una interfaz funcional tipo *dashboard* y la validación externa sobre una cohorte multicéntrica independiente. De este modo, el trabajo se orienta no solo a la obtención de un buen rendimiento predictivo, sino también a su posible utilidad como herramienta de apoyo a la decisión clínica.

Metodología

El trabajo se estructuró en tres fases principales: construcción de las cohortes, desarrollo y evaluación interna de los modelos sobre MIMIC-IV, y validación externa sobre eICU-CRD.

El principal objetivo metodológico fue definir tres ventanas para ver la necesidad de soporte vasopresor en tres horizontes temporales clínicamente diferenciados. Las ventanas temporales fueron: corta, observación 0-3 h y predicción 3-12 h; media, observación 0-6 h y predicción 6-24 h; y larga, observación 0-12 h y predicción 12-48 h tras el ingreso.

El motivo de esta elección de franjas es cubrir distintos escenarios asistenciales: desde la detección precoz de deterioro hemodinámico inminente hasta la identificación de pacientes con riesgo de evolución desfavorable en un plazo más amplio. En todos los casos, los predictores se extrajeron exclusivamente de periodos previos al inicio de la noradrenalina, evitando así cualquier forma de fuga de información desde el evento hacia el modelo.

4.1. Datos y variables por ventana

La cohorte de entrenamiento y evaluación interna se construyó a partir de MIMIC-IV. El acceso a esta BBDD requirió completar el curso de formación en investigación con datos humanos del CITI Program ([CITI Program, 2026](#)), registrar el proyecto en PhysioNet ([PhysioNet, 2026](#)), esperar su aprobación y firmar el correspondiente acuerdo de uso de datos. Dicho acuerdo obliga, entre otros aspectos, a no intentar reidentificar pacientes, no redistribuir los datos y publicar el código necesario para la reproducibilidad del proyecto en un repositorio público.

Inicialmente se valoró utilizar como cohorte de validación externa un conjunto de datos desidentificado de pacientes de la UCI del Hospital Universitario de Burgos (HUBU). El objetivo era evaluar la extrapolabilidad de los modelos entrenados en MIMIC-IV a una población europea y a un sistema sanitario distinto. Sin embargo, esta alternativa fue finalmente descartada para esta fase del trabajo. La decisión se debió a la dificultad técnica para extraer de forma homogénea todas las variables requeridas y, especialmente, a la marcada heterogeneidad entre los sistemas asistenciales, los protocolos clínicos y la estructura de registro de ambas cohortes. La diferencia no se limitaba al origen geográfico de los pacientes, sino que afectaba a aspectos directamente relacionados con la práctica clínica: criterios de ingreso en UCI, intensidad de monitorización, disponibilidad y periodicidad de determinadas variables, pautas de tratamiento y soporte hemodinámico.

A pesar de ello, se elaboró el documento requerido para el Comité de Ética en Investigación del HUBU. Como línea futura, una vez confirmada la viabilidad de extracción de las variables necesarias, se prevé solicitar su aprobación para realizar una validación externa sobre estos datos del HUBU. Esta validación tendría una doble finalidad: evaluar la extrapolabilidad de los modelos a un contexto sanitario europeo y explorar su posible publicación científica una vez identificados todos los aspectos a considerar.

Finalmente se seleccionó eICU-CRD ([Pollard et al., 2018](#)) como cohorte de validación externa. Aunque también procede de población norteamericana, su carácter multicéntrico permite evaluar el rendimiento de los modelos en un entorno interhospitalario heterogéneo, con variabilidad real entre centros y prácticas asistenciales, abordando una de las principales limitaciones que presentaban la mayor parte de estudios publicados y mencionados en el estado del arte. Al mismo tiempo, mantiene una mayor comparabilidad estructural con MIMIC-IV que la disponible inicialmente con los datos del HUBU. Los requisitos de acceso y utilización fueron equivalentes a los de MIMIC-IV, al tratarse también de una base de datos alojada en PhysioNet.

La cohorte de desarrollo se construyó mediante consultas SQL directas sobre las tablas de MIMIC-IV alojadas en un servidor PostgreSQL local. El proceso siguió un flujo estructurado en varias etapas.

La selección inicial de variables se basó en criterios clínicos y en la disponibilidad de dichas variables en MIMIC-IV. Se priorizaron constantes vitales, parámetros analíticos, variables respiratorias, marcadores de función orgánica y datos básicos del paciente con relación fisiopatológica plausible con el deterioro hemodinámico y el posible inicio de soporte vasopresor. Esta selección se apoyó además en las variables y criterios recogidos en el Protocolo

Código Sepsis del Hospital Universitario de Burgos, especialmente aquellos relacionados con la monitorización inicial, la detección de hipoperfusión, la valoración de disfunción orgánica y los criterios de valoración por UCI. De este modo, el conjunto inicial de predictores no se definió únicamente por disponibilidad técnica en la base de datos, sino también por su relevancia clínica en el manejo del paciente crítico con sospecha de sepsis o shock.

En primer lugar, se identificaron todas las estancias en UCI y se exigió una duración mínima de estancia suficiente para que el horizonte de predicción quedara completamente contenido dentro del seguimiento disponible.

Para las ventanas Corto y Medio se exigió una estancia superior a 24 horas. Para la ventana Largo se exigió una estancia superior a 48 horas. Este criterio conservador evita casos negativos falsos, es decir, pacientes que podrían haber recibido noradrenalina si su estancia en UCI hubiera sido más larga o que no la han recibido hasta su alta o fallecimiento por la brevedad de su estancia.

El evento objetivo fue el primer inicio de perfusión de noradrenalina durante la estancia en UCI. En MIMIC-IV se localizó a partir del `itemid` 221906 de la tabla `inputevents`. Para cada estancia se calculó el tiempo transcurrido, en horas, desde el ingreso en UCI hasta el primer inicio registrado de noradrenalina. Se excluyeron las estancias en las que la noradrenalina se había iniciado antes del comienzo de la ventana de observación correspondiente. Con ello se garantizó que todos los predictores se extrajeran de un periodo libre de tratamiento vasopresor, evitando que el modelo aprendiera patrones derivados de una intervención ya iniciada.

Para cada ventana temporal se asignó una etiqueta binaria. Una estancia recibió etiqueta positiva (1) cuando el primer inicio de perfusión de noradrenalina ocurrió estrictamente dentro del intervalo de predicción definido para esa ventana. Por el contrario, recibió etiqueta negativa (0) cuando no ocurrió dentro de dicho horizonte.

La etiqueta negativa incluye dos situaciones: pacientes que nunca requirieron soporte vasopresor durante toda su estancia en UCI y pacientes que iniciaron noradrenalina fuera del horizonte predictivo evaluado, por ejemplo de forma tardía una vez cerrada la ventana de predicción.

La presencia de sepsis se identificó mediante la tabla derivada `mimicv_derived.sepsis3`. La puntuación SOFA se obtuvo a partir de `mimicv_derived.sofa`. Ambas tablas proceden del repositorio oficial de scripts derivados de MIMIC-IV mantenido por MIT-LCP ([MIT Laboratory for Computational Physiology, 2024](#)), que implementa los criterios Sepsis-3.

Cálculo del SOFA (ventana 24 h) Para cada hora h de la estancia: Respiratorio: $P/F < 100 \rightarrow 4$, $< 200 \rightarrow 3$, $< 300 \rightarrow 2$, $< 400 \rightarrow 1$ Coagulación: $plt < 20 \rightarrow 4$, $< 50 \rightarrow 3$, $< 100 \rightarrow 2$, $< 150 \rightarrow 1$ Hepático: $bili \geq 12 \rightarrow 4$, $\geq 6 \rightarrow 3$, $\geq 2 \rightarrow 2$, $\geq 1.2 \rightarrow 1$ Cardiovascular: $norepi > 0.1 \rightarrow 4$, $\leq 0.1 \rightarrow 3$, dopamina $> 0 \rightarrow 2$, MAP $< 70 \rightarrow 1$ Neurológico: $GCS < 6 \rightarrow 4$, $6-9 \rightarrow 3$, $10-12 \rightarrow 2$, $13-14 \rightarrow 1$ Renal: $creat \geq 5 \rightarrow 4$, $\geq 3.5 \rightarrow 3$, $\geq 2 \rightarrow 2$, $\geq 1.2 \rightarrow 1$ Componente _{24h} $\leftarrow$ MAX(componente, 23 h) SOFA _{24h} $\leftarrow \sum 6$ componentes _{24h}	Detección de Sepsis-3 Para cada antibiótico administrado: Si cultivo en $\pm 72/24$ h del antibiótico: sospеча $\leftarrow$ verdadero $t_s \leftarrow \min(t_{\text{cultivo}}, t_{\text{antibiótico}})$ Para cada evento de sospecha: Si $\exists$ SOFA ≥ 2 en $[t_s - 48h, t_s + 24h]$: sepsis3 $\leftarrow$ verdadero $t_{\text{onset}} \leftarrow$ primer endtime con SOFA ≥ 2 Devolver registro más temprano con sospecha $\wedge$ SOFA ≥ 2
--	--

Tabla 4.1: Pseudocódigo de los algoritmos del repositorio MIT-LCP para el cálculo horario del SOFA y la detección del *onset* de Sepsis-3 en MIMIC-IV [Johnson et al. \(2023\)](#) MIT Laboratory for Computational Physiology (2024).

La puntuación SOFA se incorporó como variable predictora. La variable de sepsis se utilizó principalmente como variable de análisis diferencial por subgrupos, dada su importancia clínica y su relación directa con el inicio de soporte vasopresor.

La cohorte de validación externa se construyó mediante consultas SQL sobre las tablas de eICU-CRD, alojadas en el mismo entorno local que MIMIC-IV. Se aplicaron las mismas restricciones de estancia mínima obligatoria utilizadas en la cohorte de desarrollo.

En eICU-CRD, el evento objetivo se identificó a partir de la tabla *infusionDrug*. Se buscaron perfusiones cuyo nombre de fármaco contuviera los términos *norepinephrine* o *levophed* (nombre comercial). Se excluyeron las entradas que contenían el término *volume*, con el fin de evitar falsos positivos relacionados con soluciones de reposición o registros no correspondientes a perfusión vasopresora.

Para cada estancia se registró el primer inicio de noradrenalina en minutos desde el ingreso en UCI. Posteriormente, este valor se convirtió a horas para mantener la consistencia con MIMIC-IV. Se aplicaron los mismos criterios de exclusión de noradrenalina precoz y de asignación de etiqueta binaria utilizados en la cohorte de entrenamiento.

A diferencia de MIMIC-IV, eICU-CRD no dispone de tablas derivadas precalculadas para SOFA ni para sepsis. Por ello, el índice SOFA se calculó específicamente en SQL a partir de sus seis componentes fundamentales y de manera similar a como se calcula en el repositorio del MIT-LCP.

En eICU-CRD no fue posible obtener un indicador de sepsis equivalente al disponible en MIMIC-IV. Aunque la base de datos dispone de información microbiológica estructurada para el requerimiento de “sospecha de infección”, esta está poco poblada por disponibilidad limitada de interfaces microbiológicas según la documentación oficial.

Se valoró aproximar la sepsis mediante códigos ICD, pero esta opción se descartó por no considerarse metodológicamente adecuada. La codificación administrativa es introducida manualmente a posteriori por personal médico, lo que puede incorporar errores humanos, omisiones o codificación de entidades clínicas similares pero no equivalentes. Por tanto, el análisis diferencial por subgrupos de sepsis se realizó únicamente sobre la cohorte de MIMIC-IV.

El tratamiento de datos faltantes se abordó con un criterio deliberadamente estricto. Tanto en las variables predictoras de MIMIC-IV y eICU-CRD como en los componentes individuales del SOFA calculado para eICU-CRD, se descartó el uso de técnicas de imputación estadística, incluyendo sustitución por media, mediana o algoritmos KNN.

La decisión se justificó por dos motivos. En primer lugar, la imputación introduce un componente sintético que exige asumir supuestos metodológicos complejos sobre el mecanismo de ausencia de datos, lo que excedía el alcance de este trabajo. En segundo lugar, tras analizar la dinámica asistencial de la UCI, se descartó también asignar una puntuación de cero a los componentes ausentes del SOFA, ya que la ausencia de registro no equivale necesariamente a normalidad clínica. En consecuencia, se retuvieron únicamente las estancias con registros reales e íntegros en la totalidad de las variables analizadas.

Este criterio tuvo una consecuencia directa sobre la composición de las cohortes finales, recogida en las Tabla 4.2 y Tabla 4.3. En MIMIC-IV la prevalencia del evento aumentó desde el rango 4–6 % en las cohortes brutas hasta el 10–11 % tras el filtro, mientras que en eICU-CRD el incremento

fue aún más pronunciado, desde el 3–4 % hasta el 10–14 %, reflejo de la menor completitud de registro analítico en una base de datos multicéntrica con mayor variabilidad entre sistemas de información hospitalarios. Este cambio es compatible con un sesgo de monitorización esperable en cuidados intensivos: los pacientes con analíticas completas, gases arteriales, constantes vitales frecuentes y control estricto de diuresis son, por definición, pacientes con mayor gravedad clínica percibida por el equipo sanitario.

Tabla 4.2: Efecto del filtro de completitud sobre el tamaño y la prevalencia de cada cohorte de entrenamiento (MIMIC-IV).

	Estancias Ventana brutas	Prevalencia bruta	Estancias tras filtro	Prevalencia tras filtro
Corto (3–12 h)	67.858	5,29 %	1.667	10,32 %
Medio (6–24 h)	65.825	4,31 %	3.282	10,30 %
Largo (12–48 h)	38.051	5,63 %	4.088	11,15 %

Tabla 4.3: Efecto del filtro de completitud sobre el tamaño y la prevalencia de cada cohorte de validación externa (eICU-CRD).

	Estancias Ventana brutas	Prevalencia bruta	Estancias tras filtro	Prevalencia tras filtro
Corto (3–12 h)	125.124	3,65 %	789	14,45 %
Medio (6–24 h)	122.922	3,46 %	1.396	11,89 %
Largo (12–48 h)	68.778	3,91 %	2.030	9,80 %

Aunque este filtrado reduce el tamaño muestral y selecciona una población de mayor gravedad, también refina la cohorte hacia la población diana

real del modelo: pacientes con alta intensidad de monitorización y sospecha de deterioro hemodinámico. Las estancias excluidas corresponden previsiblemente a ingresos postquirúrgicos breves o cuadros de baja complejidad, escenarios donde la necesidad de soporte vasopresor es poco frecuente y donde una herramienta predictiva de este tipo tendría menor o escaso valor asistencial.

Antes del modelado se realizó un análisis exploratorio de datos sobre la cohorte de MIMIC-IV mediante un *notebook* de Jupyter. Para cada variable continua se inspeccionaron estadísticos descriptivos, percentiles extremos y la distribución de valores desagregada por etiqueta del evento, lo que confirmó la presencia de distribuciones asimétricas, colas pesadas y valores extremos frecuentes en variables clínicas de pacientes críticos.

Para el tratamiento de estos valores extremos se siguió la lógica de preprocesamiento propuesta por Gupta et al. ([Gupta et al., 2022](#)) para datos de MIMIC-IV, que recomienda winsorización sobre las variables clínicas continuas. La eliminación directa de filas se descartó porque en UCI un valor extremo no es necesariamente un error de registro —puede reflejar la situación real de un paciente crítico—, y prescindir de esas estancias introduciría un sesgo de selección adicional sobre una cohorte que ya ha sido filtrada por completitud. La sustitución por valores imputados se descartó por el mismo motivo que en el tratamiento de datos faltantes: introducir componentes sintéticos exige asumir supuestos sobre la distribución real que no pueden verificarse con los datos disponibles.

La winsorización se aplicó al percentil 2 y 98 de forma uniforme sobre todas las variables clínicas continuas, sin excepciones por variable. Es importante señalar que este procedimiento se aplicó sobre los estadísticos de resumen ya agregados por estancia y ventana (media, mínimo y máximo) y no sobre las mediciones individuales en bruto. Esto responde a que la unidad de análisis del modelo es la estancia, no la medición puntual: un valor extremo clínicamente relevante es el que afecta al estadístico de resumen de la estancia, no un pico instantáneo que puede reflejar un transitorio real. Un ejemplo ilustrativo es la MAP: valores inferiores a 20 mmHg o superiores a 200 mmHg en el estadístico de resumen de una ventana de seis horas son difícilmente atribuibles a la fisiología del paciente y más probablemente a artefactos de monitorización o errores de transcripción.

Quedaron excluidas de la winsorización las variables con rango acotado por definición —Glasgow (3-15) y SOFA (0-24)— y las variables binarias, para las que el procedimiento carece de sentido. Los percentiles 2 y 98 se calcularon exclusivamente sobre MIMIC-IV y se almacenaron en un fichero

de referencia que se aplicó posteriormente a eICU-CRD, garantizando que el tratamiento de valores extremos en la cohorte externa se realizara con parámetros aprendidos en el conjunto de entrenamiento y evitando así cualquier forma de fuga de información.

Con el objetivo de identificar redundancias en el espacio de predictores, se calculó la matriz de correlación de Spearman sobre las 76 variables del conjunto inicial, utilizando únicamente la primera estancia por paciente para evitar que las réplicas de un mismo sujeto inflaran artificialmente las asociaciones. Se eligió el coeficiente de Spearman al ser más robusto que el de Pearson por su robustez ante distribuciones asimétricas y valores extremos.




Figura 4.1: Análisis de correlación y estructura de agrupamiento de las 76 variables predictoras (MIMIC-IV, ventana Medio). Izquierda: matriz de correlación de Spearman. Derecha: dendrograma jerárquico con corte en $|\rho| = 0,7$.

La matriz resultante, representada como mapa de calor, reveló la presencia de bloques de alta correlación positiva correspondientes a los tres estadísticos de resumen de cada variable fisiológica: media, mínimo y máximo de una misma magnitud mostraron correlaciones entre sí superiores a 0,7 de forma sistemática. Este patrón era esperable dado que los tres estadísticos se calculan sobre la misma ventana de observación y reflejan la misma señal clínica con distintos énfasis. Adicionalmente se observaron correlaciones positivas moderadas-altas entre variables con relación fisiopatológica conocida,

como la PAFI (pf) con sus componentes, o entre los distintos marcadores de función hepática (GPT, GOT, bilirrubina). Para visualizar la estructura de agrupamiento de forma más interpretable, se construyó un dendrograma jerárquico mediante enlace promedio sobre la matriz de distancias $1 - |\rho|$. El dendrograma confirmó la formación de clusters compactos dentro de cada variable fisiológica (los tres estadísticos de una misma magnitud se agrupan sistemáticamente antes de unirse con otras variables), así como superclústeres entre magnitudes clínicamente relacionadas.

A partir de estos resultados se aplicó un proceso de selección en dos fases. En la primera fase se eligió el estadístico de resumen más representativo de cada variable mediante criterio clínico: se seleccionó el mínimo para variables donde el valor más bajo refleja el peor estado fisiológico del paciente (MAP, P/F, SpO2, GCS, pH, bicarbonato, plaquetas, hemoglobina, leucocitos, glucemia, temperatura), y el máximo para variables donde el valor más alto refleja el peor estado (creatinina, lactato, frecuencia respiratoria, GPT, TP, SOFA, FiO2). Para las variables en las que la dirección clínica no era inequívoca —frecuencia cardíaca, bilirrubina, y el resto de las variables con clusters internos sin dirección clara— se recurrió a una segunda fase de desempate estadístico basada en el AUC univariante y la d de Cohen, seleccionando el estadístico con mayor capacidad discriminativa sobre la etiqueta del evento. El resultado de este proceso fue **hr_media** y **bilirrubina_media** como estadísticos seleccionados por desempate.

Tras la selección del estadístico, se descartaron las variables redundantes por solapamiento de información: la PaO2 en todas sus variantes (redundante con PAFI), la GOT en todas sus variantes (mismo cluster que GPT, con correlaciones superiores a 0,99), y la variable **tiene_sepsis** (su información discriminativa queda recogida en el SOFA y sus componentes; su aportación única —la sospecha de infección— no es objetivamente cuantificable de forma comparable entre bases de datos). En la ventana Largo se eliminó adicionalmente **fio2_max** por su alta correlación con P/F en esa ventana y posteriormente en todas las demás. El conjunto final quedó reducido a 25 variables para las ventanas.

La correlación máxima residual entre variables del conjunto final fue $|\rho| = 0,477$ (P/F mínimo – FiO2 máximo) en la ventana Medio, $|\rho| = 0,514$ (bilirrubina media – plaquetas mínimas) en la ventana Corto, y $|\rho| = 0,516$ (ventilación invasiva – GCS mínimo) en la ventana Largo tras excluir **fio2_max**. Ningún par superó el umbral de $|\rho| = 0,52$, lo que confirma la ausencia de multicolinealidad relevante en el espacio de predictores final.




Figura 4.2: Dendrogramas de agrupamiento jerárquico sobre el conjunto final de variables predictoras en cada ventana temporal. Distancia = $1 - |\rho|$; línea roja: $|\rho| = 0,7$; línea naranja: $|\rho| = 0,5$. Ningún par de variables supera el umbral de $|\rho| = 0,52$.

Con el fin de identificar qué variables contribuían de forma estadísticamente significativa al rendimiento de cada regresor probado (Regresión logística, Naive Bayes, Random Forest, LightGBM, XGBoost y Catboost), se diseñó una validación cruzada anidada con estructura 5×3 . El bucle externo dividió las estancias en 5 particiones mediante **StratifiedGroupKFold**, manteniendo la proporción de positivos y negativos en cada partición y garantizando que todas las estancias de un mismo paciente quedaran íntegramente en el mismo fold para evitar fuga de información entre estancias del mismo sujeto. El bucle interno repitió el mismo esquema con 3 particiones para la búsqueda de hiperparámetros mediante **GridSearchCV**. En cada fold externo, el modelo con los mejores hiperparámetros identificados en el bucle interno se reentrenó sobre los datos de entrenamiento completos del fold y se evaluó sobre el conjunto de test, que nunca había participado ni en el entrenamiento ni en la selección de hiperparámetros. Se aplicó **RobustScaler** dentro del pipeline para la Regresión Logística y el Naive Bayes, garantizando que la normalización se ajustara exclusivamente sobre los datos de entrenamiento de cada fold.

Sobre el conjunto de test de cada fold externo se calculó la importancia por permutación (*permutation importance*): cada variable se permutó aleatoriamente 50 veces y se registró la caída resultante en el AUC-ROC. Una variable se consideró significativa para un modelo dado cuando el intervalo de confianza al 95 % de esa caída —calculado como los percentiles 2,5 y 97,5 sobre los 5 folds— excluía el cero, es decir, cuando su eliminación producía una degradación del rendimiento distinguible de la variación aleatoria. Este proceso se ejecutó de forma independiente para cada uno de los seis algoritmos y para cada una de las tres ventanas temporales.

Paralelamente, se realizó un análisis de significancia univariante sobre la primera estancia por paciente para evitar dependencias entre observaciones del mismo sujeto. Para las variables continuas se aplicó el test de Mann-Whitney U y para las variables binarias el test chi-cuadrado. Los p-valores resultantes se corrigieron mediante el método de Benjamini-Hochberg (FDR $q < 0,05$) para controlar la tasa de falsos descubrimientos derivada de las comparaciones múltiples.

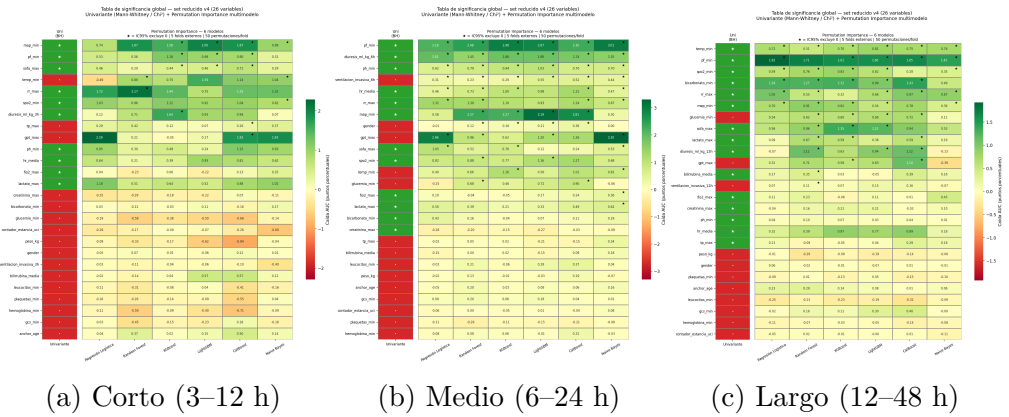


Figura 4.3: Importancia por permutación de cada variable para los seis algoritmos evaluados, en cada ventana temporal. Las barras representan la caída media de AUC-ROC al permutar la variable; los intervalos de confianza al 95 % se calcularon sobre los 5 folds externos. Las variables cuyo IC95 % excluye el cero se consideraron estadísticamente significativas para ese regresor.

Que una variable sea estadísticamente significativa en la permutation importance no garantiza que el modelo esté aprendiendo la relación fisiopatológica correcta: podría estar captando un artefacto de la muestra, una correlación espuria o una asociación en dirección contraria a la esperada clínicamente. Para verificar este aspecto se calculó, sobre la primera estancia por paciente, el OR ajustado mediante regresión logística multivariante con todas las variables del conjunto reducido, estandarizadas previamente para hacer los coeficientes comparables entre sí. Se contrastó la dirección del OR ajustado con la dirección observada en los datos brutos: si los pacientes positivos presentaban valores más altos de una variable pero el OR ajustado era menor que 1, o viceversa, se consideraba que el modelo aprendía una dirección de efecto incoherente con los datos, lo que en presencia de multicolinealidad residual puede deberse a supresión estadística entre predictores.

Las variables que mostraron esta incoherencia en alguna de las ventanas fueron eliminadas del conjunto final de esa ventana, independientemente de su significancia en la permutation importance.

En la ventana Medio, se eliminaron por incoherencia de dirección `creatinina_max` (valores más altos en positivos pero OR ajustado < 1), `ph_min` (valores más bajos en positivos pero OR ajustado > 1) y `gpt_max` (sin diferencia en medianas entre grupos pero OR ajustado marcadamente protector). En la ventana Corto, las eliminadas por incoherencia fueron `creatinina_max` (misma dirección incoherente que en la ventana Medio) y `gpt_max`.

En la ventana Largo, se eliminaron `ph_min` (valores más bajos en positivos pero OR ajustado > 1), `lactato_max` (valores más altos en positivos pero OR ajustado < 1) y `gpt_max`, que mostró sistemáticamente un comportamiento incoherente en las tres ventanas.

4.2. Baseline final y métricas

La elección de algoritmos respondió a tres criterios: cubrir un espectro amplio de complejidad estadística (desde modelos lineales hasta *gradient boosting*), incluir al menos un representante de cada gran familia metodológica (lineal, bayesiano, *bagging*, *boosting*), y limitar el conjunto a algoritmos con implementación madura, documentación sólida e interpretabilidad factible mediante técnicas como SHAP para evitar que se convirtiesen en una “caja negra”.

Se evaluaron seis algoritmos: La **Regresión Logística**, modelo lineal de referencia. **Random Forest**, un conjunto de árboles entrenados con muestreo bootstrap y selección aleatoria de variables en cada split, lo que reduce la varianza respecto a un árbol único y captura interacciones no lineales sin necesidad de especificarlas explícitamente. **XGBoost**, una implementación optimizada de *gradient boosting* sobre árboles de decisión, donde cada árbol nuevo se entrena para corregir los errores del previo y dispone de mecanismos integrados para gestionar el desbalance de clases. **LightGBM**, que comparte filosofía con XGBoost pero utiliza una estrategia de crecimiento de árbol por hojas (*leaf-wise*) en lugar de por niveles, lo que puede traducirse en menor tiempo de entrenamiento y mejor ajuste con grandes volúmenes de datos, **CatBoost** es otro algoritmo de *gradient boosting* diseñado originalmente para manejar variables categóricas pero que se comporta de forma muy estable también con predictores continuos, gracias a su uso de árboles simétricos y a sus estrategias internas de regularización. Por último, el **Naive**

Bayes Gaussiano, que asume independencia condicional entre predictores dado el evento; aunque esta hipótesis es claramente irreal en el contexto clínico, su inclusión sirve como segunda cota inferior y permite comprobar si la estructura de dependencia entre variables aporta algo respecto a una suposición ingenua de independencia.

La prevalencia del evento positivo en el conjunto de entrenamiento se sitúa entre el 10 % y el 11 % según la ventana, lo que constituye un desbalance moderado. En la Regresión Logística, Random Forest y LightGBM se utilizó `class_weight='balanced'` (con la variante `balanced_subsample` también incluida en el grid de Random Forest), que reescala internamente la función de pérdida de forma inversamente proporcional a la frecuencia de cada clase. En XGBoost se exploraron distintos valores del parámetro `scale_pos_weight`, que cumple una función equivalente penalizando más los errores sobre la clase minoritaria. CatBoost y Naive Bayes no requirieron parámetro explícito: el primero gestiona internamente el desbalance mediante sus estrategias de regularización, y el segundo es naturalmente robusto a distribuciones de clase desiguales por su formulación bayesiana.

El escalado se aplicó únicamente a los algoritmos cuya formulación matemática es sensible a la magnitud de las variables: la Regresión Logística, cuya optimización mediante `liblinear` depende de la escala de los coeficientes, y el Naive Bayes Gaussiano, que estima parámetros de distribuciones univariantes cuya varianza depende de la escala original de cada predictor. En ambos casos se utilizó `RobustScaler` en lugar del habitual `StandardScaler`. La diferencia es metodológicamente relevante: `RobustScaler` centra cada variable en su mediana y la escala según el rango intercuartílico en lugar de la media y la desviación estándar, lo que lo hace más robusto a la presencia de valores extremos que, aunque ya habían sido winsorizados, podían seguir influyendo en los estadísticos basados en momentos. Los algoritmos basados en árboles (Random Forest, XGBoost, LightGBM, CatBoost) no necesitan escalado, ya que sus *splits* se basan en órdenes relativos de valores y son invariantes a transformaciones monótonas.

Adicionalmente, el escalado se integró dentro del *pipeline* de scikit-learn, de modo que sus parámetros (medianas y rangos intercuartílicos) se ajustaron exclusivamente sobre los datos de entrenamiento de cada fold, evitando así fuga de información desde el conjunto de test.

Cada algoritmo dispone de un conjunto propio de hiperparámetros que controlan su capacidad de generalización y su tendencia al sobreajuste. Para cada uno se definió un *grid* específico, intentando cubrir el rango

habitualmente reportado en la literatura para problemas tabulares de tamaño similar.

Para la **Regresión Logística** se exploró el parámetro de regularización inverso C en doce valores distribuidos logarítmicamente entre 10^{-4} y 50, lo que permite contemplar tanto soluciones fuertemente regularizadas (útiles cuando hay multicolinealidad residual o predictores poco informativos) como soluciones prácticamente sin regularización.

Para **Random Forest** se exploró un total de 1.575 combinaciones distintas, variando el número de árboles entre 300 y 1.000, la profundidad máxima entre ilimitada y 30 niveles, el número mínimo de muestras por hoja entre 1 y 5, la fracción de variables consideradas en cada *split* (`sqrt`, 0,3 y 0,5 sobre el total), y el esquema de balanceo de clases.

Para **XGBoost** se barrieron 1.944 combinaciones que incluyen el número de árboles, la profundidad máxima, la tasa de aprendizaje (entre 0,005 y 0,1), las fracciones de muestreo de filas (`subsample`) y de columnas (`colsample_bytree`), el parámetro de regularización L2 (`reg_lambda`) y el factor de peso de la clase positiva. La combinación de tasa de aprendizaje baja con número alto de árboles suele producir modelos más estables.

Para **LightGBM** se exploraron 1.296 combinaciones variando el número de árboles, el número máximo de hojas, la tasa de aprendizaje, el número mínimo de muestras por hoja (`min_child_samples`), la regularización L2, el muestreo de filas y el esquema de balanceo de clases.

Para **CatBoost** se barrieron 216 combinaciones que cubren el número de iteraciones, la profundidad de los árboles, la tasa de aprendizaje, la regularización L2 sobre las hojas (`l2_leaf_reg`) y la temperatura del muestreo bayesiano (`bagging_temperature`), que controla el grado de aleatoriedad introducido en el ensemble.

Para **Naive Bayes** el único hiperparámetro relevante es `var_smoothing`, que añade una pequeña cantidad a la varianza estimada de cada variable para estabilizar el cálculo cuando esta es muy pequeña. Se exploraron 30 valores distribuidos logarítmicamente entre 10^{-12} y 10^{-2} .

El rendimiento de cada modelo se estimó mediante la misma validación cruzada anidada 5×3 ya descrita en el análisis de permutation importance. El bucle externo, de 5 folds, proporciona la estimación insesgada del rendimiento del modelo sobre datos no vistos. El bucle interno, de 3 folds, se dedica exclusivamente a la búsqueda de hiperparámetros mediante `GridSearchCV` optimizando el AUC-ROC. Tanto el bucle externo como el interno utilizan `StratifiedGroupKFold`, lo que garantiza dos propiedades simultáneamente:

por un lado, mantiene la proporción de positivos y negativos estable entre particiones; por otro, asegura que todas las estancias de un mismo paciente queden íntegramente en el mismo fold, eliminando la posibilidad de fuga de información entre estancias correlacionadas del mismo sujeto. En cada fold externo, el modelo con los mejores hiperparámetros seleccionados por el bucle interno se reentrena sobre el bloque completo de entrenamiento y se evalúa una única vez sobre el bloque de test.

La elección de métricas se diseñó para evaluar simultáneamente la capacidad discriminativa del modelo y la calidad de las probabilidades que predice. Dada la presencia de desbalance de clases moderado y la naturaleza clínica del problema —donde una probabilidad mal calibrada puede llevar a decisiones asistenciales incorrectas— se evaluaron seis métricas complementarias:

El **AUC-ROC** mide la probabilidad de que el modelo asigne una puntuación más alta a una estancia positiva aleatoria que a una negativa aleatoria. Es la métrica estándar en la literatura de aprendizaje automático médico, invariante a la prevalencia y al umbral de decisión. El **AUC-PR** (área bajo la curva precisión-recall) es especialmente relevante en problemas desbalanceados: mientras que el AUC-ROC puede ser engañosamente alto cuando la mayoría de las observaciones son negativas, el AUC-PR penaliza explícitamente los falsos positivos y es más sensible al rendimiento sobre la clase minoritaria, que en este caso es la clínicamente relevante.

El **Brier score** mide el error cuadrático medio entre las probabilidades predichas y las etiquetas reales; valores más bajos indican mejores predicciones probabilísticas. Sin embargo, su valor absoluto depende de la prevalencia del evento, lo que dificulta la comparación entre ventanas con distintas frecuencias de positivos. Por este motivo se incorporó el **Brier Skill Score (BSS)**, definido como $BSS = 1 - \text{Brier}_{\text{modelo}} / \text{Brier}_{\text{nulo}}$, donde el modelo nulo predice constantemente la prevalencia observada. Un BSS positivo indica que el modelo aporta mejora respecto a la predicción trivial basada únicamente en la prevalencia, y su interpretación es comparable entre ventanas.

El **Expected Calibration Error (ECE)** mide la diferencia media entre la probabilidad predicha y la frecuencia observada de positivos, agrupando las predicciones en 10 *bins* equiespaciados. Un ECE bajo indica buena calibración: cuando el modelo predice 30 % de probabilidad de inicio de noradrenalina, aproximadamente el 30 % de esos pacientes realmente inician el tratamiento. La calibración es especialmente importante en este contexto clínico, donde una herramienta predictiva que se utilice para apoyar decisio-

nes asistenciales debe ofrecer probabilidades que el clínico pueda interpretar literalmente y no simplemente como un *ranking* relativo.

Finalmente, el **LogLoss** o entropía cruzada binaria penaliza fuertemente las predicciones erróneas hechas con alta confianza, complementando al Brier score como medida global de calidad probabilística.

La validación cruzada anidada proporciona una estimación insesgada del rendimiento, pero no devuelve un modelo único utilizable en producción: en cada uno de los 5 folds externos se entrena un modelo distinto, con hiperparámetros potencialmente diferentes seleccionados por el bucle interno. Para obtener un único modelo final por ventana y algoritmo se aplicó el siguiente procedimiento: tras completar la CV anidada, se identificó el valor más frecuente (voto mayoritario) de cada hiperparámetro entre los 5 folds externos, y se reentrenó el pipeline completo —incluyendo escalado cuando correspondía— sobre el 100 % de la cohorte de MIMIC-IV con esos hiperparámetros fijos. Esta estrategia garantiza que el modelo final aprovecha toda la información disponible para su ajuste, mientras que las métricas reportadas siguen procediendo exclusivamente de la CV anidada y son por tanto representativas del rendimiento esperable sobre pacientes nuevos.

Cada modelo final se serializó mediante `joblib` en un fichero `.pkl` que contiene tanto el pipeline de preprocesamiento como el estimador entrenado. Esto permite cargar el modelo en cualquier entorno con las mismas versiones de las librerías y aplicarlo directamente a nuevas observaciones sin necesidad de reentrenarlo, lo cual fue imprescindible para el desarrollo posterior del dashboard interactivo y para la validación externa sobre eICU-CRD.

Las métricas obtenidas en la validación cruzada anidada del baseline son la estimación más realista del rendimiento generalizable de cada modelo, ya que cada predicción se realiza sobre estancias que no participaron ni en el entrenamiento ni en la búsqueda de hiperparámetros. Sin embargo, esas métricas se reportan como medias y desviaciones por fold, lo que dificulta inspeccionar visualmente la curva ROC, la curva precision-recall o la calibración del modelo. Para solventar esta limitación se reconstruyeron las probabilidades *out-of-fold* (OOF) de cada modelo final mediante la función `cross_val_predict` de `sklearn`, aplicada sobre el mismo esquema de validación cruzada externa utilizado en el baseline: `StratifiedGroupKFold` con 5 particiones, semilla fija y agrupamiento por `subject_id`. De este modo, para cada estancia se obtuvo una predicción generada por un modelo que nunca había visto a ese paciente durante su entrenamiento. Las probabilidades OOF concatenadas permiten dibujar una única curva ROC, una única curva precision-recall y una única curva de calibración por modelo,

que reflejan de forma agregada y honesta el comportamiento esperable del modelo en datos nuevos.

Para cada combinación de modelo y ventana temporal se generó una figura compuesta por tres paneles: la curva ROC con su AUC, la curva precision-recall con su AUC-PR (incluyendo la línea horizontal correspondiente a la prevalencia del evento como referencia del rendimiento esperable de un clasificador aleatorio), y la curva de calibración construida con diez bins de igual número de muestras (estrategia *quantile*) para evitar bins vacíos en las regiones de baja densidad de probabilidad predicha.

[PONER ALGUNA FIG AQUÍ]

La capacidad discriminativa medida por AUC-ROC informa sobre la habilidad del modelo para ordenar correctamente a los pacientes por riesgo, pero no garantiza que las probabilidades predichas se correspondan numéricamente con las frecuencias reales del evento. Un modelo puede separar perfectamente positivos de negativos y, al mismo tiempo, predecir probabilidades sistemáticamente más altas o más bajas que la prevalencia real, lo que comprometería su utilidad clínica en un dashboard de soporte a la decisión donde la cifra mostrada al profesional sanitario debe reflejar un riesgo interpretable. Por este motivo, tras la evaluación inicial del baseline se inspeccionaron las curvas de calibración OOF y los valores de *Expected Calibration Error* (ECE) y *Brier Skill Score* (BSS) de cada modelo. Se identificaron como candidatos a recalibración aquellos modelos que combinaban un buen rendimiento discriminativo (AUC-ROC robusto) con un ECE elevado o una curva de calibración visiblemente desviada de la diagonal: CatBoost en las ventanas Corto y Medio, y XGBoost en las tres ventanas.

Para cada uno de estos modelos se evaluaron empíricamente tres familias de calibradores aplicados sobre las probabilidades OOF: el método de Platt sin regularización (regresión logística con $C = 10^{10}$, que ajusta una sigmoide de dos parámetros sobre las probabilidades brutas), el método de Platt regularizado (con el parámetro C optimizado mediante validación cruzada interna usando *negative Brier score* como criterio, lo que penaliza ajustes sobreajustados a los folds de entrenamiento) y la regresión isotónica (un método no paramétrico que aprende una función monotonía creciente sobre los puntos observados, más flexible pero más exigente en términos de tamaño muestral). Cada calibrador se ajustó dentro de cada uno de los cinco folds de la validación cruzada externa, utilizando exclusivamente las probabilidades brutas del conjunto de entrenamiento de ese fold, y se aplicó después sobre las probabilidades brutas del conjunto de test del mismo fold. Este procedimiento, análogo al utilizado para generar las probabilidades

OOF originales, garantiza que la evaluación del efecto del calibrador esté libre de fuga de información.

El criterio de selección del calibrador final fue minimizar el ECE entre los métodos que conservaban un BSS estrictamente positivo respecto al modelo sin calibrar. Esta condición es relevante porque la calibración puede mejorar el ECE a costa de comprimir la distribución de probabilidades hacia la prevalencia, lo que degradaría la capacidad informativa del modelo respecto a un predictor que asignase a todos los pacientes la probabilidad climatológica. En los casos en los que ningún calibrador conseguía mantener un BSS positivo, se conservó el modelo sin calibrar. Una vez seleccionado el método óptimo, se reentrenó el calibrador sobre las probabilidades OOF completas y se guardó serializado junto con el modelo base en una clase `ModeloCalibrado` que encapsula ambos componentes y expone los métodos `predict_proba` y `predict` estándar de la API de `sklearn`, lo que permite su integración transparente en el dashboard final.

[Aquí podría ir una figura comparativa de la calibración antes y después del XGBoost]

La interpretabilidad post-hoc se abordó mediante valores SHAP (*SHapley Additive exPlanations*), que asigna a cada variable predictora una contribución cuantitativa a la diferencia entre la predicción individual y el valor esperado del modelo sobre la población. A diferencia de la importancia por permutación, que opera a nivel agregado y mide cuánto degrada el rendimiento la pérdida de una variable, los valores SHAP descomponen la predicción puntual de cada paciente en contribuciones aditivas por variable, lo que permite analizar tanto la importancia global de un predictor como su efecto direccional y la heterogeneidad de su impacto entre subgrupos de pacientes.

El método de cálculo se adaptó a la arquitectura de cada algoritmo. Para los modelos basados en árboles (Random Forest, XGBoost, LightGBM y CatBoost) se utilizó `TreeExplainer`, que calcula los valores SHAP de forma exacta y eficiente aprovechando la estructura del ensemble, sin necesidad de muestreo ni de escalado de las variables. Para la regresión logística se empleó `LinearExplainer` con el modo `interventional` de perturbación, que calcula los valores SHAP exactos para modelos lineales aplicados sobre las variables ya estandarizadas. Para Naive Bayes, al no existir un explainer exacto disponible, se recurrió a `KernelExplainer`, un método aproximado y agnóstico al modelo que estima los valores SHAP mediante muestreo de combinaciones de variables; se utilizó una muestra de fondo de 200 estancias y se evaluó sobre 500 estancias seleccionadas aleatoriamente con semilla

fija, con 100 permutaciones por estimación para mantener un compromiso razonable entre precisión y coste computacional.

La visualización se realizó mediante diagramas de tipo *beeswarm* (también llamados *summary plot*), que muestran simultáneamente tres dimensiones de información para cada variable: la magnitud del impacto (eje horizontal, valor SHAP), la dirección del impacto (signo del valor SHAP, donde valores positivos aumentan la probabilidad predicha y valores negativos la disminuyen) y el valor original de la variable (codificado en color, típicamente azul para valores bajos y rojo para valores altos). Esta representación permite identificar de un vistazo si una variable contribuye de forma monótonica al riesgo, si presenta efectos no lineales o umbrales, y si la dirección del efecto es coherente con la fisiopatología esperada.

Además de mejorar la interpretabilidad, los análisis SHAP se utilizaron como una comprobación cualitativa adicional de coherencia fisiopatológica. En particular, permitieron verificar si los modelos asignaban mayor riesgo a patrones clínicamente esperables, como hipotensión, peor oxigenación, mayor necesidad de FiO_2 , deterioro neurológico o aumento de marcadores de disfunción orgánica. Esta revisión fue especialmente importante tras el tratamiento de valores extremos, ya que permitió comprobar que las predicciones no dependían de artefactos aislados de registro, como valores implausibles de MAP, sino de relaciones consistentes entre variables clínicas y riesgo de inicio de noradrenalina. Por tanto, SHAP no se empleó como técnica de selección automática de variables, sino como una capa de auditoría e interpretabilidad para reducir el carácter de “caja negra” de los modelos finales.

[Aquí podría ir una rejilla con algún diagrama]

Una vez seleccionado y calibrado el modelo final de cada ventana, se realizó un análisis diferencial por subgrupos clínicos para evaluar si el rendimiento del modelo era homogéneo entre pacientes con y sin sepsis, dado que el inicio de noradrenalina es particularmente frecuente en el contexto del shock séptico y un comportamiento desigual entre subgrupos podría comprometer la utilidad clínica del modelo en una u otra población. Este análisis se realizó exclusivamente sobre la cohorte de MIMIC-IV, ya que en eICU-CRD no fue posible construir un indicador de sepsis equivalente al disponible en MIMIC-IV, como se justificó en la sección de construcción de cohortes.

Para garantizar una evaluación honesta también en este análisis, las probabilidades utilizadas para cada paciente fueron las probabilidades OOF calibradas: en cada fold de la validación cruzada externa se reentrenó el

modelo base sobre el conjunto de entrenamiento del fold, se ajustó el calibrador de Platt sobre las probabilidades brutas de ese mismo conjunto de entrenamiento y se aplicó el calibrador sobre las probabilidades brutas del conjunto de test. Las probabilidades OOF calibradas resultantes se estratificaron posteriormente según el valor de la variable `tiene_sepsis` en tres subgrupos: la cohorte global, los pacientes con sepsis identificada según Sepsis-3 y los pacientes sin sepsis identificada. Para cada subgrupo se calcularon las mismas métricas que en la evaluación global del baseline: AUC-ROC, AUC-PR, BSS y ECE.

Como benchmark clínico se comparó el rendimiento del modelo con el de la puntuación SOFA utilizada como predictor aislado. Dado que el SOFA no produce probabilidades sino una puntuación entera en el rango $[0, 24]$, la comparación se limitó a las métricas basadas en el orden de las predicciones (AUC-ROC y AUC-PR), que no requieren que la salida sea una probabilidad calibrada. Este benchmark constituye una referencia conservadora pero clínicamente relevante, ya que el SOFA es la herramienta de evaluación de gravedad más extendida en cuidados intensivos y cualquier modelo que pretenda aportar valor en la práctica clínica debería superarlo claramente. La comparación se realizó sobre el mismo conjunto de pacientes y la misma etiqueta utilizados para la evaluación del modelo, para garantizar que las diferencias observadas reflejen genuinamente la capacidad predictiva diferencial y no artefactos del muestreo.

[Algo del SOFA]

4.3. Dashboard clínico y limitaciones de uso

Como parte final del trabajo se desarrolló un prototipo de *dashboard* clínico en Python utilizando Streamlit. El objetivo de esta aplicación no fue sustituir la valoración médica, sino demostrar la viabilidad técnica de integrar los modelos entrenados en una interfaz sencilla, interpretable y orientada a la consulta individual de pacientes.

El diseño del *dashboard* siguió deliberadamente un enfoque minimalista. La aplicación permite seleccionar una de las ventanas temporales disponibles, cargar un archivo CSV con las variables clínicas del paciente durante el periodo de observación correspondiente y obtener una estimación individualizada del riesgo de inicio de noradrenalina. En esta versión del prototipo se integraron los modelos de las ventanas media y larga: la ventana media estima el riesgo de inicio entre las 6 y las 24 horas, mientras que la ventana

larga estima el riesgo entre las 12 y las 48 horas tras el ingreso. La corta fue excluida por malos resultados tras su validación externa.

El archivo CSV de entrada debe contener una fila por medición del paciente e incluir las variables necesarias para cada modelo. A partir de estos datos brutos, el sistema calcula automáticamente los estadísticos agregados requeridos por el modelo, como el mínimo de MAP, el cociente $\text{PaO}_2/\text{FiO}_2$, la diuresis acumulada normalizada por peso, la frecuencia cardiaca media, el SOFA máximo o los valores mínimos de SpO_2 , bicarbonato, temperatura y glucemia, según la ventana seleccionada. De este modo, el usuario no introduce directamente las variables finales del modelo, sino mediciones clínicas ordinarias que posteriormente son transformadas por la aplicación.

Una vez generado el vector de entrada, el modelo correspondiente se carga desde un archivo serializado en formato `.pkl` mediante `joblib` o `pickle`. La probabilidad estimada se transforma además en un percentil de riesgo utilizando como referencia la distribución de probabilidades obtenida en la cohorte de entrenamiento de MIMIC-IV. Esta decisión facilita la interpretación del resultado: en lugar de mostrar únicamente una probabilidad aislada, el sistema indica la posición relativa del paciente respecto a una población UCI de referencia. Por ejemplo, un percentil 90 significa que el paciente se sitúa por encima del 90 % de los pacientes de referencia en riesgo estimado por el modelo.

Junto al percentil de riesgo, el *dashboard* muestra una explicación individual basada en valores SHAP. Esta visualización permite identificar qué variables empujan la predicción hacia mayor riesgo y cuáles la reducen en ese paciente concreto. Por tanto, el sistema no se limita a mostrar una cifra final, sino que permite revisar si la predicción está apoyada en factores clínicamente plausibles, como hipotensión, peor oxigenación, mayor SOFA o alteraciones metabólicas. Esta explicación es especialmente importante en un contexto clínico, donde una predicción sin justificación sería difícilmente aceptable y convertiría el modelo en una herramienta de tipo “caja negra”.

Una decisión central del diseño fue evitar que el *dashboard* emitiera recomendaciones clínicas directas. La aplicación no indica si debe iniciarse noradrenalina, no propone dosis, no genera alarmas terapéuticas y no clasifica al paciente en categorías cerradas de actuación. Esta restricción es deliberada. En una herramienta clínica real, ofrecer recomendaciones automáticas a partir de un modelo retrospectivo no validado prospectivamente supondría un riesgo metodológico, ético y asistencial. El inicio de soporte vasopresor depende de múltiples factores que no siempre están recogidos en los datos estructurados, como la exploración clínica, la respuesta a fluidoterapia, el

contexto quirúrgico, la evolución reciente, las preferencias terapéuticas o el criterio del equipo responsable.

Por este motivo, el prototipo se planteó únicamente como una herramienta de apoyo visual a la interpretación del riesgo. Los modelos integrados no deben entenderse como sistemas que deciden por el clínico, sino como aproximaciones complementarias que observan el mismo problema desde perspectivas temporales diferentes. La ventana media está orientada a detectar riesgo en un horizonte más próximo, mientras que la ventana larga permite explorar una posible evolución desfavorable en un plazo más amplio. Ambas salidas deben interpretarse como información adicional, no como una indicación terapéutica.

La propia interfaz incluye un aviso explícito indicando que se trata de un prototipo académico de investigación, sin validación clínica prospectiva ni autorización regulatoria, y que no debe utilizarse en práctica clínica real. Esta advertencia forma parte del diseño del sistema y refleja una limitación fundamental del trabajo: aunque los modelos hayan sido evaluados retrospectivamente y validados externamente sobre eICU-CRD, su uso asistencial requeriría una validación prospectiva, revisión por comités clínicos y éticos, análisis de impacto sobre el flujo de trabajo y una integración segura con los sistemas de información hospitalarios.

En conjunto, el *dashboard* demuestra que los modelos desarrollados pueden desplegarse en una interfaz comprensible, reproducible e interpretable. Sin embargo, su función dentro de este TFG es exclusivamente demostrativa: sirve para ilustrar cómo podrían presentarse las predicciones y sus explicaciones en un entorno clínico, no para guiar decisiones terapéuticas reales.

4.4. Metodología de Ingeniería del Software

El desarrollo software del proyecto siguió una metodología experimental e iterativa. A diferencia de una aplicación software tradicional con requisitos funcionales cerrados desde el inicio, el flujo de trabajo se fue refinando progresivamente en función de los resultados obtenidos durante la construcción de cohortes, el análisis exploratorio, la selección de variables, el entrenamiento de modelos, la calibración y la validación externa.

No se aplicó un marco formal como Scrum, dado que el trabajo fue desarrollado por un único autor y la planificación estuvo guiada principalmente por objetivos metodológicos y experimentales. En su lugar, se siguió un ciclo

incremental basado en versiones sucesivas del conjunto de datos, los modelos y los scripts de análisis. Cada iteración permitió corregir errores, mejorar la definición de variables, revisar el tratamiento de valores extremos y validar de nuevo los resultados obtenidos.

El código se organizó en módulos funcionales diferenciados: construcción de cohortes mediante consultas SQL, preprocesamiento y análisis exploratorio, selección de variables, entrenamiento de modelos, elegir las ventanas temporales, calibración, interpretabilidad mediante SHAP, validación externa y desarrollo del prototipo de dashboard. Esta organización permitió mantener la trazabilidad entre los resultados presentados en la memoria y los scripts utilizados para generarlos.

El control de versiones se realizó mediante Git y GitHub. El repositorio incluye el código necesario para reproducir el flujo de trabajo, respetando las restricciones de uso de MIMIC-IV y eICU-CRD, que impiden redistribuir directamente los datos clínicos. Por este motivo, los archivos intermedios derivados de las bases de datos no se incluyen en el repositorio, aunque sí se documenta el procedimiento necesario para regenerarlos a partir de las credenciales y permisos correspondientes.

El prototipo de dashboard se desarrolló con Streamlit siguiendo un diseño deliberadamente simple. La aplicación carga modelos previamente entrenados y serializados, transforma un archivo CSV de entrada en las variables requeridas por cada modelo, calcula el percentil de riesgo del paciente y muestra una explicación individual mediante SHAP. No se implementaron recomendaciones clínicas automáticas ni reglas terapéuticas, ya que el objetivo del software es demostrar la viabilidad técnica de presentar predicciones interpretables, no sustituir la decisión médica.

Resultados

5.1. Resumen de resultados

Breve resumen de los resultados. En caso de ser un trabajo muy experimental, los resultados completos pueden aparecer en su anexo correspondiente.

Debería haber una correspondencia entre los objetivos y los resultados explicados en esta sección

A continuación se muestra un **ejemplo de figura generada con R**:

```
library(ggplot2)

ggplot(iris, aes(x = Species, y = Sepal.Length, fill = Species)) +
  geom_boxplot(alpha = 0.7, show.legend = FALSE) +
  labs(
    x = "Especie",
    y = "Longitud del sépalo (cm)"
  ) +
  theme_minimal(base_size = 11) +
  theme(panel.grid.minor = element_blank())
```

Debería existir correspondencia entre los objetivos definidos y los resultados mostrados (Koza, 1992).




Figura 5.1: Distribución de la longitud de sépal por especie en el conjunto iris

Discusión

Se realizará un análisis crítico de los resultados, interpretando su significado y, cuando sea pertinente, comparándolos con los resultados de trabajos previos, obtenidos con la revisión del estado del arte; de forma que se destaquen las mejoras y aportes sobre el mismo.

Conclusiones

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas.

7.1. Aspectos relevantes

Este apartado pretende recoger los aspectos más interesantes del **desarrollo del proyecto**, comentados por los autores del mismo y que den respuesta a los objetivos planteados.

Debe incluir los detalles más relevantes en cada fase del desarrollo, justificando los caminos tomados, especialmente aquellos que no sean triviales.

Puede ser el lugar más adecuado para documentar los aspectos más interesantes del proyecto y también los resultados negativos obtenidos por soluciones previas a la solución entregada.

Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

Líneas de trabajo futuras

La línea de trabajo más prioritaria e inmediata consiste en retomar y consolidar la validación externa planificada sobre los datos reales del Hospital Universitario de Burgos (HUBU). Aunque la heterogeneidad en las estructuras de registro y las barreras técnicas de extracción obligaron a sustituir esta cohorte por la base de datos multicéntrica eICU-CRD, la transferencia del modelo a una población de referencia europea sigue siendo un hito indispensable para garantizar la generalizabilidad del algoritmo sobre esta población. Una vez garantizada la viabilidad de extracción desde los sistemas de información clínica de la UCI del HUBU, se procederá a la tramitación ante el Comité de Ética de Investigación del centro, y se diseñará un proceso de mapeo y traducción iterativa de variables clínicas locales hacia el esquema estructurado de la pipeline actual, garantizando la homogeneidad de los predictores clave.

Una segunda línea de trabajo sería la transición hacia modelos basados en series temporales. El enfoque actual utiliza métricas estáticas resumidas (mínimos, máximos o medias) dentro de una ventana fija, descartando la riqueza dinámica y la tendencia temporal de las constantes vitales. Se plantea reestructurar la arquitectura predictiva sustituyendo los árboles estáticos por modelos capaces de procesar secuencias temporales. Esto incluye la implementación de redes neuronales recurrentes (LSTM) o Transformers temporales adaptados a registros clínicos tabulares, o el uso de librerías como `tsfresh` o `sktime` para la extracción automatizada de características dinámicas.

Un tercer ejemplo es la implementación de modelos de análisis de supervivencia. La formulación binaria estricta ligada a ventanas temporales fijas limita la toma de decisiones clínicas. La integración de técnicas de Análisis

de Supervivencia aplicado al Machine Learning permitirá modelar de forma continua el tiempo hasta el evento gestionando correctamente la censura de datos (altas hospitalarias o fallecimientos prematuros antes de que ocurra el evento).

Por último, podría valorarse de cara a un futuro y si estos modelos predictivos cumplen con los requisitos para convertirse en herramientas clínicas validadas, la integración de estos en el software de una UCI que ya se use para monitorizar pacientes, por ejemplo, mediante conexión directa del backend con las bases de datos de monitorización en tiempo real de la unidad, ejecutando el algoritmo en segundo plano de forma automática ante cada nueva analítica o constante registrada. En su defecto, también cabría explorar la posibilidad de que el Dashboard se convierta en uno multipaciente que permita la vigilancia simultánea y centralizada de todas las camas del servicio.

Bibliografía

- CITI Program (2026). Collaborative institutional training initiative. Accedido en marzo de 2026.
- Duval, L., Villié, A., Zheng, F., Terraz, G., Blein, S., Duperchy, E., Everett, M., Frieling, J., Llitjos, J.-F., and Bodinier, M. (2025). Early prediction of vasopressor initiation in ICU sepsis patients using an interpretable EHR-based ML model. *BMC Medical Informatics and Decision Making*, 25(1):442.
- Evans, L., Rhodes, A., Alhazzani, W., et al. (2021). Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021. *Intensive Care Medicine*, 47:1181–1247.
- Fleischmann-Struzek, C., Mellhammar, L., Rose, N., et al. (2020). Incidence and mortality of hospital- and ICU-treated sepsis: results from an updated and expanded systematic review and meta-analysis. *Intensive Care Medicine*, 46:1552–1562.
- Grupo de Trabajo Sepsis HUBU (2025). Protocolo Código Sepsis HUBU. Manejo integral del paciente séptico. III edición. Technical report, Complejo Asistencial Universitario de Burgos.
- Gupta, M., Gallamoza, B., Cutrona, N., Dhakal, P., Poulain, R., and Behesh-ti, R. (2022). An extensive data processing pipeline for MIMIC-IV. In *Proceedings of the 2nd Machine Learning for Health Symposium*, volume 193 of *Proceedings of Machine Learning Research*, pages 311–325. PMLR.
- Jiang, Z., Zhang, S., Yuan, Y., Wang, J., and Hu, Z. (2025). Chronosynthnet: a dual-task deep learning model development and validation study for

- predicting real-time norepinephrine dosage and the early detection of hypotension in patients with septic shock. *Cardiovascular Diagnosis and Therapy*, 15(4):833–846.
- Johnson, A. E. W., Bulgarelli, L., Shen, L., et al. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.
- Kalimouttou, A., Kennedy, J. N., Feng, J., Singh, H., Saria, S., Angus, D. C., Seymour, C. W., and Pirracchio, R. (2025). Optimal vasopressin initiation in septic shock: The OVISS reinforcement learning study. *JAMA*, 333(19):1688–1698.
- Koza, J. R. (1992). *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30.
- MIT Laboratory for Computational Physiology (2024). MIMIC code repository. <https://github.com/MIT-LCP/mimic-code>. Accedido: abril de 2026.
- Persson, I., Macura, A., Becedas, D., and Sjövall, F. (2024). Early prediction of sepsis in intensive care patients using the machine learning algorithm NAVOY® sepsis, a prospective randomized clinical validation study. *Journal of Critical Care*, 80:154400.
- PhysioNet (2026). Physionet: The research resource for complex physiologic signals. Accedido en marzo de 2026.
- Pollard, T. J., Johnson, A. E. W., Raffa, J. D., Celi, L. A., Mark, R. G., and Badawi, O. (2018). The eICU collaborative research database, a freely available multi-center database for critical care research. *Scientific Data*, 5:180178.
- Rockenschaub, P., Akay, E. M., Carlisle, B. G., et al. (2025). External validation of AI-based scoring systems in the ICU: a systematic review and meta-analysis. *BMC Medical Informatics and Decision Making*, 25:5.
- Scheibner, A., Betthausen, K. D., Bewley, A. F., Juang, P., Lizza, B., Micek, S., and Lyons, P. G. (2022). Machine learning to predict vasopressin responsiveness in patients with septic shock. *Pharmacotherapy*, 42(6):460–471.

- Shanmugam, H., Airen, L., and Rawat, S. (2025). Machine learning and deep learning models for early sepsis prediction: A scoping review. *Indian Journal of Critical Care Medicine*, 29(6):516–524.
- Singer, M., Deutschman, C. S., Seymour, C. W., Shankar-Hari, M., Annane, D., Bauer, M., Bellomo, R., Bernard, G. R., Chiche, J.-D., Coopersmith, C. M., Hotchkiss, R. S., Levy, M. M., Marshall, J. C., Martin, G. S., Opal, S. M., Rubenfeld, G. D., van der Poll, T., Vincent, J.-L., and Angus, D. C. (2016). The third international consensus definitions for sepsis and septic shock (Sepsis-3). *JAMA*, 315(8):801–810.
- Vincent, J.-L. and De Backer, D. (2013). Circulatory shock. *New England Journal of Medicine*, 369(18):1726–1734.
- Zhang, T., Qu, Y., Wang, D., Zhong, M., Cheng, Y., and Zhang, M. (2024). Optimizing sepsis treatment strategies via a reinforcement learning model. *Biomedical Engineering Letters*, 14(2):279–289.