




**UNIVERSIDAD  
DE BURGOS**

**Escuela Politécnica Superior**

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la  
Salud**

**Estimación temprana del  
riesgo de inicio de  
noradrenalina en UCI  
mediante aprendizaje  
automático y dashboard  
interpretable**

Presentado por Daniel Marina de la Cal  
en Universidad de Burgos


Tutores: Antonio Jesús Canepa Oneto – Sergio  
Ossa Echeverri – Fernando Callejo Torre

---



**UNIVERSIDAD  
DE BURGOS**

**Escuela Politécnica Superior**  
Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la  
Salud**

**Estimación temprana del  
riesgo de inicio de  
noradrenalina en UCI  
mediante aprendizaje  
automático y dashboard  
interpretable**

Presentado por Daniel Marina de la Cal  
en Universidad de Burgos

20 de mayo de 2026

---

Tutores: Antonio Jesús Canepa Oneto – Sergio Ossa  
Echeverri – Fernando Callejo Torre





UNIVERSIDAD  
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Antonio Jesús Canepa Oneto, profesor/a del departamento de Ingeniería Informática del área de Lenguajes Informáticos. D. Sergio Ossa Echeverri, médico intensivista del Hospital Universitario de Burgos. D. Fernando Callejo Torre, médico intensivista del Hospital Universitario de Burgos.

Expone/n:

Que el/la alumno/a D. Daniel Marina de la Cal, con DNI 71565266F, ha realizado el Trabajo final de Grado en Ingeniería de la Salud titulado *Estimación temprana del riesgo de inicio de noradrenalina en UCI mediante aprendizaje automático y dashboard interpretable*.

Y que dicho trabajo ha sido realizado por el/la alumno/a bajo la dirección del/los que suscribe/n.

En Burgos, a 20 de mayo de 2026

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Antonio Jesús  
Canepa Oneto

D. Sergio Ossa  
Echeverri

D. Fernando Callejo  
Torre







## **Resumen**

Este TFG propone el desarrollo de modelos de aprendizaje automático orientados a estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes críticos ingresados en UCI, a partir de variables clínicas disponibles durante las primeras horas de estancia, como constantes vitales, parámetros analíticos y datos básicos del paciente. El objetivo no es solo predecir si el paciente requerirá soporte vasopresor en una ventana temporal definida, sino también ofrecer una herramienta interpretable, en forma de dashboard, que permita visualizar el riesgo estimado y los factores que más contribuyen a dicha predicción en cada caso.

## **Descriptores**

Aprendizaje automático, Predicción, Dashboard, Sepsis, UCI, Noradrenalina, vasopresor.

## **Abstract**

This Bachelor's Thesis proposes the development of machine learning models aimed at the early estimation of the risk of initiating noradrenaline in critically ill patients admitted to the ICU, based on clinical variables available during the first hours of admission, such as vital signs, laboratory parameters, and basic patient data. The objective is not only to predict whether the patient will require vasopressor support within a defined time window, but also to provide an interpretable tool in the form of a dashboard. This tool will allow the visualization of the estimated risk and the factors that contribute most to this prediction in each individual case.

## **Keywords**

Machine Learning, Sepsis, Prediction, Dashboard, ICU, norepinephrine, vasopressor.

---

# Índice general

---

|                                                                           |     |
|---------------------------------------------------------------------------|-----|
| Índice general                                                            | iii |
| Índice de figuras                                                         | v   |
| Índice de tablas                                                          | vi  |
| Introducción                                                              | 1   |
| Objetivos                                                                 | 5   |
| Conceptos teóricos                                                        | 9   |
| Metodología                                                               | 15  |
| 4.1. 2. Fuentes de datos . . . . .                                        | 16  |
| 4.2. 3. Construcción de la cohorte de MIMIC-IV . . . . .                  | 17  |
| 4.3. 4. Construcción de la cohorte de eICU-CRD . . . . .                  | 18  |
| 4.4. 5. Manejo de datos faltantes . . . . .                               | 20  |
| 4.5. 6. Análisis exploratorio y tratamiento de valores extremos . . . . . | 21  |
| 4.6. 7. Selección del estadístico de resumen por variable . . . . .       | 22  |
| 4.7. 8. Análisis de correlación y multicolinealidad . . . . .             | 23  |
| 4.8. 9. Selección de variables predictoras . . . . .                      | 24  |
| 4.9. 10. Análisis específico del valor predictivo de la sepsis . . . . .  | 26  |
| 4.10. 11. Modelos de aprendizaje automático . . . . .                     | 27  |
| 4.11. 12. Validación cruzada anidada . . . . .                            | 28  |
| 4.12. 13. Métricas de evaluación . . . . .                                | 29  |
| 4.13. 14. Calibración probabilística . . . . .                            | 29  |
| 4.14. 15. Selección del modelo final por ventana . . . . .                | 30  |

|                                                                  |           |
|------------------------------------------------------------------|-----------|
| 4.15. 16. Reentrenamiento sobre la cohorte completa . . . . .    | 31        |
| 4.16. 17. Interpretabilidad mediante SHAP . . . . .              | 31        |
| 4.17. 18. Análisis de subgrupos y comparación con SOFA . . . . . | 32        |
| 4.18. 19. Validación externa . . . . .                           | 32        |
| 4.19. 20. Prototipo de dashboard clínico . . . . .               | 33        |
| 4.20. 21. Metodología de ingeniería del software . . . . .       | 34        |
| 4.21. 22. Reproducibilidad . . . . .                             | 36        |
| <b>Resultados</b>                                                | <b>39</b> |
| 5.1. Resumen de resultados . . . . .                             | 39        |
| <b>Discusión</b>                                                 | <b>41</b> |
| <b>Conclusiones</b>                                              | <b>43</b> |
| 7.1. Aspectos relevantes . . . . .                               | 43        |
| <b>Líneas de trabajo futuras</b>                                 | <b>45</b> |
| <b>Bibliografía</b>                                              | <b>47</b> |

---

# Índice de figuras

---

5.1. Distribución de la longitud de sépalo por especie en el conjunto iris 40

---

# Índice de tablas

---

|                                                                     |    |
|---------------------------------------------------------------------|----|
| 4.1. Estadísticos descriptivos del conjunto de datos iris . . . . . | 37 |
|---------------------------------------------------------------------|----|

---

# Introducción

---

## Contexto clínico y relevancia del problema

El paciente crítico ingresado en la Unidad de Cuidados Intensivos (UCI) presenta con frecuencia situaciones de fallo orgánico o riesgo inminente de deterioro clínico, lo que exige una monitorización continua y una respuesta terapéutica rápida. Dentro de este contexto, la inestabilidad hemodinámica constituye uno de los problemas más relevantes, ya que puede comprometer la perfusión tisular y favorecer la progresión hacia disfunción multiorgánica.

Entre las intervenciones empleadas para el soporte hemodinámico se encuentra la administración de vasopresores. Estos fármacos permiten mantener una presión de perfusión adecuada cuando los mecanismos compensadores del organismo y la reposición de volumen no son suficientes. La noradrenalina es el vasopresor de primera elección en la mayoría de los escenarios de shock distributivo e inestabilidad hemodinámica en UCI, especialmente en el shock séptico [Evans et al. \(2021\)](#).

La sepsis y el shock séptico representan una de las principales causas de necesidad de soporte vasopresor en pacientes críticos. A escala global, se estimaron 48,9 millones de casos de sepsis y 11 millones de muertes atribuibles en 2017 [Fleischmann-Struzek et al. \(2020\)](#). En adultos hospitalizados, la incidencia de sepsis tratada en UCI alcanza aproximadamente 58 casos por cada 100.000 personas-año [Fleischmann-Struzek et al. \(2020\)](#). En España, la mortalidad de los pacientes sépticos ingresados en UCI se sitúa alrededor del 30, % y puede alcanzar el 50, % en los casos de shock séptico [Grupo de Trabajo Sepsis HUBU \(2025\)](#). No obstante, la necesidad de noradrenalina no se limita a la sepsis, ya que otras formas de shock circulatorio pueden requerir también soporte vasopresor [Vincent and De Backer \(2013\)](#). Por ello, la predicción del inicio de noradrenalina constituye un problema clínico

relevante en la cohorte general de pacientes críticos, más allá de un único diagnóstico.

### Justificación del problema

La decisión de iniciar noradrenalina en un paciente crítico no depende de una única variable aislada. En la práctica clínica habitual, esta decisión se basa en la interpretación conjunta de múltiples señales, como la evolución de la presión arterial, la frecuencia cardíaca, el lactato, la respuesta a la fluidoterapia, la diuresis, el grado de disfunción orgánica, la situación respiratoria y el contexto clínico global del paciente [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta complejidad puede dificultar la identificación temprana de los pacientes que evolucionarán hacia la necesidad de soporte vasopresor.

Además, el momento óptimo de inicio de la noradrenalina continúa siendo un aspecto clínico relevante. Un inicio excesivamente tardío puede prolongar la hipoperfusión y favorecer una mayor acumulación de fluidos, mientras que una indicación innecesaria podría exponer al paciente a tratamientos invasivos no justificados. En este contexto, disponer de herramientas capaces de estimar de forma temprana el riesgo de requerir noradrenalina podría ayudar a complementar la valoración clínica y favorecer una vigilancia más dirigida de los pacientes con mayor probabilidad de deterioro hemodinámico.

### Planteamiento del trabajo

En los últimos años, el aprendizaje automático (*machine learning*, ML) ha adquirido un papel creciente en el análisis de datos clínicos complejos. Su capacidad para integrar simultáneamente variables fisiológicas, analíticas y demográficas resulta especialmente atractiva en el entorno de UCI, donde la toma de decisiones se apoya en información heterogénea y cambiante. Las bases de datos clínicas de gran escala, como MIMIC-IV y eICU, han facilitado el desarrollo y la evaluación de este tipo de modelos en pacientes críticos [Johnson et al. \(2023\)](#); [Pollard et al. \(2018\)](#).

El presente Trabajo de Fin de Grado propone el desarrollo y la validación de modelos de aprendizaje automático para estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes adultos ingresados en UCI. Para ello, se emplean variables clínicas y analíticas disponibles durante las primeras horas de estancia, con el objetivo de anticipar la necesidad de soporte vasopresor antes de que se produzca el evento.

A diferencia de enfoques centrados exclusivamente en pacientes sépticos, este trabajo se plantea sobre una cohorte general de pacientes adultos de UCI de MIMIC-IV, sin restricción diagnóstica inicial. Esta decisión permite



abordar el problema desde una perspectiva más amplia y ajustada al uso real de la noradrenalina en cuidados intensivos. La presencia de sepsis se considera posteriormente como variable de análisis para estudiar el comportamiento diferencial de los modelos en subgrupos clínicamente relevantes.

El trabajo incorpora tres elementos de interés práctico. En primer lugar, se diseñan distintas ventanas temporales de predicción para evaluar el rendimiento del modelo en diferentes escenarios de anticipación clínica. En segundo lugar, se aplica interpretabilidad mediante valores SHAP, con el fin de identificar qué variables contribuyen con mayor peso a la predicción tanto a nivel global como individual. En tercer lugar, se desarrolla un prototipo de *dashboard* clínico en Streamlit, orientado a visualizar el riesgo estimado y los factores explicativos principales de cada paciente. Finalmente, la capacidad de generalización del modelo se evalúa mediante validación externa sobre la base de datos eICU [Pollard et al. \(2018\)](#).

### Estructura de la memoria

El presente documento se organiza en ocho capítulos. Tras este capítulo introductorio, el **Capítulo 2** recoge los objetivos del trabajo. El **Capítulo 3** desarrolla el marco teórico y el estado del arte, incluyendo los fundamentos clínicos del shock, el uso de vasopresores, las bases del aprendizaje automático aplicado a UCI y la revisión de trabajos previos relacionados. El **Capítulo 4** describe la metodología empleada, incluyendo la construcción de cohortes, la definición del evento objetivo, el preprocesamiento de datos, el entrenamiento de modelos y la validación externa. Los **Capítulos 5 y 6** presentan y discuten los resultados obtenidos. El **Capítulo 7** recoge las conclusiones principales y el **Capítulo 8** propone posibles líneas de trabajo futuro.



---

# Objetivos

---

## Objetivo principal

El objetivo principal de este Trabajo de Fin de Grado es desarrollar y validar modelos de aprendizaje automático para la estimación temprana del riesgo de inicio de noradrenalina en pacientes adultos ingresados en la Unidad de Cuidados Intensivos (UCI), utilizando variables clínicas y analíticas disponibles durante las primeras horas de estancia. Esto se materializará en un *dashboard* interpretable diseñado para su uso a pie de cama, que permitirá visualizar el riesgo estimado y los factores clínicos con mayor contribución a dicha predicción en cada paciente de forma individualizada.

## Objetivos específicos

1. Desarrollar modelos predictivos de aprendizaje automático entrenados sobre la base de datos MIMIC-IV que estimen la probabilidad de inicio de noradrenalina en UCI en distintas ventanas temporales tras el ingreso.
2. Evaluar y comparar el rendimiento de distintos algoritmos de clasificación supervisada, incluyendo regresión logística, XGBoost, entre otros, mediante métricas de discriminación y calibración.
3. Desarrollar un prototipo de *dashboard* clínico interpretable que muestre, para cada paciente, la probabilidad estimada de requerir noradrenalina, los factores con mayor peso en la predicción y una clasificación orientativa del nivel de riesgo basada en percentiles.
4. Realizar una validación externa de los modelos predictivos con datos de pacientes reales provenientes de otro repositorio distinto del de entrenamiento.

5. Medir la usabilidad del *dashboard* mediante una encuesta de satisfacción dirigida al personal clínico de la UCI del Hospital Universitario de Burgos.

### Objetivos técnicos

1. Definir y construir a partir de MIMIC-IV la cohorte general de pacientes adultos de UCI, registrando la presencia de sepsis como variable para el análisis de rendimiento diferencial por subgrupos.
2. Extraer y preprocesar las variables predictoras relevantes disponibles en las primeras horas del ingreso en UCI, incluyendo constantes vitales, parámetros analíticos y otros indicadores de disfunción orgánica y perfusión tisular.
3. Identificar el evento objetivo, definido como el inicio de noradrenalina, a partir de la tabla `inputevents` de MIMIC-IV, distinguiendo entre diferentes ventanas temporales de predicción.
4. Implementar técnicas de manejo del desequilibrio de clases, imputación de datos faltantes y evaluación de calibración, adaptadas a las características habituales de los datos clínicos reales de UCI.
5. Aplicar técnicas de interpretabilidad basadas en valores SHAP (*SHapley Additive exPlanations*) para cuantificar la contribución individual de cada variable a la predicción, tanto a nivel global de la cohorte como a nivel de paciente individual [Lundberg and Lee \(2017\)](#).
6. Desarrollar la interfaz del prototipo del *dashboard* utilizando Python (Streamlit), incorporando visualización del riesgo estimado, explicación por variables y clasificación orientativa del nivel de alerta.
7. Documentar todo el proceso de desarrollo en el repositorio GitHub del proyecto, con el objetivo de favorecer la reproducibilidad del código y del entorno de trabajo.

### Objetivos personales

1. Aplicar de forma integrada los conocimientos adquiridos en el Grado de Ingeniería de la Salud a un problema clínico real y de alta relevancia asistencial.

2. Adquirir experiencia práctica en el manejo de bases de datos clínicas de gran escala como MIMIC-IV, así como en los flujos de trabajo habituales en ciencia de datos aplicada a la salud.
3. Profundizar en el campo del aprendizaje automático interpretable y su aplicación en entornos de cuidados intensivos, donde la explicabilidad de las predicciones es un requisito clínico especialmente relevante.
4. Comprender las implicaciones éticas, legales y de privacidad del uso de datos clínicos en investigación, así como los procedimientos de validación en entornos hospitalarios reales.
5. Desarrollar capacidad crítica para comparar el trabajo propio con la literatura existente, identificando las aportaciones diferenciales del presente TFG respecto a los trabajos previos en el área.



---

## Conceptos teóricos

---

### **Inestabilidad hemodinámica en UCI y deterioro hemodinámico**

Fisiopatológicamente, el shock séptico representa el estadio más crítico de la disfunción hemodinámica, caracterizado por una profunda alteración de la macro y microcirculación secundaria a una respuesta desregulada del huésped frente a la infección [Singer et al. \(2016\)](#). Los criterios operativos establecidos por el consenso Sepsis-3 no son meros umbrales estadísticos, sino reflejos de hitos fisiológicos críticos. Una PAM inferior a 65 mmHg compromete la presión de perfusión crítica de órganos vitales (como el cerebro y el riñón), pudiendo superar los límites inferiores funcionales. Por su parte, la elevación del lactato actúa como un marcador de hipoxia tisular, indicando el viraje del metabolismo celular hacia la vía anaerobia debido a la hipoperfusión.

La evaluación de este estado de shock en la práctica asistencial requiere la integración continua de flujos heterogéneos de información. El protocolo institucional del Código Sepsis del Hospital Universitario de Burgos (HUBU) sistematiza esta valoración mediante el uso secuencial de escalas de cribado y gravedad como qSOFA y SOFA, complementadas con la monitorización estrecha de indicadores analíticos y funcionales de fallo orgánico, tales como el ritmo diurético, la función renal (creatinina), el perfil hepático (bilirrubina), la coagulación (recuento plaquetario) y el intercambio gaseoso (relación  $\text{PaO}_2/\text{FiO}_2$ ) [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta aproximación permite al clínico componer un mapa del estado hemodinámico y de la reserva funcional del paciente crítico.

Sin embargo, la traducción de estas variables analíticas y constantes vitales en una decisión terapéutica concreta, como el inicio de soporte vasopresor con noradrenalina, revela las limitaciones inherentes de los sistemas

de puntuación tradicionales. El deterioro hemodinámico real es un proceso dinámico y caracterizado por interacciones no lineales entre las variables fisiológicas, donde la respuesta a tratamientos previos (como la fluidoterapia) altera continuamente la probabilidad del evento objetivo [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Por consiguiente, la identificación predictiva del riesgo de requerir vasopresores excede la capacidad de las reglas de decisión clínicas fijas, justificando la exploración de otras metodologías capaces de modelar esta complejidad temporal de forma continua.

### Uso de vasopresores y papel de la noradrenalina

Tanto las guías de la *Surviving Sepsis Campaign* como el protocolo local del HUBU establecen la noradrenalina como vasopresor de primera elección en el shock séptico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#), y esta recomendación se extiende de facto a la mayoría de los escenarios de shock distributivo en UCI. Cuando se requieren dosis elevadas de noradrenalina para alcanzar una presión arterial media segura, puede asociarse vasopresina como segundo vasopresor. Asimismo, en presencia de disfunción miocárdica asociada o de hipoperfusión persistente a pesar de una adecuada presión arterial, puede considerarse el uso de dobutamina como soporte inotrópico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Este esquema terapéutico refleja que el tratamiento hemodinámico del paciente crítico no es estático, sino progresivo y dependiente de la evolución clínica.

### Bases de datos clínicas y aprendizaje automático en UCI

El desarrollo de modelos predictivos en cuidados intensivos ha estado estrechamente ligado a la disponibilidad de bases de datos clínicas de gran escala. Entre ellas, MIMIC-IV (*Medical Information Mart for Intensive Care*, versión IV) ocupa un lugar destacado por tratarse de una base de datos pública, desidentificada y diseñada específicamente para investigación clínica [Johnson et al. \(2023\)](#). MIMIC-IV integra información hospitalaria de un único centro terciario de Boston, incluyendo episodios de UCI, resultados analíticos, administración de fármacos, procedimientos y medidas fisiológicas, todo ello con una estructura que permite estudiar eventos dinámicos como el inicio de vasopresores o la evolución hemodinámica del paciente [Johnson et al. \(2023\)](#).

Para la evaluación de la generalización de los modelos fuera del entorno de desarrollo, la base de datos eICU-CRD (*eICU Collaborative Research Database*) constituye un recurso complementario de gran relevancia [Pollard et al. \(2018\)](#). A diferencia de MIMIC-IV, eICU-CRD agrega datos de centenares de hospitales de Estados Unidos, lo que permite evaluar si un modelo



entrenado en un único centro mantiene su rendimiento en una población más heterogénea y con prácticas clínicas potencialmente distintas [Pollard et al. \(2018\)](#). Esta característica la convierte en un entorno especialmente adecuado para la validación externa de modelos desarrollados sobre MIMIC-IV.

La estimación del riesgo de inicio de noradrenalina exige definir ventanas de observación y de predicción clínicamente plausibles, utilizando únicamente la información disponible antes del evento. Ambas bases de datos comparten una estructura temporal que hace posible este tipo de diseño retrospectivo.

Dentro de este marco, el aprendizaje automático ha adquirido un papel creciente en la predicción de eventos clínicos en pacientes críticos. En datos clínicos tabulares se emplean con frecuencia algoritmos como la regresión logística, Random Forest, XGBoost, LightGBM o CatBoost, que permiten modelar relaciones no lineales e interacciones complejas entre variables. Su atractivo radica en la capacidad para combinar simultáneamente información procedente de múltiples dominios clínicos, algo difícil de reproducir con reglas clínicas simples o con modelos univariantes. Sin embargo, este aumento de capacidad predictiva suele ir acompañado de una menor interpretabilidad, lo que supone una limitación importante cuando el objetivo final es apoyar decisiones clínicas reales.

### **Interpretabilidad y explicabilidad de modelos**

En aplicaciones clínicas, la interpretabilidad del modelo no constituye un elemento accesorio, sino un requisito relevante para facilitar la confianza del profesional sanitario y permitir una evaluación crítica de la predicción generada. En este contexto, adquieren relevancia técnicas de explicación como SHAP (*SHapley Additive exPlanations*), que permiten descomponer la predicción de un modelo en la contribución individual de cada variable [Lundberg and Lee \(2017\)](#).

Este enfoque ofrece una doble utilidad. Por un lado, permite identificar qué variables son más influyentes a nivel global dentro de la cohorte, lo que facilita interpretar el comportamiento general del modelo. Por otro, hace posible explicar predicciones concretas a nivel individual, mostrando qué factores empujan el riesgo estimado en una u otra dirección para un paciente determinado [Lundberg and Lee \(2017\)](#). En un entorno de apoyo a la decisión clínica, esta capacidad puede resultar especialmente valiosa, ya que aproxima la salida del modelo a un razonamiento más comprensible para el profesional.

### **Estado del arte y trabajos relacionados**

Entre los estudios más próximos al objetivo de este TFG destaca el trabajo de Duval et al., que desarrollaron un modelo interpretable basado en historia clínica electrónica para predecir el inicio de perfusión continua de vasopresores en pacientes sépticos ingresados en UCI a partir de datos de MIMIC-IV [Duval et al. \(2025\)](#). El modelo utilizó variables medidas en la ventana de -6 a -2 horas respecto al inicio del tratamiento y el mejor clasificador fue un *Random Forest* con un AUROC de 0,75. Entre los predictores más relevantes se encontraban el descenso de la presión arterial media entre -2 y -4 horas, un lactato  $> 2,5$  mmol/L y valores de hematocrito fuera del rango 30-37 % [Duval et al. \(2025\)](#). Los autores señalan, además, que las alertas del modelo podrían generarse entre 2 y 4 horas antes del inicio del vasopresor, lo que apoya la viabilidad técnica de anticipar este tipo de decisión terapéutica [Duval et al. \(2025\)](#). No obstante, el propio estudio subraya que se trata de una validación interna y que aún se requiere validación externa y evaluación prospectiva antes de plantear una implementación clínica real.

Junto a este trabajo, existen otros estudios relacionados que contribuyen a contextualizar el problema, aunque orientados a objetivos clínicos sutilmente distintos. Scheibner et al. desarrollaron y validaron externamente modelos de aprendizaje automático para predecir la respuesta a la vasopresina como segundo vasopresor en pacientes con shock séptico tratados con noradrenalina, mostrando un rendimiento modesto y poniendo de manifiesto la complejidad de anticipar la respuesta farmacológica individual [Scheibner et al. \(2022\)](#). En una línea diferente, Persson et al. realizaron un ensayo clínico aleatorizado y prospectivo para validar un algoritmo de predicción temprana de sepsis en pacientes críticos, demostrando que este tipo de sistemas puede evaluarse más allá del entorno retrospectivo y en condiciones más próximas a la práctica clínica real [Persson et al. \(2024\)](#). Aunque su objetivo no fue la monitorización de vasopresores, este estudio refuerza la relevancia de avanzar hacia diseños de validación más cercanos al uso asistencial.

Otros trabajos han abordado tareas más complejas, como la predicción continua de dosis o la optimización de decisiones terapéuticas mediante modelos temporales y aprendizaje por refuerzo. Jiang et al. propusieron ChronoSynthNet, un modelo con componentes *Transformer* y LSTM para estimar en tiempo real la dosis de noradrenalina y detectar precozmente hipotensión en pacientes con shock séptico [Jiang et al. \(2025\)](#). Este tipo de enfoques aprovecha mejor la naturaleza temporal de los datos, pero también incrementa de forma notable la complejidad metodológica. En paralelo, los enfoques de aprendizaje por refuerzo han intentado derivar políticas terapéuticas para orientar decisiones hemodinámicas en sepsis. Por ejemplo, Zhang et al. describieron un modelo orientado a optimizar estrategias de

tratamiento mediante recomendaciones sobre vasopresores y fluidoterapia, incorporando mecanismos para reducir ajustes bruscos de dosis [Zhang et al. \(2024\)](#), mientras que el estudio OVISS exploró el momento óptimo de inicio de vasopresina en pacientes con shock séptico tratados con noradrenalina [Kalimoultou et al. \(2025\)](#). Aunque estos trabajos son metodológicamente ambiciosos, responden a preguntas clínicas distintas y más complejas que la estimación temprana del primer inicio de noradrenalina.

### **Limitaciones de la literatura y posicionamiento del TFG**

A pesar del avance metodológico observado, la literatura disponible presenta varias limitaciones recurrentes. En primer lugar, muchos estudios continúan evaluando su rendimiento principalmente mediante métricas de discriminación retrospectiva, especialmente el AUROC, sin trasladar de forma suficiente esos resultados a escenarios de uso clínico real [Shanmugam et al. \(2025\)](#). En segundo lugar, la validación externa sigue siendo limitada en una parte importante de los trabajos publicados, lo que dificulta valorar la robustez de los modelos fuera del centro o cohorte de desarrollo [Rockenschaub et al. \(2025\)](#). Además, una proporción relevante de los estudios permanece en fases de validación retrospectiva o de prueba de concepto, lo que limita la estimación de su utilidad operativa real y refuerza la necesidad de modelos interpretables y clínicamente integrables [Shanmugam et al. \(2025\)](#); [Rockenschaub et al. \(2025\)](#).

A partir de esta revisión, el nicho del presente TFG queda claramente definido. El interés del trabajo no reside únicamente en desarrollar un modelo predictivo adicional, sino en abordar un problema clínico concreto y accionable: la estimación temprana del riesgo de inicio de noradrenalina en pacientes críticos a partir de variables disponibles durante las primeras horas de estancia, sobre una cohorte general de adultos en UCI sin restricción diagnóstica. La propuesta añade, además, tres elementos de interés práctico: el uso de modelos con selección de variables por ventana, la traducción del resultado a una interfaz funcional tipo *dashboard* y la validación externa sobre una cohorte multicéntrica independiente. De este modo, el trabajo se orienta no solo a la obtención de un buen rendimiento predictivo, sino también a su posible utilidad como herramienta de apoyo a la decisión clínica.



---

# Metodología

---

## 1. Diseño general del estudio

Este Trabajo de Fin de Grado se planteó como un estudio retrospectivo de desarrollo, validación e interpretación de modelos predictivos de aprendizaje automático orientados a estimar el riesgo de inicio de perfusión de noradrenalina en pacientes adultos ingresados en unidades de cuidados intensivos. El trabajo se estructuró en tres fases principales: construcción de las cohortes, desarrollo y evaluación interna de los modelos sobre MIMIC-IV, y validación externa sobre eICU-CRD.

El objetivo metodológico fue construir modelos capaces de anticipar la necesidad de soporte vasopresor en tres horizontes temporales clínicamente diferenciados:

- **Ventana Corto:** predicción del inicio de noradrenalina entre las 3 y las 12 horas posteriores al periodo de observación.
- **Ventana Medio:** predicción del inicio de noradrenalina entre las 6 y las 24 horas.
- **Ventana Largo:** predicción del inicio de noradrenalina entre las 12 y las 48 horas.

Estas ventanas se definieron para cubrir distintos escenarios asistenciales: desde la detección precoz de deterioro hemodinámico inminente hasta la identificación de pacientes con riesgo de evolución desfavorable en un plazo más amplio. En todos los casos, los predictores se extrajeron exclusivamente de periodos previos al inicio de la noradrenalina, evitando así cualquier forma de fuga de información desde el evento hacia el modelo.

## 4.1. 2. Fuentes de datos

### Cohorte de desarrollo: MIMIC-IV

La cohorte de entrenamiento y evaluación interna se construyó a partir de MIMIC-IV (*Medical Information Mart for Intensive Care*, versión IV), una base de datos clínica desidentificada que recoge información de pacientes adultos ingresados en el Beth Israel Deaconess Medical Center de Boston entre 2008 y 2019.

El acceso a MIMIC-IV requirió completar el curso de formación en investigación con datos humanos del CITI Program, registrar el proyecto en PhysioNet, esperar su aprobación y firmar el correspondiente acuerdo de uso de datos. Dicho acuerdo obliga, entre otros aspectos, a no intentar reidentificar pacientes, no redistribuir los datos y publicar el código necesario para la reproducibilidad del proyecto en un repositorio público.

### Planteamiento inicial de validación externa con datos del HUBU

Inicialmente se valoró utilizar como cohorte de validación externa un conjunto de datos desidentificado de pacientes de la UCI del Hospital Universitario de Burgos (HUBU). El objetivo era evaluar la extrapolabilidad de los modelos entrenados en MIMIC-IV a una población europea y a un sistema sanitario distinto.

Sin embargo, esta alternativa fue finalmente descartada para esta fase del trabajo. La decisión se debió a la dificultad técnica para extraer de forma homogénea todas las variables requeridas y, especialmente, a la marcada heterogeneidad entre los sistemas asistenciales, los protocolos clínicos y la estructura de registro de ambas cohortes. La diferencia no se limitaba al origen geográfico de los pacientes, sino que afectaba a aspectos directamente relacionados con la práctica clínica: criterios de ingreso en UCI, intensidad de monitorización, disponibilidad y periodicidad de determinadas variables, pautas de tratamiento y soporte hemodinámico.

A pesar de ello, se elaboró el documento requerido para el Comité de Ética en Investigación del HUBU. Como línea futura, una vez confirmada la viabilidad de extracción de las variables necesarias, se prevé solicitar su aprobación para realizar una validación externa sobre datos europeos procedentes de una UCI de referencia. Esta validación tendría una doble finalidad: evaluar la extrapolabilidad de los modelos a un contexto sanitario europeo y explorar su posible publicación científica.

### 2.3. Cohorte de validación externa: eICU-CRD

Finalmente se seleccionó eICU-CRD como cohorte de validación externa. Aunque también procede de población norteamericana, su carácter multicéntrico permite evaluar el rendimiento de los modelos en un entorno interhospitalario heterogéneo, con variabilidad real entre centros y prácticas asistenciales. Al mismo tiempo, mantiene una mayor comparabilidad estructural con MIMIC-IV que la disponible inicialmente con los datos del HUBU.

Esta elección permite evaluar la generalización de los modelos más allá de una única institución, abordando una limitación frecuente en estudios previos basados en cohortes monocéntricas. Los requisitos de acceso y utilización fueron equivalentes a los de MIMIC-IV, al tratarse también de una base de datos alojada en PhysioNet.

## 4.2. 3. Construcción de la cohorte de MIMIC-IV

La cohorte de desarrollo se construyó mediante consultas SQL directas sobre las tablas de MIMIC-IV alojadas en un servidor PostgreSQL local. El proceso siguió un flujo estructurado en varias etapas.

### 3.1. Selección inicial de estancias

En primer lugar, se identificaron todas las estancias en UCI correspondientes a pacientes adultos, definidos como aquellos con edad igual o superior a 18 años. Además, se exigió una duración mínima de estancia suficiente para que el horizonte de predicción quedara completamente contenido dentro del seguimiento disponible.

Para las ventanas Corto y Medio se exigió una estancia superior a 24 horas. Para la ventana Largo se exigió una estancia superior a 48 horas. Este criterio conservador evita el truncamiento informativo de los casos negativos, es decir, pacientes que podrían haber recibido noradrenalina si su estancia en UCI hubiera sido más larga.

### 3.2. Definición del evento objetivo

El evento objetivo fue el primer inicio de perfusión de noradrenalina durante la estancia en UCI. En MIMIC-IV se localizó a partir del `itemid`

221906 de la tabla `inputevents`. Para cada estancia se calculó el tiempo transcurrido, en horas, desde el ingreso en UCI hasta el primer inicio registrado de noradrenalina.

Se excluyeron las estancias en las que la noradrenalina se había iniciado antes del comienzo de la ventana de observación correspondiente. Con ello se garantizó que todos los predictores se extrajeran de un periodo libre de tratamiento vasopresor, evitando que el modelo aprendiera patrones derivados de una intervención ya iniciada.

### 3.3. Asignación de la etiqueta binaria

Para cada ventana temporal se asignó una etiqueta binaria. Una estancia recibió etiqueta positiva (1) cuando el primer inicio de perfusión de noradrenalina ocurrió estrictamente dentro del intervalo de predicción definido para esa ventana. Por el contrario, recibió etiqueta negativa (0) cuando no ocurrió dentro de dicho horizonte.

La etiqueta negativa incluye dos situaciones: pacientes que nunca requirieron soporte vasopresor durante toda su estancia en UCI y pacientes que iniciaron noradrenalina fuera del horizonte predictivo evaluado, por ejemplo de forma tardía una vez cerrada la ventana de predicción.

### 3.4. Identificación de sepsis y cálculo de SOFA

La presencia de sepsis se identificó mediante la tabla derivada `mimicv_derived.sepsis3`. La puntuación SOFA se obtuvo a partir de `mimicv_derived.sofa`. Ambas tablas proceden del repositorio oficial de scripts derivados de MIMIC-IV mantenido por MIT-LCP, que implementa los criterios Sepsis-3.

La puntuación SOFA se incorporó como variable predictora. La variable de sepsis se utilizó principalmente como variable de análisis diferencial por subgrupos, dada su importancia clínica y su relación directa con el inicio de soporte vasopresor.

## 4.3. 4. Construcción de la cohorte de eICU-CRD

La cohorte de validación externa se construyó mediante consultas SQL sobre las tablas de eICU-CRD, alojadas en el mismo entorno local que



MIMIC-IV. Se aplicaron las mismas restricciones de edad adulta y estancia mínima obligatoria utilizadas en la cohorte de desarrollo.

#### 4.1. Identificación del evento objetivo en eICU-CRD

En eICU-CRD, el evento objetivo se identificó a partir de la tabla `infusionDrug`. Se buscaron perfusiones cuyo nombre de fármaco contuviera los términos *norepinephrine* o *levophed*, este último correspondiente a un nombre comercial de la noradrenalina. Se excluyeron las entradas que contenían el término *volume*, con el fin de evitar falsos positivos relacionados con soluciones de reposición o registros no correspondientes a perfusión vasopresora.

Para cada estancia se registró el primer inicio de noradrenalina en minutos desde el ingreso en UCI. Posteriormente, este valor se convirtió a horas para mantener la consistencia con MIMIC-IV. Se aplicaron los mismos criterios de exclusión de noradrenalina precoz y de asignación de etiqueta binaria utilizados en la cohorte de entrenamiento.

#### 4.2. Cálculo de SOFA en eICU-CRD

A diferencia de MIMIC-IV, eICU-CRD no dispone de tablas derivadas precalculadas para SOFA ni para sepsis. Por ello, el índice SOFA se calculó específicamente en SQL a partir de sus seis componentes fundamentales:

- **Componente respiratorio:** calculado mediante el cociente  $\text{PaO}_2/\text{FiO}_2$ . La  $\text{PaO}_2$  se extrajo de la tabla `lab` y la  $\text{FiO}_2$  de `respiratoryCharting`.
- **Componente cardiovascular:** calculado a partir de la presencia de vasopresores registrados dentro de la ventana temporal permitida en `infusionDrug`.
- **Componente neurológico:** calculado mediante la puntuación mínima de Glasgow registrada en `nurseCharting`.
- **Componente hepático:** calculado a partir de la bilirrubina en `lab`.
- **Componente de coagulación:** calculado a partir del recuento de plaquetas en `lab`.
- **Componente renal:** calculado a partir de la creatinina en `lab`.

Cada componente se puntuó conforme a los umbrales estándar de Sepsis-3. Para evitar introducir valores artificiales, se aplicó un criterio estricto de completitud: cualquier estancia con valor nulo en alguno de los seis

componentes del SOFA fue descartada de la cohorte de validación externa, reteniendo únicamente aquellas con todos los componentes medidos de forma real.

### **4.3. Limitación en la identificación de sepsis en eICU-CRD**

En eICU-CRD no fue posible obtener un indicador de sepsis equivalente al disponible en MIMIC-IV. La implementación completa de los criterios Sepsis-3 requiere identificar la sospecha de infección asociada a cultivos biológicos, un campo que no está disponible de forma estructurada en esta base de datos.

Se valoró aproximar la sepsis mediante códigos ICD-9 o ICD-10, pero esta opción se descartó por no considerarse metodológicamente adecuada. La codificación administrativa es introducida manualmente a posteriori por personal médico, lo que puede incorporar errores humanos, omisiones o codificación de entidades clínicas similares pero no equivalentes. Por tanto, el análisis diferencial por subgrupos de sepsis se realizó únicamente sobre la cohorte de MIMIC-IV.

## **4.4. 5. Manejo de datos faltantes**

El tratamiento de datos faltantes se abordó con un criterio deliberadamente estricto. Tanto en las variables predictoras de MIMIC-IV y eICU-CRD como en los componentes individuales del SOFA calculado para eICU-CRD, se descartó el uso de técnicas de imputación estadística, incluyendo sustitución por media, mediana o algoritmos KNN.

La decisión se justificó por dos motivos. En primer lugar, la imputación introduce un componente sintético que exige asumir supuestos metodológicos complejos sobre el mecanismo de ausencia de datos, lo que excedía el alcance de este trabajo. En segundo lugar, tras analizar la dinámica asistencial de la UCI, se descartó también asignar una puntuación de cero a los componentes ausentes del SOFA, ya que la ausencia de registro no equivale necesariamente a normalidad clínica.

En consecuencia, se retuvieron únicamente las estancias con registros reales e íntegros en la totalidad de las variables analizadas.

Esta decisión tuvo una consecuencia directa sobre la composición de las cohortes finales: la prevalencia del evento objetivo aumentó desde aproximadamente el 3-4 % en las cohortes brutas originales hasta el 10-11 % tras el filtro de completitud. Este cambio es compatible con un sesgo de

monitorización esperable en cuidados intensivos. Los pacientes con analíticas completas, gases arteriales, constantes vitales frecuentes y control estricto de diuresis son, por definición, pacientes con mayor gravedad clínica percibida por el equipo sanitario.

Aunque este filtrado reduce el tamaño muestral y selecciona una población de mayor gravedad, también refina la cohorte hacia la población diana real del modelo: pacientes con alta intensidad de monitorización, sospecha de deterioro hemodinámico o riesgo de shock en evolución. Por el contrario, muchas de las estancias excluidas por registros incompletos corresponden previsiblemente a ingresos postquirúrgicos breves o cuadros de baja complejidad, escenarios donde la necesidad de soporte vasopresor es menos frecuente y donde una herramienta predictiva de este tipo tendría menor valor asistencial.

## **4.5. 6. Análisis exploratorio y tratamiento de valores extremos**

Antes del modelado se realizó un análisis exploratorio de datos sobre la cohorte de MIMIC-IV mediante un *notebook* de Jupyter. Esta fase tuvo dos objetivos: caracterizar la distribución de cada variable predictora y detectar valores fisiológicamente implausibles o erráticos que pudieran distorsionar el aprendizaje de los modelos.

Para cada variable continua se inspeccionaron histogramas, diagramas de caja y percentiles extremos, tanto en la cohorte completa como desagregando por etiqueta del evento. Esta revisión permitió identificar distribuciones asimétricas, colas pesadas y valores extremos frecuentes en variables clínicas de pacientes críticos.

A partir de esta exploración se aplicó una estrategia de winsorización al percentil 2 y 98 sobre las variables clínicas continuas. La winsorización mantiene el tamaño muestral, pero acota los valores extremos a límites predefinidos. Esta opción se prefirió frente a la eliminación de filas porque en UCI un valor extremo no es necesariamente un error de registro; puede reflejar la situación real de un paciente crítico.

Quedaron excluidas de la winsorización las variables con rango acotado por definición, como la escala de Glasgow y la puntuación SOFA, así como las variables binarias, como sepsis o ventilación invasiva. Los percentiles 2 y 98 se calcularon exclusivamente sobre MIMIC-IV y se guardaron en un fichero de referencia. Posteriormente se aplicaron esos mismos umbrales

a eICU-CRD, garantizando que el tratamiento de valores extremos en la cohorte externa se realizara con parámetros aprendidos en la cohorte de entrenamiento. Este orden evita cualquier forma de fuga de información desde la validación externa hacia el modelo.

## 4.6. 7. Selección del estadístico de resumen por variable

Cada parámetro analítico y constante vital se extrajo inicialmente con tres estadísticos calculados sobre la ventana de observación: media, mínimo y máximo. Conservar los tres habría introducido una colinealidad elevada, ya que los tres derivan de la misma señal fisiológica y comparten una proporción sustancial de información.

Para evitarlo, se seleccionó un único estadístico por variable mediante un procedimiento jerárquico en dos pasos: primero un criterio clínico y, cuando este no era concluyente, un criterio estadístico de desempate.

### 7.1. Criterio clínico

El criterio clínico se aplicó de forma preferente. Para cada variable se eligió el estadístico con mayor sentido fisiopatológico para anticipar deterioro hemodinámico.

En la presión arterial media se retuvo el valor mínimo, dado que la hipotensión es el desencadenante directo del soporte vasopresor. En lactato, creatinina, bilirrubina y GPT se retuvo el valor máximo, al tratarse de marcadores cuya elevación refleja hipoperfusión tisular, fracaso renal, disfunción hepática o daño hepatocelular. En la diuresis se utilizó el valor acumulado y normalizado por peso corporal en la ventana completa, ya que su valor instantáneo tiene menor interpretación clínica.

Para  $\text{SpO}_2$ , pH, plaquetas y bicarbonato se seleccionó el mínimo, puesto que su descenso refleja deterioro respiratorio, acidosis o disfunción de la coagulación. Para  $\text{FiO}_2$  se eligió el máximo, como indicador de mayor necesidad de oxígeno suplementario, mientras que para el cociente  $\text{PaO}_2/\text{FiO}_2$  se conservó el mínimo, al representar la peor situación de oxigenación. En la frecuencia cardiaca se conservó la media como reflejo del tono autonómico predominante durante la ventana, y en la frecuencia respiratoria se retuvo el máximo como marcador de distrés respiratorio.

## 7.2. Criterio estadístico de desempate

El criterio estadístico se aplicó únicamente cuando el sentido clínico no resolvía la elección de forma inequívoca o cuando existían dos estadísticos clínicamente plausibles. En estos casos se ejecutó un análisis de desempate que comparó para cada candidato:

- El AUC-ROC univariante frente a la etiqueta del evento, como medida de capacidad discriminativa aislada.
- La magnitud del efecto mediante la  $d$  de Cohen entre positivos y negativos.
- La mediana y el rango intercuartílico en cada grupo, para comprobar la coherencia de la dirección del efecto.

Cuando el AUC univariante era inferior a 0,5, se interpretaba como 1 – AUC, asumiendo que la variable podía tener una dirección protectora o de riesgo según su naturaleza clínica. Se retuvo el estadístico con mayor poder discriminativo siempre que su dirección fuera coherente con el sentido fisiopatológico esperado. Si el ganador estadístico contradecía claramente el criterio clínico, se priorizó la interpretación clínica, dado que un efecto inverso aparente podía deberse a confusión por covariables.

Este procedimiento se aplicó especialmente a variables ambiguas como temperatura, tiempo de protrombina, GPT, FiO<sub>2</sub>, bilirrubina, leucocitos, SOFA, glucemia y plaquetas.

## 4.7. 8. Análisis de correlación y multicolinealidad

Una vez seleccionado un único estadístico por variable, se evaluó la redundancia entre predictores candidatos sobre la primera estancia de cada paciente. Esta restricción evitó la dependencia entre observaciones procedentes del mismo individuo.

### 8.1. Correlación de Spearman

Se calculó la matriz de correlación de Spearman entre todas las variables candidatas. Se prefirió Spearman frente a Pearson porque es más robusta ante distribuciones asimétricas y valores extremos residuales, habituales en variables clínicas de UCI. La matriz se visualizó como un mapa de calor

centrado en cero, lo que permitió identificar bloques de variables fuertemente asociadas.

Se extrajeron los pares del triángulo superior de la matriz con coeficiente absoluto superior a 0,5, umbral considerado indicativo de redundancia potencial.

### 8.3. Asociaciones con variables binarias

Para las variables binarias del conjunto de datos, como sepsis, ventilación invasiva o sexo, se calcularon asociaciones específicas. En pares binaria-binaria se utilizó el coeficiente phi, equivalente a una correlación de Pearson sobre variables codificadas como 0/1. En pares binaria-continua se empleó Spearman como aproximación al coeficiente *rank-biserial*. Se reportaron únicamente asociaciones con coeficiente absoluto superior a 0,2 para evitar sobrerrepresentar correlaciones triviales.

### 8.4. Agrupamiento jerárquico

Como análisis complementario se realizó un agrupamiento jerárquico ascendente sobre la distancia  $1 - |\rho|$ , utilizando enlace medio, utilizando enlace medio. El dendrograma resultante permitió visualizar la organización de las variables en grupos de información compartida. Se aplicó un corte a distancia 0,3, equivalente a equivalente a  $|\rho| \geq 0,7$ , para identificar *clusters* de variables redundantes.

Este análisis se utilizó como información de apoyo para la selección posterior de variables. No se aplicó un recorte automático por correlación, ya que la decisión final sobre qué predictores conservar dependió de la importancia por permutación y de la coherencia clínica del efecto.

## 4.8. 9. Selección de variables predictoras

La selección final de predictores se realizó de forma independiente para cada algoritmo y ventana temporal. El objetivo fue identificar variables con contribución predictiva robusta y, al mismo tiempo, clínicamente coherente. El procedimiento constó de dos etapas.

### 9.1. Importancia por permutación

En la primera etapa se calculó la importancia por permutación de todos los predictores candidatos. Esta técnica mide la contribución de una

variable evaluando cuánto cae el rendimiento del modelo cuando sus valores se permutan aleatoriamente, rompiendo su relación con la etiqueta pero manteniendo su distribución marginal.

El procedimiento se ejecutó dentro de una validación cruzada estratificada con grupos (`StratifiedGroupKFold`,  $k = 5$ ), agrupando por `subject_id`. En cada *fold* se permutaron repetidamente las variables, con 30 repeticiones por variable y *fold*, y se calculó la caída media del AUC-ROC.

A partir de las repeticiones se construyó una distribución empírica de la importancia de cada predictor y se estimó un intervalo de confianza al 95 % mediante *bootstrap*. El criterio de retención fue estricto: se conservaron únicamente las variables cuyo intervalo de confianza inferior excluía el cero. Por tanto, solo se retuvieron variables con contribución positiva y estadísticamente robusta al rendimiento del modelo.

Sobre los p-valores derivados de esta etapa se aplicó corrección de Benjamini-Hochberg para controlar la tasa de falsos descubrimientos en un contexto de comparaciones múltiples.

## 9.2. Verificación de dirección y coherencia clínica

La segunda etapa evaluó si las variables preseleccionadas mostraban una dirección de efecto coherente con la fisiopatología esperada. Para las variables continuas se aplicó el test de Mann-Whitney U comparando las distribuciones entre positivos y negativos. Para las variables binarias se empleó el test chi-cuadrado de independencia, con conmutación al test exacto de Fisher cuando existían celdas con frecuencia cero.

Además, se calculó el *odds ratio* crudo de cada variable mediante regresión logística univariante estandarizada. Este estimador reflejó la asociación bivalente entre cada predictor y el inicio de noradrenalina. Posteriormente se ajustó una regresión logística multivariante estandarizada con todas las variables candidatas que habían superado la primera etapa, obteniendo el *odds ratio* ajustado de cada predictor.

Para cada variable se comparó la dirección del efecto en los datos crudos, evaluada mediante la mediana en positivos y negativos, con el signo del coeficiente en la regresión multivariante. Cuando ambas direcciones coincidían, la variable se consideró clínicamente coherente. Cuando no coincidían, se marcó como efecto inverso y se revisó de forma específica.

Las variables con efecto inverso se descartaron salvo que existiera una explicación clínica documentada para la inversión. En ausencia de dicha ex-

plicación, mantenerlas habría supuesto aceptar una relación potencialmente espuria, con riesgo de mala generalización externa.

### 9.3. Selección final por modelo y ventana

El conjunto final de predictores se definió como la intersección entre las variables con importancia por permutación robusta y las variables con dirección clínicamente coherente. Este proceso se ejecutó de forma independiente para cada uno de los seis algoritmos y para cada ventana temporal.

Esta independencia es metodológicamente relevante. Los predictores que resultan informativos para un modelo lineal no tienen por qué coincidir con los que aprovecha un modelo basado en árboles, ya que estos últimos pueden capturar relaciones no lineales e interacciones de orden superior. Forzar el mismo subconjunto de variables para todos los algoritmos habría introducido un sesgo hacia determinados tipos de modelos.

Como resultado, el número de variables retenidas varió entre modelos y ventanas. En el caso más restrictivo, *Random Forest* en la ventana Corto retuvo únicamente `temp_min` y `rr_max`, mientras que otros modelos, como Naive Bayes en la ventana Medio, conservaron hasta 11 variables.

## 4.9. 10. Análisis específico del valor predictivo de la sepsis

La sepsis recibió un análisis específico por su importancia clínica y por su prevalencia en la cohorte. Este análisis se realizó sobre MIMIC-IV, especialmente en la ventana Medio.

En primer lugar, se cuantificó la asociación entre `tiene_sepsis` y el inicio de noradrenalina mediante una tabla de contingencia 2 X 2. A partir de ella se calcularon riesgo relativo, *odds ratio* crudo con intervalo de confianza al 95 %, sensibilidad, especificidad, valor predictivo positivo, valor predictivo negativo, AUC-ROC como predictor único, información mutua con la etiqueta y test chi-cuadrado de independencia.

En segundo lugar, se evaluó la ganancia marginal de incluir la sepsis como predictor. Para ello se ajustó una regresión logística con todas las variables predictoras excluyendo `tiene_sepsis` y otra incluyendo dicha variable. Ambos modelos se compararon mediante AUC-ROC en validación cruzada agrupada por paciente.



Este análisis permitió determinar si la sepsis aportaba información adicional al modelo o si su efecto estaba ya capturado por otras variables como SOFA, constantes vitales y parámetros analíticos. Los resultados motivaron tratar la sepsis principalmente como variable descriptiva y de análisis diferencial por subgrupos, en lugar de incorporarla como predictor principal en todos los modelos.

## 4.10. 11. Modelos de aprendizaje automático

Se entrenaron y compararon seis algoritmos de clasificación supervisada para cada ventana temporal:

- Regresión logística.
- Naive Bayes gaussiano.
- *Random Forest*.
- XGBoost.
- LightGBM.
- CatBoost.

Esta selección cubre varios paradigmas de aprendizaje supervisado sobre datos tabulares: un modelo lineal de referencia con regularización, un modelo probabilístico basal, un método de ensamblado por *bagging* y tres implementaciones avanzadas de potenciación de gradiente.

Para los clasificadores sensibles a la escala y a la presencia de valores extremos, concretamente regresión logística y Naive Bayes, se integró **RobustScaler** en la primera etapa de la *pipeline*. Este transformador centra mediante la mediana y escala mediante el rango intercuartílico, lo que reduce la influencia de valores extremos residuales tras la winsorización.

Para los modelos basados en árboles de decisión, es decir, *Random Forest*, XGBoost, LightGBM y CatBoost, el escalado se omitió deliberadamente. Las particiones de los árboles son invariantes a transformaciones monótonas de las variables, por lo que el escalado no aporta una ventaja metodológica clara.

## 4.11. 12. Validación cruzada anidada

El rendimiento de los modelos se estimó mediante validación cruzada anidada (*Nested Cross-Validation*) con `StratifiedGroupKFold` en ambos niveles: 5 *folds* en el bucle externo y 3 *folds* en el bucle interno.

La condición de grupo garantiza que todas las estancias asociadas a un mismo paciente se asignen en bloque al conjunto de entrenamiento o al conjunto de prueba. Esto evita que un mismo paciente aparezca simultáneamente en entrenamiento y evaluación, situación que produciría fuga de información y métricas artificialmente optimistas.

La estratificación mantiene una prevalencia similar del evento objetivo en cada *fold*. Este aspecto es especialmente importante en una cohorte con desequilibrio moderado de clases, donde la proporción de positivos tras el filtro de completitud se sitúa aproximadamente en el 10-11 %.

### 12.1. Bucle externo

El bucle externo, compuesto por 5 *folds*, se dedicó exclusivamente a la evaluación del rendimiento general. En cada iteración, el conjunto de datos se dividió en un 80 % de desarrollo y un 20 % de prueba externa. El 20 % reservado no se utilizó en ningún momento para seleccionar hiperparámetros.

### 12.2. Bucle interno

El bucle interno, compuesto por 3 *folds*, se dedicó a la optimización de hiperparámetros mediante búsqueda exhaustiva en rejilla (`GridSearchCV`). El conjunto de desarrollo del bucle externo se subdividió internamente en tres partes, utilizando dos tercios para entrenamiento local y un tercio para validación local en cada iteración.

La métrica objetivo de la búsqueda fue el AUC-ROC. Una vez identificada la combinación óptima de hiperparámetros en el bucle interno, el modelo se reentrenó con esa configuración sobre el 80 % completo del *fold* externo y se evaluó de forma ciega sobre el 20 % reservado.

Esta arquitectura garantiza que la selección de hiperparámetros y la evaluación del rendimiento permanezcan separadas, evitando el sesgo optimista que aparece cuando ambas decisiones se toman sobre los mismos datos.

## 4.12. 13. Métricas de evaluación

En cada *fold* externo se calcularon métricas complementarias de discriminación, rendimiento probabilístico y calibración.

El **AUC-ROC** evaluó la capacidad del modelo para ordenar correctamente a los pacientes según su riesgo. Un valor de 0,5 equivale al azar y un valor de 1,0 a discriminación perfecta.

El **AUC-PR** o *Average Precision* se utilizó por su relevancia en cohortes desequilibradas. Esta métrica enfatiza la precisión alcanzada a distintos niveles de sensibilidad y no se ve inflada por la abundancia de casos negativos.

El **Brier Score** midió el error cuadrático medio entre la probabilidad predicha y la etiqueta observada, evaluando conjuntamente discriminación y calibración.

El **Brier Skill Score** se calculó como:

$$BSS = 1 - \frac{BS_{\text{modelo}}}{BS_{\text{climatología}}}$$

La climatología corresponde a un modelo trivial que predice siempre la prevalencia observada del evento. Un BSS positivo indica que el modelo aporta ganancia predictiva real frente a la probabilidad basal; un BSS negativo indica que el modelo es peor que predecir siempre la prevalencia.

El **Expected Calibration Error** se calculó dividiendo las predicciones en 10 intervalos uniformes y ponderando la diferencia absoluta entre la probabilidad media predicha y la frecuencia observada del evento en cada intervalo. Esta métrica evalúa si las probabilidades emitidas por el modelo son fiables en términos absolutos.

Finalmente, se calculó también la **Log-Loss** como métrica estándar de evaluación probabilística. Para todas las métricas se reportaron media y desviación estándar a través de los 5 *folds* externos.

## 4.13. 14. Calibración probabilística

Dado que el objetivo final es desarrollar una herramienta de apoyo a la decisión clínica, no basta con que los modelos discriminen correctamente entre pacientes de mayor y menor riesgo. Las probabilidades emitidas deben ser interpretables en términos absolutos. Por ejemplo, si el modelo asigna a

un paciente un riesgo del 20 %, debería observarse que aproximadamente uno de cada cinco pacientes con predicciones similares inicia noradrenalina.

Por este motivo, sobre los modelos con BSS positivo se evaluaron técnicas de calibración post-hoc. Se probaron tres variantes:

- Calibración de Platt pura, mediante regresión logística sin regularización.
- Calibración de Platt regularizada, seleccionando el parámetro de regularización mediante validación cruzada interna y minimizando el Brier negativo.
- Regresión isotónica, como calibrador no paramétrico.

El procedimiento se ejecutó dentro de una validación cruzada con `StratifiedGroupKFold` de 5 *folds*. En cada *fold*, el calibrador se ajustó sobre las probabilidades del conjunto de entrenamiento y se aplicó sobre las probabilidades del conjunto de prueba, sin solapamiento. Esto evitó el sobreajuste del calibrador.

El criterio de selección fue el ECE más bajo entre las variantes que mantenían BSS positivo. CatBoost no requirió calibración en ninguna ventana, ya que su ECE nativo fue inferior a 0,02 en los tres horizontes. XGBoost en la ventana Medio mejoró su ECE mediante calibración de Platt pura. En la ventana Largo, la calibración no mejoró el BSS y se descartó.

## 4.14. 15. Selección del modelo final por ventana

La selección del modelo final se basó principalmente en el Brier Skill Score, considerado el criterio más exigente al medir la mejora relativa frente a un predictor trivial basado en la prevalencia. También se valoraron un ECE bajo, preferiblemente inferior a 0,03, y un AUC-ROC competitivo.

Se permitió seleccionar un segundo modelo por ventana cuando existía otro algoritmo con BSS positivo, ECE aceptable y un perfil de variables complementario al modelo primario. Esta decisión permitió explorar la robustez de los resultados ante distintas familias de modelos.

En la ventana **Corto (3-12 h)**, ningún segundo modelo alcanzó BSS positivo de forma consistente en la validación cruzada, por lo que se seleccionó únicamente CatBoost.

En las ventanas **Medio (6-24 h)** y **Largo (12-48 h)**, se seleccionó CatBoost como modelo primario y XGBoost como segundo modelo. En la ventana Medio, XGBoost se utilizó con calibración de Platt; en la ventana Largo, la calibración se descartó al no mejorar el BSS.

#### 4.15. 16. Reentrenamiento sobre la cohorte completa

Una vez confirmado el rendimiento mediante validación cruzada anidada, los modelos finales se reentrenaron sobre el 100 % de la cohorte de desarrollo. Los hiperparámetros utilizados en este reentrenamiento se determinaron mediante votación mayoritaria sobre las cinco configuraciones óptimas obtenidas en los *folds* externos.

Para cada hiperparámetro se seleccionó el valor más frecuente entre los cinco *folds*. Este procedimiento estabiliza la elección frente a fluctuaciones aleatorias de las particiones y refleja la configuración más robusta a lo largo de la cohorte.

Los modelos finales se serializaron en formato `.pkl` mediante `joblib` y se integraron posteriormente en los *scripts* de validación externa y en el prototipo de *dashboard* clínico.

#### 4.16. 17. Interpretabilidad mediante SHAP

Para interpretar los modelos finales se calcularon valores SHAP (*SHapley Additive exPlanations*), que permiten descomponer cada predicción en la contribución individual de cada variable.

La elección del explicador dependió del tipo de modelo. Para modelos basados en árboles, como *Random Forest*, XGBoost, LightGBM y CatBoost, se utilizó `TreeExplainer`, por su eficiencia y adecuación a este tipo de estructuras. Para regresión logística se utilizó `LinearExplainer` sobre los datos escalados. Para Naive Bayes se empleó `KernelExplainer`, un método agnóstico al modelo, con una muestra de fondo de 200 observaciones y un muestreo de 500 puntos sobre el conjunto de evaluación.

Sobre los modelos finales se generaron gráficos *beeswarm*, que muestran para cada variable la magnitud del valor SHAP y la dirección del efecto en función del valor de la variable. Estos gráficos permitieron interpretar el

comportamiento global del modelo y comprobar que las relaciones aprendidas eran clínicamente plausibles.

También se calcularon valores SHAP sobre la cohorte de validación externa de eICU-CRD, con el fin de comparar la consistencia del comportamiento del modelo entre cohortes. En el caso particular del modelo calibrado de la ventana Medio, se diseñó un procedimiento para extraer el modelo de árboles subyacente desde la estructura compuesta del calibrador, aplicando previamente las transformaciones intermedias necesarias para que `TreeExplainer` operara sobre el núcleo del modelo.

## 4.17. 18. Análisis de subgrupos y comparación con SOFA

Sobre la cohorte de MIMIC-IV se realizó un análisis de rendimiento diferencial entre pacientes con sepsis (`tiene_sepsis = 1`) y sin sepsis (`tiene_sepsis = 0`). Para ello se generaron predicciones fuera de muestra mediante validación cruzada con `StratifiedGroupKFold` de 5 *folds*, reentrenando el modelo en cada partición y obteniendo predicciones sobre pacientes no vistos.

En cada subgrupo se calcularon AUC-ROC, AUC-PR, BSS y ECE. Este análisis permitió evaluar si el modelo mantenía un rendimiento comparable en ambos contextos clínicos.

Además, se evaluó la puntuación SOFA aislada como referencia clínica basal. Para ello se calcularon su AUC-ROC y AUC-PR en la cohorte global de cada ventana. Esta comparación permitió contextualizar el valor añadido de los modelos de aprendizaje automático frente a una herramienta clínica ampliamente utilizada en UCI.

## 4.18. 19. Validación externa

Los modelos entrenados sobre MIMIC-IV se aplicaron directamente sobre las cohortes de eICU-CRD, sin reentrenamiento, para evaluar su capacidad de generalización a un entorno multicéntrico independiente.

El rendimiento externo se midió mediante AUC-ROC, AUC-PR, BSS y ECE. Para cada métrica se calcularon intervalos de confianza al 95 % mediante *bootstrap* con 1.000 iteraciones y semilla fija igual a 42, garantizando la reproducibilidad del procedimiento.

La diferencia de AUC-ROC entre cada modelo y SOFA se contrastó mediante una aproximación *bootstrap* al test de DeLong. En cada iteración se remuestreó con reemplazo el conjunto de pacientes, se recalculó la diferencia de AUC y, a partir de la distribución obtenida, se estimó el p-valor bilateral. Este enfoque evita asumir normalidad y se adapta de forma natural a la estructura de las cohortes externas.

Para la ventana Largo se exploró adicionalmente una recalibración local de Platt sobre eICU-CRD mediante **StratifiedKFold** de 5 *folds*. Esta recalibración se aplicó únicamente sobre las probabilidades producidas en eICU-CRD, sin modificar los pesos del modelo entrenado en MIMIC-IV. El objetivo fue absorber desplazamientos sistemáticos en las probabilidades predichas derivados de diferencias de prevalencia o distribución de predictores entre cohortes.

De forma complementaria, se generó una tabla comparativa de características basales entre MIMIC-IV y eICU-CRD para cada ventana temporal. Se compararon edad, sexo, peso, SOFA, prevalencia de sepsis y prevalencia del evento. Para variables continuas se utilizó el test de Mann-Whitney U y para variables categóricas el test chi-cuadrado. También se generaron gráficos de caja comparativos para las variables predictoras de cada modelo, con el objetivo de identificar diferencias de distribución que pudieran explicar parte de la pérdida de rendimiento entre validación interna y externa.

## 4.19. 20. Prototipo de dashboard clínico

Como parte del trabajo se desarrolló un prototipo de *dashboard* clínico en Python utilizando Streamlit. La aplicación permite introducir manualmente los valores de las variables predictoras de un paciente y obtener, para cada una de las tres ventanas temporales, una estimación individualizada del riesgo de inicio de noradrenalina.

El *dashboard* proporciona tres elementos principales:

- **Probabilidad estimada** de inicio de noradrenalina en cada ventana temporal.
- **Clasificación orientativa del nivel de riesgo** en bajo, intermedio o alto, basada en percentiles de la distribución de probabilidades de la cohorte de entrenamiento. Este enfoque evita umbrales arbitrarios y ancla la interpretación en la experiencia del propio modelo.

- **Explicación individual mediante SHAP**, mostrando los principales factores que empujan la predicción hacia mayor o menor riesgo en ese paciente concreto.

Los modelos entrenados se cargan como archivos serializados `.pkl` mediante `joblib`. Los percentiles de referencia de la cohorte de entrenamiento se almacenan como archivos CSV auxiliares.

## 4.20. 21. Metodología de ingeniería del software

El desarrollo del software siguió una metodología experimental iterativa, propia de proyectos de ciencia de datos en los que la solución no está cerrada desde el inicio y se refina progresivamente en función de los resultados clínicos y estadísticos obtenidos.

No se aplicó un marco formal de gestión como Scrum o Kanban, dado que el trabajo fue desarrollado por un único autor y la planificación respondió a una hoja de ruta científica más que a un *backlog* de funcionalidades. La disciplina de desarrollo se articuló principalmente alrededor del control de versiones, la trazabilidad de los experimentos y la revisión progresiva de resultados.

El proyecto se estructuró en versiones sucesivas, incluyendo v1, v2, v3, v4 y v4\_4. Cada versión incorporó mejoras concretas tras la evaluación crítica de la anterior: ampliación de la cohorte, redefinición de ventanas de observación, corrección del manejo de la diuresis nula en eICU-CRD, incorporación de técnicas de calibración y ajustes en la validación externa, entre otras.

El control de versiones se realizó mediante Git y GitHub. Se mantuvo un repositorio público que cumple el requisito del acuerdo de uso de MIMIC-IV y eICU-CRD de publicar el código necesario para la reproducibilidad. El repositorio contiene las consultas SQL de construcción de cohortes, los *scripts* de análisis exploratorio, selección de variables, entrenamiento, calibración, interpretabilidad, validación externa y la aplicación Streamlit.

Los modelos serializados y los archivos CSV intermedios no se versionaron en el repositorio por su volumen y por las restricciones de no redistribución de datos derivados de MIMIC-IV y eICU-CRD.

El código se organizó en carpetas funcionales: construcción y limpieza de datos, modelado, modelos entrenados, figuras y tablas, y aplicación del



*dashboard*. Esta organización facilita la trazabilidad, ya que cada figura o métrica reportada en la memoria puede asociarse al *script* que la genera, y los modelos finales pueden recargarse desde sus archivos `.pkl` sin necesidad de reentrenamiento.

El entorno de desarrollo utilizó Python 3.12 junto con librerías del ecosistema científico y de aprendizaje automático, incluyendo `pandas`, `numpy`, `scikit-learn`, `xgboost`, `lightgbm`, `catboost`, `shap`, `matplotlib`, `seaborn`, `streamlit`, `jupyter`, `statsmodels` y `scipy`. La base de datos se gestionó mediante PostgreSQL alojado localmente. El IDE principal fue Visual Studio Code, y la memoria del proyecto se redactó en Quarto con compilación a PDF mediante `pdflatex`.

Dada la naturaleza eminentemente empírica y de investigación del proyecto, se adoptó un enfoque de ciclo de vida basado en prototipado rápido, prescindiendo deliberadamente del modelado formal mediante diagramas estructurados de clases o casos de uso (UML). En su lugar, el esfuerzo de ingeniería de software se centró en el codiseño y la construcción progresiva de una arquitectura orientada a flujos de datos (data-driven pipeline), garantizando el acoplamiento determinista entre las etapas críticas de extracción SQL, preprocesamiento robusto, inferencia de los modelos y renderizado analítico en tiempo real.

El cuadro de mando (dashboard) en Streamlit se modeló siguiendo una estrategia de desarrollo incremental y evolutivo. El diseño inicial partió de un núcleo mínimo funcional enfocado en la persistencia y carga de los serializadores de los modelos de Machine Learning, integrando secuencialmente en iteraciones posteriores los módulos reactivos de distribución probabilística, categorización del nivel de riesgo clínico e interpretabilidad local mediante valores SHAP. La solución resultante consolida una arquitectura monolítica simplificada que centraliza el ciclo de vida de la aplicación, delegando el control y la persistencia de los hilos de ejecución en el sistema de gestión de estados nativo de la plataforma (`st.session_state`). Esta simplificación arquitectónica reduce de forma drástica la sobrecarga de infraestructura y la deuda técnica del sistema, permitiendo orientar los recursos de cómputo hacia el verdadero núcleo de la herramienta: validar la viabilidad técnica y la transparencia algorítmica de los modelos predictivos en un entorno simulado de práctica médica intensiva.

## 4.21. 22. Reproducibilidad

La reproducibilidad se garantizó mediante una combinación de control de versiones, serialización de modelos, uso de semillas fijas y separación clara entre datos, código y resultados.

Las consultas SQL permiten reconstruir las cohortes a partir de las bases de datos originales alojadas localmente. Los *scripts* de Python reproducen el análisis exploratorio, la winsorización, la selección de variables, el entrenamiento de modelos, la calibración, la interpretabilidad y la validación externa. Las semillas se fijaron cuando el procedimiento lo permitía, especialmente en validación cruzada, *bootstrap* y algoritmos con componentes aleatorios.

Los modelos finales se almacenaron en formato `.pkl`, permitiendo su reutilización directa en el *dashboard* y en los análisis de validación sin necesidad de repetir el entrenamiento completo. Esta decisión reduce la variabilidad entre ejecuciones y facilita la auditoría de los resultados reportados.

En conjunto, el flujo metodológico priorizó tres principios: evitar la fuga de información, mantener la coherencia clínica de los predictores y evaluar no solo la discriminación de los modelos, sino también la fiabilidad de sus probabilidades y su capacidad de generalización externa.

---

%%-----Miau-----

---

-

A continuación se muestra un **ejemplo de tabla generada con R** usando `knitr::kable()`:

```
library(knitr)
library(dplyr)

iris |>
  group_by(Species) |>
  summarise(
    N          = n(),
    Media_SL   = round(mean(Sepal.Length), 2),
    SD_SL      = round(sd(Sepal.Length), 2),
    Media_PL   = round(mean(Petal.Length), 2),
    SD_PL      = round(sd(Petal.Length), 2)
  ) |>
  kable(
```

Tabla 4.1: Estadísticos descriptivos del conjunto de datos iris

| Especie    | N  | Media Sep.L | SD Sep.L | Media Pet.L | SD Pet.L |
|------------|----|-------------|----------|-------------|----------|
| setosa     | 50 | 5.01        | 0.35     | 1.46        | 0.17     |
| versicolor | 50 | 5.94        | 0.52     | 4.26        | 0.47     |
| virginica  | 50 | 6.59        | 0.64     | 5.55        | 0.55     |

```
col.names = c("Especie", "N", "Media Sep.L",
              "SD Sep.L", "Media Pet.L", "SD Pet.L"),
booktabs  = TRUE,
format    = "latex"
)
```

Y podremos referenciar esta tabla en el texto como la tabla 4.1 que aparece en la página 37.

```
% %-----Grrrr-----Miau-----
```

```
## Metodología de Ingeniería del Software
```

Si el TFG incluye desarrollo software, indicar la metodología seguida. Se pueden incluir diagramas de casos de uso, diagramas de clases, diagramas de secuencia, etc. para describir el diseño del software desarrollado.



---

# Resultados

---

## 5.1. Resumen de resultados

Breve resumen de los resultados. En caso de ser un trabajo muy experimental, los resultados completos pueden aparecer en su anexo correspondiente.

Debería haber una correspondencia entre los objetivos y los resultados explicados en esta sección

A continuación se muestra un **ejemplo de figura generada con R**:

```
library(ggplot2)

ggplot(iris, aes(x = Species, y = Sepal.Length, fill = Species)) +
  geom_boxplot(alpha = 0.7, show.legend = FALSE) +
  labs(
    x = "Especie",
    y = "Longitud del sépalo (cm)"
  ) +
  theme_minimal(base_size = 11) +
  theme(panel.grid.minor = element_blank())
```

Debería existir correspondencia entre los objetivos definidos y los resultados mostrados (Koza, 1992).




Figura 5.1: Distribución de la longitud de sépal por especie en el conjunto iris

---

## Discusión

---

Se realizará un análisis crítico de los resultados, interpretando su significado y, cuando sea pertinente, comparándolos con los resultados de trabajos previos, obtenidos con la revisión del estado del arte; de forma que se destaquen las mejoras y aportes sobre el mismo.





---

# Conclusiones

---

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas.

## 7.1. Aspectos relevantes

Este apartado pretende recoger los aspectos más interesantes del **desarrollo del proyecto**, comentados por los autores del mismo y que den respuesta a los objetivos planteados.

Debe incluir los detalles más relevantes en cada fase del desarrollo, justificando los caminos tomados, especialmente aquellos que no sean triviales.

Puede ser el lugar más adecuado para documentar los aspectos más interesantes del proyecto y también los resultados negativos obtenidos por soluciones previas a la solución entregada.

Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.



---

## Líneas de trabajo futuras

---

La línea de trabajo más prioritaria e inmediata consiste en retomar y consolidar la validación externa planificada sobre los datos reales del Hospital Universitario de Burgos (HUBU). Aunque la heterogeneidad en las estructuras de registro y las barreras técnicas de extracción obligaron a sustituir esta cohorte por la base de datos multicéntrica eICU-CRD, la transferencia del modelo a una población de referencia europea sigue siendo un hito indispensable para garantizar la generalizabilidad del algoritmo sobre esta población. Una vez garantizada la viabilidad de extracción desde los sistemas de información clínica de la UCI del HUBU, se procederá a la tramitación ante el Comité de Ética de Investigación del centro, y se diseñará un proceso de mapeo y traducción iterativa de variables clínicas locales hacia el esquema estructurado de la pipeline actual, garantizando la homogeneidad de los predictores clave.

Una segunda línea de trabajo sería la transición hacia modelos basados en series temporales. El enfoque actual utiliza métricas estáticas resumidas (mínimos, máximos o medias) dentro de una ventana fija, descartando la riqueza dinámica y la tendencia temporal de las constantes vitales. Se plantea reestructurar la arquitectura predictiva sustituyendo los árboles estáticos por modelos capaces de procesar secuencias temporales. Esto incluye la implementación de redes neuronales recurrentes (LSTM) o Transformers temporales adaptados a registros clínicos tabulares, o el uso de librerías como `tsfresh` o `sktime` para la extracción automatizada de características dinámicas.

Un tercer ejemplo es la implementación de modelos de análisis de supervivencia. La formulación binaria estricta ligada a ventanas temporales fijas limita la toma de decisiones clínicas. La integración de técnicas de Análisis

de Supervivencia aplicado al Machine Learning permitirá modelar de forma continua el tiempo hasta el evento gestionando correctamente la censura de datos (altas hospitalarias o fallecimientos prematuros antes de que ocurra el evento).

Por último, podría valorarse de cara a un futuro y si estos modelos predictivos cumplen con los requisitos para convertirse en herramientas clínicas validadas, la integración de estos en el software de una UCI que ya se use para monitorizar pacientes, por ejemplo, mediante conexión directa del backend con las bases de datos de monitorización en tiempo real de la unidad, ejecutando el algoritmo en segundo plano de forma automática ante cada nueva analítica o constante registrada. En su defecto, también cabría explorar la posibilidad de que el Dashboard se convierta en uno multipaciente que permita la vigilancia simultánea y centralizada de todas las camas del servicio.

---

## Bibliografía

---

- Duval, L., Villié, A., Zheng, F., Terraz, G., Blein, S., Duperchy, E., Everett, M., Frieling, J., Llitjos, J.-F., and Bodinier, M. (2025). Early prediction of vasopressor initiation in ICU sepsis patients using an interpretable EHR-based ML model. *BMC Medical Informatics and Decision Making*, 25(1):442.
- Evans, L., Rhodes, A., Alhazzani, W., et al. (2021). Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021. *Intensive Care Medicine*, 47:1181–1247.
- Fleischmann-Struzek, C., Mellhammar, L., Rose, N., et al. (2020). Incidence and mortality of hospital- and ICU-treated sepsis: results from an updated and expanded systematic review and meta-analysis. *Intensive Care Medicine*, 46:1552–1562.
- Grupo de Trabajo Sepsis HUBU (2025). Protocolo Código Sepsis HUBU. Manejo integral del paciente séptico. III edición. Technical report, Complejo Asistencial Universitario de Burgos.
- Jiang, Z., Zhang, S., Yuan, Y., Wang, J., and Hu, Z. (2025). Chronosynthnet: a dual-task deep learning model development and validation study for predicting real-time norepinephrine dosage and the early detection of hypotension in patients with septic shock. *Cardiovascular Diagnosis and Therapy*, 15(4):833–846.
- Johnson, A. E. W., Bulgarelli, L., Shen, L., et al. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.
- Kalimouttou, A., Kennedy, J. N., Feng, J., Singh, H., Saria, S., Angus, D. C., Seymour, C. W., and Pirracchio, R. (2025). Optimal vasopressin

- initiation in septic shock: The OVISS reinforcement learning study. *JAMA*, 333(19):1688–1698.
- Koza, J. R. (1992). *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30.
- Persson, I., Macura, A., Becedas, D., and Sjövall, F. (2024). Early prediction of sepsis in intensive care patients using the machine learning algorithm NAVOY® sepsis, a prospective randomized clinical validation study. *Journal of Critical Care*, 80:154400.
- Pollard, T. J., Johnson, A. E. W., Raffa, J. D., Celi, L. A., Mark, R. G., and Badawi, O. (2018). The eICU collaborative research database, a freely available multi-center database for critical care research. *Scientific Data*, 5:180178.
- Rockenschaub, P., Akay, E. M., Carlisle, B. G., et al. (2025). External validation of AI-based scoring systems in the ICU: a systematic review and meta-analysis. *BMC Medical Informatics and Decision Making*, 25:5.
- Scheibner, A., Betthausen, K. D., Bewley, A. F., Juang, P., Lizza, B., Micek, S., and Lyons, P. G. (2022). Machine learning to predict vasopressin responsiveness in patients with septic shock. *Pharmacotherapy*, 42(6):460–471.
- Shanmugam, H., Airen, L., and Rawat, S. (2025). Machine learning and deep learning models for early sepsis prediction: A scoping review. *Indian Journal of Critical Care Medicine*, 29(6):516–524.
- Singer, M., Deutschman, C. S., Seymour, C. W., Shankar-Hari, M., Annane, D., Bauer, M., Bellomo, R., Bernard, G. R., Chiche, J.-D., Coopersmith, C. M., Hotchkiss, R. S., Levy, M. M., Marshall, J. C., Martin, G. S., Opal, S. M., Rubenfeld, G. D., van der Poll, T., Vincent, J.-L., and Angus, D. C. (2016). The third international consensus definitions for sepsis and septic shock (Sepsis-3). *JAMA*, 315(8):801–810.
- Vincent, J.-L. and De Backer, D. (2013). Circulatory shock. *New England Journal of Medicine*, 369(18):1726–1734.

Zhang, T., Qu, Y., Wang, D., Zhong, M., Cheng, Y., and Zhang, M. (2024).  
Optimizing sepsis treatment strategies via a reinforcement learning model.  
*Biomedical Engineering Letters*, 14(2):279–289.