




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana del
riesgo de inicio de
noradrenalina en
UCI mediante aprendizaje
automático y dashboard
interpretable**


Presentado por Daniel Marina de la Cal
en Universidad de Burgos

Tutores: Antonio Jesús Canepa Oneto – Sergio
Ossa Echeverri – Fernando Callejo Torre



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior
Grado en Ingeniería de la Salud



**TFG del Grado en Ingeniería de la
Salud**

**Estimación temprana del
riesgo de inicio de
noradrenalina en
UCI mediante aprendizaje
automático y dashboard
interpretable**

Presentado por Daniel Marina de la Cal
en Universidad de Burgos

27 de marzo de 2026

Tutores: Antonio Jesús Canepa Oneto – Sergio Ossa
Echeverri – Fernando Callejo Torre



UNIVERSIDAD
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Antonio Jesús Canepa Oneto, profesor/a del departamento de Ingeniería Informática del área de Lenguajes Informáticos. D. Sergio Ossa Echeverri, médico intensivista del Hospital Universitario de Burgos. D. Fernando Callejo Torre, médico intensivista del Hospital Universitario de Burgos.

Expone/n:

Que el/la alumno/a D. Daniel Marina de la Cal, con DNI 71565266F, ha realizado el Trabajo final de Grado en Ingeniería de la Salud titulado *Estimación temprana del riesgo de inicio de noradrenalina en UCI mediante aprendizaje automático y dashboard interpretable*.

Y que dicho trabajo ha sido realizado por el/la alumno/a bajo la dirección del/los que suscribe/n.

En Burgos, a 27 de marzo de 2026

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Antonio Jesús
Canepa Oneto

D. Sergio Ossa
Echeverri

D. Fernando Callejo
Torre

Resumen

Este TFG propone el desarrollo de un modelo de aprendizaje automático orientado a estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes críticos ingresados en UCI, a partir de variables clínicas disponibles durante las primeras horas de estancia, como constantes vitales, parámetros analíticos y datos básicos del paciente. El objetivo no es solo predecir si el paciente requerirá soporte vasopresor en una ventana temporal definida, sino también ofrecer una herramienta interpretable, en forma de dashboard, que permita visualizar el riesgo estimado y los factores que más contribuyen a dicha predicción en cada caso.

Descriptores

Aprendizaje automático, Predicción, Dashboard, Sepsis, UCI, Norepinefrina, Noradrenalina.

Abstract

This Bachelor's Thesis proposes the development of a machine learning model aimed at the early estimation of the risk of initiating noradrenaline in critically ill patients admitted to the ICU, based on clinical variables available during the first hours of admission, such as vital signs, laboratory parameters, and basic patient data. The objective is not only to predict whether the patient will require vasopressor support within a defined time window, but also to provide an interpretable tool in the form of a dashboard. This tool will allow for the visualization of the estimated risk and the factors that contribute most to this prediction in each individual case.

Keywords

Machine Learning, Sepsis, Prediction, Dashboard, ICU, norepinephrine.

Índice general

Índice general	iii
Índice de figuras	iv
Índice de tablas	v
Introducción	1
Objetivos	5
Conceptos teóricos	9
Metodología	15
4.1. Descripción de los datos	15
4.2. Técnicas y herramientas	15
4.3. Metodología de Ingeniería del Software	16
Resultados	17
5.1. Resumen de resultados	17
Discusión	19
Conclusiones	21
7.1. Aspectos relevantes	21
Líneas de trabajo futuras	23
Bibliografía	25

Índice de figuras

5.1. Distribución de la longitud de sépalo por especie en el conjunto iris	18
--	----

Índice de tablas

4.1. Estadísticos descriptivos del conjunto de datos iris	16
---	----

Introducción

Contexto clínico y relevancia del problema

La sepsis se define como la disfunción orgánica potencialmente mortal causada por una respuesta desregulada del organismo huésped frente a la infección [Singer et al. \(2016\)](#). Se trata de una de las urgencias médicas más relevantes en el ámbito hospitalario por su elevada frecuencia, su gravedad y la necesidad de instaurar medidas terapéuticas en plazos muy cortos. En adultos hospitalizados, la incidencia estimada de sepsis tratada en hospital se sitúa en torno a 189 casos por cada 100.000 personas-año, mientras que la incidencia de sepsis tratada en UCI alcanza aproximadamente 58 casos por cada 100.000 personas-año [Fleischmann-Struzek et al. \(2020\)](#). A escala global, se estimaron 48,9 millones de casos y 11 millones de muertes atribuibles a la sepsis en 2017 [Fleischmann-Struzek et al. \(2020\)](#). En España, la mortalidad en pacientes sépticos ingresados en UCI se sitúa alrededor del 30 % y puede alcanzar el 50 % en los casos de shock séptico, lo que pone de manifiesto la magnitud clínica del problema [Grupo de Trabajo Sepsis HUBU \(2025\)](#).

La sepsis es, además, una patología marcadamente tiempo-dependiente. En pacientes con shock séptico, el retraso en la administración de antibioterapia eficaz se ha asociado con un peor pronóstico [Kumar et al. \(2006\)](#). Esta urgencia terapéutica ha motivado el desarrollo de protocolos asistenciales específicos y de guías clínicas orientadas a favorecer la identificación y el tratamiento precoz [Evans et al. \(2021\)](#). Junto al control de la infección, el soporte hemodinámico constituye uno de los pilares fundamentales del manejo inicial. De acuerdo con la definición de Sepsis-3, el shock séptico se caracteriza por la necesidad de vasopresores para mantener una presión arterial media (PAM) ≥ 65 mmHg y por un lactato sérico > 2 mmol/L pese a una adecuada resucitación con fluidos [Singer et al. \(2016\)](#). En este escenario,

la detección temprana del deterioro hemodinámico resulta especialmente relevante.

Justificación del problema

En el contexto del shock séptico, la noradrenalina constituye el vasopresor de primera elección tanto en las guías internacionales de la *Surviving Sepsis Campaign* como en el Protocolo Código Sepsis del Complejo Asistencial Universitario de Burgos (HUBU) [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Su efecto predominante sobre los receptores alfa-adrenérgicos favorece la vasoconstricción periférica y el aumento de la presión arterial media, con un perfil clínico favorable frente a otras alternativas [Evans et al. \(2021\)](#). Por ello, el inicio de noradrenalina representa una decisión terapéutica crítica en el manejo del paciente séptico con inestabilidad hemodinámica.

Aunque la evidencia reciente sugiere que un inicio más precoz de noradrenalina podría asociarse con mejores resultados clínicos, menor administración acumulada de fluidos y una consecución más rápida de objetivos hemodinámicos, el momento óptimo de inicio continúa siendo objeto de debate [Shi et al. \(2025\)](#); [Firzli et al. \(2023\)](#). En la práctica clínica habitual, esta decisión no depende de una sola variable ni de un umbral aislado, sino de la interpretación conjunta de signos vitales, biomarcadores, respuesta a fluidoterapia, escalas de disfunción orgánica y juicio clínico. Esta complejidad dificulta una estratificación homogénea y precoz del riesgo, especialmente en entornos dinámicos como la UCI.

Planteamiento del trabajo

En los últimos años, el aprendizaje automático (*machine learning*, ML) ha despertado un interés creciente en la predicción de eventos clínicos en pacientes críticos, favorecido por la disponibilidad de bases de datos de gran escala como MIMIC-IV y por la capacidad de estos modelos para integrar simultáneamente múltiples variables clínicas [Johnson et al. \(2023\)](#); [Shanmugam et al. \(2025\)](#). Sin embargo, buena parte de los trabajos publicados se ha centrado en tareas generales, como la predicción de mortalidad o la detección precoz de sepsis, o bien en métricas de rendimiento retrospectivas que no siempre se traducen en una utilidad operativa clara a pie de cama [Shanmugam et al. \(2025\)](#); [Rockenschaub et al. \(2025\)](#).

En este contexto, el presente Trabajo de Fin de Grado se plantea con el propósito de desarrollar un modelo interpretable para estimar de forma temprana el riesgo de inicio de noradrenalina en pacientes adultos ingresados en UCI, utilizando variables clínicas y analíticas disponibles durante las

primeras horas de estancia. El enfoque del trabajo no se limita al entrenamiento del modelo predictivo, sino que contempla también su integración en un *dashboard* clínico, la incorporación de explicaciones individualizadas mediante valores SHAP y la exploración de su aplicabilidad en un entorno asistencial real. De este modo, el trabajo se sitúa en la intersección entre el desarrollo técnico, la explicabilidad clínica y la orientación práctica hacia la toma de decisiones.

Estructura de la memoria

El presente documento se organiza en ocho capítulos. Tras este capítulo introductorio, el **Capítulo 2** recoge los objetivos del trabajo. El **Capítulo 3** desarrolla el marco teórico y el estado del arte. El **Capítulo 4** describe la metodología empleada. Los **Capítulos 5 y 6** presentan y discuten los resultados. El **Capítulo 7** recoge las conclusiones y el **Capítulo 8** propone posibles líneas de trabajo futuro.

Objetivos

Objetivo principal

El objetivo principal de este Trabajo de Fin de Grado es desarrollar y validar un modelo de aprendizaje automático para la estimación temprana del riesgo de inicio de noradrenalina en pacientes adultos ingresados en la Unidad de Cuidados Intensivos (UCI), utilizando variables clínicas y analíticas disponibles durante las primeras horas de estancia. El modelo se materializará en un *dashboard* interpretable diseñado para su uso a pie de cama, que permitirá visualizar el riesgo estimado y los factores clínicos con mayor contribución a dicha predicción en cada paciente de forma individualizada.

Objetivos específicos

1. Desarrollar un modelo predictivo de aprendizaje automático entrenado sobre la base de datos MIMIC-IV que estime la probabilidad de inicio de noradrenalina en UCI en distintas ventanas temporales tras el ingreso.
2. Evaluar y comparar el rendimiento de distintos algoritmos de clasificación supervisada, incluyendo regresión logística, XGBoost, entre otros, mediante métricas de discriminación y calibración.
3. Desarrollar un *dashboard* clínico interpretable que muestre, para cada paciente, la probabilidad estimada de requerir noradrenalina, los factores con mayor peso en la predicción y una clasificación orientativa del nivel de riesgo.
4. Realizar una validación externa del modelo con datos reales del Complejo Asistencial Universitario de Burgos (HUBU), accediendo a datos

anonimizados de manera autorizada y proporcionados por el personal de UCI, con el fin de evaluar la generalización del modelo en una población española y en un contexto clínico diferente al de entrenamiento.

5. Medir la usabilidad del *dashboard* mediante una encuesta de satisfacción dirigida al personal clínico de la UCI del HUBU.

Objetivos técnicos

1. Definir y construir la cohorte de estudio a partir de MIMIC-IV, aplicando criterios de inclusión y exclusión clínicamente justificados, con la cohorte general de pacientes adultos de UCI como base y el subgrupo de sepsis como análisis específico.
2. Extraer y preprocesar las variables predictoras relevantes disponibles en las primeras horas del ingreso en UCI, incluyendo constantes vitales, parámetros analíticos y otros indicadores de disfunción orgánica y perfusión tisular.
3. Identificar el evento objetivo, definido como el inicio de noradrenalina, a partir de la tabla `inpuvents` de MIMIC-IV, distinguiendo entre diferentes ventanas temporales de predicción.
4. Implementar técnicas de manejo del desequilibrio de clases, imputación de datos faltantes y evaluación de calibración, adaptadas a las características habituales de los datos clínicos reales de UCI.
5. Aplicar técnicas de interpretabilidad basadas en valores SHAP (*SHapley Additive exPlanations*) para cuantificar la contribución individual de cada variable a la predicción, tanto a nivel global de la cohorte como a nivel de paciente individual [Lundberg and Lee \(2017\)](#).
6. Desarrollar la interfaz del *dashboard* utilizando Python (Streamlit) o R (Shiny), incorporando visualización del riesgo estimado, explicación por variables y clasificación orientativa del nivel de alerta.
7. Documentar todo el proceso de desarrollo en el repositorio GitHub del proyecto, con el objetivo de favorecer la reproducibilidad del código y del entorno de trabajo.

Objetivos personales

1. Aplicar de forma integrada los conocimientos adquiridos en el Grado de Ingeniería de la Salud a un problema clínico real y de alta relevancia asistencial.
2. Adquirir experiencia práctica en el manejo de bases de datos clínicas de gran escala como MIMIC-IV, así como en los flujos de trabajo habituales en ciencia de datos aplicada a la salud.
3. Profundizar en el campo del aprendizaje automático interpretable y su aplicación en entornos de cuidados intensivos, donde la explicabilidad de las predicciones es un requisito clínico especialmente relevante.
4. Comprender las implicaciones éticas, legales y de privacidad del uso de datos clínicos en investigación, así como los procedimientos de validación en entornos hospitalarios reales.
5. Desarrollar capacidad crítica para comparar el trabajo propio con la literatura existente, identificando las aportaciones diferenciales del presente TFG respecto a los trabajos previos en el área.

Conceptos teóricos

Sepsis, shock séptico y deterioro hemodinámico

La identificación precoz de la sepsis y del deterioro hemodinámico asociado constituye uno de los principales retos clínicos en el ámbito de los cuidados intensivos. La sepsis no solo implica la presencia de infección, sino también la aparición de disfunción orgánica secundaria a una respuesta huésped desregulada [Singer et al. \(2016\)](#). Cuando el proceso progresa hacia shock séptico, el paciente presenta una situación de fracaso circulatorio y metabólico que se asocia a una mortalidad especialmente elevada [Singer et al. \(2016\)](#). En este contexto, la evolución clínica puede ser rápida y obligar a tomar decisiones terapéuticas en un intervalo de tiempo muy reducido.

La valoración inicial del paciente séptico combina información procedente de la exploración clínica, las constantes vitales, los parámetros analíticos y las escalas de disfunción orgánica. El protocolo Código Sepsis del HUBU recoge el uso de herramientas como qSOFA y SOFA, así como la valoración de variables relacionadas con hipoperfusión y fracaso orgánico, entre ellas la hipotensión arterial, el lactato, la diuresis, la creatinina, la bilirrubina, el recuento plaquetario o la relación $\text{PaO}_2/\text{FiO}_2$ [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Estas variables forman parte habitual del razonamiento clínico, tanto para la detección precoz como para la monitorización evolutiva del paciente.

No obstante, estas herramientas presentan limitaciones cuando se utilizan de manera aislada para anticipar decisiones terapéuticas concretas. qSOFA puede ser útil como instrumento de cribado rápido, pero no sustituye a una valoración clínica completa ni al cálculo del SOFA. Del mismo modo, el lactato y otros biomarcadores resultan relevantes para apoyar el diagnóstico y monitorizar la evolución, pero la necesidad de vasopresores depende de una

interpretación clínica más amplia, que incluye la respuesta a la fluidoterapia, la persistencia de hipotensión o hipoperfusión y la situación general del paciente [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta complejidad explica por qué la identificación precoz del riesgo de deterioro hemodinámico sigue siendo un problema clínico no resuelto de forma simple mediante reglas fijas.

Uso de vasopresores y papel de la noradrenalina

En el manejo del shock séptico, la administración de vasopresores está indicada cuando persisten signos de hipoperfusión y/o hipotensión a pesar de una resucitación adecuada con fluidos [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Tanto las guías de la *Surviving Sepsis Campaign* como el protocolo local del HUBU establecen la noradrenalina como vasopresor de primera elección [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Esta recomendación se fundamenta en su capacidad para aumentar de forma eficaz la presión arterial media mediante un efecto predominantemente alfa-adrenérgico, con escaso efecto cronotrópico y un perfil clínico más favorable que otras alternativas, especialmente la dopamina [Evans et al. \(2021\)](#).

El objetivo hemodinámico inicial habitual consiste en mantener una presión arterial media superior a 65 mmHg [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Cuando se requieren dosis elevadas de noradrenalina para alcanzar dicho objetivo, puede asociarse vasopresina como segundo vasopresor. Asimismo, en presencia de disfunción miocárdica asociada o de hipoperfusión persistente a pesar de una adecuada presión arterial, puede considerarse el uso de dobutamina como soporte inotrópico [Evans et al. \(2021\)](#); [Grupo de Trabajo Sepsis HUBU \(2025\)](#). Este esquema terapéutico refleja que el tratamiento hemodinámico del paciente séptico no es estático, sino progresivo y dependiente de la evolución clínica.

Aun así, la decisión de iniciar noradrenalina no depende de un único umbral ni de una sola variable. En la práctica clínica habitual intervienen de manera simultánea la tendencia de las constantes vitales, el nivel de lactato, la respuesta a fluidoterapia, la situación respiratoria, el grado de disfunción orgánica y el contexto clínico global del paciente. Esta característica limita el rendimiento de los sistemas de alerta basados exclusivamente en reglas simples y justifica el interés por herramientas capaces de integrar múltiples señales clínicas de forma simultánea.

Bases de datos clínicas y aprendizaje automático en UCI

El desarrollo de modelos predictivos en cuidados intensivos ha estado estrechamente ligado a la disponibilidad de bases de datos clínicas de gran escala. Entre ellas, MIMIC-IV (*Medical Information Mart for Intensive Care*,

versión IV) ocupa un lugar destacado por tratarse de una base de datos pública, desidentificada y diseñada específicamente para investigación clínica [Johnson et al. \(2023\)](#). MIMIC-IV integra información hospitalaria, episodios de UCI, resultados analíticos, administración de fármacos, procedimientos y medidas fisiológicas, todo ello con una estructura temporal que permite estudiar eventos dinámicos como el inicio de vasopresores o la evolución hemodinámica del paciente [Johnson et al. \(2023\)](#).

Esta dimensión temporal resulta especialmente relevante en estudios de predicción temprana. A diferencia de otras tareas más estáticas, la estimación del riesgo de inicio de noradrenalina exige definir ventanas de observación y de predicción clínicamente plausibles, utilizando únicamente la información disponible antes del evento. En este sentido, MIMIC-IV constituye un entorno adecuado para construir cohortes retrospectivas y desarrollar modelos centrados en las primeras horas de estancia en UCI.

Dentro de este marco, el aprendizaje automático ha adquirido un papel creciente en la predicción de eventos clínicos en pacientes críticos. En datos clínicos tabulares se emplean con frecuencia algoritmos como la regresión logística, *Random Forest*, XGBoost o LightGBM, que permiten modelar relaciones no lineales e interacciones complejas entre variables. Su atractivo radica en la capacidad para combinar simultáneamente información procedente de múltiples dominios clínicos, algo difícil de reproducir con reglas clínicas simples o con modelos univariantes. Sin embargo, este aumento de capacidad predictiva suele ir acompañado de una menor interpretabilidad, lo que supone una limitación importante cuando el objetivo final es apoyar decisiones clínicas reales.

Interpretabilidad y explicabilidad de modelos

En aplicaciones clínicas, la interpretabilidad del modelo no constituye un elemento accesorio, sino un requisito relevante para facilitar la confianza del profesional sanitario y permitir una evaluación crítica de la predicción generada. En este contexto, adquieren relevancia técnicas de explicación como SHAP (*SHapley Additive exPlanations*), que permiten descomponer la predicción de un modelo en la contribución individual de cada variable [Lundberg and Lee \(2017\)](#).

Este enfoque ofrece una doble utilidad. Por un lado, permite identificar qué variables son más influyentes a nivel global dentro de la cohorte, lo que facilita interpretar el comportamiento general del modelo. Por otro, hace posible explicar predicciones concretas a nivel individual, mostrando qué factores empujan el riesgo estimado en una u otra dirección para un paciente determinado [Lundberg and Lee \(2017\)](#). En un entorno de apoyo

a la decisión clínica, esta capacidad puede resultar especialmente valiosa, ya que aproxima la salida del modelo a un razonamiento más comprensible para el profesional.

Estado del arte y trabajos relacionados

Entre los estudios más próximos al objetivo de este TFG destaca el trabajo de Duval et al., que desarrolló un modelo interpretable basado en historia clínica electrónica para predecir el inicio de perfusión continua de vasopresores en pacientes sépticos ingresados en UCI a partir de datos de MIMIC-IV [Duval et al. \(2025\)](#). El modelo utilizó variables medidas en la ventana de -6 a -2 horas respecto al inicio del tratamiento y el mejor clasificador fue un *Random Forest* con un AUROC de 0,75. Entre los predictores más relevantes se encontraban el descenso de la presión arterial media entre -2 y -4 horas, un lactato $> 2,5$ mmol/L y valores de hematocrito fuera del rango 30–37 % [Duval et al. \(2025\)](#). Los autores señalan, además, que las alertas del modelo podrían generarse entre 2 y 4 horas antes del inicio del vasopresor, lo que apoya la viabilidad técnica de anticipar este tipo de decisión terapéutica [Duval et al. \(2025\)](#). No obstante, el propio estudio subraya que se trata de una validación interna y que aún se requiere validación externa y evaluación prospectiva antes de plantear una implementación clínica real.

Junto a este trabajo, existen otros estudios relacionados que contribuyen a contextualizar el problema, aunque no se centran exactamente en el primer inicio de noradrenalina. Scheibner et al. desarrollaron y validaron externamente modelos de aprendizaje automático para predecir la respuesta a vasopresina como segundo vasopresor en pacientes con shock séptico tratados con noradrenalina, mostrando un rendimiento modesto y poniendo de manifiesto la complejidad de anticipar la respuesta farmacológica individual [Scheibner et al. \(2022\)](#). En una línea diferente, Persson et al. validaron prospectivamente un algoritmo de predicción temprana de sepsis en pacientes críticos, demostrando que este tipo de sistemas puede evaluarse más allá del entorno retrospectivo y en condiciones más próximas a la práctica clínica real [Persson et al. \(2024\)](#). Aunque su objetivo no fue el uso de vasopresores, este estudio refuerza la relevancia de avanzar hacia diseños de validación más cercanos al uso asistencial.

Otros trabajos han abordado tareas más complejas, como la predicción continua de dosis o la optimización de decisiones terapéuticas mediante modelos temporales y aprendizaje por refuerzo. Jiang et al. propusieron ChronoSynthNet, un modelo multitarea con componentes *Transformer* y LSTM para estimar en tiempo real la dosis de noradrenalina y detectar precozmente hipotensión en pacientes con shock séptico [Jiang et al. \(2025\)](#).

Este tipo de enfoques aprovecha mejor la naturaleza temporal de los datos, pero también incrementa de forma notable la complejidad metodológica y aún requieren validación prospectiva multicéntrica antes de su despliegue clínico. En paralelo, los enfoques de aprendizaje por refuerzo han intentado derivar políticas terapéuticas para orientar decisiones hemodinámicas en sepsis. Zhang et al. describieron un modelo orientado a optimizar estrategias de tratamiento mediante recomendaciones sobre vasopresores y fluidoterapia, incorporando mecanismos para reducir ajustes bruscos de dosis [Zhang et al. \(2024\)](#), mientras que el estudio OVISS exploró el momento óptimo de inicio de vasopresina en pacientes con shock séptico tratados con noradrenalina [Kalimouttou et al. \(2025\)](#). Aunque estos trabajos son metodológicamente ambiciosos, responden a preguntas clínicas distintas y más complejas que la estimación temprana del primer inicio de noradrenalina.

Limitaciones de la literatura y posicionamiento del TFG

A pesar del avance metodológico observado, la literatura disponible presenta varias limitaciones recurrentes. En primer lugar, muchos estudios continúan evaluando su rendimiento principalmente mediante métricas de discriminación retrospectiva, especialmente el AUROC, sin trasladar de forma suficiente esos resultados a escenarios de uso clínico real [Shanmugam et al. \(2025\)](#). En segundo lugar, la validación externa sigue siendo limitada en una parte importante de los trabajos publicados, lo que dificulta valorar la robustez de los modelos fuera del centro o cohorte de desarrollo [Rockenschaub et al. \(2025\)](#). Además, una proporción relevante de la literatura permanece en fases de validación retrospectiva o de prueba de concepto, lo que limita la estimación de su utilidad operativa real y refuerza la necesidad de modelos interpretables y clínicamente integrables [Shanmugam et al. \(2025\)](#); [Rockenschaub et al. \(2025\)](#).

A partir de esta revisión, el nicho del presente TFG queda claramente definido. El interés del trabajo no reside únicamente en desarrollar un modelo predictivo adicional, sino en abordar un problema clínico concreto y accionable: la estimación temprana del riesgo de inicio de noradrenalina en pacientes críticos a partir de variables disponibles durante las primeras horas de estancia. La propuesta añade, además, tres elementos de interés práctico: el uso de un modelo interpretable, la traducción del resultado a una interfaz funcional tipo *dashboard* y la exploración de su aplicabilidad fuera del entorno original de entrenamiento. De este modo, el trabajo se orienta no solo a la obtención de un buen rendimiento predictivo, sino también a su posible utilidad como herramienta de apoyo a la decisión clínica.

Metodología

4.1. Descripción de los datos

Se describirán los datos utilizados en el proyecto.

4.2. Técnicas y herramientas

A continuación se muestra un **ejemplo de tabla generada con R** usando `knitr::kable()`:

```
library(knitr)
library(dplyr)

iris |>
  group_by(Species) |>
  summarise(
    N          = n(),
    Media_SL   = round(mean(Sepal.Length), 2),
    SD_SL      = round(sd(Sepal.Length), 2),
    Media_PL   = round(mean(Petal.Length), 2),
    SD_PL      = round(sd(Petal.Length), 2)
  ) |>
  kable(
    col.names = c("Especie", "N", "Media Sep.L",
                  "SD Sep.L", "Media Pet.L", "SD Pet.L"),
    booktabs  = TRUE,
    format    = "latex"
  )
```

Tabla 4.1: Estadísticos descriptivos del conjunto de datos iris

Especie	N	Media Sep.L	SD Sep.L	Media Pet.L	SD Pet.L
setosa	50	5.01	0.35	1.46	0.17
versicolor	50	5.94	0.52	4.26	0.47
virginica	50	6.59	0.64	5.55	0.55

Y podremos referenciar esta tabla en el texto como la tabla [4.1](#) que aparece en la página [16](#).

4.3. Metodología de Ingeniería del Software

Si el TFG incluye desarrollo software, indicar la metodología seguida. Se pueden incluir diagramas de casos de uso, diagramas de clases, diagramas de secuencia, etc. para describir el diseño del software desarrollado.

Resultados

5.1. Resumen de resultados

Breve resumen de los resultados. En caso de ser un trabajo muy experimental, los resultados completos pueden aparecer en su anexo correspondiente.

Debería haber una correspondencia entre los objetivos y los resultados explicados en esta sección

A continuación se muestra un **ejemplo de figura generada con R**:

```
library(ggplot2)

ggplot(iris, aes(x = Species, y = Sepal.Length, fill = Species)) +
  geom_boxplot(alpha = 0.7, show.legend = FALSE) +
  labs(
    x = "Especie",
    y = "Longitud del sépalo (cm)"
  ) +
  theme_minimal(base_size = 11) +
  theme(panel.grid.minor = element_blank())
```

Debería existir correspondencia entre los objetivos definidos y los resultados mostrados (Koza, 1992).




Figura 5.1: Distribución de la longitud de sépal por especie en el conjunto iris

Discusión

Se realizará un análisis crítico de los resultados, interpretando su significado y, cuando sea pertinente, comparándolos con los resultados de trabajos previos, obtenidos con la revisión del estado del arte; de forma que se destaquen las mejoras y aportes sobre el mismo.

Conclusiones

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas.

7.1. Aspectos relevantes

Este apartado pretende recoger los aspectos más interesantes del **desarrollo del proyecto**, comentados por los autores del mismo y que den respuesta a los objetivos planteados.

Debe incluir los detalles más relevantes en cada fase del desarrollo, justificando los caminos tomados, especialmente aquellos que no sean triviales.

Puede ser el lugar más adecuado para documentar los aspectos más interesantes del proyecto y también los resultados negativos obtenidos por soluciones previas a la solución entregada.

Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

Líneas de trabajo futuras

Este capítulo debería ser informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

- Duval, L., Villié, A., Zheng, F., Terraz, G., Blein, S., Duperchy, E., Everett, M., Frieling, J., Llitjos, J.-F., and Bodinier, M. (2025). Early prediction of vasopressor initiation in ICU sepsis patients using an interpretable EHR-based ML model. *BMC Medical Informatics and Decision Making*, 25(1):442.
- Evans, L., Rhodes, A., Alhazzani, W., et al. (2021). Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021. *Intensive Care Medicine*, 47:1181–1247.
- Firzli, T. R., Miah, F. Z., Horton, C., Akhtar, H., Riddle, M., and Siddiqui, F. (2023). Influence of time from admission to norepinephrine administration and volume of fluids received on outcomes of patients meeting sepsis-3 criteria: a retrospective study using the mimic-iv database. *Trauma Surgery & Acute Care Open*, 8(1):e001024.
- Fleischmann-Struzek, C., Mellhammar, L., Rose, N., et al. (2020). Incidence and mortality of hospital- and ICU-treated sepsis: results from an updated and expanded systematic review and meta-analysis. *Intensive Care Medicine*, 46:1552–1562.
- Grupo de Trabajo Sepsis HUBU (2025). Protocolo Código Sepsis HUBU. Manejo integral del paciente séptico. III edición. Technical report, Complejo Asistencial Universitario de Burgos.
- Jiang, Z., Zhang, S., Yuan, Y., Wang, J., and Hu, Z. (2025). Chronosynthnet: a dual-task deep learning model development and validation study for predicting real-time norepinephrine dosage and the early detection of hypotension in patients with septic shock. *Cardiovascular Diagnosis and Therapy*, 15(4):833–846.

- Johnson, A. E. W., Bulgarelli, L., Shen, L., et al. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.
- Kalimouttou, A., Kennedy, J. N., Feng, J., Singh, H., Saria, S., Angus, D. C., Seymour, C. W., and Pirracchio, R. (2025). Optimal vasopressin initiation in septic shock: The OVISS reinforcement learning study. *JAMA*, 333(19):1688–1698.
- Koza, J. R. (1992). *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press.
- Kumar, A., Roberts, D., Wood, K. E., et al. (2006). Duration of hypotension before initiation of effective antimicrobial therapy is the critical determinant of survival in human septic shock. *Critical Care Medicine*, 34(6):1589–1596.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30.
- Persson, I., Macura, A., Becedas, D., and Sjövall, F. (2024). Early prediction of sepsis in intensive care patients using the machine learning algorithm NAVOY® sepsis, a prospective randomized clinical validation study. *Journal of Critical Care*, 80:154400.
- Rockenschaub, P., Akay, E. M., Carlisle, B. G., et al. (2025). External validation of AI-based scoring systems in the ICU: a systematic review and meta-analysis. *BMC Medical Informatics and Decision Making*, 25:5.
- Scheibner, A., Betthausen, K. D., Bewley, A. F., Juang, P., Lizza, B., Micek, S., and Lyons, P. G. (2022). Machine learning to predict vasopressin responsiveness in patients with septic shock. *Pharmacotherapy*, 42(6):460–471.
- Shanmugam, H., Airen, L., and Rawat, S. (2025). Machine learning and deep learning models for early sepsis prediction: A scoping review. *Indian Journal of Critical Care Medicine*, 29(6):516–524.
- Shi, R., Braïk, R., Monnet, X., et al. (2025). Early norepinephrine for patients with septic shock: an updated systematic review and meta-analysis with trial sequential analysis. *Critical Care*, 29(1):182.
- Singer, M., Deutschman, C. S., Seymour, C. W., Shankar-Hari, M., Annane, D., Bauer, M., Bellomo, R., Bernard, G. R., Chiche, J.-D., Coopersmith,

C. M., Hotchkiss, R. S., Levy, M. M., Marshall, J. C., Martin, G. S., Opal, S. M., Rubenfeld, G. D., van der Poll, T., Vincent, J.-L., and Angus, D. C. (2016). The third international consensus definitions for sepsis and septic shock (Sepsis-3). *JAMA*, 315(8):801–810.

Zhang, T., Qu, Y., Wang, D., Zhong, M., Cheng, Y., and Zhang, M. (2024). Optimizing sepsis treatment strategies via a reinforcement learning model. *Biomedical Engineering Letters*, 14(2):279–289.